

基于 CNN 的质子交换膜燃料电池故障诊断

党翰斌¹, 马 睿¹, 周俊杰², 皇甫宜耿¹

(1.西北工业大学, 自动化学院, 陕西 西安 710072;

2.特变电工西安电气科技有限公司, 陕西 西安 710119)

摘要:可靠性低和耐久性差的问题是制约质子交换膜燃料电池(PEMFC)发展的主要瓶颈,故障诊断技术作为解决这些问题的重要途径之一而备受研究人员关注。这里针对传统基于机器学习诊断方法所存在的数据分析能力较弱及诊断过程易出现累计误差等问题,提出了一种基于卷积神经网络(CNN)的深度学习故障诊断方法,该方法具备自主学习能力,可通过**图像信号**自动提取故障诊断特征,在实例中的应用结果表明该方法能精确识别燃料电池的膜干故障、氢气泄露故障、正常状态及未知状态,并且诊断性能优于支持向量机(SVM)、K-最近邻(KNN)等传统机器学习算法。因此,该方法具有进一步深入研究的价值,同时对于促进燃料电池故障诊断技术进一步发展也具有重要意义。

关键词:质子交换膜燃料电池;卷积神经网络;故障诊断

中图分类号:TM911.4

文献标识码:A

文章编号:1000-100X(2020)12-0052-4

Fault Diagnosis of Proton Exchange Membrane Fuel Cells Based on CNN

DANG Han-bin¹, MA Rui¹, ZHOU Jun-jie², HUANGFU Yi-geng¹

(Northwestern Polytechnical University, Xi'an 710072, China)

Abstract: The problems of low reliability and poor durability are currently the main bottlenecks restricting the development of proton exchange membrane fuel cells(PEMFC). As one of the important ways to solve these two problems, fault diagnosis technology has attracted researchers' attention greatly. In view of the weak data analysis capabilities of traditional machine learning based diagnosis methods and the prone to accumulated errors in the diagnosis process, a deep learning fault diagnosis method is proposed based on convolutional neural network(CNN). This method has the ability to learn independently and the fault diagnosis features can be automatically extracted. The application results in the example show that the method can accurately identify the membrane drying fault, hydrogen leakage fault, normal state and unknown state of the fuel cells, and the diagnostic performance is significantly better than the support vector machine(SVM), K-nearest neighbor(KNN) methods. Therefore, this method has the value of further in-depth research, and it is also of great significance to promote the further development of fuel cells fault diagnosis technology.

Keywords: proton exchange membrane fuel cells; convolutional neural network; fault diagnosis

Foundation Project: Supported by National Natural Science Foundation of China(No.52007155); The Key Research and Development Program of Shaanxi Province(No.2020GY-100)

1 引言

作为一种电化学反应装置,PEMFC 可将氢气中蕴含的化学能直接转化为电能供给负载,整个过程不涉及燃烧反应,因此不受卡诺循环限制,具有清洁无污染、功率密度率高、启动速度快及运行噪音小等优势,目前已被广泛应用于交通运输、固定式发电等领域^[1]。然而,现阶段 PEMFC 仍然面

临着可靠性低和耐久性差的问题,探寻准确有效的故障诊断方法对其性能的提升及未来产业化发展都具有十分重要的意义。

当前关于燃料电池故障诊断技术的研究已有很多,按照诊断原理可分为**基于模型法**、**基于数据驱动法**及**基于实验测试法**3类^[2-3]。由于 PEMFC 是一种多物理场、多参数耦合的非线性复杂系统,因此很难建立其精确的故障模型,而基于实验测试法对于设备的要求又普遍较高,因此**基于数据驱动法**更适合应用在燃料电池故障诊断中,被认为是最具前景的一类诊断方法^[4]。

迄今为止,基于数据驱动法大多采用机器学习方法来实现故障识别,虽然具有诊断速度快、诊

基金项目:国家自然科学基金(52007155);陕西省重点研发计划一般项目(2020GY-100)

定稿日期:2020-11-27

作者简介:党翰斌(1996-),男,陕西渭南人,硕士研究生,研究方向为质子交换膜燃料电池故障诊断及健康管理。



断精度高等优势,但不具备特征自选取能力,需借助专家知识等方法来提前对特征进行选取,易受到人为经验因素的影响,另外由于诊断环节相对较多,其间累积的误差也会对诊断结果造成一定影响。而深度学习具备“端到端”的学习模式^[5],可以自动提取故障诊断特征,有效避免了人为因素导致的诊断误差,CNN 作为一种经典的深度学习方法目前已广泛使用在电力系统^[6]、电机^[7]等的故障诊断中,并显现出了良好的故障识别能力,然而尚未有文献显示 CNN 已应用在 PEMFC 故障诊断领域中。这里将利用 CNN 对 PEMFC 膜干故障、氢气泄漏故障、正常状态及未知状态的诊断方法进行识别,并通过对比传统 SVM 和 KNN 算法的诊断结果来对该方法的诊断性能进行进一步验证。

2 基于 CNN 的 PEMFC 故障诊断

燃料电池运行状态可以实时反映在输出电压、电流等参数的变化上,通过 CNN 的自主学习能力来识别这些参数信号在图像中的变化可以达到诊断故障类型的目的。

2.1 故障类型

此处的目标在于精确识别燃料电池的运行状态(即故障状态、正常状态和未知状态),而相关研究表明,燃料电池膜干故障和氢气泄漏故障是其运行过程中最常见的两种故障类型^[8],因此对于这两种故障的精确诊断是保证燃料电池安全持久运行的关键。

2.1.1 膜干故障

这种故障一般是由于燃料电池水热管理系统异常所引起的,膜干发生后显著影响质子传导率,进而导致电堆输出电压逐渐下降,如果没有及时发现和隔离将会对电堆造成不可逆的损伤,甚至会因温度过高发生自燃,导致出现无法挽回的损失。

2.1.2 氢气泄漏故障

这种故障是由于阳极供氢系统异常导致的,故障发生后电堆阳极缺乏充足的燃料,其输出电压会逐渐下降,严重时会引起电堆电压出现“反极”现象,若未能及时处理则会导致氢氧混合,致使电堆发生爆炸。此外,由于氢气是种易燃易爆气体,泄漏出来的氢气也会增加事故发生的风险。

2.2 CNN 原理概述

CNN 的设计灵感来源于大脑视觉皮层的脑神经结构,不同于传统人工神经网络的全连接方式,它一般是由卷积层、池化层、全连接层 3 部分组

成,并由激活函数增加模型的非线性表达能力。下面将对各部分展开详细介绍。

2.2.1 卷积层

卷积层的作用是通过卷积计算来提取输入图片的特征,具体过程如图 1 所示。因此,卷积计算过程的实质为特征提取过程,其数学表达式为:

$$f_{r,c} = \sum_{i,j}^{kernel-size} W_{i,j} X_{r+j,c+j} + b \quad (1)$$

式中: $W_{i,j}$ 为卷积核第 i 行、第 j 列的权重; $X_{r+j,c+j}$ 为输入特征映射图第 $r+j$ 行、第 $c+j$ 列的坐标值; $f_{r,c}$ 为输出特征映射图第 r 行、第 c 列的坐标值; b 为偏置项。




图 1 卷积层计算过程示意图

Fig. 1 The calculation process of convolutional layer

由于 CNN 在卷积运算过程中其卷积核的权重是共享的,因此相比于全连接神经网络其参数计算量将大幅减少,训练速度更快。

2.2.2 池化层

池化层又称下采样层,其目的是通过下采样过程对卷积操作后的特征映射图进行降维,以降低模型的参数量,防止过拟合。经过池化层后,输入图片的维度会进一步降低,得到的特征图也更加抽象。池化层的数学表达式如下:

$$f_{r,c}' = \max_{i,j}^{kernel-size} \{X_{r+j,c+j}\} \quad (2)$$

式中: $f_{r,c}'$ 为池化后的映射图中第 r 行、第 c 列处的坐标值。

通过池化层后,映射图的尺寸会成倍减小,因而减少了模型的计算量。常用的池化方法包括平均值池化法和最大值池化法两种,这里采用的是效果更佳的最大值池化法。

2.2.3 激活函数

卷积层与池化层的数据变换方式都是线性的,为了使其具备非线性表达能力,需要在模型中加入激活函数,常用的激活函数主要有 3 种: tanh 函数、Sigmoid 函数和 ReLu 函数,其中 ReLu 函数收敛速度更快,容易求导,且彻底解决了梯度消失问题,因此应用最为广泛。

ReLu 函数的表达式为:

$$f(x)=\begin{cases} x, & x\geq 0 \\ 0, & x<0 \end{cases} \quad (3)$$

2.2.4 全连接层

全连接层位于 CNN 模型的尾端,结构与传统的 ANN 结构相同,主要功能是对卷积层和池化层所提取的故障特征进行分类,从而达到识别输入图像类别的目的。

2.3 CNN 结构的设计

这里在 LeNet-5 的基础上构建如图 2 所示的 CNN 模型结构,模型的隐藏层由 3 层卷积层、3 层池化层及 3 层全连接层构成,激活函数为 ReLU 函数,池化层为最大值池化,步长为 1×2;输出层采用 Softmax 分类器,并通过反向传播方法对模型中的权重 W 和 b 进行更新。




图 2 CNN 分类模型的结构

Fig. 2 The structure of the CNN classification model

3 实验结果与分析

3.1 燃料电池系统

这里采用 100 kW 级 EC 型 PEMFC 系统^[9],其拓扑结构如图 3 所示。




图 3 EC 型 PEMFC 系统拓扑结构

Fig. 3 The topological structure of EC PEMFC system

系统包含多个传感器以监测包括电堆电压、电流、阴/阳极的出/入口压力、温度等 20 个变量,从而能够更加全面准确地掌握电堆的运行状态。

3.2 诊断决策

3.2.1 数据获取

通过筛选归一化后得到燃料电池在膜干故

障、氢气泄漏故障、正常状态及未知状态的 600 组信号图像作为样本集,其中膜干故障包括 100 组,氢气泄漏故障包括 100 组,正常状态包括 200 组,未知状态包括 200 组。随机选取各状态 40% 的样本作为训练集,其余作为测试集。

3.2.2 诊断结果

CNN 模型结构如图 2 所示,选取 zero-padding 方式,并设置 Dropout=0.5,得到测试集上的故障诊断结果如图 4 所示,该结果表明基于 CNN 的故障诊断方法能够精准识别燃料电池的运行状态及故障类别,诊断性能优异。




图 4 故障诊断结果

Fig. 4 The fault diagnostic results

3.3 对比分析

为验证 CNN 算法的诊断效果,这里分别采用 SVM 算法和 KNN 算法这两种传统机器学习方法与之进行对比,在相同样本数据的基础上对两种算法的参数设置如下:

①SVM 算法:采用“One vs One”多分类策略,核函数分别选择了“线性(linear)函数”与“高斯径向基(RBF)函数”,并通过网格搜索方法对参数进行了寻优。

②KNN 算法:利用欧氏距离计算样本间距,并通过网格搜索方法对邻近值 k 进行寻优。

表 1 为 3 种方法的对比结果,结果显示基于 CNN 的诊断方法对于各状态的诊断效果要优于传统的机器学习方法,因此在未来燃料电池故障诊断中具有很大的潜力。

表 1 对比结果

Table 1 The comparison results

健康状态	诊断正确率/%			
	CNN	SVM(linear)	SVM(RBF)	KNN
未知状态	100	90.41	98.18	97.85
膜干故障	100	86.62	99.83	100
氢气泄露故障	100	70.05	96.79	96.83
正常状态	100	100	100	99.75
合计	100	89.64	98.8	98.69

4 结 论

采用卷积神经网络对质子交换膜燃料电池进行故障诊断, 诊断结果表明该方法可有效识别燃料电池膜干故障、氢气泄露故障、正常状态及未知状态等 4 种运行状态, 识别率可达 100%, 并通过对比支持向量机、K-最近邻等传统机器学习方法, 验证了该方法优良的诊断性能。然而这里并未考虑电堆老化及动态运行过程对于诊断的影响, 另外其诊断周期约为 2.08 s, 目前还不能完全满足在线应用的要求, 亟待进一步的研究和突破。

参考文献

- [1] Sharaf O Z, Orhan M F. An Overview of Fuel Cell Technology: Fundamentals and Applications[J]. A Renewable and Sustainable Energy Reviews, 2014, 32(3): 810-853.
- [2] 陈维荣, 刘嘉蔚, 李 奇, 等. 质子交换膜燃料电池故障诊断方法综述及展望[J]. 中国电机工程学报, 2017, 37(16): 4712-4721.
- [3] 张雪霞, 蒋 宇, 孙腾飞, 等. 质子交换膜燃料电池水淹和膜干故障诊断研究综述[J]. 西南交通大学学报, 2020, 55(4): 828-838, 864.

- [4] Zheng Z, Petrone R, Pera M C, et al. A Review on Non-model Based Diagnosis Methodologies for PEM Fuel Cell Stacks and Systems[J]. International Journal of Hydrogen Energy, 2013, 38(1): 8914-8926.
- [5] 和敬涵, 罗国敏, 程梦晓, 等. 新一代人工智能在电力系统故障分析及定位中的研究综述[J]. 中国电机工程学报, 2020, 40(17): 5506-5515.
- [6] Mirzaei M, Vahidi B, Hosseini S H. Accurate Fault Location and Faulted Section Determination Based on Deep Learning for a Parallel-compensated Three-terminal Transmission Line[J]. IET Generation, Transmission & Distribution, 2019, 13(13): 2770-2778.
- [7] Wen L, Li X, Guo L, et al. A New Convolutional Neural Network-based Data-driven Fault Diagnosis Method[J]. IEEE Trans. on Industrial Electronics, 2018, 65(7): 5990-5998.
- [8] Benmouna A, Becherif M, Depernet D, et al. Fault Diagnosis Methods for Proton Exchange Membrane Fuel Cell System[J]. International Journal of Hydrogen Energy, 2017, 42(2): 1534-1543.
- [9] 刘嘉蔚, 李 奇, 陈维荣, 等. 基于在线序列超限学习机和主成分分析的蒸汽冷却燃料电池系统快速故障诊断方法[J]. 电工技术学报, 2019, 34(18): 3949-3960.

(上接第 27 页)假设 0.8 s 电网故障中断供电, 电解槽以故障最小功率指令 0.5 MW 运行, 因系统电源输出高于负载需求, 母线电压上升超过 1 125 V, 储能装置充电并稳定母线电压至 1 134 V, 运行模式转至模式 1。

5 结 论

针对风/光互补制储氢系统的结构与特点构建了经济性较强的风机、光伏、储能装置、电解槽及并网变换器连接于直流母线的拓扑结构。借鉴直流微电网典型 DBS 控制策略, 设计了协调自制控制方案, 结合系统内各设备特性引入功率/电压反下垂控制。最后, 在 Matlab/Simulink 中搭建系统仿真模型, 仿真结果验证了各单元能够根据母线电压确定工作模式并维持母线电压稳定, 且 4 种运行模式间可自由切换, 实现系统主动协调控制。

参考文献

- [1] 刘明义, 郑建涛, 徐海卫, 等. 电解水制氢技术在可再生能源发电领域的应用[A]. 中国电机工程学会年会[C]. 2013: 123-126.
- [2] 肖 宇. 氢储能: 支撑起智能电网和可再生能源发电

- 规模化[J]. 中国战略新兴产业, 2016, 25(1): 46-49.
- [3] 梁 慧. 日本氢能源技术发展战略及启示[J]. 国际石油经济, 2016, 24(8): 87-95.
- [4] 袁铁江, 段青熙, 秦艳辉, 等. 风电-氢储能与煤化工多能耦合系统能量广域协调控制架构[J]. 高电压技术, 2016, 42(9): 2748-2755.
- [5] A G Dutton, J A M Bleijs, H Dienhart, et al. Experiences in the Design, Sizing, Economics, and Implementation of Autonomous Wind-powered Hydrogen Production Systems Hydrogen Energy[J]. International Journal of Hydrogen Energy, 2000, 25(8): 705-722.
- [6] 蔡国伟, 孔令国, 彭 龙, 等. 基于氢储能的主动型光伏发电系统建模与控制[J]. 太阳能学报, 2016, 37(10): 2451-2459.
- [7] 刘鹏飞. 风光氢储综合供电系统优化配置与能量管理研究[D]. 杭州: 浙江大学, 2017.
- [8] 蔡国伟, 陈 冲, 孔令国, 等. 风电/光伏/制氢/超级电容器并网系统建模与控制[J]. 电网技术, 2016, 40(10): 2982-2990.
- [9] 张自东, 邱才明, 张东霞, 等. 基于深度强化学习的微电网复合储能协调控制方法[J]. 电网技术, 2019, 43(6): 1914-1921.
- [10] 王皓界. 直流微电网动态特性分析与控制[D]. 北京: 华北电力大学, 2018.