

国内图书分类号：TM911.4  
国际图书分类号：621.3

密级：公开

西南交通大学  
研究生学位论文

基于信息融合与深度学习的机车燃料电池故障  
诊断

年          级二零一九级  
姓          名郭雪庆  
申请学位级别工学硕士  
专          业电气工程  
指 导 老 师张雪霞 副教授

二零二二年五月

Classified Index: TM911.4

U.D.C: 621.3

Southwest Jiaotong University

Master Degree Thesis

FAULT DIAGNOSIS BASED ON  
INFORMATION FUSION AND  
DEEP LEARNING FOR FUEL CELL IN TRAM

Grade: 2019

Candidate: Guo Xueqing

Academic Degree Applied for : Master

Speciality: Electrical Engineering

Supervisor: A.Prof. Zhang Xuexia

May, 2022

## 摘要

为助力大功率质子交换膜燃料电池商业化应用,确保燃料电池系统安全可靠运行至关重要。因此,探究有效的故障诊断方法对提升大功率质子交换膜燃料电池的安全性具有重要意义。

本文以西南交通大学与中车唐山公司共同研制的燃料电池/超级电容混合动力 100% 低地板有轨电车的质子交换膜燃料电池系统为研究对象,以机车历史数据为基础,开展了数据驱动的故障诊断方法研究,以实现有轨电车用质子交换膜燃料电池的故障诊断。具体研究内容如下:

首先,本文介绍了混合动力有轨电车的外观、参数,以及有轨电车用质子交换膜燃料电池系统的结构、原理,并描述了质子交换膜燃料电池数据采集系统所能监测到的电量与非电量参数。通过机车实际运行的典型监测量变化情况,分析了在机车运行过程中不同监测量之间的变化特点,进而对有轨电车用质子交换膜燃料电池系统的故障分级及故障类型进行详细描述,并对比分析了故障样本与正常态样本的典型监测量,结果显示故障样本数据之间存在一定耦合性与随机性。

然后,针对复杂故障样本数据集,本文设计了数据层信息融合的基于 GRU 的故障诊断框架。利用 t-SNE 降维可视化算法说明了样本数据集的复杂性,并通过对比分析选择了合适的 GRU 层数、优化器类型、数据预处理策略等模型参数,结果表明该方法能较好地识别包括正常状态在内的共五类样本数据。此外,对比了分别以 28、14、11 维监测量作为模型输入时的诊断结果,验证了该方法在更多维的输入时具有更好的诊断准确率。将该方法与 SVM 算法的测试结果进行对比,进一步验证了该诊断方法的可行性。

其次,针对不均衡故障样本数据集,本文提出了特征层信息融合的基于 BPNN-InceptionNet 的故障诊断框架。在该框架中,首先利用一个 BPNN 将输入数据升维成更高维的抽象特征,进而利用特征重构技术将抽象特征转换为特征图,最后利用一个基于 InceptionNet 设计的卷积网络对特征图进行分类。诊断结果表明,对于总共包含七种状态类的不均衡数据集,该方法的测试结果的 kappa 系数要高于 BPNN-VGG、GRU 和 SVM 模型,证明了该方法对此不均衡数据集的诊断有效性。

最后,针对一类包含少数样本的并存故障数据集,本文引入了决策层信息融合的基于 D-S 证据理论的多模型融合故障诊断框架。在该框架中,利用 D-S 证据理论组合规则,对两个 BPNN-InceptionNet 模型的预测输出进行融合,以一个实例计算结果验证了该方法在得到综合的诊断决策方面具有一定的可行性。

**关键词:** 有轨电车; 燃料电池系统; 故障诊断; 信息融合; 深度学习

## Abstract

In order to facilitate the commercial application of high-power proton exchange membrane fuel cell, it is very important to ensure the safe and reliable operation of fuel cell system. Therefore, it is of great significance to explore effective fault diagnosis methods to improve the safety and reliability of high-power proton exchange membrane fuel cell.

In this paper, the research object is the proton exchange membrane fuel cell system of the fuel cell/ultracapacitor hybrid 100% low floor tram jointly developed by Southwest Jiaotong University and CRRC Tangshan Co., Ltd. Based on the historical data of the tram, the data-driven fault diagnosis method is studied to realize the fault diagnosis of proton exchange membrane fuel cell in tram. The specific research contents are as follows:

Firstly, this paper introduces the appearance and parameters of the hybrid tram, as well as the structure and principle of the proton exchange membrane fuel cell system in tram. Then the electric and non-electric parameters that can be monitored by the data acquisition system for proton exchange membrane fuel cell are explained. The characteristics of different typical monitored quantities are analyzed based on the variation of the typical monitored quantities acquired in the course of running of the hybrid tram. Then, the fault levels and fault types of the proton exchange membrane fuel cell system in tram are described in detail, and the typical monitored quantities of fault samples are compared with those of normal samples. The coupling and randomness among fault sample data has been verified from the results.

Secondly, a fault diagnosis framework based on GRU based on information fusion in data layer is designed for complex fault sample data set. The t-SNE dimensionality reduction visualization algorithm is used to illustrate the complexity of the sample data set, and the model parameters such as appropriate GRU layers, optimizer type and data preprocessing strategy are selected through comparative analysis. The results show that the method can identify five types of sample data including normal state well. In addition, the diagnostic results with 28, 14 and 11 dimensions as the inputs of the model are compared, and it is verified that the proposed method has better diagnostic accuracy with more dimensional inputs. The proposed method is compared with the test results of SVM algorithm, which further demonstrates the feasibility of the proposed method.

Thirdly, a fault diagnosis framework based on BPNN-InceptionNet based on information fusion in feature layer is proposed for unbalanced fault sample data set. In this framework, a BPNN is first used to raise the dimension of input data into higher-dimensional abstract features, and then feature reconstruction technology is applied to transform the abstract

features into feature maps. Finally, a convolutional network based on InceptionNet is used to classify feature maps. The diagnostic results show that the kappa coefficient of the proposed method is higher than that of BPNN-VGG, GRU and SVM models for the unbalanced data sets with seven state classes, which proves the diagnosing effectiveness of the proposed method for the unbalanced data sets.

Finally, a multi-model fusion fault diagnosis framework based on D-S evidence theory based on information fusion in decision level is introduced for a coexisting fault data sets containing a few samples. In this framework, the prediction outputs of two BPNN-InceptionNet models are fused by using D-S evidence theory combination rules, and the results of an example show that the proposed method is feasible in obtaining comprehensive diagnosis decisions.

**Keywords:** Tram; Fuel cell system; Fault diagnosis; Information fusion; Deep Learning

# 目 录

第 1 章 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 燃料电池轨道交通应用现状.....	2
1.2.2 燃料电池故障诊断研究现状.....	2
1.2.3 基于深度学习方法的故障诊断研究现状 .....	5
1.2.4 基于信息融合结构的故障诊断研究现状 .....	6
1.3 本文的主要研究方法 with 内容 .....	6
第 2 章 有轨电车用燃料电池系统数据采集与分析 .....	8
2.1 燃料电池混合动力有轨电车 .....	8
2.1.1 有轨电车外观及主要参数.....	8
2.1.2 有轨电车用混合动力系统配置.....	8
2.2 有轨电车用燃料电池系统 .....	9
2.2.1 HD6 燃料电池电堆 .....	9
2.2.2 燃料电池辅助系统.....	10
2.3 有轨电车用燃料电池系统运行数据分析 .....	11
2.3.1 历史运行数据分析.....	11
2.3.2 故障等级划分.....	15
2.3.3 故障种类分析.....	16
2.3.4 故障数据案例分析.....	18
2.4 本章小结.....	21
第 3 章 数据层信息融合的深度学习故障诊断方法 .....	22
3.1 复杂故障样本数据.....	22
3.1.1 t-SNE 数据可视化及输入数据处理.....	22
3.2 GRU 方法 .....	25
3.3 基于 GRU 的燃料电池系统故障诊断 .....	27
3.3.1 GRU 故障诊断框架及参数 .....	27
3.3.2 GRU 诊断性能的影响因素分析 .....	28
3.4 本章小结.....	33
第 4 章 特征层信息融合的深度学习故障诊断方法 .....	34
4.1 不均衡故障样本数据.....	34
4.2 BPNN-InceptionNet 方法.....	34
4.2.1 BPNN-InceptionNet 框架.....	35
4.2.2 基于 InceptionNet 的卷积网络.....	36

4.3 基于 BPNN-InceptionNet 的燃料电池系统故障诊断 .....	39
4.3.1 模型参数设置.....	39
4.3.2 诊断结果分析.....	40
4.4 本章小结.....	43
第 5 章 决策层信息融合的深度学习故障诊断方法 .....	44
5.1 并存故障样本数据.....	44
5.2 D-S 证据理论方法 .....	45
5.2.1 D-S 证据理论 .....	46
5.2.2 基于 D-S 证据理论的多模型融合诊断方法流程 .....	47
5.3 基于 D-S 证据理论的多模型融合的燃料电池系统故障诊断....	48
5.3.1 BPNN-InceptionNet 模型测试.....	48
5.3.2 Dempster 组合规则实例 .....	48
5.4 本章小结.....	50
结论与展望.....	51
参考文献.....	53

# 第 1 章 绪论

## 1.1 研究背景与意义

近年来,我国政府部门陆续出台关于推动氢能燃料电池在交通领域方面的应用发展的政策。中国交通运输部与科技部于 2017 年发布《“十三五”交通领域科技创新专项规划》<sup>[1]</sup>,规划中明确指出需要优化升级氢能燃料电池动力系统,努力突破燃料电池/动力电池混合动力集成控制与能量优化管理等技术。中共中央、国务院于 2021 年印发了《国家综合立体交通网规划纲要》<sup>[2]</sup>,将氢能燃料电池应用于轨道交通领域符合我国构建创新智慧、安全绿色的现代化高质量综合交运网络的目标。质子交换膜燃料电池(Proton Exchange Membrane Fuel Cell, PEMFC)是应用最为广泛的氢能燃料电池之一,将其作为主动力源的燃料电池机车已取得了突破性进展<sup>[3]</sup>,本文提及的燃料电池皆指的是 PEMFC。为了进一步助力 PEMFC 机车的商业化,确保 PEMFC 的安全可靠运行至关重要,而故障诊断是确保其安全可靠运行的亟待解决的关键难题<sup>[4-5]</sup>。

机车用 PEMFC 系统是一个由多个子系统构成的复杂系统,包括氢气供应与循环子系统、空气供应子系统、主冷却循环与散热子系统、辅冷却循环与散热子系统等。在机车运行过程中,PEMFC 系统中的各子系统都可能会产生系统级的故障类型,如去离子乙二醇入口低压故障、去离子乙二醇入口高温故障、氢气供应压力低等故障。这些发生在不同子系统的故障或与电气量相关,或与非电气量相关,故障产生的原因也多种多样,此外在机车运行时还需要考虑环境和人为因素的影响,这些就导致了机车用 PEMFC 系统各类故障具有复杂性、不确定性等特点,因此研究适合机车用 PEMFC 系统的故障诊断方法是具有现实意义且存在一定困难的<sup>[6-10]</sup>。

PEMFC 的故障诊断方法主要可分为模型驱动、实验驱动和数据驱动的诊断方法。模型驱动的故障诊断依赖于准确的数学物理模型的建立,需要对 PEMFC 内部机理有深刻的理解。实验驱动的故障诊断需要借助各类测试设备对 PEMFC 进行实验分析。数据驱动的故障诊断是一种基于历史数据的方法,利用算法模型分析数据特点,学习不同故障类数据特征,从而实现故障的识别与诊断。针对于机车用 PEMFC 这种复杂的系统,分析内部机理并构建准确的数学物理模型、装设昂贵的额外测试设备等都是较为复杂和困难的,因此数据驱动的故障诊断方法更适用于机车用 PEMFC 系统此类大功率应用场景<sup>[11-15]</sup>。

在数据驱动的诊断方法中,深度学习是新一代的神经网络,相较于浅层神经网络模型,深度学习方法具有更强的非线性特征学习能力和对高维数据的处理能力,深度学习方法已在模式识别、故障诊断等领域展现出了其独特的优势。此外信息融合是一种有效的数据处理技术,用以融合异构、不完整的原始数据,这也是机车用 PEMFC 系



统的数据特点,因此在信息融合结构的不同层级上研究深度学习故障诊断框架,用以对复杂的机车用 PEMFC 系统实现数据驱动的故障诊断是有意义的<sup>[16-18]</sup>。

## 1.2 国内外研究现状

### 1.2.1 燃料电池轨道交通应用现状

在轨道交通领域,利用燃料电池代替传统内燃机作为动力源,能减小投资成本,兼顾环境清洁与城市美观的优点,具有很好的发展前景。许多主机厂已经纷纷投入氢能燃料电池在轨道交通上的应用实践<sup>[19]</sup>。美国车辆工程有限责任公司于 2002 年研发了首台 PEMFC 矿用机车样车,该样车由两个燃料电池电堆串联,能提供净功率 17kW 的动力,供氢系统能保证燃料电池矿用车在地下连续工作八小时。美国 BNSF 铁路公司于 2009 年研制了燃料电池调车机车,该机车采用 PEMFC 作为动力源,持续功率可达 240kW,利用高压氢气瓶能至多提供 68kg 的氢气燃料,保证机车能连续运行十一个小时<sup>[20]</sup>。美国 Vehicle Projects 公司于 2012 年与南非英美铂金公司合作开发了五辆 PEMFC 矿用车辆。东日本铁路公司和日本铁路技术研究会于 2007 年研发了世界首列燃料电池/蓄电池混合动力机车组 KuMoYa E995-1,由 130kW 的 PEMFC 组和 19kWh 的锂离子电池构成动力源,供氢系统能提供至多 720L 氢气燃料,最远可保证动车行驶一百公里,并在商业线路上完成了试运营阶段<sup>[20]</sup>。西班牙窄轨铁路公司于 2011 年研制了一辆以 24kW 的 PEMFC 为主动力源的城际机车,储氢瓶能提供至多 105.6 立方米体积的氢气燃料,该城际机车至多载客量为三十人,最高时速为二十公里<sup>[21]</sup>。法国阿尔斯通公司基于柴油列车 Coradia Lint 54,于 2016 年研发了氢燃料电池火车 CoradiaiLINT,该火车配备了 396kW 燃料电池系统以及 222kW 的锂电池作为动力源,最高载客量三百人,最高时速为一百四十公里,并于 2018 年在德国正式商业化运行<sup>[20-21]</sup>。

现如今有轨电车是 PEMFC 在轨道交通应用的研究热点之一<sup>[22]</sup>,并且该领域内我国与国外的起步相差并不大,技术水平差距尚小。在国内,西南交通大学早在 2008 年就开始了将燃料电池应用到轨道交通的研究当中,并于 2013 年下线了中国首辆燃料电池机车“蓝天号”,同年与中车唐山公司共同申报并获批国家科技支撑计划项目“燃料电池/超级电容混合动力 100%低地板有轨电车研制”,2016 年该混合动力机车成功下线,标志着世界上首列成功投入应用的燃料电池 100%低地板现代有轨电车<sup>[23-25]</sup>。

### 1.2.2 燃料电池故障诊断研究现状

PEMFC 系统内部是一个复杂的物理环境,耦合了电化学、电磁学、热力学和流体力学等多物理场,当 PEMFC 发生故障时,不同的故障产生原因与系统的外特性表征变化并非严格一一对应,这些都给准确的 PEMFC 故障诊断技术带来了很大的挑战。在现有的研究成果中,PEMFC 的故障诊断方法主要可以分为模型驱动的故障诊断、实验驱

动的故障诊断和数据驱动的故障诊断<sup>[26]</sup>。

模型驱动的故障诊断也被称为基于残差的诊断,将系统的实际监测量测量值与所建立模型的预计输出值进行比较生成残差,随后通过残差分析和决策完成故障诊断任务<sup>[27-28]</sup>。在文献[29]中,利用氧气过量系数、电堆电压值、电堆电流值和空压机转速四个变量生成了四个残差,并引入相对故障灵敏度的概念,形成三维残差空间,在仿真平台上验证了六种故障在残差空间中不存在重叠区域,因此,可以利用生成残差空间的方法对这六类故障实现准确检测和隔离。文献[30]构建了一个包含 121 个方程和 119 个变量的集总参数模型对 PEMFC 系统进行仿真,创新性地将结构分析和因果计算理论应用于模型驱动的 PEMFC 故障诊断。文献[31]提出了一种用于时滞线性参数变化系统的未知输入观测器,来对 PEMFC 系统的执行器实现故障诊断。除了上述通过构建数学物理模型来描述 PEMFC 系统的方式外,还可以利用神经网络的方法。文献[32]利用训练后的 Elman 神经网络来描述 PEMFC 系统特性,通过网络的输出值和阴极压降的测量值作比较生成残差,将得到的残差与设定的故障阈值进行对比,从而实现水淹故障的诊断。在文献[33]中,研究发现神经网络工作在依赖模式时对故障不敏感,因此提出了一种工作在独立模式下的径向基函数网络来预测过程输出,可以实现敏感的故障监测,随后通过另一个高信噪比的径向基函数网络实现故障隔离。此外,还有许多研究着眼于 PEMFC 电堆的内部动态行为,并根据电池内部动态行为,建立三维电学模型来估计电堆内的电压电流分布。文献[34]中提出了一个考虑了三个几何方向的电路等效模型,通过测量电池的电压和温度,并且在每个单电池片上定义了 9 个部分,以此展现单电池片内的电压、温度分布的均衡性。将实验结果和理论结果对比,验证了提出的电路模型的有效性,结果表明在每个单电池片内的 9 个区段分别有着不同的电压电流分布特性,另外也证实了该模型具有很好的故障敏感性,能在减少传感器数量的前提下实现 PEMFC 的水淹和膜干的故障诊断和故障区域定位。文献[35]提出了一种故障诊断两步法,首先,建立了一个 3D 故障敏感模型来估计 PEMFC 的局部参数,包括单电池片内的温度、电流和电压分布,利用该 3D 模型能够模拟不同等级的水淹和膜干故障,包括水淹故障、高度水淹故障、膜干故障、高度膜干故障。随后,采用了一个两层前馈人工神经网络(Artificial Neural Network, ANN)来对不同等级的故障进行识别,并将故障定位到单电池片内的 9 个区段中。从实验结果表明该方法能对考虑的故障进行较好的诊断识别和定位。文献[36]则针对于多单片的 PEMFC 电堆提出了一个 3D 电路模型,以提供一个快速估计电堆内电势和电流密度分布的工具,该模型能很好的反应电堆参数、操作条件和扰动的变化影响,仿真结果还表明,电堆内部的不均衡性很大程度上受到材料的电学性能和电堆几何形状的影响。

综上所述,基于模型的故障诊断通常十分依赖于有效的模型建立,需要对 PEMFC 的内部电学机理及其他物理场的耦合规律有较深的理解,才能构建出能较为准确估计过程输出的模型。另外,当燃料电池出现不同故障时,可能会破坏模型的初始条件,因

此需要重新构建模型或调整模型参数，这都增加了基于模型的故障诊断的复杂度与成本。而 3D 的电路模型也往往是考虑单片或小型电堆内部的不均衡性分布，对于有轨电车这类大功率 PEMFC 应用，准确的 3D 电堆模型的研究还很少，并仍然具有较大的复杂度。

实验驱动的故障诊断需要借助某些测量设备来对 PEMFC 进行状态检测，并通过故障实验结合测量结果中的信息进行诊断。电化学阻抗谱是一种先进的非破坏性诊断技术，可用于探索 PEMFC 电堆在各种外部条件下的内部阻抗信息，并有助于建立等效电路模型<sup>[37]</sup>。文献[38]利用电化学阻抗谱测量了一个 80 单片电堆在 30 至 300 赫兹下的电堆阻抗谱信息，以此对电堆是否发生水淹或膜干故障进行评判。文献[39]提出了一种动态电化学阻抗谱方法，该方法能在一个运行参数变化的动态系统，例如变负载工况下，同时获得电池单片和电堆的阻抗信息，使用这些阻抗信息能构建动态环境下的数据库，用以实现电堆在操作条件变化下的故障诊断和故障定位。还有研究利用燃料电池运行过程中的电磁现象，通过磁传感器设备测量电堆周围的磁感线分布来进行故障诊断。文献[40]在燃料电池电堆四周安置了 30 个磁传感器，得到电堆周围的磁场分布曲线图进而估计电池内的电流密度分布，不同的电流密度分布反应了电堆处于不同的健康状态，此外研究中还探讨了不同的磁传感器排列方式对故障诊断的准确度的影响。文献[41]同样利用了电堆四周的磁场分布，设计了三维偏微分仿真模型，用来建立磁场分布特征和电堆故障的对应关系，从而实现电堆故障诊断和故障的单片定位。另外也有将可视化技术与设备应用到燃料电池故障诊断中的研究。文献[42]第一次引入中子成像技术来对 PEMFC 进行内部水状态观测。文献[43]利用了 X 射线成像技术分析高温环境对质子交换膜的影响，探讨了膜干故障时电池内部水蒸气的分压情况。

综上所述，实验驱动的故障诊断通常需要额外的测试或测量设备，这些设备的价格通常较高，且对于成像技术甚至需要定制透明电池用于实验，因此这些方法更适用于实验室内的 PEMFC 单片或小功率电堆的研究，在大功率 PEMFC 应用中，高成本和安装空间等问题都还需要更多的解决方案。

数据驱动的故障诊断是基于大量的历史数据，从历史数据中找到故障特征来实施诊断任务。一般而言，信号处理方法和人工智能(Artificial Intelligence, AI)方法都可用于数据驱动的故障诊断。经验模态分解(Empirical mode decomposition, EMD)是一种有效的处理非平稳信号的方法，当前已在 PEMFC 故障诊断中得到应用，文献[44]对一个 50W 单电池片的输出电压进行 EMD 分析，得到 14 个本征模态函数(Intrinsic Mode Functions, IMFs)，并从中选取了两个与水淹和膜干最相关的本征模态函数作为诊断指标，通过这两个指标来反映电堆的健康状态。小波变换(Wavelet Transform, WT)是一种常见的用于信号时频域分析的工具，也被应用于 PEMFC 故障诊断，在文献[45]中，首先对一个含 40 片单电池的 PEMFC 电堆的压力和电压信号进行小波变换分析，利用小波变换分解出的细节变量的相对小波能量(Relative Wavelet Energy, RWE)实现高空气计

量比故障诊断。文献[46]提出了一种基于多分辨率分析的五级离散小波变换方法,来分析 PEMFC 系统的健康状态。上述文献是一些信号处理技术在 PEMFC 系统故障诊断中的应用,而人工智能方法也越来越多地被应用在 PEMFC 故障诊断任务当中,并在性能表现中展露出其特有的优势。神经网络具有很强的非线性表达能力,在模式识别领域有了广泛的应用,文献[47]采用一个多人工神经网络集成的方法对 PEMFC 系统的四类故障进行识别,结果显示该集成人工神经网络的诊断精度要优于集成网络中的任意一个子神经网络的诊断精度。文献[48]利用基于反向传播(Back Propagation, BP)算法的多层感知机(Multilayer Perceptron, MLP)建立了一个 PEMFC 的最优阻抗模型,利用该阻抗模型对 PEMFC 的水淹和膜干进行故障识别。考虑到随着 PEMFC 的运行时间增加,电堆性能会随之下降,因此也有研究专注于在线自适应故障诊断策略。例如在文献[49]中,利用 Fisher 判别分析和球形多分类支持向量机从电池单片电压中成功抽取特征,利用抽取出的特征可以对 PEMFC 的已知健康状态分类,还能识别其可能发生的新故障,进一步地,利用增量学习方法,还可以实现在线自适应诊断,并在一个含 40 片电池的的电堆上验证了诊断方法的诊断精度。

综上所述,数据驱动的故障诊断通常不需要建立准确的 PEMFC 模型,而是从大量历史数据中学习到故障相关特征从而实现诊断任务,因此对于本文要研究的有轨电车用燃料电池系统,数据驱动的故障诊断方法相比于模型和实验驱动的方法具有独到的优势。但是基于信号处理和传统人工智能算法的数据驱动方法往往只能处理少量的历史数据,以及对少数类故障进行诊断,而有轨电车用燃料电池系统在运行时会产生丰富的历史数据,以及可能会出现多种故障类型,因此提出适合机车大功率 PEMFC 系统的数据驱动故障诊断方法是有必要的。

### 1.2.3 基于深度学习方法的故障诊断研究现状

近年来,随着大数据的兴起以及计算设备运算能力的增强,使得神经网络研究迎来了新的浪潮,深度学习作为新一代的神经网络,在模型结构复杂度上有了不同程度的增加,与传统的浅层神经网络模型存在表达能力不足、难以处理高维数据等问题相比,深度学习在特征挖掘和模型拟合方面显示出独特的潜力和优势,基于深度学习的故障诊断与预测成为一个具有创新性和良好前景的研究领域<sup>[50-51]</sup>。较为常用的深度学习基本模型框架可以分为深度置信网络(Deep Belief Network, DBN)、循环神经网络(Recurrent Neural Network, RNN)、卷积神经网络(Convolutional Neural Network, CNN)、自动编码器(Auto-encoder, AE)等<sup>[52-56]</sup>。文献[57]先采集旋转机械的振动信号,随后利用 Morlet 小波分解得到小波尺度特征图,将其输入到卷积神经网络来实现机械故障诊断。文献[58]分析了属于 RNN 的三种变体模型: vanilla RNN、长短期记忆网络(Long short-term memory, LSTM)、门控循环单元网络(Gate Recurrent Unit, GRU),并研究了它们各自在航空发动机故障诊断中的性能,结果表明 LSTM 和 GRU 的性能表现更优,但三者

的集成模型并没有提升诊断任务的精度。文献[59]利用小波函数作为 AE 的激活函数,形成小波自动编码器模型,进而将多个小波自动编码器形成深度小波自动编码器来提取特征,最后使用极限学习机实现滚动轴承的故障诊断。DBN 也在滚动轴承、齿轮箱、燃料电池等装置的故障诊断中展现了其故障分类能力。

综上所述,深度学习方法由于其优秀的自动学习特征的能力,已经在故障诊断等多个领域内大放异彩,但在大功率燃料电池系统中的研究还是不足。因此对于深度学习方法在有轨电车用燃料电池系统故障诊断中的应用,还需要继续深入探究。

#### 1.2.4 基于信息融合结构的故障诊断研究现状

信息融合(或多传感器数据融合)是一种有效的数据处理技术,将来自传感器的异构、复杂、不完整的原始信息进行融合,从而获得完整、有价值的信息用于后续处理<sup>[60-63]</sup>。信息融合技术已广泛应用于军事探测、无线传感器网络、轨迹跟踪等领域。然而,基于信息融合的 PEMFC 系统故障诊断研究还较少<sup>[64-66]</sup>。信息融合包括多种结构,如 Joint Directors of Laboratories (JDL)架构和 Luo and Kay 的三层融合架构<sup>[60,67]</sup>。其中 Luo and Kay 的三层融合结构是故障诊断和缺陷检测领域的常用结构,由低到高的三层融合结构主要包括数据层(信号层)融合<sup>[68]</sup>、特征层融合<sup>[69]</sup>和决策层融合<sup>[70-71]</sup>。其中,数据层融合属于第一层次的融合,其将收集到的多源信息进行直接处理。特征层信息融合属于第二层的融合,其主要将原始多源信息中的特征信息进行再处理。决策层信息融合是第三层的融合,其主要在决策层对来自多个判断源的决策进行融合输出,提高最终结果的综合性与容错能力。当前已有研究将信息融合结构应用于神经网络中来构建出性能更好的故障诊断框架,分析并证实了诊断框架的有效性。文献[72]直接将多传感器数据作为 CNN 网络的输入,利用 CNN 网络学习原始数据中的特征来分类,而舍去了人工提取特征的步骤,最后在滚动轴承的故障诊断中验证了方法的准确性。文献[73]将证据理论引入发动机故障的诊断任务,考虑了两种质量函数的计算方法,提出了一种改进的质量函数提高证据组合的性能,此外还引入了证据熵来评价信息融合的性能,结果验证了该方法能解决冲突决策问题,在融合多传感器信息时展现了好的准确度。

综上所述,将信息融合的结构与神经网络方法进行结合,并将其应用到故障诊断领域是一个研究热点。在深度学习自动学习特征的效果显著的当下,借助信息融合的结构改进深度学习故障诊断框架是很有必要的,但现在的相关研究还不算多,尤其是对于有轨电车用燃料电池系统的故障诊断领域。

### 1.3 本文的主要研究方法 with 内容

本文的研究对象是西南交通大学与中车唐山公司共研的燃料电池/超级电容混合动力 100%低地板有轨电车的 PEMFC 系统,研究目标是针对该燃料电池系统可能发生的各类故障进行故障诊断,研究方法是利用深度学习和信息融合实现不同的故障诊断框

架的建立，本文的主要内容可以总结为以下几点：

(1) 本文将对有轨电车的参数以及有轨电车的动力系统进行介绍，重点介绍机车动力系统中的燃料电池系统，并对燃料电池系统的结构、工作原理以及燃料电池电堆的参数进行描述。随后介绍了数据采集系统及其能采集到的所有有关燃料电池系统的共 28 种电量与非电量监测参数。这部分将在第 2 章中介绍。

(2) 为了直观说明燃料电池系统的数据特征，文本将选择一段机车实际运行时间内的部分监测数据，通过不同监测数据的变化趋势来说明在机车运行时部分参数的变化特点。此外本文还将对燃料电池系统的故障分级，以及燃料电池系统发生的故障类型进行详细描述，并选取了部分故障样本与正常样本来对比说明故障样本的数据特征。这部分将在第 2 章中介绍。

(3) 为了实现复杂故障样本数据集的故障诊断，本文研究了数据层信息融合的基于 GRU 的燃料电池系统故障诊断框架，并利用 t-SNE 降维可视化算法说明样本数据的复杂度。诊断结果证明了该方法对复杂故障样本的诊断有效性，与 SVM 算法的对比结果也证明了该方法有较好的诊断表现。这部分将在第 3 章中介绍。

(4) 为了实现不均衡故障样本数据集的故障诊断，本文提出了一种特征层信息融合的基于 BPNN-InceptionNet 的燃料电池系统故障诊断框架，并对该诊断框架内的各部分计算原理进行详细描述。通过引入  $\kappa$  系数为指标评价模型性能，结果证明了该框架有优于其他数种模型的诊断不均衡样本的性能表现。这部分将在第 4 章中介绍。

(5) 为了实现并存故障样本数据集的故障诊断，本文引入了一种决策层信息融合的基于 D-S 证据理论的燃料电池系统故障诊断框架，对 D-S 证据理论的原理和证据组合规则进行了详细描述，并以一个实例计算说明了该方法在输出综合诊断决策方面的可行性。这部分在第 5 章中介绍。

第 2 章 有轨电车用燃料电池系统数据采集与分析

2.1 燃料电池混合动力有轨电车

2.1.1 有轨电车外观及主要参数

本文研究的对象是本团队与中车唐山公司共同研发并成功下线运行的燃料电池/超级电容混合动力有轨电车，这辆 100%低地板现代有轨电车是世界首列商用型氢燃料混合动力有轨电车，标志着我国的新能源轨道交通领域实现的一项突破性进展。该列混合动力有轨电车的一次加氢时间为 15 分钟，可持续运行 40 公里，最大运行速度可达每小时 70 公里，载客量最多可达 347 人，且能依据运行规划合理扩增编组及满载客量。机车的整体外观如图 2-1 所示，机车主要参数指标于表 2-1 中列出<sup>[74-76]</sup>。



图 2-1 混合动力有轨电车

表 2-1 机车主要参数

参数	数值
环境温度/℃	-25～42
母线电压/V	750
车辆编组	Mc-T-Mc
长度/m	30.19
宽度/m	2.65
高度/m	3.5
轴重/t	10.5
列车自重/t	51.06
最大坡度/‰	50
加速度/(m/s <sup>2</sup> )	1.2

2.1.2 有轨电车用混合动力系统配置

混合动力有轨电车的动力系统主要包括燃料电池系统、动力电池系统、超级电容

系统和牵引系统，其中，除了牵引系统以外，燃料电池系统、动力电池系统以及超级电容系统均各自配备了两套以协同工作。

燃料电池的续航能力充足，因此，燃料电池系统作为混合动力有轨电车的主动力源，提供电能以牵引机车运行，本文主要研究的故障诊断对象就是此燃料电池系统；本车配置的燃料电池电堆为 Ballard 公司 HD6 型 PEMFC。超级电容具有功率密度大的优点，被用来在机车制动的过程中将产生的制动能量进行回收，本车配置的超级电容采用的是 MaxWell 公司的 BMOD0165 P048 型产品，以 11 串 3 并的连接方式构成容量 45F、额定电压 528V 的超级电容组。动力电池在牵引过程中的出力并不多，其主要作用是当有轨电车发生紧急故障，主动力源失去控制、无法正常工作时，动力电池中储存的电能必须能将将电车牵引回最近的车辆段，本车配置的动力电池为钛酸锂电池，以 144 串 2 并的连接方式构成容量 20A·h、额定电压 331V 的动力电池组。有轨电车充分发挥燃料电池系统、动力电池系统和超级电容系统各自的优势，三者联合供电，使得有轨电车能以较高的能量利用效率运行，并提高了经济性。有轨电车的动力系统配置参数如表 2-2 所示<sup>[75-76]</sup>。

表 2-2 有轨电车动力系统配置

参数名称	数值
燃料电池电压/V	440~710
燃料电池标称功率/kW	150
燃料电池电堆最大电流/A	320
超级电容电压/V	280~528
超级电容最大电流/A	700
超级电容容量/F	45
动力电池电压/V	279~396
动力电池最大电流/A	120
动力电池容量/A·h	20
储氢罐数量/个	4
储氢容量/kg	12
储氢压力/Mpa	35

## 2.2 有轨电车用燃料电池系统

### 2.2.1 HD6 燃料电池电堆

有轨电车用燃料电池系统中使用的单套 HD6 型 PEMFC 电堆的外观示意图如图 2-2 所示，电堆相关参数如表 2-3 所示<sup>[74]</sup>。





图 2-2 HD6 型 PEMFC 电堆外观

表 2-3 电堆主要参数

参数名称	数值
电堆重量/kg	440
电堆尺寸/mm	1530×871×495
标称功率/kW	150
最大功率/kW	170
工作电压/V	465~730
最大工作电流/A	300
单片数量/片	735
燃料	氢气
氧化剂	空气
冷却剂	水和去离子乙二醇


2.2.2 燃料电池辅助系统

除燃料电池电堆以外，有轨电车用燃料电池系统还包括其他的辅助系统以协助电堆正常工作，整个 HD6 燃料电池系统的结构图如图 2-3 所示<sup>[75]</sup>，以下介绍燃料电池辅助系统的原理及功能。

在氢气供给子系统中，高压氢气罐中的氢气通过过滤器滤除杂质后依次通过调压阀和电磁阀来调整氢气的压力和流量至合适的范围之内，以保证电堆的安全运行，随后氢气经过氢气输入端口，被通入燃料电池电堆的阳极入口进行电化学反应。经过反应，剩余的氢气将从电堆阳极出口排出，排出的氢气一部分进入氢气循环子系统，流经氢气循环泵，重新通入电堆阳极入口，实现燃料的回收再利用，同时反应的水汽也能通过这种方式对阳极入口氢气进行加湿；剩余的排出氢气经过排气阀流出，此时，从排气阀流出的剩余氢气被依次流经通风空气输入端口和过滤器的空气稀释后，经过通风管道一起从通风空气输出端口排出，防止氢气排出时浓度过高而产生爆炸隐患。

在空气供给子系统，空气压缩机在驱动电机的带动下，对流经过滤器的空气进行加压，加压后的清洁空气流进空气输入端口，在端口后通过加湿器装置进行气体加湿，加湿后的空气被通入燃料电池电堆阴极入口进行电化学反应。在电堆阴极出口排出的

反应剩余空气将通过气液分离器装置进行气液分离，干燥空气通过空气输出端口排出，空气中的液体被回收至水箱中，而水箱中的液态水经过加湿泵，作用于加湿器，完成对电堆阴极入口空气的加湿功能。



FUEL IN: 氢气输入端口; AIR IN: 空气输入端口; AIR OUT: 空气输出端口; DI-WEG IN: 冷却液输入端口; DI-WEG OUT: 冷却液输出端口; COND IN: 冷凝剂输入端口; COND OUT: 冷凝剂输出端口; VENT IN: 通风空气输入端口; VENT OUT: 通风空气输出端口。

图 2-3 燃料电池系统结构

为了对有轨电车大功率燃料电池系统进行良好的温度控制，该燃料电池系统中配置了主冷却循环与散热子系统以及辅冷却循环与散热子系统。主冷却循环与散热子系统主要由冷却液循环泵、去离子水过滤器、冷却循环回路散热风机构成，通过冷却液输入端口流入电堆，从冷却液输出端口流出电堆，通过这一过程来对电堆进行温度控制。辅冷却循环与散热子系统主要由冷凝剂循环泵、冷凝剂循环回路散热风机构成，通过辅冷却循环与散热子系统，可以控制气液分离器内的温度，从而降低气液分离器中分离出的液态水温度。最后燃料电池电堆通过输出线，经过DC/DC变换器来给负载进行供电。

## 2.3 有轨电车用燃料电池系统运行数据分析

### 2.3.1 历史运行数据分析

在燃料电池混合动力有轨电车系统中，配置了各类传感器及检测设备，结合数据

传输总线等装置构成有轨电车数据采集系统，数据采集频率为每秒采样一次，用以实时监测有轨电车的运行状态和参数，具体的检测参数如表 2-4 所示，其包含压力、温度、流量等非电量参数，以及电流、电压等电气量参数。

表 2-4 数据采集系统监测参数

参数	编号
DCDC 限制电流/A	$x_1$
模块入口氢气压力/MPa	$x_2$
模块入口冷却液温度/°C	$x_3$
电堆总电流/A	$x_4$
电堆电压/V	$x_5$
辅机电流/A	$x_6$
测试请求流量/(L·S <sup>-1</sup> )	$x_7$
冷却液流量/(L·S <sup>-1</sup> )	$x_8$
氢气压力/MPa	$x_9$
环境温度/°C	$x_{10}$
冷却液温度/°C	$x_{11}$
冷凝剂温度/°C	$x_{12}$
DCDC 输出电压/V	$x_{13}$
DCDC 输入电流/A	$x_{14}$
绝缘阻值/ $\Omega$	$x_{15}$
请求电流/A	$x_{16}$
电堆电流设定点/V	$x_{17}$
电堆出口氢气压力/Mpa	$x_{18}$
电堆入口氢气压力/Mpa	$x_{19}$
冷却液入口压力/Mpa	$x_{20}$
空气入口压力/Mpa	$x_{21}$
电堆冷却液出口温度/°C	$x_{22}$
电堆冷却液入口温度/°C	$x_{23}$
空压机入口空气温度/°C	$x_{24}$
空气出口温度/°C	$x_{25}$
空压机电压/V	$x_{26}$
空压机电流/A	$x_{27}$
冷却液请求流量/(L·S <sup>-1</sup> )	$x_{28}$

用于本文的研究数据皆是基于此有轨电车数据采集系统，原始数据来自于有轨电车实际运行数据，总量达数十万组。随后将以部分机车历史数据为例，对燃料电池系统运行情况做简要分析。图 2-4 展示了一段在机车实际连续运行 1485s 下，HD6 电堆的状态、电压和总电流随时间变化的曲线图。

其中，HD6 状态被分为了几个不同挡位：0 表示开机前状态；1~4 表示启动状态；5 表示正常运行状态；7 表示故障状态。从图中可以看出，在这段运行时间里，HD6 开机后很快进入正常运行状态，并在较长时间内保持正常运行。在 HD6 正常运行时，可

以观察到,电堆总电流和电堆电压虽然都在一定程度上出现了测量波动,二者的曲线都出现了毛刺段,但平均数值都表现出相对于故障状态时更高的数值水平,在此期间,电压平均值为 633.2V,电流平均值为 92.9A。而当 HD6 进入一故障状态,也即图 2-4 中红色椭圆标记的区段,电堆电压逐渐降低,电堆电流也降至 20A 左右以满足最小工作电流的要求。




图 2-4 HD6 状态、电堆电压和电流随时间变化曲线

氢气是燃料电池重要的气体燃料,其压力大小对燃料电池系统的运行起着关键作用,过小的氢气压力可能使得燃料不足、电化学反应不完全,从而造成燃料电池运行效率降低;而过高的气体压力有可能对燃料电池的膜电极造成不可逆的损坏,也有可能因压力过大进而影响气体在电池流道内的流速,从而影响电化学反应的正常进行,使得电池效率降低<sup>[76]</sup>。因此,对氢气压力的监测有利于判断有轨电车用燃料电池系统是否正常运行。图 2-5 展示了在同一运行时间段内,数据采集系统监测到的与氢气压力相关的测量值。HD6 在开机前以及启动状态时,系统内氢气压力保持在 16.65Mpa 左右的水平,而模块入口氢气压力、电堆出口和入口氢气压力都呈现极低值的水平。当 HD6 进入正常运行状态,系统内氢气压力开始下降,用来为燃料电池模块供给所需的氢气,压力值在低于初始压力的水平上下波动;与此同时,模块入口氢气压力开始上升,经过调压阀将氢气压力减小后通入电堆以发生电化学反应,因此此时电堆入口和出口的氢气压力都开始上升且趋于稳定,且二者压力值远小于模块入口氢气压力,以防止通入电堆的氢气压力过大而对电堆造成损坏。当 HD6 进入此故障状态时,系统氢气压力值立刻回到初始水平并保持相对稳定,而电堆入口和出口氢气压力则开始缓慢下降至极低水平。此外,在红色矩形标记的区段内,模块入口氢气压力变化并不明显,而在标记区段外,模块入口氢气压力则迅速下降至极低水平,这说明在标记的这段 HD6 故障运行时间内,仅仅通过模块入口氢气压力这一测量量可能无法及时判断出故障,因为当

模块入口氢气压力显著下降至极低水平时, HD6 已经于故障状态运行了一段时间, 这不利于燃料电池系统的健康。

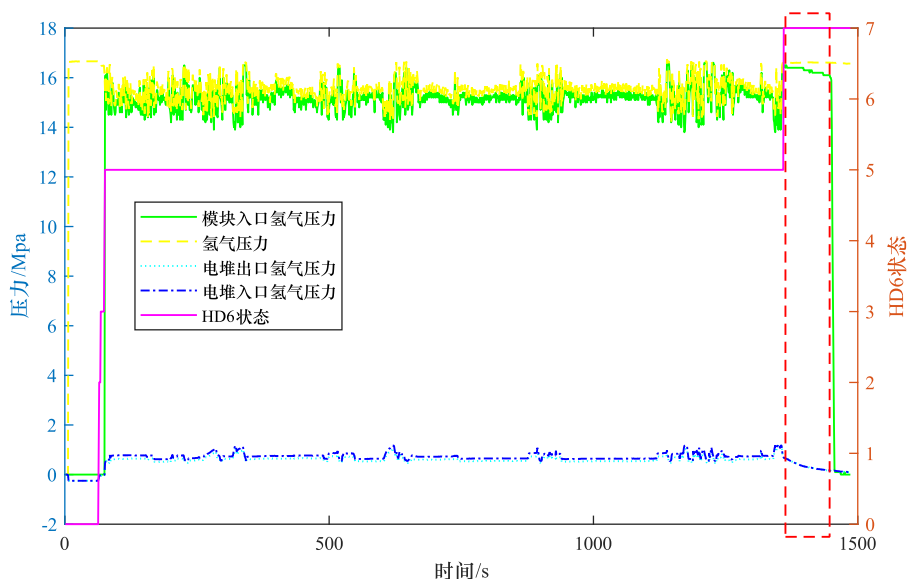


图 2-5 HD6 状态、氢气压力相关监测量随时间变化曲线

温度对于燃料电池系统的正常运行也十分重要, 过高的温度可能会对燃料电池的膜电极造成不可逆的损坏, 因此对系统内各子系统的温度进行实时监控也显得尤为关键。图 2-6 展示了在同一段时间内, 有轨电车用燃料电池系统内与温度相关的部分测量值曲线。从图中可以看出, 这些温度监测量在 HD6 处于正常运行状态时, 都能保持相对稳定的水平, 并没有出现显著的温度异常变化。其中, 电堆冷却液出口温度高于入口温度, 同时也高于其他温度, 这正好反映了冷却液用以将电堆反应产生的多余热量带走以防止电堆内温度过高产生不良后果的作用。此外, 当 HD6 进入此故障状态时, 可以观测到, 空压机入口空气温度和空气出口温度皆出现了短暂升高并缓慢下降, 且在整个故障状态区段, 二者的温度都分别稍高于各自在 HD6 正常运行时的平均温度。

另外, 图 2-7 显示了 HD6 在上述的正常运行时间区段内, 电堆冷却液出入口的温度变化曲线, 可以看出电堆冷却液出口温度高于入口温度, 并且从红色椭圆标记区域可以明显看出二者具有相反的变化趋势, 当电堆冷却液出口温度过高, 则系统通过调整冷却液循环回路散热风机和冷却液循环泵功率等措施降低电堆冷却液入口温度, 从而维持电堆的工作温度在正常范围内。

从上述有轨电车运行数据的实例分析, 在 HD6 燃料电池系统处于不同的工作状态时, 不同的测量量之间由于物理规律或是运行逻辑的限制而存在着相互关联的耦合关系, 有些量之间具有相同的变化规律, 同时有些量之间具有相反的变化规律。此外, 当 HD6 燃料电池进入某一故障状态时, 不同物理量可能显示出不同的特点, 例如有些物理量可能会突变, 有些物理量可能缓慢变化, 而还有些物理量可能延迟变化或无明显变化。这些测量的数据中蕴含了丰富的信息, 利用这些信息来对燃料电池进行故障诊

断能有效地提高诊断的可靠性与准确度，而面对如此庞大的测量数据以及数据间可能存在的耦合和冗余等特点，设计出合适的故障诊断框架是有难度且是十分有必要的。

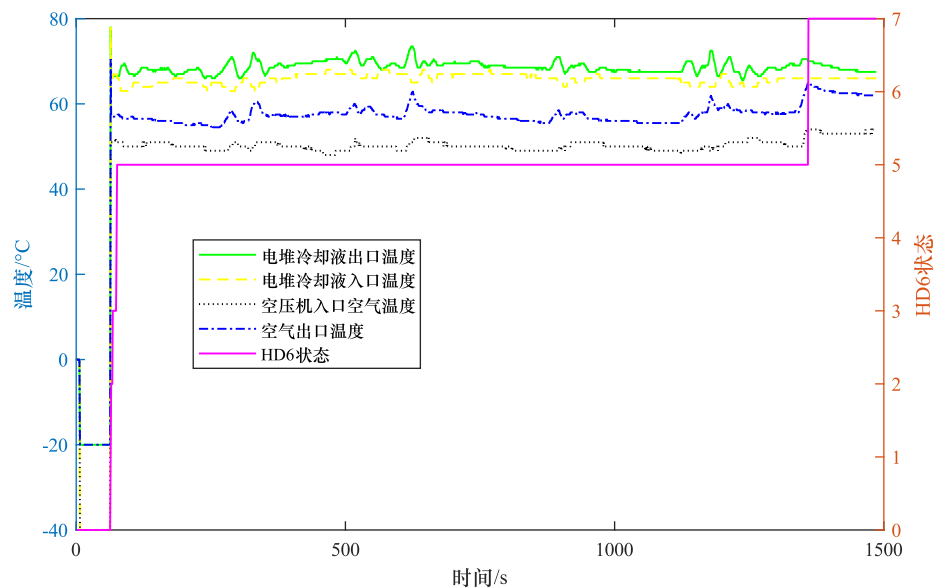


图 2-6 HD6 状态、温度相关监测量随时间变化曲线




图 2-7 电堆冷却液出入口温度随时间变化曲线

### 2.3.2 故障等级划分

经过各种性能测试和实验发现，有轨电车在正常运行时，数据采集系统所监测到的各类参数均在一定的工作范围内波动，而当燃料电池系统出现故障时，有系统参数会发生越界，不同的越界程度反映了不同的故障严重程度，因此，本文所研究的有轨电车将燃料电池系统可能发生的各类故障根据严重程度的不同进行了等级划分，故障的

不同等级描述如表 2-5 所示。

综合表 2-5 可知, 燃料电池系统 0 级故障只作为参考信息, 1 级故障虽不会导致停机, 但也要及时注意排查, 避免故障趋于更严重的 2 级和 3 级, 而 2 级和 3 级的故障相对较为严重, 可能使得燃料电池系统停机。通常当燃料电池系统处于 0 级、1 级故障时, HD6 模块运行状态仍是状态 5 (正常运行状态), 而 3 级故障和部分 2 级故障则会导致 HD6 模块进入状态 7 (故障状态)。

表 2-5 燃料电池系统故障等级划分

故障分级	说明
0 级	<ul style="list-style-type: none"><li>● 只是作为参考信息;</li><li>● 严重的 0 级故障会被记录。</li></ul>
1 级	<ul style="list-style-type: none"><li>● 系统参数越界;</li><li>● 故障信息通过总线向驱动系统报告;</li><li>● 燃料电池模块的输出功率可能由于故障而降低;</li><li>● 不会导致停机。</li></ul>
2 级	<ul style="list-style-type: none"><li>● 系统参数严重越界;</li><li>● 故障信息通过总线向驱动系统报告;</li><li>● 当测量电流降为 0 时, 燃料电池模块进入待机状态, 若此时 2 级故障激活时间超过 10 秒, 则燃料电池模块进入故障状态并停机;</li><li>● 可尝试重启, 若多次重启失败则需查明并清除故障, 故障清除之后方可允许重启运行。</li></ul>
3 级	<ul style="list-style-type: none"><li>● 系统参数越界已超安全范围, 燃料电池模块需即刻停机;</li><li>● 故障信息通过总线向驱动系统报告;</li><li>● 燃料电池模块立刻进入故障状态;</li><li>● 未查明并清除故障前禁止重启。</li></ul>

### 2.3.3 故障种类分析

有轨电车内部是一个非常庞大复杂的系统, 各个子系统之间不仅需要完成各自的任務, 还有着相互配合工作的联系, 作为有轨电车的动力来源, 燃料电池系统更是一个包含电化学、电磁学、热力学、流体力学等多物理场耦合过程的环境。因此在燃料电池系统的实际运行过程中, 电气、环境、机械等因素都可能会导致燃料电池系统发生各类故障, 本小节将对在前期实验中, 从机车数据采集系统中收集到的, 燃料电池系统发生的故障种类进行全面分析。

(1) 去离子乙二醇入口低压 1 级故障: 去离子乙二醇常作为冷却液, 应用于燃料电池系统的冷却子系统。造成该故障的原因可能是冷却液的液位过低、燃料电池的冷却液流量不足、冷却系统出现故障、冷却液入口的过滤器发生堵塞、压力传感器本体或接线出现问题等。相应地, 可以通过调整冷却液量、检查冷却系统设定点与实际流量的比率、检查冷却系统、检查冷却液入口过滤器和传感器等设备来排查并清除故障。此外,



在实验数据中还发现,去离子乙二醇入口低压的1级故障会被误报成0级故障,增加了漏检的概率以及燃料电池系统忽视故障的风险,因此更加说明了,提出准确的故障诊断方法来识别各类故障的必要性。

(2) 电流设定点偏差1级故障:该故障的产生原因是电流互感器出现故障,需要重新检测相关设备的运行状态。同样地,该1级故障也出现了误报成0级故障的现象。

(3) 去离子乙二醇入口高温1级故障:产生该故障的原因可能是燃料电池系统中存在空气、冷却系统(如加热器、热交换功能)失常、传感器故障等。相应地,可以通过检查冷却液排出口、检查冷却系统及相关传感器功能等手段排查故障。

(4) 氢气出入口压差低2级故障:该类故障的产生原因可能是氢气循环泵故障、远程换向器装配故障、氢气循环风机发生故障、氢气供应过程压力损失等。相应地,可以通过检查氢气循环风机、检查远程换向器功能、检查氢气供应系统是否正常工作等手段排查此类故障。

(5) 氢气供应压力低2级故障:该故障发生在供氢子系统,过低的氢气供应压力会导致电堆反应不完全,从而影响电堆的输出功率。造成该故障可能是因为储氢罐内剩余氢气过少、储氢系统失常、储氢罐压力调节器失效、相关电磁阀故障等。相应地,可以通过检查储氢罐内的氢气燃料、检查储氢系统、调整储氢罐压力调节器、检查电磁阀功能等手段排查此故障。

(6) 反向电堆电流2级故障:该故障发生的原因可能是驱动系统故障,错误地在燃料电池模块中主动施加了反向电流。相应的排查故障手段是检查驱动系统功能是否正常。

(7) 氢气排气信号电压低2级故障:此故障可能是由于接线问题导致的。

(8) 空气压力低1级故障:空气压力低可能导致燃料电池电堆内氧气缺乏,可能会导致电堆内部的电化学反应不完全,影响电堆输出功率,严重地甚至会影响质子交换膜的寿命健康。造成该故障的原因可能是空气供应子系统故障、排气阀或背压阀等设备故障等。相应地可以通过检查空气供应子系统功能、调整空气压缩机、检查阀门设备是否正常等措施来排查故障。

(9) 氢气泄漏2级故障:持续的氢气泄漏会导致空气中的氢气浓度逐渐升高,增加了安全隐患。有多种原因可能导致该故障,如氢气传感器失灵、氢气排气阀故障、减压阀密封不良、燃料电池内部出现氢气传输泄漏。可以通过检查传感器和排气阀、执行子系统传输泄漏测试来排查此类故障。

(10) 电堆电压信号低2级故障:此故障可能是由于线路连接失常导致的。

(11) 去离子乙二醇出口温度信号电压高1级故障:此故障可能是由于接线问题导致的。



### 2.3.4 故障数据案例分析

从上一小节的故障类描述中可以发现,有轨电车用燃料电池系统中的各子系统均可能出现各种、严重程度不一的故障,其中包括与冷却子系统相关的故障,如去离子乙二醇入口低压故障、去离子乙二醇入口高温故障等,与气体供应和循环子系统有关的故障,如氢气供应压力低故障、空气压力低故障等,与系统设备相关的故障,如电流设定点偏差故障,与线路连接有关的故障,如信号电压异常的故障,与驱动系统有关的故障,如反向电堆电流故障。本文只考虑与燃料电池相关的各子系统故障和设备相关故障,忽略与线路连接相关的信号电压异常故障以及与驱动系统相关的反向电堆电流故障。这些不同的故障所联系的物理量也有所不同,有的故障与非电气量(如温度、压力等)相关,而有的故障与电气量(如电压、电流等)相关,这些特点各异的故障数据,为提出准确的故障诊断方法带来了挑战。


随后将以部分曲线图的形式对不同故障样本进行特点分析。图 2-8(a)分别展示了表示正常状态的样本与表示去离子乙二醇入口低压 1 级故障的样本的电堆总电流与电堆电压的数据图,其中虚线左侧为正常状态样本的相关数据,虚线右侧为故障样本的相关数据。可以发现,当发生去离子乙二醇入口低压 1 级故障时,故障样本的电堆总电流值和电堆电压值呈现了样本间的波动性,不及正常状态样本间的平稳性,且故障样本的电堆电压平均值要高于正常态样本的电堆电压平均值,而故障样本的电堆总电流平均值要低于正常态样本的电堆总电流平均值。

图 2-8(b)则展示了不同样本的冷却液流量、冷却液温度和冷却液入口压力数据,同样地,虚线左侧表示正常态样本数据,虚线右侧表示去离子乙二醇入口低压 1 级故障的样本数据。从图中可见,正常类样本的冷却液流量、冷却液温度和冷却液入口压力都能保持相对稳定的数值。而故障样本的三类数据值都表现出了较大的样本间波动,故障样本的冷却液流量和冷却液温度的平均值相较于正常态样本均有所下降,相比之下温度的减少并不显著,但也存在部分故障样本的冷却液流量出现大幅升高的现象。故障样本的冷却液入口压力相较于正常样本有较为明显的降低,甚至有数个故障样本的冷却液入口压力降至 0Mpa。


图 2-8(c)则展示了正常态样本与去离子乙二醇入口低压 1 级故障样本的电堆冷却液出入口温度数据的情况。从图中数据可以发现,当发生去离子乙二醇入口低压 1 级故障时,电堆冷却液出入口温度普遍下降,但也存在部分故障样本的电堆冷却液出口温度异常升高的情况。

图 2-9 则将正常态与去离子乙二醇入口高温 1 级故障的部分样本进行部分监测量数据对比。其中图 2-9(a)展示了部分正常态样本和去离子乙二醇入口高温 1 级故障样本的电堆总电流和电堆电压数据对比,其中,虚线左侧表示正常态样本,虚线右侧表示去离子乙二醇入口高温 1 级故障样本。从图中可以发现,当发生去离子乙二醇入口高温 1


级故障时，电堆总电流普遍下降至最低工作电流附近；而电堆电压则表现出了较大的样本间波动，例如有的故障样本的电堆电压下降至较低的值，有的故障样本的电堆电压表现为在正常样本电压值附近。



(a) 正常态与故障态样本的电堆总电流和电堆电压



(b) 正常态与故障态样本的冷却液流量、温度和入口压力




(c) 正常态与故障态样本的电堆冷却液出入口温度


图 2-8 正常态与去离子乙二醇入口低压 1 级故障样本的部分监测量数据对比

图 2-9(b)展示了正常态样本与去离子乙二醇入口高温 1 级故障样本的冷却液流量、温度, 以及冷却液入口压力的数据, 可以发现, 当发生去离子乙二醇入口高温 1 级故障时, 冷却液温度相较于正常样本并无太大变化。而对于冷却液流量和冷却液温度, 多数故障样本表现出较低, 甚至低至 0 的数值水平; 而部分故障样本表现为和正常状态时相近的数值水平。


图 2-9(c)则展示了正常态样本与去离子乙二醇入口高温 1 级故障样本的电堆冷却液出入口温度、模块入口冷却液温度的数据图。从曲线图中可以得到, 当出现去离子乙二醇入口高温 1 级故障时, 故障样本的电堆冷却液出口温度与正常态样本的电堆冷却液出口温度在数值范围上并无明显的差异。相反可以发现, 图中所有故障样本的模块入口冷却液温度以及电堆冷却液入口温度的最低值, 皆分别高于所有正常态样本的模块入口冷却液温度以及电堆冷却液入口温度的最高值。



(a) 正常态与故障态样本的电堆总电流和电堆电压



(b) 正常态与故障态样本的冷却液流量、温度和入口压力



(c) 正常态与故障态样本的模块入口冷却液温度以及电堆冷却液出入口温度

图 2-9 正常态与去离子乙二醇入口高温 1 级故障样本的部分监测量数据对比

以上描述分别分析了两种故障样本的部分监测数据与正常态样本所对应数据的区别与联系。可以发现,当有轨电车用燃料电池系统发生某一故障时,不同的监测数据可能表现出不同的变化规律或是平均变化幅度;而当发生不同故障时,同一个监测数据可能会表现出相同的变化趋势,也可能具有完全不同的变化规律;此外,即便是发生同一故障,不同的故障样本之间也可能具有较大的差异性与波动性。由此可见,原始的监测数据中蕴含了大量有关燃料电池系统运行状态的信息,这些监测数据虽然丰富,但也具有相当的耦合性、复杂性,以及一定的偶然性。因此,借助合适的数据驱动方法,提取并学习到数据中隐含的特征信息,以达到准确的有轨电车用燃料电池系统故障诊断的目的,这有利于机车的健康运行及进一步的商业化应用。

## 2.4 本章小结

本章首先简要介绍了本文研究的燃料电池/超级电容混合动力有轨电车的外观、主要参数,随后对有轨电车的动力系统构成进行了功能描述,并分别介绍了动力系统内的燃料电池系统、动力电池系统和超级电容系统的配置参数。进一步地,对 HD6 型燃料电池电堆的外观、参数,以及燃料电池系统的结构与各子系统工作原理进行了说明。接着详细分析了机车燃料电池数据采集系统采集到的各类监测数据,采集到的监测量包括各类非电气量和电气量。随后,机车实际运行一段时间内的部分监测量变化情况被用来分析,总结了不同的监测物理量之间存在的相互关联性和耦合性。最后,详细介绍了燃料电池系统的故障等级划分,以及在机车实际运行中燃料电池系统出现的各种故障类型,并说明了不同故障的可能产生原因和故障排查手段。此外,通过不同故障样本与正常态样本的部分监测量对比,进一步说明故障样本数据之间的复杂性、耦合性和偶然性等特点。

## 第3章 数据层信息融合的深度学习故障诊断方法

### 3.1 复杂故障样本数据

正如 2.3.3 中所描述的,在有轨电车用燃料电池系统实际工作过程中,可能会产生与不同子系统相关、故障等级不同的多种故障类型,因此为了满足实际故障诊断需求,本章构造了复杂故障样本数据集,用以进行故障诊断研究,将构造的复杂故障样本数据集的样本类型及编号描述如表 3-1 所示。其中 F1 和 F2 为与冷却子系统相关的故障, F3 和 F4 为与气体供应及循环子系统相关的故障。从物理量相关情况可以看到, F1、F3、F4 为与压力值相关的故障, F2 为与温度相关的故障。此外在以往的机车燃料电池系统故障诊断研究中,通常只考虑了 1 级故障<sup>[56]</sup>,不满足机车实际需求,因此在本章构建的复杂故障样本数据集中, F1 和 F2 为 1 级故障类型, F3 和 F4 为 2 级故障类型。综上所述,本章构建的复杂故障样本数据集中的故障类型具有符合实际情况的复杂度与关联度,对该数据集进行故障诊断研究具有实际意义。

表 3-1 样本类型及编号

编号	N	F1	F2	F3	F4
类型	正常态	去离子乙二醇入口低压 1 级故障	去离子乙二醇入口高温 1 级故障	氢气出入口压差低 2 级故障	氢气供应压力低 2 级故障

#### 3.1.1 t-SNE 数据可视化及输入数据处理

为了对构建的复杂故障样本数据集有一个可视化的理解,本小节采用 t 分布随机近邻嵌入(t-Distributed Stochastic Neighbor Embedding, t-SNE)算法对数据集进行降维可视化处理。t-SNE 是 Laurens Van der Maaten 和 Geoffrey Hinton 在 2008 年提出的一种非线性降维算法,适用于将高维数据降为二维或三维数据以达到可视化的目的,且该算法在可视化方面具备了优于其他降维算法的表现。将 t-SNE 算法原理进行简单介绍,计算公式描述如下<sup>[77]</sup>。

对于给定的高维数据集  $\{x_1, x_2, x_3, \dots\}$ , 有降维并保持原数据点之间相对关系的对应低维数据集  $Y = \{y_1, y_2, y_3, \dots\}$ , 对于高维数据集中的  $x_i$  和  $x_j$  有<sup>[77]</sup>:

$$p_{ji} = \exp(-\|x_i - x_j\|^2 / 2\sigma_i^2) / \sum_{k \neq i} \exp(-\|x_i - x_k\|^2 / 2\sigma_i^2) \quad (3-1)$$

式(3-1)中  $p_{ji}$  表示  $x_j$  是  $x_i$  近邻的概率,  $\sigma_i$  表示与  $x_i$  最近邻的 N 个点的方差值, N 表

示困惑度，困惑度用公式表示如下<sup>[77]</sup>：

$$\text{perp}(p_i) = 2^{-\sum_j p_{ij} \log_2 p_{ji}} \quad (3-2)$$

式(3-2)中  $\text{perp}(p_i)$  表示  $x_i$  的困惑度。对于低维数据集中的  $y_i$  和  $y_j$ ，有<sup>[77]</sup>：

$$q_{ji} = \exp(-\|y_i - y_j\|^2) / \sum_{k \neq i} \exp(-\|y_i - y_k\|^2) \quad (3-3)$$

式(3-3)中  $q_{ji}$  表示  $y_j$  是  $y_i$  近邻的概率。根据  $p_{ji}$  和  $q_{ji}$  可以定义损失函数，通过减小损失函数来迭代更新低维数据  $y_1, y_2, y_3, \dots$ ，利用衡量两个分布相似性的 KL 散度来定义损失函数，如下<sup>[77]</sup>：

$$C = \sum_i \sum_j p_{ji} \log(p_{ji} / q_{ji}) \quad (3-4)$$

式(3-4)中  $C$  表示 KL 散度值。为了解决拥挤问题，将高维数据集的近邻概率和低维数据集的近邻概率进行修改如下<sup>[77]</sup>：

$$p_{ij} = (p_{ij} + p_{ji}) / 2n \quad (3-5)$$

$$q_{ij} = (1 + \|y_i - y_j\|^2)^{-1} / \sum_{k \neq i} (1 + \|y_i - y_k\|^2)^{-1} \quad (3-6)$$

式(3-5)中  $p_{ij}$  表示改写后的高维空间中的概率分布， $n$  表示数据集中的样本数。式(3-6)中  $q_{ij}$  表示改写后的低维空间中的概率分布。进一步地，为了更新低维数据，将令损失函数对每个低维空间元素求梯度，在算法迭代过程中，梯度计算公式和低维数据更新公式分别下<sup>[77]</sup>：

$$\partial C / \partial y_i = 4 \sum_j (p_{ij} - q_{ij})(y_i - y_j)(1 + \|y_i - y_j\|^2)^{-1} \quad (3-7)$$

$$Y^{(t)} = Y^{(t-1)} + \eta(\partial C / \partial y_i) + \alpha(t)(Y^{(t-1)} - Y^{(t-2)}) \quad (3-8)$$

式(3-7)中， $\partial C / \partial y_i$  表示损失函数  $C$  对  $y_i$  求梯度，式(3-8)中， $Y^{(t)}$ 、 $Y^{(t-1)}$ 、 $Y^{(t-2)}$  分别表示第  $t$  次、第  $t-1$  次、第  $t-2$  次迭代时的低维数据集，可优化参数  $\eta$  和  $\alpha(t)$  分别表示学习率和动量。

在构建的数据集中，每一例样本包含 28 维参数（见表 2-4），将数据集的总共 1714 例样本引入 t-SNE 算法中降至二维空间，迭代 1500 次后的可视化结果如图 3-1 所示。从可视化结果中可以看出，表示不同状态类的样本点之间并不存在显著的空间差异，代表不同状态的样本点在相当一部分区域都形成了重叠，因此，t-SNE 可视化结果可以在一定程度上说明本章构建的复杂故障样本数据集中的样本具有高度相似的数据特征分布，也进一步说明本章研究的复杂故障样本诊断任务存在一定难度。

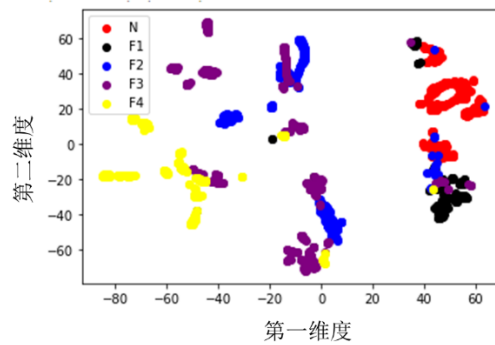


图 3-1 t-SNE 降维可视化结果

在训练故障诊断模型时，通常需要将数据集中的样本进行划分，本研究中将原始数据集以 6: 2: 2 的比例划分为三个子数据集，分别是训练集、验证集和测试集，训练集中的样本被用于迭代更新模型的内部参数。验证集中的样本用于在每一次迭代后验证一次模型性能，观察在模型训练过程中是否发生了过拟合或欠拟合问题。当迭代结束后，模型内参数训练完毕，此时用测试集样本对最终的模型进行测试，并以此评估本次训练模型的性能表现。此外，为了保证不同子数据集之间表示不同状态类样本比例的一致性，表示 N、F1、F2、F3、F4 的样本数量各自在训练集、验证集和测试集中均满足 6: 2: 2 的比例，各子数据集的样本分配如表 3-2 所示。

表 3-2 各子数据集中的样本分布

样本类型	N	F1	F2	F3	F4
训练集样本数	240	116	218	264	190
验证集样本数	80	39	73	88	63
测试集样本数	80	39	73	88	63
样本总数	400	194	364	440	316

如表 2-4 中所描述的，有关燃料电池系统的监测数据共有 28 个监测参数，分别表示了不同的物理量，不同参数的样本数据具有不同的量纲和数值区间，直接融合这些数据来实现故障诊断可能会影响算法的收敛速度和性能表现，因此需要对输入数据进行去量纲化处理。机器学习中常用的去量纲化数据预处理方法有三种，分别是归一化、z-score 标准化和 L2 正则化，计算过程如下所述<sup>[78]</sup>。

归一化是将同一参数的数据映射到一个指定区间内，通常是利用最小-最大缩放法将数据缩放至[0, 1]之间，将原始数据缩放至[0, 1]区间范围内的归一化计算公式可以表示如下<sup>[78]</sup>：

$$x_{norm}^{(i)} = \frac{x^{(i)} - x_{\min}}{x_{\max} - x_{\min}} \quad (3-9)$$

式(3-9)中  $x_{norm}^{(i)}$  表示该参数的第  $i$  个样本经过归一化处理后的值； $x^{(i)}$  表示该参数的

第 $i$ 个样本的原始值； $x_{\max}$ 和 $x_{\min}$ 分别表示该参数在所有样本中的最大和最小值。

z-score 标准化是将同一参数的数据映射到均值为 0，标准差为 1 的正态分布中，z-score 标准化公式表示如下<sup>[78]</sup>：

$$x_{std}^{(i)} = \frac{x^{(i)} - \mu_x}{\sigma_x} \quad (3-10)$$

式(3-10)中 $x_{std}^{(i)}$ 表示该参数的第 $i$ 个样本经过 z-score 标准化处理后的值； $x^{(i)}$ 表示该参数的第 $i$ 个样本的原始值； $\mu_x$ 和 $\sigma_x$ 分别表示该参数在所有样本中的均值和标准差。

L2 正则化可以将同一参数的样本向量变化为单位范数向量，L2 正则化可以用如下公式表示<sup>[78]</sup>：

$$x_{reg}^{(i)} = \frac{x^{(i)}}{\sqrt{\sum x^2}} \quad (3-11)$$

式(3-11)中 $x_{reg}^{(i)}$ 表示该参数的第 $i$ 个样本经过 L2 正则化处理后的值。 $x^{(i)}$ 表示该参数的第 $i$ 个样本的原始值。 $\sqrt{\sum x^2}$ 表示该参数样本的 L2 范数。

将式(3-9)~(3-11)分别定义为数据预处理策略 1~3，不同的数据预处理策略可能会对算法的预测性能有不同的影响，在 3.3 基于 GRU 的故障诊断中将对这三种数据预处理策略进行对比分析。

## 3.2 GRU 方法

如第 2 章所述，在有轨电车运行中能采集到有关燃料电池系统丰富的多源信息，这些数据特点与故障之间并非简单的对应关系，因此，充分利用、融合这些多源、多传感器信息有助于数据驱动型故障诊断方法的提出和应用。数据层信息融合要求尽可能地利用原始多源数据，在对原始数据进行简单处理后，直接应用到后续故障诊断方法当中。本文面对的是来自于有轨电车用燃料电池系统的高维多源信息，由于传统的神经网络方法存在处理高维数据时能力不足的问题<sup>[66]</sup>，因此，本研究在信息融合的策略上设计深度学习方法以更好地从多源数据中提取特征信息并诊断多类故障。

RNN 是深度学习中的一个重要类型，由于其对序列数据非线性特征的学习能力强而被广泛用于语音识别、机器翻译、情感分类、语言建模等领域。近年来，越来越多的 RNN 被应用于故障诊断的研究中，并显示出了算法的优势。作为 RNN 的变种，长短时记忆神经网络(Long short-term memory, LSTM)具有其特有的门控单元结构，由于能缓解梯度消失，在一定程度上能解决简单 RNN 网络的长期依赖问题，使得 LSTM 的应用十分广泛。门控循环单元神经网络(Gate Recurrent Unit, GRU)是 LSTM 的变种，于



2014年由Kyunghyun Cho等人首次提出,相较于LSTM,GRU不仅能解决普通RNN的长期依赖问题,而且由于比LSTM少了一个门控单位,其在网络计算的时间成本上具有更好的优势<sup>[79]</sup>。在现有的文献中,GRU已在故障诊断领域有所实现,例如将其应用在电网、滚动轴承、变流器、执行器等电气系统或设备的故障诊断中,而在燃料电池系统中的应用却还很少。因此,本章设计了融合数据层信息的基于GRU的故障诊断方法,应用于本章复杂故障样本数据集的故障诊断问题。

GRU在输入输出的结构上和普通循环神经网络RNN是一样的,一个GRU的基本输入输出单元的结构如图3-2所示。将该GRU循环单元展开成链式结构,用一系列串接的GRU节点表示以方便理解,如图3-3。其中 $x^t$ 表示当前的输入, $h^{t-1}$ 表示上一个GRU节点计算的输出隐状态,该隐状态包含了与之前节点与输入有关的信息。通过 $x^t$ 和 $h^{t-1}$ 的输入,GRU节点会计算得到当前的节点输出 $y^t$ 和传递至下一GRU节点的隐状态 $h^t$ 。另外值得说明的是,其中 $y^t$ 与 $h^t$ 是等值的,之所以用不同字母表示,是因为 $h^t$ 只作为本层隐状态的更新,而当GRU进行多层堆叠时, $y^t$ 可视为下一层GRU的输入 $x^t$ 。




图 3-2 GRU 基本输入输出单元




图 3-3 GRU 单元的链式展开示意图

每个GRU节点内的计算流程如图3-4所示。一个GRU节点内包括了两个门控单元,分别为更新门和重置门,更新门决定了要保留多少从前一节点传来的信息,重置门决定了要遗忘多少从前一节点传来的信息。GRU节点的内部计算公式如下所示<sup>[79]</sup>:

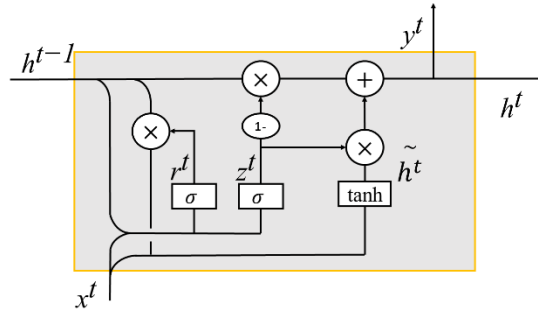


图 3-4 GRU 节点内计算流程

$$r^t = \sigma(\mathbf{W}_r \cdot [h^{t-1}, x^t] + b_r) \quad (3-12)$$

$$z^t = \sigma(\mathbf{W}_z \cdot [h^{t-1}, x^t] + b_z) \quad (3-13)$$

式(3-12)中的  $r^t$  表示重置门控信号,  $\mathbf{W}_r$  表示重置门计算时的内部权值矩阵。式(3-13)中的  $z^t$  表示更新门控信号,  $\mathbf{W}_z$  表示更新门计算时的内部权值矩阵。式(3-12)和(3-13)中的  $\sigma$  表示 sigmoid 函数, 能将括号内的数据变换到 0~1 的范围内,  $b_r$  和  $b_z$  分别表示计算中的偏置量。

中间隐状态和节点最终输出的隐状态分别用  $\tilde{h}^t$  和  $h^t$  表示, 二者的前向计算公式分别下所示<sup>[79]</sup>:

$$\tilde{h}^t = \tanh(\mathbf{W}_h \cdot [r^t * h^{t-1}, x^t] + b_h) \quad (3-14)$$

$$h^t = (1 - z^t) \odot h^{t-1} + z^t \odot \tilde{h}^t \quad (3-15)$$

式(3-14)中的  $\tanh$  是一个激活函数, 能将数据缩放到 -1~1 的范围内;  $\mathbf{W}_h$  表示隐状态计算时的权值矩阵; 式(3-15)中的  $\odot$  表示哈达玛积, 也即同型矩阵对应元素相乘。

相比于 LSTM 的输入门、遗忘门和输出门, GRU 只通过两个门单元完成对之前节点信息的记忆与遗忘, 在一定程度解决梯度消失问题的同时, 还能减少模型训练时间。

### 3.3 基于 GRU 的燃料电池系统故障诊断

#### 3.3.1 GRU 故障诊断框架及参数

在本研究中, 采用了多层 GRU 堆叠的形式, 通过加深网络的深度, 充分利用深度学习特有的特征学习能力, 以期实现结果更优的故障诊断结果, 采用的 GRU 故障诊断框架如图 3-5 所示。其中 GRU 层数是可调参数, 最后一层 GRU 将通过一个全连接层形成一个五分类器, 全连接层五分类器包含五个简单神经元, 输入数据经过模型会在

每个简单神经元处输出一个数值，最后通过  $\text{argmax}$  函数得到模型对输入数据的分类结果， $\text{argmax}$  函数的计算公式如下<sup>[80]</sup>：




图 3-5 GRU 故障诊断框架

$$\text{argmax } f(x) = \{x | \forall y: f(y) \leq f(x)\} \quad (3-16)$$

式(3-16)中  $x$  或  $y$  表示神经元序号； $f(x)$ 和  $f(y)$ 分别表示第  $x$  和第  $y$  个神经元的输出值。在诊断中，令  $x=0,1,2,3,4$ ，分别指代模型输出的对输入样本数据的预测分类结果为 N、F1~F4 状态类。

在该故障诊断框架中，有许多参数可以自行配置，例如采用 GRU 的层数，每层 GRU 内部的隐状态维度， $\text{batch\_size}$  数、 $\text{epochs}$  数、优化器类型、学习率参数等。其中，GRU 层数越深、每层 GRU 内部的隐状态维度越高，则此深度学习网络的复杂性会提高，与之俱来的是可能的特征学习能力的增强（复杂度过高的网络有发生过拟合的风险）和网络计算成本的增加。 $\text{batch\_size}$  是在算法进行反向梯度计算时的一个参数，过小的  $\text{batch\_size}$  会导致算法收敛速度变慢，而随着  $\text{batch\_size}$  的增大，算法收敛速度会变快但也增加了算法难以收敛的风险。 $\text{epochs}$  数表示模型的迭代次数。而优化器类型、学习率参数和损失函数的选择也在一定程度上对算法的收敛产生了影响。在深度学习中，通常对上述这些可调参数的具体设置并没有统一的标准，需要经过研究人员的多次调参来不断优化深度学习模型的性能表现，并且在面对不同故障诊断问题或是具有不同数据特点的样本时，不同的参数设置可能都会对算法的故障分类性能产生不同的影响。因此，下一小节将对 GRU 诊断框架的部分可调参数进行对比，分析不同参数设置对模型诊断性能的影响，并通过将 GRU 诊断模型与多分类支持向量机(Support Vector Machines, SVM)进行性能对比，体现出基于 GRU 的故障诊断框架在燃料电池系统故障诊断领域的可行性。

### 3.3.2 GRU 诊断性能的影响因素分析

#### (1) 不同 GRU 层数对模型诊断性能的影响

在该故障诊断中，经过多次仿真发现，GRU 层数选择三层到四层是较为合适的，少于三层会导致模型的学习能力不足，而多于四层的 GRU 结构会导致模型计算时间过长且诊断结果并没无明显变化。同样地，隐状态维度也不应选的过大，避免加重算法的计算负担。定义一个 GRU 框架的配置参数如表 3-3 所示。

表 3-3 GRU 框架配置参数

参数	取值
GRU 层数	3
每层 GRU 的隐状态维度	56、56、56
batch_size	42
Epochs	2200
优化器类型	Adam
学习率参数	0.00001

此外,在故障多分类问题的模型训练阶段,通常选用交叉熵函数作为损失函数,模型通过减小损失函数来迭代更新模型内部的相关可学习参数,交叉熵函数的计算公式如下所示<sup>[80]</sup>:

$$y'_i = \text{softmax}(y_i) = \exp(y_i) / \sum_{j=1}^n \exp(y_j) \quad (3-17)$$

$$L = -\sum_{j=1}^n P_j \log(y'_j) \quad (3-18)$$

式(3-17)和(3-18)中,  $y_i$  表示模型中最后的全连接层中的第  $i$  个神经元输出,在本研究中  $i=0, 1, 2, 3, 4$ , 分别表示神经元序号;  $\text{softmax}$  函数可以将全连接层中五个神经元的输出  $y_i$  转换成概率值表示,即  $y'_i \in [0,1]$  且满足  $y'_0 + y'_1 + y'_2 + y'_3 + y'_4 = 1$ ;  $y'_0 \sim y'_4$  的物理意义分别是模型预测本次输入的样本属于第 N、F1、F2、F3、F4 的概率值;  $P_j$  则表示输入样本对应的真实的概率值。  $L$  表示交叉熵损失函数计算结果。

将 3.2.2 中的训练集和验证集导入配置参数如表 3-2 所示的 GRU 框架,用于模型的训练过程,迭代 2200 次后训练完毕,观察到此时模型对于训练集的损失函数已趋于稳定,将测试集数据导入训练完成后的模型中,根据测试集数据得到模型的预测结果。此外将上述的配置参数中的 GRU 层数改为四层,同时其他参数不变,利用相同的子数据集完成模型的训练和测试过程,并根据测试集数据同样得到模型的预测结果,三层和四层结构的 GRU 在测试集上的准确率表现如表 3-4 所示。

表 3-4 不同层数 GRU 准确率测试结果

类型	N	F1	F2	F3	F4	总体
准确率 (三层)	100%	92.31%	95.89%	95.45%	100%	97.08%
准确率 (四层)	100%	92.31%	97.26%	94.32%	96.83%	96.50%

从准确率结果上来看,三层 GRU 相比于四层 GRU,在相同的测试集上对于 F3、F4 状态类样本的预测准确度更高,对于 N、F1 状态类样本的预测准确率相同,对于 F2 状态类样本的预测准确率要低。从样本总体准确率结果来看,三层 GRU 结构的模型总体预测准确率为 97.08%,要高于四层 GRU 结构的模型总体预测准确率 96.50%。因此,

在本任务中考虑设置 GRU 层数为三层是更合适的。

### (2) 不同优化器类型对模型诊断性能的影响

在深度学习网络的训练过程中，将通过不同的优化器来实现网络内部可训练参数的反向更新，常见的优化器有 SGD 优化器、Adam 优化器、Adamax 优化器等，其中 Adam 优化器应用最为广泛，Adamax 是 Adam 优化器的变种。现在将 GRU 诊断框架的参数按表 3-2 设置，分别对比不同优化器执行模型参数更新时，训练后模型对于测试集样本的预测表现，结果如表 3-5 所示。

从表中数据可以看出，利用三种优化器对模型参数进行更新，训练后的模型均能对 N 类样本实现准确检测。但是当优化器类型选择为 SGD 时，模型对 F1、F2、F4 类样本皆失去分类能力，训练后模型对这三类样本的预测准确率都为 0%，可见针对本章的故障诊断任务，无法使用 SGD 优化器。而使用 Adamax 优化器时，模型对 F1~F4 类样本的预测准确率皆低于使用 Adam 优化器时模型的预测准确率。使用 Adam 优化器时的模型总体预测准确率为 97.08%，也都分别优于使用 SGD 时的总体预测准确率 48.69%和使用 Adamax 时的总体预测准确率 84.26%，因此，考虑在本任务中选择 Adam 优化器是更合适的。

表 3-5 不同优化器下的准确率测试结果

类型	N	F1	F2	F3	F4	总体
准确率 (Adam)	100%	92.31%	95.89%	95.45%	100%	97.08%
准确率 (SGD)	100%	0%	0%	98.86%	0%	48.69%
准确率 (Adamax)	100%	89.74%	94.52%	61.36%	80.95%	84.26%

### (3) 不同数据预处理策略对模型诊断性能的影响

随后将对不同的数据预处理策略进行对比，上述诊断结果都是在数据预处理策略 2 下实现的，现将 GRU 诊断框架的参数按照表 3-2 设置，分别测试在不同数据预处理策略下模型对测试集样本的预测准确率，结果如表 3-6 所示。

表 3-6 不同预处理策略下的准确率测试结果

类型	N	F1	F2	F3	F4	总体
准确率 (策略 1)	100%	76.92%	97.26%	78.41%	88.89%	89.21%
准确率 (策略 2)	100%	92.31%	95.89%	95.45%	100%	97.08%
准确率 (策略 3)	97.50%	84.62%	53.42%	84.09%	80.95%	80.17%

从表中准确率数据可以看出，当数据预处理策略选择策略 2（z-score 标准化）时，

总体准确率表现最好, 因此在本故障诊断任务中, 选择 z-score 标准化预处理策略是更合理的, 将此时的准确率表现作为模型的最终性能表现。

#### (4) 不同输入参数维度对模型诊断性能的影响

此外, 之前诊断中的输入数据包含了所有原始 28 维监测参数, 为了进一步说明多源数据融合的必要性的, 现通过仅改变输入数据维度进行了对比。如 3.1 所述, 本章的复杂故障样本数据集中的故障类 F1~F4 与压力和温度直接相关, 因此构造了只包含压力和温度的 14 维监测数据作为输入, 以及只包含电气量 (电压、电流、电阻) 的 11 维监测数据作为输入来进行对比分析, 具体的输入数据维度及参数如表 3-7 所示。

表 3-7 不同输入维度选择的参数

参数名称	编号	28 维	14 维	11 维
DCDC 限制电流/A	$x_1$	✓		✓
模块入口氢气压力/MPa	$x_2$	✓	✓	
模块入口冷却液温度/°C	$x_3$	✓	✓	
电堆总电流/A	$x_4$	✓		✓
电堆电压/V	$x_5$	✓		✓
辅机电流/A	$x_6$	✓		✓
测试请求流量/(L·S <sup>-1</sup> )	$x_7$	✓		
冷却液流量/(L·S <sup>-1</sup> )	$x_8$	✓		
氢气压力/MPa	$x_9$	✓	✓	
环境温度/°C	$x_{10}$	✓	✓	
冷却液温度/°C	$x_{11}$	✓	✓	
冷凝剂温度/°C	$x_{12}$	✓	✓	
DCDC 输出电压/V	$x_{13}$	✓		✓
DCDC 输入电流/A	$x_{14}$	✓		✓
绝缘阻值/ $\Omega$	$x_{15}$	✓		✓
请求电流/A	$x_{16}$	✓		✓
电堆电流设定值/V	$x_{17}$	✓		✓
电堆出口氢气压力/Mpa	$x_{18}$	✓	✓	
电堆入口氢气压力/Mpa	$x_{19}$	✓	✓	
冷却液入口压力/Mpa	$x_{20}$	✓	✓	
空气入口压力/Mpa	$x_{21}$	✓	✓	
电堆冷却液出口温度/°C	$x_{22}$	✓	✓	
电堆冷却液入口温度/°C	$x_{23}$	✓	✓	
空压机入口空气温度/°C	$x_{24}$	✓	✓	
空气出口温度/°C	$x_{25}$	✓	✓	
空压机电压/V	$x_{26}$	✓		✓
空压机电流/A	$x_{27}$	✓		✓
冷却液请求流量/(L·S <sup>-1</sup> )	$x_{28}$	✓		

对比诊断结果如图 3-6 所示, 从图中可以看出, 当输入数据的维度分别为与压力、温度相关 14 维和与电气量相关的 11 维, 模型在测试集上的总体预测准确率均低于以

28 维的监测量作为输入时的模型总体预测准确率。由此可见,融合越丰富的数据层信息,对本章设计的基于 GRU 的燃料电池系统故障诊断方法具有更好的测试精度表现。




图 3-6 GRU 在不同输入数据维度下的准确率对比

#### (5) 不同模型的诊断性能对比

随后,对多分类支持向量机 SVM 进行训练,并用相同的测试集数据对训练好的 SVM 进行测试,将其与 GRU 模型进行性能对比,对比结果如图 3-7 所示。

结果显示,针对于测试集中的 N 类样本,GRU 与 SVM 的分类准确率是一样的,均能准确预测,然而针对于测试集中的 F1、F2、F3 和 F4 类样本,GRU 的分类准确率都高于对应的 SVM 的分类准确率,GRU 对这五类状态样本的总体预测准确率为 97.08%,高于 SVM 的 74.34%,且 SVM 对 F2 类样本的分类精度显著低于 GRU 对 F2 类样本的分类精度。通过比较可以说明,对于本章研究的有轨电车用燃料电池系统的复杂故障样本数据集的诊断任务,基于 GRU 的故障诊断方法相较于多分类支持向量机 SVM 具有更好的适用性。




图 3-7 GRU 与 SVM 的准确率对比

### 3.4 本章小结

本章对复杂故障样本数据集开展了故障诊断研究,设计了数据层信息融合的基于GRU的有轨电车用燃料电池系统故障诊断框架,该复杂故障数据集中包含了历史数据中采集到的机车燃料电池系统出现的正常态、去离子乙二醇入口低压1级故障、去离子乙二醇入口高温1级故障、氢气出入口压差低2级故障、氢气供应压力低2级故障等五类样本数据。首先介绍了一种数据降维算法t-SNE用于可视化分析,可视化结果在一定程度上说明了本次故障诊断存在一定的难度。本章还对常用的几种数据预处理策略进行了描述,并在诊断结果中验证了在本故障诊断任务中使用z-score标准化对输入数据进行预处理具有更好的适用性。然后对GRU的结构、原理进行了介绍。最后,针对于GRU模型中部分可调参数开展了对比研究,选择了模型合适的包括GRU层数、优化器类型等参数。此外还用不同的输入数据维度对设计的模型进行测试,结果证实将越丰富的数据层信息进行融合,模型的故障诊断性能越佳。最后将该方法与多分类支持向量机SVM在同一测试集上进行对比分析,结果显示本章采用的方法相较于SVM在测试集上具有更好的预测准确率表现。



## 第4章 特征层信息融合的深度学习故障诊断方法

### 4.1 不均衡故障样本数据

在第三章中考虑了复杂故障样本数据集，且从表 3-2 的不同类型样本总数可以看出，各类样本的数量分布相对均衡，但由于机车实际运行时，燃料电池系统故障的发生存在偶然性，因此实际历史数据中存在故障样本数量不均衡的现象。当使用不均衡样本数据集用以训练模型时，模型倾向于学习大样本数据的特征，而对小样本数据特征的学习不足，进而影响模型的整体性能表现，因此对不均衡故障样本的故障诊断将更加考验诊断方法的泛化能力。本章的故障诊断任务将考虑此类不均衡故障样本数据集，所构建的数据集包含的样本类型及编号如表 4-1 所示，表中 N、F1~F4 的样本类型及样本数与第三章中相同，在此基础上引入了相较于这五类样本不均衡的大样本类 F5（电流设定偏差 1 级故障）与小样本类 F6（氢气泄漏 2 级故障）。

表 4-1 样本类型、编号及总数

编号	N	F1	F2	F3	F4	F5	F6
类型	正常态	去离子乙醇入口低压 1 级故障	去离子乙醇入口高温 1 级故障	氢气出口压差低 2 级故障	氢气供应压力低 2 级故障	电流设定点偏差 1 级故障	氢气泄漏 2 级故障
总数	400	194	364	440	316	1696	30

### 4.2 BPNN-InceptionNet 方法

在第二章中描述的基于 GRU 的燃料电池系统故障诊断方法是建立在数据层信息融合结构上的，通过数据预处理后，直接将所有的 28 维监测参数数据作为输入，通过一个单一的诊断网络 GRU 进行故障分类。数据层信息融合结构是最基础的一种融合结构，而在本章将提出一种复杂度稍高的，以特征层信息融合为结构的基于 BPNN-InceptionNet 的燃料电池系统故障诊断方法，其中 BPNN 网络用于提取抽象特征并融合成特征图，InceptionNet 网络用于特征图的分类。

卷积神经网络 CNN 是根据动物视觉为启发而提出的一种深度学习方法，在处理高维数据，尤其是图像数据时具有较强的特征学习能力，由于 CNN 的卷积核具有权值共享的特点，也使得 CNN 的参数数量得到了减少、算法的运算速度得到了提升。当前 CNN 已在计算机视觉、图像识别、目标检测、机械故障诊断等领域展示出了其强大的能力。在本章提出的基于 BPNN-InceptionNet 的燃料电池系统故障诊断方法中，设计了一个 InceptionNet 形式的卷积网络框架用于故障分类，其中 InceptionNet 是由谷歌团队研发的一系列卷积网络结构，随着多个版本的更新，分别对传统卷积网络的架构提出了许多创新性的设计。因此，本章将对所提出的基于 BPNN-InceptionNet 的诊断框架进行详

细介绍,并将其应用到有轨电车用燃料电池系统的不均衡样本的故障诊断问题当中,并分析其性能表现及可行性。

#### 4.2.1 BPNN-InceptionNet 框架

通常特征层信息融合要求先对输入原始数据提取特征,将提取出的数据特征用于后续的处理,从原始数据中提取的特征可以是时域特征、频域特征或是抽象特征等,考虑到所采集到的机车故障数据并非时间上完全连续的样本,对它们进行时频域分析是存在困难的,因此选择提取抽象特征是更合适本研究的。另外,为了避免丢失关键的隐含信息,本文采用了全连接的反向传播神经网络(Back Propagation Neural Network, BPNN)来对原始数据进行升维提取特征,与主成分分析(Principal Component Analysis, PCA)等降维提取特征的算法相比,这种方式能够很好地保留原始输入数据的特征。

因此,对本文所提出的基于 BPNN-InceptionNet 的故障诊断框架的基本流程描述如下。首先利用一个全连接反向传播神经网络 BPNN 对输入数据进行升维处理,提取出一个高维的抽象特征。然后利用特征重构,进而将向量形式的高维抽象特征重构为张量形式的特征图,该重构后的特征图将在一个更紧凑的尺度空间包含所有特征信息,至此完成了特征层信息融合的步骤。由于前一阶段新生成特征图的数据形式和真实图像的数据形式一致,因此可以应用卷积网络对特征图进行特征学习和分类,在本研究中采用的卷积网络是根据 InceptionNet 设计的一个卷积网络框架,在后续的对比分析中显示出了较其他卷积网络更好的故障分类表现。基于 BPNN-InceptionNet 的故障诊断框架原理图如图 4-1 所示,本小节将对该故障诊断框架进行详细描述。

图 4-1 中在特征层信息融合部分使用了一个三层 BPNN 结构,分别为一个输入层、一个隐藏层和一个输出层,每层由一定数量的神经元构成。为了在提取高维抽象特征时不丢失原始的输入信息,将 BPNN 设置为全连接形式,也即同一层的神经元互不相连,相邻层的神经元相互连接,这样的连接保证了除输入层外,每一层的每个神经元的输出值都是根据前一层的所有神经元计算出来的,这样就能逐层进行信息传输,从而提取出抽象特征。BPNN 中输出层神经元的个数是抽象特征向量的维数,输出层每个神经元的输出值就是抽象特征向量中的一个值。特征重构操作可以将抽象特征进行重排列,形成一个特征图,相比于向量形式能以更紧凑的排列方式包含所有特征值,有利于之后用卷积网络进行特征学习及故障分类。

图 4-1 中的 BPNN 为单隐层结构,其中隐藏层神经元的输出值和输出层神经元的输出值计算公式分别如下<sup>[80]</sup>:

$$h^{(j)} = \text{relu}(\sum_{i=0}^{M-1} w_{ij}x_i + b_j) \quad (4-1)$$

$$y^{(k)} = \sum_{j=0}^{N-1} w_{jk}h^{(j)} + b_k \quad (4-2)$$

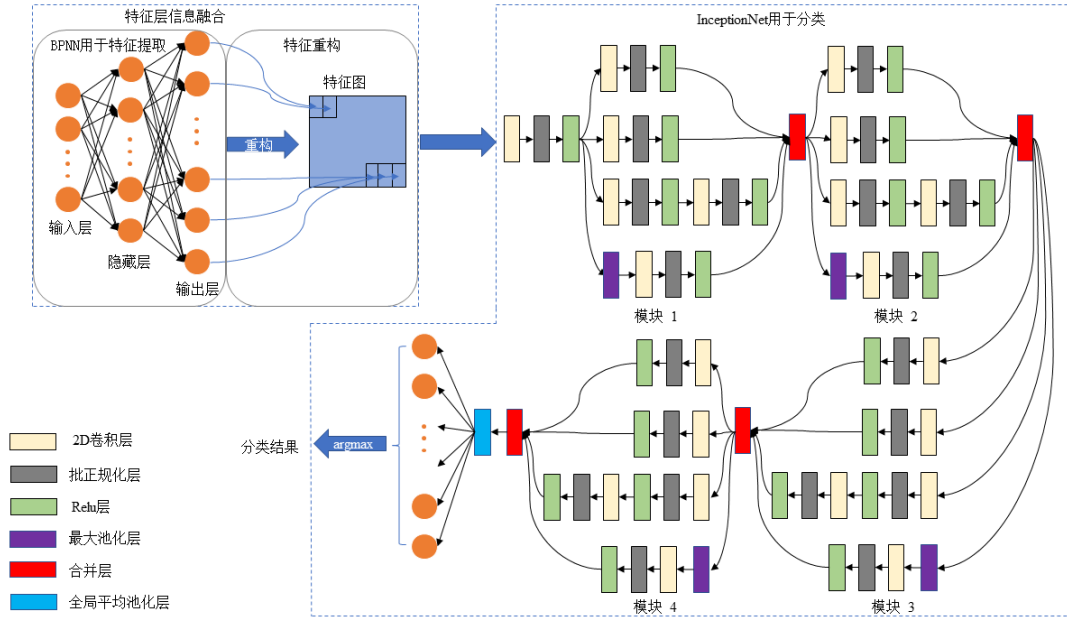


图 4-1 BPNN-InceptionNet 诊断框架原理图

式(4-1)和(4-2)中  $h^{(j)}$  表示隐藏层中第  $j$  个神经元的输出值;  $relu$  表示一个激活函数, 能将大于等于零的值保持, 而将小于零的值置为零;  $w_{ij}$  表示输入层的第  $i$  个神经元与隐藏层的第  $j$  个神经元之间的权值系数;  $x_i$  表示输入层的第  $i$  个神经元的值;  $b_{ij}$  表示隐藏层的第  $j$  个神经元对应的偏置项;  $M$  表示输入层神经元个数。

式(4-2)中  $y^{(k)}$  表示输出层中第  $k$  个神经元的输出值;  $w_{jk}$  表示隐藏层第  $j$  个神经元和输出层中第  $k$  个神经元之间的权值系数;  $h^{(j)}$  表示隐藏层第  $j$  个神经元的值;  $b_k$  表示输出层中第  $k$  个神经元对应的偏置项;  $N$  表示隐藏层神经元个数。权值系数和偏置项在模型训练过程是可以学习更新的参数。

BPNN-InceptionNet 框架的后半部分采用了一个基于 InceptionNet 的卷积网络进行故障分类。InceptionNet 的原始版本是 GoogleNet, 在 2014 年的 ImageNet 大规模视觉识别挑战赛(ILSVRC14)上具有良好的表现<sup>[81]</sup>。GoogLeNet 的目的是为了提高深度神经网络的识别精度和减少参数计算量, 这也是本研究以其为基础设计 CNN 用于故障诊断的原因。随后将对本研究中提出的基于 InceptionNet 的卷积网络进行详细介绍。

#### 4.2.2 基于 InceptionNet 的卷积网络

与以往的深度卷积网络只是通过不断串联叠加卷积层和池化层来加深网络深度不同, GoogleNet 提出了一种并行卷积结构, 从多个尺度中提取图像信息, 从而获得更好的特征处理能力。这个并行卷积模块被称为 Inception 模块, GoogLeNet 也被称作 InceptionNet-v1。随后, 为了解决不同的问题, InceptionNet-v2<sup>[82]</sup>, InceptionNet-v3<sup>[83]</sup> 和 InceptionNet-v4<sup>[84]</sup> 在 InceptionNet-v1 的基础上相继被提出。简单概括, v2 版本引入了批正规化(BN)层来处理内部协方差转移问题, v3 版本引入了将较大的卷积分解为较

小的或非对称的卷积, 以及“分支内分支”(branching within branches)以减少计算量的思想, 而 v4 版本则结合了残差连接(residual connection)的思想, 进一步深化了网络。本文提出的 CNN 就是基于上述的 Inception 模块、BN 层和  $3 \times 3$  小卷积核尺寸的思想。从图 4-1 可以看到, 提出的卷积网络包括 4 个模块, 每个模块包含了 2D 卷积层、批正规化层、Relu 层、最大池化层、合并层和全局平均池化层, 不同的层在图中用不同颜色的矩形块表示, 每一层解释说明如下<sup>[81-84]</sup>。

### (1) 2D 卷积层

时域中的卷积运算在解析数学中占有重要地位, 时域卷积计算公式如(4-3)所示; 如果卷积的变量是离散序列, 则公式(4-3)可以写成(4-4)<sup>[81-84]</sup>。

$$y(t) = x(t) * h(t) = \int_{-\infty}^{+\infty} x(\tau)h(t-\tau)d\tau \quad (4-3)$$

$$y(n) = x(n) * h(n) = \sum_{i=-\infty}^{+\infty} x(i)h(n-i) \quad (4-4)$$

式(4-3)和(4-4)中\*表示卷积运算符, 深度学习中的卷积层计算过程可以看作是基于离散序列卷积计算公式(4-4)的。

在 2D 卷积中又可以细分为单通道卷积和多通道卷积, 单通道卷积的原理通过一个示例来描述, 如图 4-2 所示。其中输入是一个  $5 \times 5$  的特征图, 卷积核(也叫滤波器)是一个  $3 \times 3$  的矩阵数组, 卷积操作是将卷积核上的元素与输入上的对应元素做乘积并相加, 得到输出矩阵对应位置的输出值, 表达式如式(4-5)<sup>[81-84]</sup>。在卷积操作过程中, 卷积核会以步长值在输入矩阵范围内进行滑动, 图中的卷积核以步长为 1 进行滑动(卷积核下的箭头表示滑动方向), 最后输出一个  $3 \times 3$  的特征图。

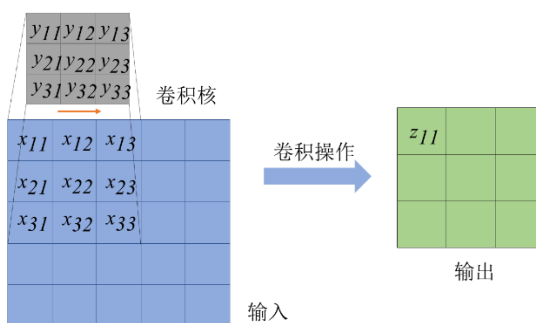


图 4-2 单通道 2D 卷积示例

$$z_{11} = \sum x_{ij}y_{ij} (i, j = 1, 2, 3) \quad (4-5)$$

多通道卷积的原理也通过一个示例来描述, 如图 4-3 所示。其中输入是一个三通道的特征图, 例如对于输入神经网络的彩色图片数据, 就是一个三通道(RGB)的像素矩阵数组, 在深度学习中可以将其表示成一个尺寸为  $(3, 5, 5)$  的张量, 其中 3 表示通道数, 两个 5 分别表示每个通道的矩阵数组的长和宽。卷积核的通道数将和输入张量的通道数匹配以进行卷积计算, 计算公式可用式(4-6)表示<sup>[81-84]</sup>。




图 4-3 三通道 2D 卷积示例

$$z_{11}^1 = \sum x_{ij}^k y_{ij}^k (i, j, k = 1, 2, 3) \quad (4-6)$$

式(4-6)中  $k$  表示通道序号, 因此可以得到, 一个三通道的  $5 \times 5$  特征图, 经过一个三通道的  $3 \times 3$  滤波器进行卷积操作后, 将会得到一个单通道的  $3 \times 3$  输出特征图。而当滤波器个数大于一个时, 每个滤波器将独立执行上述卷积过程, 最后将每个滤波器处理后输出的单通道  $3 \times 3$  特征图在通道的维度进行拼接, 形成一个尺寸为  $(n, 3, 3)$  的张量, 其中的  $n$  为滤波器个数, 也等于输出特征图的通道数。

## (2) 批正规化(Batch Normalization, BN)层

有研究者发现, 在深度神经网络的训练过程中, 层参数的变化会导致输出分布的变化, 随着网络深度的增加, 这种变化会持续向前传播, 最终使得整个网络的收敛速度较慢, 这种现象被认为是内部协变量位移(Internal covariate shift)。为了解决这一问题, 批正规化在 2015 年被提出, 该 BN 层能对每一个小批量输入特征进行输出的正规化处理, 计算过程如下所述<sup>[81-84]</sup>。

$$\mu_B = \sum_{i=1}^m x_i / m \quad (4-7)$$

$$\sigma_B^2 = \sum_{i=1}^m (x_i - \mu_B)^2 / m \quad (4-8)$$

$$\hat{x}_i = (x_i - \mu_B) / \sqrt{\sigma_B^2 + \varepsilon} \quad (4-9)$$

$$y_i = \gamma \hat{x}_i + \beta \quad (4-10)$$

式(4-7)中  $B = \{x_i | i = 1, \dots, m\}$  表示一个小批量的输入;  $\mu_B$  是整个小批量输入的均值;  $\sigma_B^2$  是整个小批量的方差。式(4-9)是将输入正规化为一个期望为 0, 方差为 1 的分布, 其中  $\varepsilon$  是一个为了数值稳定性的常数。式(4-10)进行平移和缩放处理, 并通过两个可学习重构参数  $\gamma$  和  $\beta$  的引入, 使得该层网络的输出  $y_i$  能与输入保持一致的特征分布, 以缓

解内部协变量位移现象。

### (3) Relu 层

卷积网络中的 Relu 层进行的操作实际上就是通过 relu 激活函数, 消除卷积结果中的负值, relu 函数的计算公式如(4-11) [81-84]。

$$f(x) = \begin{cases} 0, & x < 0 \\ x, & x \geq 0 \end{cases} \quad (4-11)$$

### (4) 最大池化(Maxpooling)层

池化层可以压缩从前一层输入的特征图, 拓宽感知域, 降低信息冗余, 还能减少网络的计算量。池化层的计算过程与 2D 卷积层类似, 通过一个池化核在输入特征图上滑动, 与卷积层执行卷积运算不同, 最大池化层会在池化核的感知域范围内对输入特征取最大值输出。

### (5) 合并层

合并层是用来实现输入数据拼接的功能的, 正如前文所描述的, InceptionNet 提出了一种并行卷积模型, 正如本章提出的 BPNN-InceptionNet 故障诊断框架原理图中的模块 1~4 (见图 4-1), 合并层可以在通道的维度将多个特征图进行拼接, 实现多尺度特征图的融合。例如在图 4-1 中, 任意模块中的合并层能将四个并行卷积过程输出的特征图进行拼接, 输出一个通道数等于四个并行输出特征图通道数之和的特征图。

### (6) 全局平均池化层(Global Average pooling, GAP)

全局平均池化一般用在卷积网络的末端用来提取特征, 相比于 Flatten 操作能减小网络过拟合的可能。Flatten 操作是将前一层得到的特征图在每一个通道完全展开, 最后拼接成一个特征向量, 也即输出的特征向量内的元素个数为输入特征图所有通道的所有元素个数之和。而全局平均池化层是将输入特征图的每一个通道的特征图的矩阵元素求平均后输出, 并作为输出的特征向量的元素之一, 也即输出的特征向量内的元素个数为输入特征图的通道数。由此可见, 全局平均池化层相比于 Flatten 操作能大大减少网络参数量[85]。

最后, 从图 4-1 中可以看出, 全局平均池化层之后是一个全连接层 (见 3.3.1) 用于做分类器, 全连接层中的神经元个数被设置为最终要识别的样本状态类个数, 然后通过 argmax 函数输出模型的分类结果。

## 4.3 基于 BPNN-InceptionNet 的燃料电池系统故障诊断

### 4.3.1 模型参数设置

同样地, 将本章研究的不均衡故障样本数据集按 6: 2: 2 的比例进行划分, 用来对模型进行训练和测试, 划分后各子数据集中的不同类样本的个数如表 4-2 所示。

在 BPNN-InceptionNet 故障诊断框架中, 有许多可调参数, 如在 BPNN 部分, BPNN

层数、隐藏层神经元个数、输出层神经元个数等都是可调的；在特征重构部分，假设重

表 4-2 各子数据集中的样本分布

样本类型	训练集样本数	验证集样本数	测试集样本数
N	240	80	80
F1	116	39	39
F2	218	73	73
F3	264	88	88
F4	190	63	63
F5	1018	339	339
F6	18	6	6

构特征图的尺寸为  $(n, x, y)$  是可调的，但需要满足 BPNN 的输出神经元个数与  $n$ 、 $x$ 、 $y$  的乘积相等，其中  $n$  表示重构特征图的通道数， $x$  和  $y$  分别表示特征图的长宽值；在 InceptionNet 部分，模块数（见图 4-1）、卷积网络中的核尺寸、卷积网络中的卷积核个数等也是可调的。说明该故障诊断框架具有很大的灵活性，可以根据不同的故障诊断任务进行调整，以实现更好的诊断表现。根据前期参数仿真，现将模型相关参数设置如表 4-3 所示。

表 4-3 模型参数设置

参数	取值
BPNN 层数	4
BPNN 各层神经元个数	28, 512, 1024, 3072
重构特征图尺寸	(3, 32, 32)
模块数	4
核尺寸	3×3
卷积层中卷积核数量	16
优化器类型	Adam

从表中数据可以看到，BPNN 部分将以全部 28 维监测参数作为输入，即也在数据层融合了所有原始物理量，随后 28 维原始参数被升维成 3072 维的抽象特征向量，随后被重构成尺寸为  $(3, 32, 32)$  的张量形式的特征图，最后特征图被输入到本章所提出的基于 InceptionNet 的卷积网络中用于故障分类。

### 4.3.2 诊断结果分析

将模型参数按表 4-2 设置后，对提出模型进行训练并测试，图 4-4 表示了训练过程中，模型于每次迭代时，在训练集（蓝色曲线）和验证集（红色曲线）上的准确率曲线。从图中可以看出，在迭代过程中，模型在训练集上和验证集上的准确率很快趋于稳定，并且验证集准确率接近于测试集准确率达到稳定，并没有出现下降现象，这说明在模型训练过程没有出现过拟合或欠拟合现象。

迭代结束后,用测试集数据对最终模型进行性能测试,测试结果用一个混淆矩阵表示,如图 4-5。其中横坐标表示模型预测的样本类别,纵坐标表示样本的真实类别,0 表示 N 样本,1~6 分别表示 F1~F6 样本。混淆矩阵的对角线上的数字分别表示正确预测的各类样本个数,非对角线上的数字表示未能准确预测的样本个数。




图 4-4 模型在训练过程中对训练集和验证集的准确率曲线

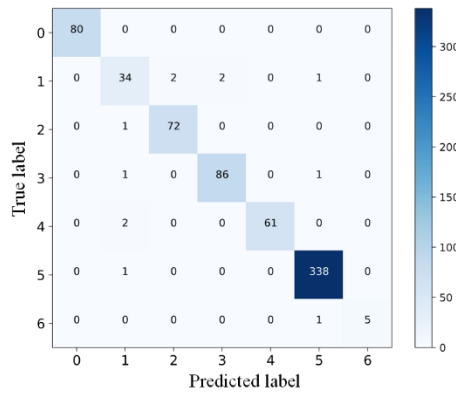


图 4-5 模型在测试集上的测试结果混淆矩阵

另外,由于本章中的数据集具有很强的不均衡性,此时无论用平均准确率还是总体准确率都难以说明算法的整体预测性能,因此本章使用机器学习中的 kappa 系数来对算法预测性能进行整体评价。Kappa 系数计算过程如式(4-12)~(4-14),其能为不均衡测试样本提供一个合适的综合性指标<sup>[86]</sup>。

$$p_0 = \sum_{i=1}^n x_{ii} / n^2 \quad (4-12)$$

$$p_c = \sum_{i=1}^n (\sum_{j=1}^n x_{ij} \times \sum_{j=1}^n x_{ji}) / n^4 \quad (4-13)$$

$$K = (p_0 - p_c) / (1 - p_c) \quad (4-14)$$

式(4-12)~(4-14)中  $x_{ij}$  是混淆矩阵中第  $i$  行第  $j$  列的元素值,  $n$  表示总共的标签类数,  $K$  表示 kappa 系数值。Kappa 系数值越接近 1, 模型的整体预测结果与实际结果的一致性更好。



对本次诊断结果进行 kappa 系数计算，kappa 系数的计算结果为 0.9752，是一个接近于 1 的数值，说明算法在不均衡测试集上的整体性能具有较好表现。在后续对比研究中，也将采用 kappa 系数为指标进行不同模型的测试性能对比。

表 4-4 VGG 结构及参数

层结构	参数
卷积层_1	卷积核数量：64，卷积核尺寸：3×3，激活函数：relu
卷积层_2	卷积核数量：64，卷积核尺寸：3×3，激活函数：relu
最大池化层_1	池化核尺寸：2×2
卷积层_3	卷积核数量：128，卷积核尺寸：3×3，激活函数：relu
卷积层_4	卷积核数量：128，卷积核尺寸：3×3，激活函数：relu
最大池化层_2	池化核尺寸：2×2
卷积层_5	卷积核数量：256，卷积核尺寸：3×3，激活函数：relu
卷积层_6	卷积核数量：256，卷积核尺寸：3×3，激活函数：relu
最大池化层_3	池化核尺寸：2×2
卷积层_7	卷积核数量：512，卷积核尺寸：3×3，激活函数：relu
卷积层_8	卷积核数量：512，卷积核尺寸：3×3，激活函数：relu
最大池化层_4	池化核尺寸：2×2
卷积层_9	卷积核数量：512，卷积核尺寸：3×3，激活函数：relu
卷积层_10	卷积核数量：512，卷积核尺寸：3×3，激活函数：relu
最大池化层_5	池化核尺寸：2×2
全连接层_1	神经元个数：256，激活函数：relu
全连接层_2	神经元个数：128，激活函数：relu
全连接层_3	神经元个数：7

在本小节，将有针对性的执行一些对比研究以验证本章提出的基于 BPNN-InceptionNet 的故障诊断框架的适用性。首先，为了验证本章中设计的卷积网络结构的优势，将 BPNN-InceptionNet 中的卷积网络替换成一种经典的顺序串联卷积结构 VGG，借此构造了 BPNN-VGG 诊断方法用来做对比方法之一，采用的 VGG 由输入到输出的层结构和层参数如表 4-4 所示<sup>[87]</sup>。随后，为了验证本章中提出的特征层融合结构的优势，将第 3 章中利用到的基于 GRU 的故障诊断方法和多分类支持向量机 SVM 也用做对比方法。

将不同模型训练完成后，在同一测试集上进行性能测试，用 kappa 系数表示的测试结果用表 4-5 表示。

表 4-5 不同模型的 kappa 系数对比

类型	BPNN-InceptionNet	BPNN-VGG	GRU	SVM
Kappa 系数	0.9752	0.9670	0.9505	0.7067

从结果上看，BPNN-InceptionNet 和 BPNN-VGG 诊断方法在测试集上的 kappa 系数要高于 GRU 和 SVM，说明本章设计的特征层信息融合结构对于本章讨论的多分类

故障诊断任务具有更好的适用性。进一步地, BPNN-InceptionNet 在测试集上的 kappa 系数要高于 BPNN-VGG, 说明本章提出的基于 InceptionNet 的卷积网络在本任务中比经典的 VGG 卷积网络有更好的适用性。

#### 4.4 本章小结

本章对不均衡故障样本数据集开展了故障诊断研究, 提出了特征层信息融合的基于 BPNN-InceptionNet 的燃料电池系统故障诊断框架。首先通过 BPNN-InceptionNet 的框架图对该诊断方法的流程进行详细描述, 该框架先利用 BPNN 网络对输入的 28 维数据进行升维, 提取高维抽象特征, 随后将向量形式的特征重构为特征图实现特征层信息融合, 最后利用一个本章设计的基于 InceptionNet 的卷积网络实现故障诊断与分类。分别详细介绍了 BPNN 与所设计的卷积网络中不同层的计算原理。随后对 BPNN-InceptionNet 进行训练并测试, 引入机器学习中的 kappa 系数来对模型的预测结果进行一致性评估。进一步地, 为了验证所提出的故障诊断框架的优势, 对不同的模型进行对比分析, 其中包括第 3 章中的 GRU 故障诊断方法、SVM 分类器, 以及设计的 BPNN-VGG 诊断框架, 从测试集的 kappa 系数结果可以说明, 本章设计的以特征层信息融合为结构的基于 BPNN-InceptionNet 的诊断框架的预测结果较其他对比方法具有更好的一致性表现。

第 5 章 决策层信息融合的深度学习故障诊断方法

5.1 并存故障样本数据

在对有轨电车用燃料电池系统的历史故障数据分析中发现，存在少量的并存故障样本，该类样本表示同时存在两种故障类型，此外，若两种故障类型同属于一个严重等级，则故障采集系统只能汇报其中一类故障，另一类故障会通过低一级严重等级的数据传输通道进行汇报，这就导致了一些严重的故障可能被忽略的不良后果。因此本章特别关注了这类特殊情况，构建了并存故障样本数据集，并对其开展了故障诊断研究。并存故障样本数据集中包含的故障类及其编号和样本总数如表 5-1 所示，其中 F1 表示电流设定点偏差 1 级故障，F2 表示空气压力低 1 级故障，F3 表示电流设定点偏差 1 级与空气压力低 1 级并存故障。

表 5-1 样本类型、编号及总数

编号	F1	F2	F3
类型	电流设定点偏差 1 级故障	空气压力低 1 级故障	电流设定点偏差 1 级与空气压力低 1 级并存故障
总数	100	10	17

将上述构建的数据集利用 t-SNE 算法进行降维可视化，迭代 1500 次后的可视化结果如图 5-1 所示。从可视化结果分析，F2 和 F3 故障具有高度的空间相似性，存在相互覆盖的区域，可以说明在该并存故障样本数据集中，F3 类样本具有的数据特征和单一故障样本 F2 具有的数据特征高度相似。不同样本的电堆总电流和空气入口压力数据如图 5-2 和图 5-3 所示，从图中代表不同故障的数据点分布容易看出，F2 和 F3 类样本的电堆总电流和空气入口压力数据更为相似。




图 5-1 t-SNE 降维可视化结果

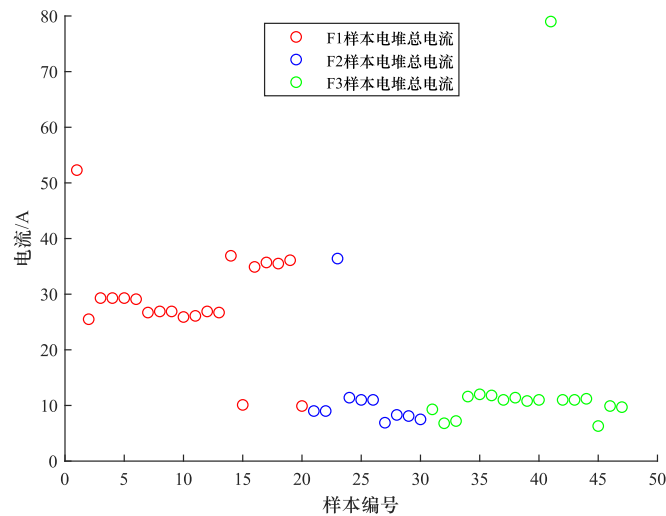


图 5-2 不同样本的电堆总电流数据对比




图 5-3 不同样本的空气入口压力数据对比

## 5.2 D-S 证据理论方法

在第 3 章和第 4 章中, 本文分别以数据层信息融合和特征层信息融合为结构设计了不同的故障诊断方法, 并且通过对比论证的方式, 以 kappa 系数为评价指标, 验证了所提出方法的适用性。在本章内, 将对信息融合中最顶层的结构——决策层信息融合结构进行研究, 并引入了基于 D-S 证据理论(Dempster-Shafer evidence theory)的多模型融合燃料电池系统故障诊断方法。D-S 证据理论的起源是由 Dempster 在二十世纪六十年代提出, 利用上下限概率来解决多值映射问题的方法, 后经过 Shafer 对证据理论进行改进, 引入信任函数, 形成了 D-S 证据理论的方法论, 也即利用证据和组合规则处理不确定推理的一种方法论。由于证据理论中的先验数据比概率推理理论中更直观易得, 且借助于不同的组合方式(如 Demster 合成规则)能综合不同专家或信息源的知

识,从而使得证据理论在专家系统、情报分析、多属性决策、信息融合等领域获得了广泛的适用性<sup>[88]</sup>。

决策层信息融合是将不同的证据在决策层进行融合,以得到综合性的推理结果。本节中引入的诊断方法,是利用两个在第4章中采用的BPNN-InceptionNet模型进行分别训练,并利用二者的输出决策进行D-S证据理论融合,得到新的推理结果,并以此作为多模型融合诊断结果作为输出。另外,在研究中发现,有轨电车用燃料电池系统不仅存在第3、4章中讨论的单一类型故障样本,还存在少量并存故障样本(此类样本表示燃料电池系统此时同时存在两种或两种以上的故障类型),因此本节将对这种并存故障样本纳入研究中,并利用构建出的数据集对本节引入的基于D-S证据理论的多模型融合燃料电池系统故障诊断方法进行验证。

### 5.2.1 D-S 证据理论

在本小节内将对D-S证据理论进行详细描述,首先介绍D-S证据理论中的相关概念,随后介绍D-S证据理论中的Demster组合规则<sup>[89]</sup>。

#### (1) 识别框架(Frame of discernment)

将一组非空集合 $\Theta = \{A_1, A_2, A_3, \dots, A_n\}$ 定义为识别框架,其中的元素分别代表 $n$ 类两两互斥的事件, $2^\Theta = \{\emptyset, \{A_1\}, \{A_2\}, \dots, \{A_n\}, \{A_1, A_2\}, \{A_1, A_3\}, \dots, \{A_1, A_n\}, \dots\}$ ,为 $\Theta$ 的幂集,其中的元素表示事件的所有可能的组合形式。

#### (2) 基本概率分配函数(Basic Probability Assignment, BPA)

在识别框架 $\Theta$ 上的一个基本概率分配函数 $m: 2^\Theta \rightarrow [0,1]$ ,满足式(5-1)<sup>[89]</sup>。

$$\begin{cases} m(\emptyset) = 0 \\ \sum_{A \subseteq \Theta} m(A) = 1, A \neq \emptyset \end{cases} \quad (5-1)$$

式(5-1)中,令 $m(A) > 0$ 的 $A$ 为焦点。

#### (3) 信任函数(Belief function)

某事件的信任函数是该事件所有子集的概率之和,在识别框架 $\Theta$ 上的基于BPA函数 $m$ 的信任函数定义为式(5-2)<sup>[89]</sup>:

$$Bel(A) = \sum_{B \subseteq A} m(B) \quad (5-2)$$

#### (4) 似然函数(Plausibility function)

某事件的似然函数是与该事件交集不为空集的概率之和,在识别框架 $\Theta$ 上的基于BPA函数 $m$ 的似然函数定义为式(5-3)<sup>[89]</sup>:

$$Pl(A) = \sum_{B \cap A \neq \emptyset} m(B) \quad (5-3)$$

#### (5) 似然函数(Plausibility function)

在证据理论中,对于识别框架 $\Theta$ 内的某个事件 $A$ ,由基本概率分配函数能计算得到关于此事件的信任函数 $Bel(A)$ 和似然函数 $Pl(A)$ ,二者组成的区间 $[Bel(A), Pl(A)]$ 为信任区间,表示对该事件的确信程度。

#### (6) Demster 组合规则

对于 $\forall A \subseteq \Theta$ ,有两个BPA函数 $m_1$ 和 $m_2$ ,二者的Demster组合规则为可用式(5-4)表示<sup>[89]</sup>。

$$m_1 \oplus m_2(A) = \frac{1}{K} \sum_{B \cap C = A} m_1(B)m_2(C) \quad (5-4)$$

其中 $m_1 \oplus m_2(A)$ 表示经合成后的基本概率分布函数, $K$ 为归一化常数, $K$ 的计算公式如下<sup>[89]</sup>:

$$K = \sum_{B \cap C \neq \emptyset} m_1(B)m_2(C) = 1 - \sum_{B \cap C = \emptyset} m_1(B)m_2(C) \quad (5-5)$$

对于多个BPA函数 $m_1, m_2, \dots, m_n$ 的Demster合成过程可见公式(5-6)~(5-7)<sup>[89]</sup>:

$$(m_1 \oplus m_2 \oplus \dots \oplus m_n)(A) = \frac{1}{K} \sum_{A_1 \cap A_2 \cap \dots \cap A_n = A} m_1(A_1)m_2(A_2)\dots m_n(A_n) \quad (5-6)$$

$$\begin{aligned} K &= \sum_{A_1 \cap A_2 \cap \dots \cap A_n \neq \emptyset} m_1(A_1)m_2(A_2)\dots m_n(A_n) \\ &= 1 - \sum_{A_1 \cap A_2 \cap \dots \cap A_n = \emptyset} m_1(A_1)m_2(A_2)\dots m_n(A_n) \end{aligned} \quad (5-7)$$

式(5-6)中 $(m_1 \oplus m_2 \oplus \dots \oplus m_n)(A)$ 表示将多个BPA(也可称为证据)合成后的基本概率分布函数。

### 5.2.2 基于D-S证据理论的多模型融合诊断方法流程

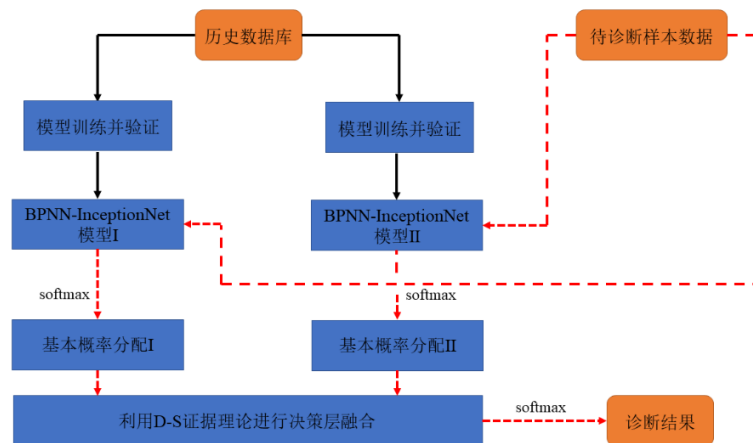


图 5-4 基于 D-S 证据理论的多模型融合诊断方法流程图

由于深度学习网络的训练中具有一定的随机性,即便是相同的模型,经过训练后的最终模型在测试集上的性能表现也可能不同,因此,本章考虑将训练后的 BPNN-InceptionNet 模型 I 和 BPNN-InceptionNet 模型 II 视为两个证据源,在两个模型的输出

端进行 D-S 证据理论融合。整个基于 D-S 证据理论的多模型融合诊断方法的流程图如图 5-4 所示, 图中黑色实线箭头表示利用历史数据训练模型的流程, 红色虚线箭头表示对待诊断样本数据进行故障诊断的流程。另外, 从图中还能发现, softmax 函数用于使模型输出一个基本概率分配 BPA, 将两个 BPA 利用 D-S 证据理论中的 Dempster 组合规则进行组合, 从而输出决策层融合后的概率分布, 进而利用 argmax 函数得到多模型融合诊断的结果。

## 5.3 基于 D-S 证据理论的多模型融合的燃料电池系统故障诊断

### 5.3.1 BPNN-InceptionNet 模型测试

将本章的并存故障样本数据集以 6: 2: 2 的比例划分为训练集、验证集和测试集, 各子数据集的样本数分布如表 5-2 所示。

表 5-2 各子数据集的样本数分布

编号	F1	F2	F3
训练集中样本数	59	6	10
验证集中样本数	21	2	3
测试集中样本数	20	2	4

将 BPNN-InceptionNet 模型 I 的参数设置如表 4-2 所述, 迭代 500 次训练模型, 训练过程中模型在训练集和验证集上的准确率曲线如图 5-5 所示。其中蓝色曲线表示模型每次迭代时在训练集上的准确率曲线, 红色曲线表示模型每次迭代时在验证集上的准确率曲线。经过迭代训练后得到最终模型, 将测试集数据用于模型的预测性能测试, 混淆矩阵的结果如图 5-6 所示, 其中 0、1、2 分别代表故障类 F1、F2、F3。可以发现, 在测试集中有一个 F1 类样本被模型 I 错误预测成了 F2 类, 将该样本挑选出来, 输入训练好的模型 I, 并通过 softmax 函数输出一个基本概率分配函数  $m_1$ 。将上述模型 I 误分类的样本输入到训练好的 BPNN-InceptionNet 模型 II 中, 也通过一个 softmax 函数输出一个基本概率分配函数  $m_2$ 。下一小节将通过 Dempster 组合规则将  $m_1$  和  $m_2$  进行组合。

### 5.3.2 Dempster 组合规则实例

在 5.3.1 中通过模型 I 和 II 分别输出了一个对误判样本的基本概率分配  $m_1$  和  $m_2$ , 随后利用式(5-4)进行 Dempster 组合,  $m_1$  和  $m_2$  以及二者组合后的概率分布  $m_1 \oplus m_2$  如表 5-3 所示。

从表中结果可以看到, 经过 Dempster 组合规则运算后, 对该类样本的融合预测概率输出为: 预测该样本属于 F1 类的概率为 0, 预测该样本属于 F2 类的概率为 76.96%,

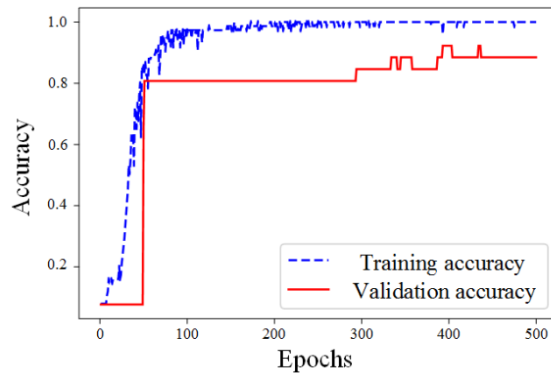


图 5-5 模型I训练过程的准确率曲线




图 5-6 模型I的测试结果混淆矩阵

表 5-3 Dempster 组合实例

BPA	F1	F2	F3
$m_1$	0.0154	0.4918	0.4928
$m_2$	0.0001	0.7630	0.2369
$m_1 \oplus m_2$	0	0.7696	0.2304

预测该样本属于 F3 类的概率为 23.04%。随后通过  $\text{argmax}$  函数输出该样本的预测结果为 F2 类，与该样本的真实类别相符。综上所述，通过 D-S 证据理论的决策层融合，能利用模型 II 的决策对模型 I 的决策进行修正，从而输出更加综合的诊断决策。

通过研究，可以发现在上述实例中，本章引入的基于 D-S 证据理论的多模型融合燃料电池系统故障诊断方法能实现决策的互补，将模型 I 误分类的样本通过决策层融合来纠正样本分类结果。但是相比于深度学习网络对于输出会以损失函数为优化目标进行迭代，使得模型参数越接近最优解。D-S 证据理论的结果很依赖于组合规则，且在大样本计算上有潜在的指数爆炸问题。此外，由不同模型生成的 BPA 函数不同，对事件的信赖度也因此不同，当证据发生较大冲突时，融合结果可能并不能满足要求。因此该融合方法在燃料电池系统故障诊断领域内的合理性还需要大量验证，此外尽管已有文献提出了许多改进的证据理论组合规则，适用于燃料电池系统故障诊断的、有效性



更强的组合规则还需要更多研究。

综上所述，本章引入的以决策层信息融合为结构的基于 D-S 证据理论的多模型融合诊断方法在结构和算法上的复杂度都要高于以特征层和数据层信息融合为结构的诊断方法。在该方法中首先利用两个或多个 BPNN-InceptionNet 深度学习模型得到各自的决策证据输出，随后将这些模型的输出在决策层进行融合，利用 D-S 证据理论的 Dempster 组合规则输出最终的模型决策。

## 5.4 本章小结

本章对并存故障样本数据集开展了故障诊断研究，引入了决策层信息融合的基于 D-S 证据理论的多模型融合诊断方法。首先，详细介绍了 D-S 证据理论的相关概念，以及 Dempster 证据组合规则的计算过程，随后通过基于 D-S 证据理论的多模型融合诊断方法的流程图详细说明了该方法的结构与诊断流程。本章研究的包含少量样本数据的并存故障样本同时存在两类故障，从 t-SNE 降维可视化的结果图中可以发现此类并存故障样本的数据特征和其包含的两类故障之一具有高度相似性。在研究中，选择出被 BPNN-InceptionNet 模型 I 误分类的一例样本进行实例计算，结果验证了所引入的融合诊断方法可以得到更综合的诊断决策。但在大样本下该方法的泛化能力、有效性，以及对证据组合规则的改进都还需要进一步研究探讨。

## 结论与展望

本文的研究对象是西南交通大学与中车唐山公司共研的燃料电池/超级电容混合动力 100%低地板有轨电车的质子交换膜燃料电池系统,以机车运行过程中采集到的燃料电池系统历史数据为基础,开展了数据驱动的故障诊断研究,以信息融合为结构设计了不同的深度学习故障诊断框架,并通过多种对比研究来选择合适的模型参数以及验证诊断模型的可行性。得到的主要结论如下:

(1) 本文描述了有轨电车用燃料电池系统的数据采集系统所能监测到的 28 个电量与非电量参数,分析这些监测量在机车运行时的变化特点,结果表明在 HD6 燃料电池电堆处于不同的工作状态时,不同的监测量之间可能存在相互关联的耦合关系,而当 HD6 燃料电池电堆进入某一故障状态时,不同监测量也会呈现不同的变化趋势。另外还比较了不同的故障样本与正常态样本的部分监测量特点,结果表明当燃料电池系统发生不同故障时,同一监测量可能表现出相同或完全不同的变换趋势,即便是发生同一故障,不同的样本间也可能具有较大的差异性与波动性。说明有轨电车用燃料电池系统的原始数据具有相当的耦合性、复杂性与随机性,原始数据中蕴含了丰富的与燃料电池系统健康状态相关的信息。

(2) 本文采用 t-SNE 降维可视化算法,将 28 维的原始数据降维至二维平面空间,从降维可视化结果中可以看出,不同类型的样本数据之间具有相似的特征表示,说明了样本数据的复杂性。

(3) 本文依据数据层信息融合结构,设计了基于 GRU 的故障诊断方法,对复杂故障样本开展了故障诊断研究。通过不同参数的对比分析,说明了选择三层 GRU 结构、Adam 优化器类型等参数以及 z-score 数据预处理策略在诊断任务中具有更好的适用性,对比了分别以 28 维、14 维、11 维数据作为 GRU 方法的输入时,模型的性能表现,结果表明该方法能有效地处理高维输入信息。将其与 SVM 算法进行了对比测试,结果发现基于 GRU 的诊断方法的预测准确率表现要优于 SVM。

(4) 本文依据特征层信息融合结构,提出了基于 BPNN-InceptionNet 的故障诊断框架,对不均衡故障样本开展了故障诊断研究,并引入 kappa 系数来评价不均衡数据集下的模型测试性能。通过对比不同模型在测试集下的 kappa 系数,结果表明 BPNN-InceptionNet 模型的 kappa 系数为 0.9752,要高于 BPNN-VGG 的 0.9670、GRU 的 0.9505 以及 SVM 的 0.7067,结果表明该诊断框架具有更好的对不均衡数据集的诊断性能。

(5) 本文依据决策层信息融合结构,引入了基于 D-S 证据理论的多模型融合的故障诊断框架,对一种并存故障小样本数据集开展了故障诊断研究,通过一个计算实例证明了该方法能融合两个 BPNN-InceptionNet 模型的预测结果,得到综合的诊断决策,但是模型结构更加复杂。

虽然本文将信息融合与深度学习相结合，提出了不同的故障诊断框架，并在诊断结果中验证了方法的有效性，但还有需要进一步研究与讨论的地方，主要有以下几项内容：

(1) 还需要继续收集有轨电车在各种运行状态下的监测数据，扩充历史数据集，这有利于数据驱动故障诊断方法的性能提升。

(2) 在基于 D-S 证据理论的多模型融合的燃料电池故障诊断方法中，对于组合规则的适用性还需要深入探讨。尤其当多个模型的输出决策出现严重冲突时，适用于有轨电车用燃料电池系统的证据组合规则还需要继续研究。

(3) 在机车持续运行下，燃料电池可能会发生正常的寿命衰减，电池各项性能相比正常时会有所退化，因此，考虑寿命衰减下的燃料电池系统故障诊断研究方法还需继续研究。

## 参考文献

- [1] “十三五”交通领域科技创新专项规划印发[J]. 现代城市研究, 2017(07): 131.
- [2] 国家综合立体交通网规划纲要[J]. 山东交通科技, 2021(02): 115.
- [3] JM. Ogden. Developing an infrastructure for hydrogen vehicles: a Southern California case study[J]. International Journal of Hydrogen Energy, 1999, 24(8): 709-730.
- [4] L. Mao, Z. Liu, D. Low, W. Pan, Q. He, L. Jackson, Q. Wu. Evaluation Method for Feature Selection in Proton Exchange Membrane Fuel Cell Fault Diagnosis[J]. IEEE Transactions on Industrial Electronics, 2022, 69(5): 5277-5286.
- [5] Y. Gou, K. Yang, W. Xu. A Fault diagnosis method of environment-friendly proton exchange membrane fuel cell for vehicles using deep learning[J]. Fresenius Environmental Bulletin, 2021, 30(3): 2931-2942.
- [6] 全睿, 黄亮, 谢长君, 全书海. 基于模糊神经网络的燃料电池发动机故障诊断[J]. 华中科技大学学报(自然科学版), 2009, 37(S1): 114-117+139.
- [7] 彭飞. 基于 PEMFC 的现代有轨电车混合动力系统关键技术研究[D]. 西南交通大学, 2014.
- [8] 全睿. 车用燃料电池系统故障诊断与维护若干关键问题研究[D]. 武汉理工大学, 2011: 2.
- [9] 高帷韬, 雷一杰, 张勋, 胡晓波, 宋平平, 赵卿, 王诚, 毛宗强. 质子交换膜燃料电池研究进展[J/OL]. 化工进展: 1-22.
- [10] 郝德利, 韩立明, 薛金生, 平晓山, 刘崇刚. 质子交换膜燃料电池技术进展[J]. 电源技术, 2001(06): 436-440.
- [11] 衣宝廉. 燃料电池的原理、技术状态与展望[J]. 电池工业, 2003(01): 16-22.
- [12] 王洪建, 程健, 张瑞云, 王鹏杰, 任永强, 许世森. 质子交换膜燃料电池应用现状及分析[J]. 热力发电, 2016, 45(03): 1-7+19.
- [13] M. Whiteley, S. Dunnett, L. Jackson. Failure Mode and Effect Analysis, and Fault Tree Analysis of Polymer Electrolyte Membrane Fuel Cells[J]. International Journal of Hydrogen Energy, 2016, 41(2): 1187-1202.
- [14] 罗马吉, 郑杰汉, 隋邦傑, 陈奔. 基于机理模型的 PEMFC 老化模拟研究[J]. 武汉理工大学学报(信息与管理工程版), 2020, 42(04): 378-382.
- [15] 叶跃坤, 池滨, 江世杰, 廖世军. 质子交换膜燃料电池膜电极耐久性的提升[J]. 化学进展, 2019, 31(12): 1637-1652.
- [16] Z. Li, C. Cadet, R. Outbib. Diagnosis for PEMFC Based on Magnetic Measurements and Data-Driven Approach[J]. IEEE Transactions on Energy Conversion, 2019, 34(2): 964-972.
- [17] 张雪霞, 蒋宇, 孙腾飞, 陈维荣. 质子交换膜燃料电池水淹和膜干故障诊断研究综述[J]. 西南交通大学学报, 2020, 55(04): 828-838+864.
- [18] 田颖, 韩峰, 李贺, 张龙海. 聚合物电解质膜燃料电池空气供应系统故障诊断[J]. 北京交通大学学报, 2020, 44(04): 116-123.
- [19] 梁建英, 刘玉文, 李克雷. 氢能在轨道交通领域的应用及前景[C]. 国际氢能产业发展报告(2017), 2017: 292-309+436-437.
- [20] 陈维荣, 钱清泉, 李奇. 燃料电池混合动力列车的研究现状与发展趋势[J]. 西南交通大学学报, 2009, 44(01): 1-6.
- [21] 汪培桢, 杨升. 氢能有轨电车应用综述[J]. 装备制造技术, 2020(02): 196-199.
- [22] 魏调忠. 氢能源与超级电容在现代有轨电车的应用[J]. 机电工程技术, 2020, 49(09): 185-187.

- 
- [23] 陈祥. 氢能源有轨电车的应用实践[J]. 现代城市轨道交通, 2021(05): 28-32.
- [24] 臧晓艳, 李明, 岳成林, 潘硕, 李硕. 燃料电池混合动力 100%低地板有轨电车设计[J]. 铁道机车车辆, 2018, 38(04): 116-120.
- [25] 杜震, 李昂. 世界首列氢燃料电池有轨电车在唐山载客运营[J]. 城市轨道交通研究, 2017, 20(11): 4.
- [26] 王兴娣. 基于数据驱动的质子交换膜燃料电池电堆故障诊断研究[D]. 西南交通大学, 2018.
- [27] R. Petrone, Z. Zheng, D. Hissel, M.C. Péra, C. Pianese, M. Sorrentino, M. Becherif, N. Yousfi-Steiner. A review on model-based diagnosis methodologies for PEMFCs[J]. International Journal of Hydrogen Energy, 2013, 38(17): 7077-7091.
- [28] Z. Zheng, R. Petrone, M.C. Péra, D. Hissel, M. Becherif, C. Pianese, N. Yousfi Steiner, M. Sorrentino. A review on non-model based diagnosis methodologies for PEM fuel cell stacks and systems[J]. International Journal of Hydrogen Energy, 2013, 38(21): 8914-8926.
- [29] T. Escobet, D. Feroldi, S. de Lira, V. Puig, J. Quevedo, J. Riera, M. Serra. Model-based fault diagnosis in PEM fuel cell systems[J]. Journal of Power Sources, 2009, 192(1): 216-223.
- [30] P. Polverino, E. Frisk, D. Jung, M. Krysander, C. Pianese. Model-based diagnosis through Structural Analysis and Causal Computation for automotive Polymer Electrolyte Membrane Fuel Cell systems[J]. Journal of Power Sources, 2017, 357: 26-40.
- [31] Z. Bougatef, N. Abdelkrim, A. Aitouche, M.N. Abdelkrim. Fault detection of a PEMFC system based on delayed LPV observer[J]. International Journal of Hydrogen Energy, 2020, 45(19): 11233-11241.
- [32] N.Y. Steiner, D. Candusso, D. Hissel, P. Moçoteguy. Model-based diagnosis for proton exchange membrane fuel cells[J]. Mathematics and Computers in Simulation, 2010, 81(2): 158-170.
- [33] M.M. Kamal, D.W. Yu, D.L. Yu. Fault detection and isolation for PEM fuel cell stack with independent RBF model[J]. Engineering Applications of Artificial Intelligence, 2014, 28: 52-63.
- [34] A. Mohammadi, G. Cirrincione, A. Djerdir, D. Khaburi. A novel approach for modeling the internal behavior of a PEMFC by using electrical circuits[J]. International Journal of Hydrogen Energy, 2018, 43(25): 11539-11549.
- [35] A. Mohammadi, A. Djerdir, N. Yousfi Steiner, D. Khaburi. Advanced diagnosis based on temperature and current density distributions in a single PEMFC[J]. International Journal of Hydrogen Energy, 2015, 40(45): 15845-15855.
- [36] M. Le Ny, O. Chadebec, G. Cauffet, J.M. Dedulle, Y. Bultel. A Three Dimensional Electrical Model of PEMFC Stack[J]. Fuel Cells, 2012, 12(2): 225-238.
- [37] S. Asghari, A. Mokmeli, M. Samavati. Study of PEM fuel cell performance by electrochemical impedance spectroscopy[J]. International Journal of Hydrogen Energy, 2010, 35(17): 9283-9290.
- [38] A. Debenjak, M. Gasperin, B. Pregelj, M. Atanasijevic-Kunc, J. Petrovcic, V. Jovan. Detection of Flooding and Drying inside a PEM Fuel Cell Stack[J]. Strojniski Vestnik-Journal of Mechanical Engineering, 2013, 59(1): 56-64.
- [39] K. Darowicki, E. Janicka, M. Mielniczek, A. Zielinski, L. Gawel, J. Mitzel, J. Hunger. Implementation of DEIS for reliable fault monitoring and detection in PEMFC single cells and stacks[J]. Electrochimica Acta, 2018, 292: 383-389.
- [40] M. Le Ny, O. Chadebec, G. Cauffet, S. Rosini, Y. Bultel. PEMFC stack diagnosis based on external magnetic field measurements[J]. Journal of Applied Electrochemistry, 2015, 45(7): 667-677.
- [41] M. Hinaje, O. Bethoux, G. Krebs, B. Davat. Nonintrusive diagnosis of a PEMFC[J]. IEEE Transactions on Magnetics, 2015, 51(3): 1-4.
- [42] R.J. Bellows, M.Y. Lin, M. Arif, A.K. Thompson, D. Jacobson. Neutron imaging technique for in situ
-

- measurement of water transport gradients within Nafion in polymer electrolyte fuel cells[J]. *Journal of the Electrochemical Society*, 1999, 146(3): 1099-1103.
- [43] F. Akitomo, T. Sasabe, T. Yoshida, H. Naito, K. Kawamura, S. Hirai. Investigation of effects of high temperature and pressure on a polymer electrolyte fuel cell with polarization analysis and X-ray imaging of liquid water[J]. *Journal of Power Sources*, 2019, 431: 205-209.
- [44] C. Damour, M. Benne, B. Grondin-Perez, M. Bessafi, D. Hissel, J.-P. Chabriot. Polymer electrolyte membrane fuel cell fault diagnosis based on empirical mode decomposition[J]. *Journal of Power Sources*, 2015, 299: 596-603.
- [45] E. Pahon, N. Yousfi Steiner, S. Jemei, D. Hissel, P. Moçoteguy. A signal-based method for fast PEMFC diagnosis[J]. *Applied Energy*, 2016, 165: 748-758.
- [46] J. Kim, Y. Tak. Implementation of discrete wavelet transform-based discrimination and state-of-health diagnosis for a polymer electrolyte membrane fuel cell[J]. *International Journal of Hydrogen Energy*, 2014, 39(20): 10664-10682.
- [47] M. Shao, X.-J. Zhu, H.-F. Cao, H.-F. Shen. An artificial neural network ensemble method for fault diagnosis of proton exchange membrane fuel cell system[J]. *Energy*, 2014, 67: 268-275.
- [48] S. Laribi, K. Mammam, Y. Sahli, K. Koussa. Analysis and diagnosis of PEM fuel cell failure modes (flooding & drying) across the physical parameters of electrochemical impedance model: Using neural networks method[J]. *Sustainable Energy Technologies and Assessments*, 2019, 34: 35-42.
- [49] Z. Li, R. Outbib, S. Giurgea, D. Hissel. Diagnosis for PEMFC Systems: A Data-Driven Approach With the Capabilities of Online Adaptation and Novel Fault Detection[J]. *IEEE Transactions on Industrial Electronics*, 2015, 62(8): 5164-5174.
- [50] DT. Hoang, HJ. Kang. A survey on Deep Learning based bearing fault diagnosis[J]. *Neurocomputing*, 2019, 335: 327-335.
- [51] C. Li, SH. Zhang, Y. Qin, E. Estupinan. A systematic review of deep transfer learning for machinery fault diagnosis[J]. *Neurocomputing*, 2020, 407: 121-135.
- [52] 陈滨斐, 章黄勇, 马宏忠, 李志新, 李呈营. 基于深度学习的电力设备故障诊断方法研究综述[J]. *电气自动化*, 2022, 44(01): 1-2+6.
- [53] 任浩, 屈剑锋, 柴毅, 唐秋, 叶欣. 深度学习在故障诊断领域中的研究现状与挑战[J]. *控制与决策*, 2017, 32(08): 1345-1358.
- [54] 文成林, 吕菲亚. 基于深度学习的故障诊断方法综述[J]. *电子与信息学报*, 2020, 42(01): 234-248.
- [55] 彭成, 李凤娟, 蒋金元. 基于深度学习的故障诊断与预测方法综述[J]. *现代电子技术*, 2022, 45(03): 111-120.
- [56] X. Zhang, J. Zhou, W. Chen. Data-driven fault diagnosis for PEMFC systems of hybrid tram based on deep learning[J]. *International Journal of Hydrogen Energy*, 2020, 45(24): 13483-13495.
- [57] O. Janssens, V. Slavkovikj, B. Vervisch, K. Stockman, M. Loccufier, S. Verstockt, R. Van de Walle, S. Van Hoecke. Convolutional Neural Network Based Fault Detection for Rotating Machinery[J]. *Journal of Sound and Vibration*, 2016, 377:331-345.
- [58] L. Guo, N. Li, F. Jia, Y. Lei, J. Lin. A recurrent neural network based health indicator for remaining useful life prediction of bearings[J]. *Neurocomputing*, 2017, 240: 98-109.
- [59] HD Shao, HK Jiang, XQ Li, SP Wu. Intelligent fault diagnosis of rolling bearing using deep wavelet auto-encoder with extreme learning machine[J]. *Knowledge-based systems*, 2018, 140: 1-14.
- [60] B. Khaleghi, A. Khamis, F.O. Karray, S.N. Razavi. Multisensor data fusion: A review of the state-of-the-art[J]. *Information Fusion*, 2013, 14(1): 28-44.
- [61] 张友, 李聪波, 林利红, 王睿. 基于多源信息融合和 ADCNN 的离心鼓风机故障诊断[J/OL]. 重

- 庆大学学报: 1-14.
- [62] 叶树璞, 孙俊. 多信息融合技术在船舶动力装置故障诊断中的应用[J]. 中国修船, 2022, 35(01): 45-48.
- [63] 李奎, 梁启明, 赵成晨, 胡博凯, 马典良, 赵伟焯. 基于多信息融合的塑壳断路器故障诊断方法研究[J]. 河南理工大学学报(自然科学版), 2022, 41(02): 93-101.
- [64] T. Meng, X. Jing, Z. Yan, W. Pedrycz. A survey on machine learning for data fusion[J]. Information Fusion, 2020, 57: 115-129.
- [65] V. Zaccaria, M. Rahman, I. Aslanidou, K. Kyprianidis. A Review of Information Fusion Methods for Gas Turbine Diagnostics[J]. Sustainability, 2019, 11(22): 6202-6221.
- [66] 张雪霞, 高雨璇, 陈维荣. 基于数据驱动的质子交换膜燃料电池寿命预测[J]. 西南交通大学学报, 2020, 55(2): 417-427.
- [67] R. C. Luo, M. G. Kay. Multisensor integration and fusion: issues and approaches[J]. Proceedings of SPIE-The International Society for Optical Engineering, 1988, 931: 42-49.
- [68] S. Liu, R.X. Gao, D. John, J.W. Staudenmayer, P.S. Freedson. Multisensor data fusion for physical activity assessment[J]. IEEE Transactions on Biomedical Engineering, 2012, 59(3): 687-696.
- [69] J. Tang, J. Qiao, Z. Wu, T. Chai, J. Zhang, W. Yu. Vibration and acoustic frequency spectra for industrial process modeling using selective fusion multi-condition samples and multi-source features[J]. Mechanical Systems and Signal Processing, 2018, 99: 142-168.
- [70] J.-H. Zhong, P.K. Wong, Z.-X. Yang. Fault diagnosis of rotating machinery based on multiple probabilistic classifiers[J]. Mechanical Systems and Signal Processing, 2018, 108: 99-114.
- [71] Y. Lin, Y. Li, X. Yin, Z. Dou. Multisensor Fault Diagnosis Modeling Based on the Evidence Theory[J]. IEEE Transactions on Reliability, 2018, 67(2): 513-521.
- [72] M. Xia, T. Li, L. Xu, L. Liu, C.W. de Silva. Fault Diagnosis for Rotating Machinery Using Multiple Sensors and Convolutional Neural Networks[J]. IEEE/ASME Transactions on Mechatronics, 2018, 23(1): 101-110.
- [73] O. Basir, X. Yuan. Engine fault diagnosis based on multi-sensor information fusion using Dempster-Shafer evidence theory[J]. Information Fusion, 2007, 8(4): 379-386.
- [74] Ballard. FCVelocityTM HD6 Integration Manual[M]. Power Systems, Commercial Confidential. 2011: 1-75.
- [75] 周静哲. 基于深度学习的有轨电车燃料电池系统故障诊断研究[D]. 西南交通大学, 2021.
- [76] 张雪霞, 蒋宇, 黄平, 郭雪庆, 陈维荣. 质子交换膜燃料电池容错控制方法综述[J]. 中国电机工程学报, 2021, 41(04): 1431-1444+1549.
- [77] L. van der Maaten, G. Hinton. Visualizing data using t-SNE[J]. Journal of Machine Learning Research, 2008, 9: 2579-2605.
- [78] Z. Yin, J. Hou. Recent advances on SVM based fault diagnosis and process monitoring in complicated industrial processes[J]. Neurocomputing, 2016, 174: 643-650.
- [79] K. Cho, B. Van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, Y. Bengio. Learning phrase representations using RNN encoder-decoder for statistical machine translation[C]. Conference on Empirical Methods in Natural Language Processing, 2014: 1724-1734.
- [80] X. Zhang, X. Guo. Fault diagnosis of proton exchange membrane fuel cell system of tram based on information fusion and deep learning[J]. International Journal of Hydrogen Energy, 2021, 46(60): 30828-30840.
- [81] C. Szegedy, W. Liu, Y. Jia, P. Sermanet, S. Reed, D. Anguelov, D. Erhan, V. Vanhoucke, A. Rabinovich. Going deeper with convolutions[C]. Proceedings of the IEEE Computer Society Conference on

---

Computer Vision and Pattern Recognition, 2015: 1-9.

- [82] S. Ioffe, C. Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift[C]. 32nd International Conference on Machine Learning, 2015: 448-456.
- [83] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, Z. Wojna. Rethinking the inception architecture for computer vision[C]. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2016: 2818-2826.
- [84] C. Szegedy, S. Ioffe, V. Vanhoucke, A. A. Alemi. Inception-v4, inception-ResNet and the impact of residual connections on learning[C]. 31st AAAI Conference on Artificial Intelligence, 2017: 4278-4284.
- [85] M. Lin, Q. Chen, S. Yan. Network in network[C]. 2nd International Conference on Learning Representations, 2014: 1-10.
- [86] S. Mishra, Nitika. Understanding the calculation of the kappa statistic: A measure of inter-observer reliability[J]. International Journal of Academic Medicine, 2016, 2(2): 217-219.
- [87] K. Simonyan, A. Zisserman. Very deep convolutional networks for large-scale image recognition[C]. 3rd International Conference on Learning Representations, 2015: 1-14.
- [88] A.P. Dempster. Upper and lower probabilities induced by a multivalued mapping[J]. Studies in Fuzziness and Soft Computing, 2008, 219: 57-72.
- [89] X. Fan, M. Zuo. Fault diagnosis of machines based on D-S evidence theory. Part 1: D-S evidence theory and its improvement[J]. Pattern Recognition Letters, 2006, 27(5): 366-376.