

基于数据驱动的锂离子电池 RUL 预测综述

张若可, 郭永芳, 余湘媛, 胡晓亚

(河北工业大学人工智能与数据科学学院, 天津 300401)

摘要: 剩余使用寿命预测技术对于锂离子电池的安全使用及维护具有重要意义。由于锂离子电池的长寿命特性以及复杂的非线性退化机制, 目前剩余使用寿命预测仍是电池状态预测的难点问题。数据驱动方法不需要考虑电池内部电化学特性, 而仅从数据角度出发, 是目前主流的预测方法。通过实例介绍了剩余使用寿命概念, 分类阐述了各种基于数据驱动的预测方法, 并对其优缺点进行了分析。最后, 针对现有方法的不足, 提出未来需要改进的方向。

关键词: 锂离子电池; 剩余使用寿命; 数据驱动; 预测方法

Review of Data-driven RUL Prediction for Lithium-ion Batteries

ZHANG Ruoke, GUO Yongfang, YU Xiangyuan, HU Xiaoya

(College of Artificial Intelligence and Data Science, Hebei University of Technology, Tianjin 300401, China)

Abstract: The prediction technology for remaining useful life (RUL) is of significance for the safe use and maintenance of lithium-ion batteries. Due to the long life characteristics and complex nonlinear degradation mechanism of lithium-ion batteries, the RUL prediction is still difficult in the prediction of battery states. The data-driven method, which does not need to consider the internal electrochemical characteristics of batteries and only starts from the perspective of data, has become a kind of mainstream prediction method. In this paper, the concept of RUL is introduced through examples, based on which a variety of data-driven RUL prediction methods are classified and their advantages and disadvantages are analyzed. Finally, in view of the shortcomings of the existing prediction methods, the directions in which improvements can be made in the future are also pointed out.

Keywords: lithium-ion battery; remaining useful life (RUL); data-driven; prediction method

锂离子电池具有能量密度高、循环寿命长、环境污染小、自放电率低等优点^[1]。如今全球能源危机和环境污染问题日益严重, 节能环保的锂离子电池具有广泛的应用市场。但在电池的使用过程中, 其内部化学物质的变化、正负极材料的损耗都会造成电池性能退化, 影响电池的寿命, 造成电池故障等, 严重威胁电池使用者的安全。

电池的健康状态 SOH (state-of-health) 估计和剩余使用寿命 RUL (remaining useful life) 预测是锂离子电池寿命相关的 2 个重要技术。SOH 表征电池

相对于新电池存储电能和能量的能力, 是定量描述电池当前性能状态的指标^[2]。电池 RUL 是表征电池老化衰退程度的参量, 目的是得到从预测时刻开始到电池寿命结束的工作时长。前者表示对电池当前状态的估计, 后者表示对于电池未来可正常使用时间的预测, 是对容量未来变化趋势的研究。准确地对 SOH 和 RUL 做出估计和预测可以方便用户了解电池处于的寿命阶段, 帮助用户建立更好的维修策略, 使电池得到更有效的使用。

基于数据驱动的 RUL 预测方法不需要考虑电池内部复杂的变化机理, 计算量小, 过程简单且适用于锂离子电池实际应用场景, 成为了锂离子电池 RUL 预测的研究热点。本文将介绍 RUL 预测的相关概念, 综述基于数据驱动的锂离子电池 RUL 预

收稿日期: 2020-12-30; 录用日期: 2021-05-06

基金项目: 河北省自然科学基金资助项目 (E2019202328)

Project Supported by Natural Science Foundation of Hebei Province (E2019202328)

测方法及其优缺点,并提出未来基于数据驱动方法预测锂离子电池 RUL 的研究建议,旨在为相关领域的研究人员提供参考。

1 锂离子电池的剩余使用寿命预测

RUL 是指电池在当前时刻到寿命终止 EOL (end-of-life)时刻前还能进行的充放电循环周期数^[3]。一般情况下,电池最大可用容量降为额定容量的 70%~80%时,电池寿命终止。常见的 RUL 定义为

$$RUL = C_{EOL} - C_i$$

(1)

式中: C_{EOL} 为新电池到寿命终止时刻前所能进行的充放电循环周期数; C_i 为当前时刻的充放电循环周期数。

图 1 为典型的锂离子电池 RUL 预测过程。




图 1 锂离子电池 RUL 预测过程

Fig. 1 RUL prediction process of lithium-ion battery

图 1 实验对象为 NASA PCoE 研究中心公开数据集集中编号为 B0005、额定容量为 2 A·h 的 18650 型号锂离子电池^[4]。数据驱动方法通常对预测起点前历史容量衰减数据进行分析,提炼锂离子电池容量衰减的内在规律,建立相应的容量退化模型,再根据建好的模型对预测起点后的容量变化进行预测。预测起点到预测终点的充放电循环次数为剩余使用寿命的预测值,预测起点到实际终点的循环周期数为剩余使用寿命的实际值。

综合国内外现有的基于数据驱动进行锂离子电池 RUL 预测的方法,本文将这些方法大致分为 3 类:基于经验退化模型的方法、基于时间序列的方法和基于多种数据驱动算法融合的方法,如表 1 所示。

表 1 基于数据驱动的锂离子电池 RUL 预测方法

Tab. 1 Data-driven RUL prediction methods for lithium-ion battery

经验退化模型法	时间序列预测法	融合方法
经验预测法	浅层模型	多种数据驱动
滤波预测法	深度学习模型	算法融合

2 基于经验退化模型的预测方法

基于经验退化模型的预测方法根据数据拟合的思想,依赖于历史容量数据,不需考虑锂离子电池内部的电化学反应及失效机制,更易于实现。经验退化模型的方法包括经验预测法和滤波预测法。

2.1 经验预测法

经验预测法认为电池容量衰减与充放电循环次数的规律可以用固定的数学关系描述^[5]。通过建立合理的数学模型,采用循环周期数为输入、电池当前容量为输出的表达式来描述电池的容量衰减轨迹,实现 RUL 预测。目前常用的数学表达式有单指数型^[6]、双指数型^[7]、多项式^[8]、混合型^[9],如表 2 所示。

表 2 常用的电池寿命经验模型数学表达式

Tab. 2 Commonly used mathematical expressions of empirical battery life model

模型	数学表达式	模型参数
单指数模型	$C_k = a_1 \exp(a_2 k)$	a_1, a_2
双指数模型	$C_k = a_1 \exp(a_2 k) + a_3 \exp(a_4 k)$	a_1, a_2, a_3, a_4
多项式模型	$C_k = a_1 k^3 + a_2 k^2 + a_3 k + a_4$	a_1, a_2, a_3, a_4
混合模型	$C_k = a_1 \exp(a_2 k) + a_3 k^2 + a_4$	a_1, a_2, a_3, a_4

表 2 中, C_k 为第 k 次循环时电池的容量, C_0 为新电池的额定容量, $a_1 \sim a_4$ 为模型参数。通过对历史容量数据进行拟合可以获得模型参数,拟合完成后,将失效阈值作为 C_k 代入表达式即可完成对应的 RUL 求解。

一般来说经验预测法方法简单,容易实现。但是由于单纯的数据拟合难以应对电池容量衰退数据波动较大的特点,容易出现过拟合问题,预测结果易发散。

2.2 滤波预测法

该方法是滤波算法与经验预测法的结合,一定

程度上解决了经验预测法单纯依靠数据拟合带来的预测效果不稳定问题。首先建立模型各参数相应的状态空间方程,以双指数模型为例,相应的状态空间方程为

$$\mathbf{x}_n = [a_{1,n} \ a_{2,n} \ a_{3,n} \ a_{4,n}]^T \quad (2)$$

$$\begin{cases} a_{1,n+1} = a_{1,n} + w_{a_{1,n}} \sim N(0, \sigma_{a_1}) \\ a_{2,n+1} = a_{2,n} + w_{a_{2,n}} \sim N(0, \sigma_{a_2}) \\ a_{3,n+1} = a_{3,n} + w_{a_{3,n}} \sim N(0, \sigma_{a_3}) \\ a_{4,n+1} = a_{4,n} + w_{a_{4,n}} \sim N(0, \sigma_{a_4}) \end{cases} \quad (3)$$

式中: \mathbf{x}_n 为状态向量; $w_{a_{i,n}} \sim N(0, \sigma_{a_i})$ 为均值为 0 的噪声; $\sigma_{a_i} \sim \sigma_{a_i}$ 为参数噪声的方差。相应的观测方程为

$$C_{\max,n} = a_1 e^{a_{2,n}} + a_3 e^{a_{3,n}} + v_n \quad v_n \sim N(0, \sigma_v) \quad (4)$$

式中: $C_{\max,n}$ 为第 n 个循环周期的电池最大可用容量; v_n 为均值为 0 的观测噪声; σ_v 为观测噪声的方差。建立状态空间方程后,用滤波算法根据训练集的容量衰退数据对状态空间方程中的状态向量进行更新,获得模型的参数,再将更新好的容量退化模型外推至失效阈值即可完成对 RUL 的预测。

目前常用的滤波类算法包括粒子滤波 PF(particle filter)、卡尔曼滤波 KF(Kalman filter)以及 2 种方法的改进算法。文献[10]采用粒子滤波结合多项式模型估计电池的健康状态并用于预测电池的剩余使用寿命。文献[11]采用无迹卡尔曼滤波 UKF(unscented KF)算法结合双指数模型,更新模型得到预测结果和训练集误差序列,再利用相关向量机回归模型对误差序列进行预测,用误差预测对无迹卡尔曼滤波得到的预测结果进行校正,进一步优化了滤波方法。

虽然滤波方法提高了经验预测法的预测精度,但上述滤波方法过于依赖经验模型的精度,当训练数据较少时预测效果不好,且由于预测阶段无法更新经验模型,导致滤波方法的长期预测精度不高。文献[12]提出了一种基于 F 分布粒子滤波 FPF(F-distribution PF)算法结合核平滑 KS(kernel smoothing)算法的方法,数学模型选择双指数模型。在预测阶段,粒子的权值由 F 核动态更新,而不是一直固定不变,有效解决了粒子退化问题。并通过 KS 算法更新锂离子电池容量退化模型的参数,根据更新

后的模型预测未来的容量。解决了模型参数预测阶段无法更新的问题,提高了滤波算法的长期预测能力。未来,滤波算法应在如何提高长期预测精度方面进行进一步的研究。

3 基于时间序列的预测方法

时间序列方法依靠事物在时间上的延续性,不需要建立具体的经验退化模型,而是从事物过去的变化规律出发,预测事物未来的变化趋势^[13]。锂离子电池容量的退化是一个长期的变化过程,而 RUL 预测就是对未来容量变化趋势的预测,可以采用时间序列方法进行 RUL 预测,具体的表达式为

$$C_{k,n+1} = f(C_{k,n}, C_{k,n-1}, C_{k,n-2}, \dots, C_{k,n-m}) \quad m < n \quad (5)$$

式中: $C_{k,n}$ 为第 n 个周期的锂离子电池最大可用容量。基于时间序列模型 $f(\cdot)$,利用第 $n-m$ 次循环周期到第 n 次循环周期之间的最大可用容量数据可以预测第 $n+1$ 次循环周期的最大可用容量^[14],递推式(5)即可完成后续周期的容量预测。目前常用的时间序列预测方法按照层次结构可以分为浅层和深层 2 种,浅层包括高斯过程回归、支持向量回归、相关向量回归、自回归移动平均等,深层的方法为深度学习方法。

3.1 浅层模型

1) 支持向量回归

支持向量回归 SVR(support vector regression)以统计学理论和结构风险最小化原理为基础,能根据有限的样本信息在复杂模型和学习能力之间寻求最佳折衷。在处理小样本、非线性和时间序列分析等方面表现出明显的优越性^[15]。SVR 通过核函数将输入空间映射到高维的特征空间,利用定义在高维空间中的线性函数进行回归预测^[16],核函数的超参数常通过交叉验证得到。

SVR 在高维空间中进行回归分析时所用的线性回归函数为

$$f(x) = \sum_{i=0}^N (a_i - a_i^*) K(x, x_i) + b \quad (6)$$

式中: a_i, a_i^* 为对偶参数, 对应的样本点为支持向量; b 为偏置项; $K(x, x_i)$ 为核函数。SVR 算法有多个核函数, 对于波动较大或趋势较平缓的容量衰退序列可以选择不同的核函数进行建模预测, 近年来已广泛应用于锂离子电池的 RUL 预测领域。

文献[17]采用粒子群优化 PSO (particle swarm optimization) 算法优化 SVR 参数的方法来预测锂离子电池的剩余使用寿命。文献[18]提出了一种基于人工蜂群 ABC (artificial bee colony) 和支持向量回归 SVR 相结合的算法预测 RUL, 并通过与粒子群优化算法的对比试验证明了 ABC 算法有更好的优化效果。文献[19]采用放电过程的平均电压、放电过程的平均电流和容量作为 SVR 的输入特征, 通过差分演化算法优化 SVR 的参数来进行锂离子电池的 RUL 预测, 并取得了很高的预测精度。文献[20]根据容量和等时间间隔放电电压差建立了 2 个特征, 并采用相空间重构方法重构了 2 个特征的时间序列, 再通过集成经验模态分解 EEMD (ensemble empirical mode decomposition) 对重构的 2 个特征进行数据预处理, 降低了数据噪声的影响。并在训练阶段对训练集产生的误差进行回归建模实现误差补偿, 优化算法选用遗传算法对 SVR 的关键参数进行优化, 实现了 RUL 的预测。

SVR 计算的复杂性取决于支持向量的数目, 而不是样本空间的维数, 在一定程度上避免了维数灾难, 并且能获得较高的预测精度和很好的收敛性。但 SVR 算法的结果为点估计, 缺乏表达预测结果不确定性的能力, 有一定的局限性。

2) 相关向量回归

相关向量回归 RVR (relevant vector regression) 是 Tipping 于 2000 年首先提出的稀疏概率模型, 和 SVR 具有相同的函数形式, 且均是由核函数将低维非线性向高维线性问题转化^[21]。但 RVR 避免了许多 SVR 的缺点, 其超参数不需要通过交叉验证方式得到, 且 RVR 预测结果以概率输出可以表达结果的不确定性。文献[22]提出了基于增量优化 RVR 的剩余使用寿命在线预测方法, 在线预测阶段只将相关向量和新的在线容量数据组成新的训练数据集。降

低了计算复杂度, 提高了 RVR 模型的预测能力。文献[23]提出了一种融合多个核函数构建相关向量回归预测模型的方法, 提高了模型的预测性能, 并将该方法应用于锂离子电池 RUL 预测。多核函数表达式为

$$\begin{cases} K_1(\mathbf{x}, \mathbf{z}) = \mathbf{x}^T \mathbf{z} + c \\ K_2(\mathbf{x}, \mathbf{z}) = (\alpha \mathbf{x}^T \mathbf{z} + c)^d \\ K_3(\mathbf{x}, \mathbf{z}) = \tanh(\alpha \mathbf{x}^T \mathbf{z} + c) \\ K_4(\mathbf{x}, \mathbf{z}) = \exp\left(-\frac{\|\mathbf{x} - \mathbf{z}\|^2}{2\sigma^2}\right) \end{cases} \quad (7)$$

$$K(\mathbf{x}, \mathbf{z}) = \omega_1 K_1(\mathbf{x}, \mathbf{z}) + \omega_2 K_2(\mathbf{x}, \mathbf{z}) + \omega_3 K_3(\mathbf{x}, \mathbf{z}) + \omega_4 K_4(\mathbf{x}, \mathbf{z}) \quad (8)$$

式中, $\omega_1, \omega_2, \omega_3, \omega_4$ 为每个核函数的权重系数。以容量数据为训练集对多个核函数线性组合的系数进行优化, 实验结果证明了多核相关向量回归预测方法优于单核相关向量回归。

RVR 算法计算复杂度较低, 能够进行点估计和区间估计, 但是 RVR 算法相关向量比较稀疏, 且锂离子电池容量数据波动较大, 进行长期预测时预测结果容易受容量再生现象的影响。

3) 自回归模型

自回归 AR (auto-regressive) 模型及其变体属于时间序列分析的一种算法, 是统计学上一种处理时间序列的方法。该方法是用自身做回归变量的过程, 即利用某时刻前若干时刻随机变量的线性组合来描述某时刻随机变量的线性回归模型^[24], 计算复杂度低。文献[25]为了提高 AR 模型对锂离子电池容量衰退变化的预测能力, 提出了非线性退化自回归 ND-AR (nonlinear degradation-AR) 时间序列模型用于锂离子电池的 RUL 预测, 并通过结合 PF 算法实现了区间估计。文献[26]将自回归滑动平均模型的变体自回归差分滑动平均 ARIMA (auto-regressive integrated moving average) 模型用于锂离子电池的寿命预测中。首先采用经验模态分解将电池容量退化趋势分解, 对不同序列分别预测, 再对各子层预测结果求和进而预测出锂离子电池的 RUL。

虽然 AR 模型及其变种模型具有计算简单、方便实现等特点。但当数据量较少时, 预测效果比较

低,容易受容量再生现象影响,因此长期预测效果不理想。而且该算法为点估计,不能对结果进行不确定性表达。

4) 高斯过程回归

高斯过程回归 GPR(Gaussian process regression)是一种建立在贝叶斯框架下的统计学习方法,通过学习样本确定核函数中超参数^[27]。高斯过程回归将电池容量衰退序列视为概率分布序列,与其他数据驱动方法相比,GPR 可以给出预测结果的区间估计,对于线性或非线性系统都有较强的预测能力。

文献[28]提出了一种基于高斯过程混合 GPM(Gaussian process mixture)的 RUL 预测方法。分别将不同的容量轨迹与不同的 GPR 模型拟合,可以很好地处理多模态问题。并与 SVR 算法进行了 RUL 预测的对比实验,结果表明,该方法具有更高的预测精度。文献[29]利用增量容量分析 ICA(incremental capacity analysis)提取的特征变量,采用 GPR 算法对电池 SOH 进行估计建模。并用 SOH 估计值建立了电池 RUL 的自回归长期预测模型。通过 4 组不同试验条件下的电池寿命数据,验证了模型的有效性。文献[30]提出了一种基于深度高斯过程回归的锂离子电池 RUL 预测方法。深度高斯过程回归 DGPR(deep-GPR)是将单个 GPR 堆叠再进行构建的算法,使得该算法进一步增强了 GPR 算法已有的预测能力和表示能力。使用电压、温度和电流等形式的时间序列数据进行容量估计,取得了很好的预测效果。

GPR 算法能够实现 RUL 的区间估计,对于容量的短期预测有很好的效果。但当数据量增大时 GPR 的计算复杂度较高,对长寿命周期电池预测精度不高,同时核函数超参数选取对结果影响较大。

3.2 深度学习模型

浅层方法虽然在锂离子电池 RUL 预测上取得了一定的成果,但是其中大多早期预测效果不好。当处理大批量长寿命周期电池数据时,浅层方法往往会出现泛化能力不强^[31],预测精度低等问题。深度学习方法具有较强的学习能力^[32],结合其处理大数据的优势,近年来开始逐渐应用于锂离子电池

RUL 预测领域。

文献[33]提出了一种基于前馈神经网络 FFNN(feed forward neural network)和重要性采样 IS(importance sampling)结合的方法。采用不同循环次数充电过程中的端电压差异作为特征,来描述锂离子电池的 RUL。在 FFNN 输入选择中,采用 IS 算法来合理减少输入神经元的数量来进行 FFNN 的输入选择,实现 RUL 的预测。文献[34]提出了由长短期记忆 LSTM(long short-term memory)递归神经网络 RNN(recurrent neural network)来预测电池的容量退化趋势。LSTM 网络结构能够学习长期依赖,可以有效地存储和更新容量退化数据中的关键信息。采用了弹性均方反向传播 RMSprop(root mean square propagation)技术对所构建的神经网络进行训练,通过引入 Dropout 技术解决过拟合问题,并结合蒙特卡洛 MC(Monte Carlo)方法给出预测结果的概率密度函数 PDF(probability density function)。通过实验对比,证明了在有一些离线数据的情况下,所构建的 LSTM-RNN 可以比 SVR、PF 更早地进行准确的 RUL 预测。文献[35]设计了一种改进型 LSTM 神经网络。首先在输入门和遗忘门加入了固定连接耦合,使得新旧信息可以同时选择,提高了网络性能。另外在输出门加入一个常量误差传递 CEC(constant error carousel)的直接连接,以屏蔽不需要的错误信号。在输入上采用温度、电流、电压、采样时间和容量的组合,考虑了不同特征和容量的相关性,实验结果表明该方法有很好的预测效果。文献[36]提出了一个深度学习结合迁移学习和集成学习预测 RUL 的方法,具体采用了扩张卷积神经网络 DCNN(dilated convolutional neural network)进行 RUL 预测,DCNN 将 CNN 每一层的膨胀大小加倍,为 RUL 预测创造足够的接受域。首先将不同源数据集中训练好的 DCNN 模型参数迁移到新的模型中,再将迁移好的各模型集成,建立一个集成模型。这种迁移、集成的方法能够有效地利用源数据集获得的知识,提高使用相对较小的训练数据集在目标任务中学习的能力。

深度学习算法通过学习一种深层非线性网络

结构,来实现复杂函数逼近,可以有效地学习容量退化序列中的关键信息。其中,LSTM 的长短时记忆结构能够学习容量序列中的长期依赖信息,对于电池寿命中后期的 RUL 预测有很好的预测效果,提高了预测的准确性和鲁棒性。另外,在有一些离线数据的情况下,深度学习可以比传统数据驱动方法更早地进行准确的 RUL 预测。但深度学习算法要求较高的硬件资源,运行时间长,参数优化也相对复杂且无法实现区间估计。未来的深度学习算法可以在如何提高收敛速度,减少训练时间和实现区间估计上做进一步研究。

4 基于数据驱动的融合方法

基于数据驱动的融合方法即多种数据驱动预测方法的结合,充分发挥各方法的优势,通过多种方法的结合来克服单一方法的缺点,获得更佳的预测效果。目前,基于数据驱动的融合方法主要有滤波算法与时序预测方法的融合,或者多种时序预测算法的融合。

4.1 基于滤波算法与时序预测的融合方法

文献[37]提出了一种结合自适应无迹卡尔曼滤波 AUKF(adaptive unscented Kalman filter)和遗传算法优化支持向量回归 GA-SVR(genetic algorithm support vector regression)的综合算法。选择双指数状态空间模型来描述锂离子电池的容量退化。采用 AUKF 方法对双指数状态空间模型进行自适应更新,然后利用遗传算法优化的 SVR 对 AUKF 训练过程中的残差进行时序预测。滤波方法的预测结果和对应的残差预测结果之和即为容量的预测值,实验结果证明了方法具有很高的预测精度。文献[38]结合了 KF 和 RVR 算法,利用 KF 对 RVM 输出进行优化滤波。利用每个周期的预测值更新训练数据集,对模型进行再训练,进而实现锂离子电池容量的迭代预测。文献[39]采用 RVR 和 PF 结合的方法来构建电池容量退化模型进行 RUL 预测,首先采用 RVR 对容量退化数据进行训练并预测,之后根据训练集数据和 RVR 的预测数据更新 PF 模型的

初始参数,再用 PF 算法根据训练数据进行预测。通过 2 种方法的结合可以在提高预测精度的同时减少训练集数据量。

4.2 基于多种时序预测算法的融合方法

文献[40]集成了 SVR、RVR、RNN 等时序预测算法,将多种算法加权结合,提出了基于精度的加权、基于分集的加权和基于优化的加权 3 种加权方案来确定各算法的权重。采用 k 倍交叉验证 CV (cross validation) 选取最优的加权方案,并验证了加权集成方法可以给出更精确的 RUL 预测。文献[41]提出了 Elman 神经网络与 LSTM 网络 2 种时序预测结合的方法预测电池的 RUL。首先采用经验模态分解 EMD(empirical mode decomposition)算法,将记录的电池容量-周期数据分解为若干子层,然后分别用 LSTM 和 Elman 神经网络预测其中的高频和低频子层,再对不同子层的预测结果求和,实现了电池 RUL 的融合预测。

基于融合的 RUL 预测方法利用各方法的优势,极大地提高了 RUL 的预测精度和预测时间,加强了预测模型的泛化能力,成为了目前较高水平的 RUL 预测方法。但仍要面临其复杂的参数、较大的计算量和融合的不确定性等挑战。

5 基于数据驱动的 RUL 预测方法对比

表 3 为基于数据驱动的 RUL 预测各方法优缺点对比。

总体而言,目前各种基于数据驱动的 RUL 预测虽然取得一定的效果,但各方法尚有需要完善的不足。基于经验退化模型的方法依赖相应的数学模型,实现简单、算法复杂度低、运行时间短,其中滤波算法可以给出 RUL 预测的区间估计,即预测结果的不确定表达,但是经验退化模型需要大量的训练数据才能建立预测效果好的数学模型。基于时序的预测方法中,浅层模型大多复杂度较低,算法运行时间短,其中 RVR、GPR 算法可以给出预测结果的区间估计,但对于大样本电池数据往往泛化能力不强。深层模型对于不同寿命时期的电池 RUL 预

测均有很好的效果,可以解决浅层模型泛化能力差的问题。不过深层模型的参数优化复杂,运行时间较长,无法给出区间估计,且依赖大量的训练数据。

融合模型结合了多种方法的优点,可以在一定程度上弥补单一方法出现的问题,但是同时也面临方法结合带来的算法复杂度高、运行时间长等问题。

表 3 基于数据驱动的锂离子电池 RUL 预测方法优缺点

Tab. 3 Advantages and disadvantages of data-driven RUL prediction methods for lithium-ion batteries

RUL 预测方法	优点	缺点
经验预测法	方法简单;可实现性强	依赖训练数据量;预测效果不稳定;无法给出区间估计
滤波预测法	短期预测效果强;可以给出区间估计	过于依赖经验模型的精度;长期预测效果不佳
SVR	训练速度较快;易解决小样本预测	核函数参数的选择对预测结果影响大;无法获得区间估计
RVR	能进行区间估计;预测运行时间短	训练时间长;长期预测效果不佳
AR	方法简单容易实现	长期预测精度低;无法给出区间估计
GPR	可以给出区间估计;小样本预测效果较好	计算复杂度高;依赖超参数的选取
深度学习	学习能力强;泛化能力强;长、短寿命周期电池均适用	算法复杂度高;运行时间长;无法给出区间估计
融合模型	融合多种预测算法的优点	参数复杂,计算量大

6 未来发展趋势

针对目前数据驱动方法应用在锂离子电池 RUL 预测中的缺陷的进一步研究,本文提出建议如下。

(1)锂离子电池容量衰退过程中会发生复杂的容量再生现象导致对于容量的长期多步预测非常困难。以上多数 RUL 预测方法缺乏对容量数据的预处理过程。未来应针对容量再生现象研究合适的预处理方法,克服其对 RUL 长期预测的影响。

(2)未来关于锂离子电池 RUL 预测的研究可以借鉴其他领域中的相关方法,分析其在锂离子电池 RUL 预测领域的可行性,如视觉图像领域中的注意力机制。

(3)现有的关于 RUL 预测的方法大多只能在中后期取得比较好的效果,不能完成关于 RUL 的早期预测,未来需要研究合适的方法可以在减少训练数据量的同时完成对 RUL 的高精度预测。

(4)目前的研究主要集中在单体电池上,但在实际应用中大多数情况采用的是电池组。为了使电池寿命预测在实际应用中发挥更大的价值,应将电池组的情况考虑进去。

7 结语

随着锂离子电池在新能源、电动汽车等多个领

域中的快速应用,电池的剩余使用寿命预测技术已经成为了这些领域中的研究热点。数据驱动方法无需考虑电池内部复杂的化学变化,易于建模实现。本文详细阐述了锂离子电池 RUL 的概念,总结了近几年国内外基于数据驱动方法对锂离子电池 RUL 预测的相关研究,分析了各方法的优缺点,并提出了未来 RUL 预测领域需要解决的问题,旨在为相关领域研究人员提供参考和借鉴。

参考文献:

[1] 罗伟林, 张立强, 吕超, 等. 锂离子电池寿命预测国外研究现状综述[J]. 电源学报, 2013, 11(1): 140-144.
Luo Weilin, Zhang Liqiang, Lü Chao, et al. Review on foreign status of life prediction of lithium-ion batteries [J]. Journal of Power Supply, 2013, 11(1): 140-144 (in Chinese).

[2] 刘大同, 周建宝, 郭力萌, 等. 锂离子电池健康评估和寿命预测综述[J]. 仪器仪表学报, 2015, 36(1): 1-16.
Liu Datong, Zhou Jianbao, Guo Limeng, et al. Survey on lithium-ion battery health assessment and cycle life estimation [J]. Chinese Journal of Scientific Instrument, 2015, 36(1): 1-16 (in Chinese).

[3] 戴海峰, 张艳伟, 魏学哲, 等. 锂离子电池剩余寿命预测研究[J]. 电源技术, 2019, 43(12): 2029-2035.
Dai Haifeng, Zhang Yanwei, Wei Xuezhe, et al. Review of remaining useful life prediction for lithium ion battery [J]. Chinese Journal of Power Sources, 2019, 43(12): 2029-2035

- (in Chinese).
- [4] Saha B, Goebel K. Battery data set, National Aeronautics and Space Administration(NASA) ames prognostics data repository [R]. Moffett Field, CA,USA, 2007.
 - [5] 熊瑞. 动力电池管理系统核心算法[M]. 北京: 机械工业出版社, 2018.
Xiong Rui. Power battery management system core algorithm [M]. Beijing: China Machine Press, 2018 (in Chinese).
 - [6] Wang Dong, Yang Fangfang, Tsui K L, et al. Remaining useful life prediction of lithium-ion batteries based on spherical cubature particle filter [J]. IEEE Transactions on Instrumentation and Measurement, 2016, 65: 1282-1291.
 - [7] He Wei, Williard N, Osterman M, et al. Prognostics of lithium-ion batteries based on Dempster-Shafer theory and the Bayesian Monte Carlo method [J]. Journal of Power Sources, 2011, 196(23): 10314-10321.
 - [8] Li Sai, Fang Huajing, Shi Bing. Remaining useful life estimation of lithium-ion battery based on interacting multiple model particle filter and support vector regression [J]. Reliability Engineering & System Safety, 2021, 210: 107542.
 - [9] Xing Yinjiao, Ma E, Tsui K L, et al. An ensemble model for predicting the remaining useful performance of lithium-ion batteries [J]. Microelectronics Reliability, 2013, 53(6): 811-820.
 - [10] Micea M V, Ungurean L, Carstoiu G N, et al. Online state-of-health assessment for battery management systems [J]. IEEE Transactions on Instrumentation and Measurement, 2011, 60(6): 1997-2006.
 - [11] Chang Yang, Fang Huajing, Zhang Yong. A new hybrid method for the prediction of the remaining useful life of a lithium-ion battery [J]. Applied Energy, 2017, 206: 1564-1578.
 - [12] Zhang Kai, Zhao Peng, Sun Canfei, et al. Remaining useful life prediction of aircraft lithium-ion batteries based on F-distribution particle filter and kernel smoothing algorithm [J]. Chinese Journal of Aeronautics, 2020, 33(5): 1517-1531.
 - [13] Lin C P, Cabrera J, Yang Fangfang, et al. Battery state of health modeling and remaining useful life prediction through time series model [J]. Applied Energy, 2020, 275: 115338.
 - [14] Chen Lin, An Jingjing, Wang Huimin, et al. Remaining useful life prediction for lithium-ion battery by combining an improved particle filter with sliding-window gray model [J]. Energy Reports, 2020, 6: 2086-2093.
 - [15] Zhao Qi, Qin Xiaoli, Zhao Hongbo, et al. A novel prediction method based on the support vector regression for the remaining useful life of lithium-ion batteries [J]. Microelectronics Reliability, 2018, 85: 99-108.
 - [16] Patil M A, Tagade P, Hariharan K S, et al. A novel multi-stage support vector machine based approach for Li ion battery remaining useful life estimation [J]. Applied Energy, 2015, 159: 285-297.
 - [17] Qin Taichun, Zeng Shengkui, Guo Jianbin. Robust prognostics for state of health estimation of lithium-ion batteries based on an improved PSO-SVR model [J]. Microelectronics Reliability, 2015, 55(9/10): 1280-1284.
 - [18] Wang Yingzhou, Ni Yulong, Lu Shuai, et al. Remaining useful life prediction of lithium-ion batteries using support vector regression optimized by artificial bee colony [J]. IEEE Transactions on Vehicular Technology, 2019, 68(10): 9543-9553.
 - [19] Wang F K, Mamo T. A hybrid model based on support vector regression and differential evolution for remaining useful lifetime prediction of lithium-ion batteries [J]. Journal of Power Sources, 2018, 401: 49-54.
 - [20] Chen Liaogehao, Zhang Yong, Zheng Ying, et al. Remaining useful life prediction of lithium-ion battery with optimal input sequence selection and error compensation [J]. Neurocomputing, 2020, 414: 245-254.
 - [21] Li Hong, Pan Donghui, Chen C L P. Intelligent prognostics for battery health monitoring using the mean entropy and relevance vector machine [J]. IEEE Transactions on Systems, Man, and Cybernetics: Systems, 2014, 44(7): 851-862.
 - [22] Liu Datong, Zhou Jianbao, Pan Dawei, et al. Lithium-ion battery remaining useful life estimation with an optimized relevance vector machine algorithm with incremental learning [J]. Measurement, 2015, 63: 143-151.
 - [23] 刘月峰, 赵光权, 彭喜元. 多核相关向量机优化模型的锂电池剩余寿命预测方法[J]. 电子学报, 2019, 47(6): 1285-1292.
Liu Yuefeng, Zhao Guangquan, Peng Xiyuan. A lithium-ion battery remaining using life prediction method based on multi-kernel relevance vector machine optimized model [J]. Acta Electronica Sinica, 2019, 47(6): 1285-1292 (in Chinese).
 - [24] Kozłowski J D. Electrochemical cell prognostics using on-line impedance measurements and model-based data fusion

- techniques [C]// 2003 IEEE Aerospace Conference Proceedings (Cat. No.03TH8652). Big Sky, MT, USA, 2003: 3257-3270.
- [25] Liu Datong, Luo Yue, Liu Jie, et al. Lithium-ion battery remaining useful life estimation based on fusion nonlinear degradation AR model and RPF algorithm [J]. Neural Computing and Applications, 2014, 25(3): 557-572.
- [26] Zhou Yapeng, Huang Miaohua. Lithium-ion batteries remaining useful life prediction based on a mixture of empirical mode decomposition and ARIMA model [J]. Microelectronics Reliability, 2016, 65: 265-273.
- [27] Li Xiaoyu, Yuan Changgui, Wang Zhenpo. Multi-time-scale framework for prognostic health condition of lithium battery using modified Gaussian process regression and nonlinear regression [J]. Journal of Power Sources, 2020, 467: 228358.
- [28] Li Lingling, Wang Pengchong, Chao K H, et al. Remaining useful life prediction for lithium-ion batteries based on Gaussian processes mixture [J]. PLoS One, 2016, 11(9): e0163004.
- [29] Li Xiaoyu, Wang Zhenpo, Yan Jinying. Prognostic health condition for lithium battery using the partial incremental capacity and Gaussian process regression [J]. Journal of Power Sources, 2019, 421: 56-67.
- [30] Tagade P, Hariharan K S, Ramachandran S, et al. Deep Gaussian process regression for lithium-ion battery health prognosis and degradation mode diagnosis [J]. Journal of Power Sources, 2020, 445: 227281.
- [31] Yang Hao, Wang Penglei, An Yabin, et al. Remaining useful life prediction based on denoising technique and deep neural network for lithium-ion capacitors [J]. eTransportation, 2020, 5: 100078.
- [32] Sheng Shen, Sadoughi M, Chen Xiangyi, et al. A deep learning method for online capacity estimation of lithium-ion batteries [J]. Journal of Energy Storage, 2019, 25: 100817.
- [33] Ji Wu, Zhang Chenbin, Chen Zonghai. An online method for lithium-ion battery remaining useful life estimation using importance sampling and neural networks [J]. Applied Energy, 2016, 173: 134-140.
- [34] Zhang Yongzhi, Xiong Rui, He Hongwen, et al. Long short-term memory recurrent neural network for remaining useful life prediction of lithium-ion batteries [J]. IEEE Transactions on Vehicular Technology, 2018, 67(7): 5695-5705.
- [35] Li Penghua, Zhang Zijian, Xiong Qingyu, et al. State-of-health estimation and remaining useful life prediction for the lithium-ion battery based on a variant long short term memory neural network [J]. Journal of Power Sources, 2020, 459: 228069.
- [36] Sheng S A, Ms A, Meng L A, et al. Deep convolutional neural networks with ensemble learning and transfer learning for capacity estimation of lithium-ion batteries [J]. Applied Energy, 2020, 260: 114296.
- [37] Xue Zhiwei, Zhang Yong, Cheng Cheng, et al. Remaining useful life prediction of lithium-ion batteries with adaptive unscented Kalman filter and optimized support vector regression [J]. Neurocomputing, 2020, 376: 95-102.
- [38] Song Yuchen, Liu Datong, Hou Yandong, et al. Satellite lithium-ion battery remaining useful life estimation with an iterative updated RVM fused with the KF algorithm [J]. Chinese Journal of Aeronautics, 2018, 31(1): 31-40.
- [39] Zhang Yongzhi, Xiong Rui, He Hongwen, et al. Validation and verification of a hybrid method for remaining useful life prediction of lithium-ion batteries [J]. Journal of Cleaner Production, 2019, 212: 240-249.
- [40] Yang Wenan, Xiao Maohua, Zhou Wei, et al. A hybrid prognostic approach for remaining useful life prediction of lithium-ion batteries [J]. Shock and Vibration, 2016, 2016: 1-15.
- [41] Li Xiaoyu, Zhang Lei, Wang Zhenpo, et al. Remaining useful life prediction for lithium-ion batteries based on a hybrid model combining the long short-term memory and Elman neural networks [J]. Journal of Energy Storage, 2019, 21: 510-518.



张若可

作者简介:

张若可(1996-),男,中国电源学会会员,硕士研究生。研究方向:锂离子电池剩余寿命预测。E-mail:350296469@qq.com。

郭永芳(1979-),女,通信作者,博士,副教授。研究方向:智能算法,锂离子电池建模与状态估计。E-mail:guoyongfang@hebut.edu.cn。

余湘媛(1998-),女,硕士研究生。研究方向:锂离子电池健康状态估计。E-mail:yuxiangyuan0503@163.com。

胡晓亚(1996-),女,硕士研究生。研究方向:锂离子电池健康状态估计。E-mail:1786818967@qq.com。