

分类号 TM911.42

密 级 公开

UDC 621.3

学校代码 10500



湖北工业大学  
HUBEI UNIVERSITY OF TECHNOLOGY

# 硕士学位论文

(学历教育-学术硕士)

题 目：基于深度学习的燃料电池系统故障监测与诊断研究

英文题目：A Study on the Fault Monitoring and Diagnosis of Fuel  
Cell System Based on Deep Learning

学位申请人姓名：乐有生

申请学位学科专业：电机与电器

指导教师姓名：全睿

二零二二年六月

分类号 TM911.42

密 级 公开

UDC 621.3

学校代码 10500



湖北工业大学  
HUBEI UNIVERSITY OF TECHNOLOGY

# 硕士学位论文

题 目 基于深度学习的燃料电池系统故障监测与诊断研究

英文题目 A Study on the Fault Monitoring and Diagnosis of Fuel

Cell System Based on Deep Learning

研究生姓名（签名） 乐有生

指导教师姓名（签名） 王岩 职 称 副教授

申请学位学科名称 电机与电器 学科代码 080801

论文答辩日期 2022 年 5 月 24 日 学位授予日期 2022 年 6 月

学院负责人 张晓星

评阅人姓名 单振宇 评阅人姓名 李振兴

2022 年 6 月 30 日

# 湖北工业大学

## 学位论文原创性声明和使用授权说明

### 原创性声明

本人郑重声明：所呈交的学位论文，是本人在导师指导下，独立进行研究工作所取得的成果。除文中已经标明引用的内容外，本论文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出贡献的个人和集体，均已在文中以明确方式标明。本声明的法律结果由本人承担。

学位论文作者签名：乐有生

日期：2022年6月30日

### 学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，即：学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权湖北工业大学可以将本学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

学位论文作者签名：乐有生

指导教师签名：王岩

日期：2022年6月30日

日期：2022年6月30日

## 摘要

燃料电池是一种将化学能直接转换为电能的发电装置，具有较好的发展前景。燃料电池系统结构复杂，运行工况多变，在工作中可能出现故障，严重情况下可能导致燃料电池电堆损坏。为了更好地从燃料电池系统实际运行的海量数据中挖掘故障信息，提高燃料电池系统的安全可靠性，本文采用深度学习方法开展其故障监测与诊断工作。本文的主要研究内容有：

(1)根据采集到的燃料电池系统时序数据，设计了一个长短期记忆(Long Short-Term Memory, LSTM)网络模型，采用 RMSprop 算法进行训练，对燃料电池系统的输出电压进行预测，根据燃料电池系统的实际电压与网络模型预测电压的残差值判断系统是否存在故障。通过与其它神经网络模型的对比发现，在进行燃料电池系统故障监测时长短期记忆网络的参数规模比全连接网络的参数规模更小，相比简单的循环神经网络，长短期记忆网络的预测性能更好。

(2)利用先进的神经网络设计方法对长短期记忆网络模型进行了改进。一种是在网络中引入残差学习机制构建残差-长短期记忆网络(Residual Network with Long Short-Term Memory, Res-LSTM), 另一种是引入聚合残差变换的设计思想，构建聚合残差变换的残差-长短期记忆网络(ResNeXt-LSTM)。其中，残差-长短期记忆网络通过堆叠残差块实现，残差块被拆分为残差函数和恒等映射，残差函数由长短期记忆网络实现，而恒等映射由输入通过短路连接实现；在构建聚合残差变换的残差-长短期记忆网络时，将残差-长短期记忆网络的残差函数重新设计为多路拓扑结构相同的残差变换的聚合形式。结果表明，相比 LSTM 网络，在均方差损失函数和预测误差标准差等指标上，Res-LSTM 模型和 ResNeXt-LSTM 模型的预测性能更好，Res-LSTM 模型的训练也更高效，有利于提高燃料电池系统的故障监测性能。

(3)针对燃料电池系统的燃料电池电堆故障、空气供给系统故障、氢气供给系统故障三种故障类型，利用测试台架中获取的数据提出基于 Res-LSTM 模型的故障诊断方法。采用 RMSprop 算法训练的 Res-LSTM 模型在测试集进行测试可以达到 0.9934 的故障诊断准确率。与其它网络对比结果表明，在所选取的数据集上 Res-LSTM 模型的故障分类准确率比 LSTM 网络模型高，其计算量也比 ResNeXt-LSTM 模型小，达到了预期效果。

**关键词：**燃料电池，故障监测与诊断，长短期记忆网络，残差学习，聚合残差变换

## Abstract

The fuel cell is a power generation device that directly converts chemical energy into electrical energy, and has a good development prospect. The fuel cell system has a complex structure and variable operating conditions, and may fail during operation, which may lead to damage to the fuel cell stack in severe cases. In order to better mine the fault information from the massive data of the actual operation of the fuel cell system and improve the safety and reliability of the fuel cell system, this paper adopts the deep learning methods to carry out the fault monitoring and diagnosis of the fuel cell system. The main research contents of this paper are:

(1) According to the collected time series data of the fuel cell system, a Long Short-Term Memory (LSTM) network model is designed, and is trained by the RMSprop algorithm to predict the output voltage of the fuel cell system. According to the voltage residual value between the actual voltage of the fuel cell system and the predicted voltage of the network, it is judged whether there is a fault in the system. The comparison shows that the parameter scale of LSTM network is smaller than that of the fully connected network. Compared with the simple recurrent neural network, the prediction performance of the LSTM network is better.

(2) The LSTM network model is improved by using advanced neural network design methods. One is to introduce a residual learning mechanism into the network to build a Residual Network with Long Short-Term Memory (Res-LSTM), and the other is to introduce the design idea of aggregated residual transformations to rebuild a residual network with long short-term memory, called ResNeXt-LSTM. The Res-LSTM model is implemented by stacking residual blocks, and the residual block is divided into residual function and identity mapping. The residual function is implemented by the LSTM network, and the identity mapping is realized by shortcut connection. When constructing the ResNeXt-LSTM, the residual function is redesigned into an aggregated form of residual transformations with the same multi-path topology. The results show that, compared with the LSTM network, the Res-LSTM and the ResNeXt-LSTM have better prediction performance in terms of mean square error loss and standard deviation of prediction error, and the Res-LSTM model is also trained more efficiently. It is beneficial to improve the fault monitoring performance of the fuel cell system.

(3) For the fuel cell stack fault, air supply system fault, and hydrogen supply system fault of the fuel cell system, a fault diagnosis method based on the Res-LSTM model is proposed using the data obtained in the test bench. The Res-LSTM model trained by the RMSprop algorithm can achieve a fault diagnosis accuracy of 0.9934 in the test set. The comparison results with other networks show that the fault classification accuracy of the Res-LSTM model is higher than that of the LSTM network model on the selected dataset, and its computational amount is also smaller than that of the ResNeXt-LSTM model, which achieves the expected goal.

**Keywords:** fuel cell, fault monitoring and diagnosis, long short-term memory network, residual learning, aggregated residual transformations

## 目录

摘要 .....	I
Abstract .....	II
目录 .....	III
第 1 章 绪论 .....	1
1.1 课题研究背景及意义 .....	1
1.2 国内外研究现状 .....	2
1.2.1 燃料电池故障诊断研究现状 .....	2
1.2.2 深度学习在燃料电池系统故障诊断研究现状 .....	4
1.3 本文研究内容和结构安排 .....	5
第 2 章 燃料电池系统深度学习故障监测与诊断方案 .....	7
2.1 质子交换膜燃料电池系统组成与故障分类 .....	7
2.2 基于深度学习的燃料电池系统故障监测与诊断方法 .....	8
2.2.1 数据提取与预处理 .....	9
2.2.2 基于深度学习的燃料电池系统故障监测与诊断总体流程 .....	13
2.2.3 深度学习算法开发语言及框架选取 .....	15
2.3 本章小结 .....	16
第 3 章 基于 LSTM 网络的燃料电池系统故障监测 .....	17
3.1 时序数据与循环神经网络 .....	17
3.2 长短期记忆网络结构 .....	18
3.3 基于 LSTM 网络的燃料电池系统故障监测 .....	20
3.3.1 LSTM 网络结构配置与训练 .....	21
3.3.2 燃料电池系统故障监测结果分析 .....	23
3.4 本章小结 .....	28
第 4 章 基于改进 LSTM 网络的燃料电池系统故障监测 .....	29
4.1 基于残差-长短期记忆网络的燃料电池系统故障监测 .....	29
4.1.1 残差学习及残差-长短期记忆网络 (Res-LSTM) .....	29
4.1.2 Res-LSTM 模型结构配置与训练 .....	33
4.1.3 基于 Res-LSTM 模型的燃料电池系统故障监测性能分析 .....	36
4.2 基于 ResNeXt-LSTM 模型的燃料电池系统故障监测 .....	41

# 湖北工业大学硕士学位论文

4.2.1 聚合残差变换的残差网络 .....	41
4.2.2 聚合残差变换的残差-长短期记忆网络 (ResNeXt-LSTM) .....	43
4.2.3 基于 ResNeXt-LSTM 模型的燃料电池系统故障监测性能分析 .....	45
4.3 本章小结 .....	51
第 5 章 基于 Res-LSTM 模型的燃料电池系统故障诊断 .....	53
5.1 燃料电池系统故障诊断问题分析 .....	53
5.2 Res-LSTM 故障诊断模型的结构配置和训练 .....	55
5.3 基于 Res-LSTM 模型的故障诊断性能测试 .....	58
5.3.1 Res-LSTM 模型的故障诊断结果 .....	58
5.3.2 Res-LSTM 模型和其它模型的故障诊断性能比较 .....	59
5.4 本章小结 .....	60
第 6 章 总结与展望 .....	61
6.1 总结 .....	61
6.2 展望 .....	62
参考文献 .....	64
致谢 .....	68
附录 .....	69

第 1 章 绪论

1.1 课题研究背景及意义

物质、能量和信息是构成自然界的基本要素。固体燃料、液体燃料和气体燃料统称为化石燃料或化石能源。传统常规化石能源属于非可再生能源。随着经济社会的发展，广泛使用化石能源造成的能源紧张、油价攀升和环境污染等问题日益严重突出，研究开发新型可再生能源成为重要的发展方向。

氢燃料电池是一种利用燃料氢气与氧气的氧化还原反应将化学能转化为电能的清洁能源装置。氢气发生化学反应的产物是水，燃料电池释放电能的过程中没有氮氧化物和硫氧化物等排放，因此其对环境友好。氢燃料电池中研究和使用的最广泛的是质子交换膜燃料电池，也称为聚合物电解质膜燃料电池，其是一种性能较优的氢燃料电池。质子交换膜燃料电池具有能量转换效率高、零排放或低排放、工作温度低、功率密度大和启动快速等特点<sup>[1]</sup>，在新能源汽车、轨道交通和固定电源等领域具有较好的应用价值<sup>[1,2]</sup>。质子交换膜燃料电池系统的组成结构如图 1.1 所示，整个系统包含氢气供给系统、空气供给系统、水热管理系统和燃料电池电堆等。

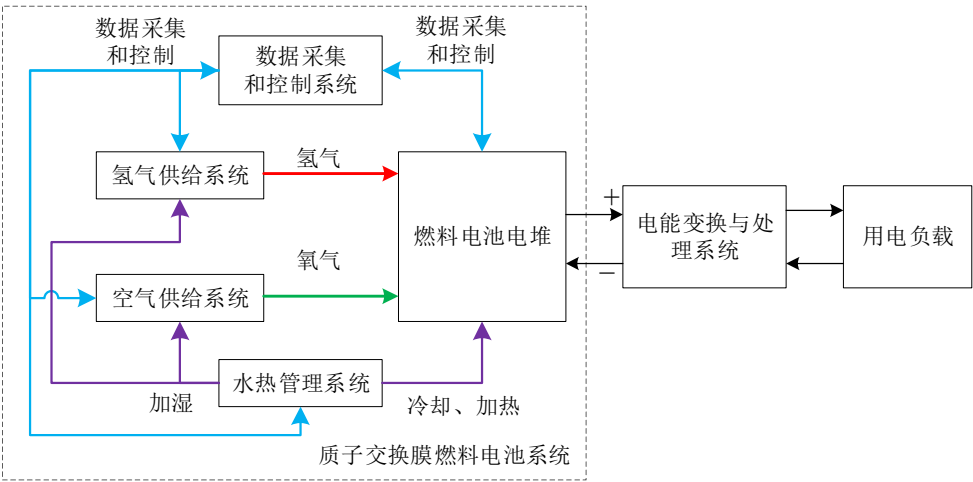


图 1.1 质子交换膜燃料电池系统结构示意图

质子交换膜燃料电池属于一种低温燃料电池，虽然相较于其它燃料电池，其性能较优且复杂度较低，但就其自身而言，质子交换膜燃料电池及其系统构成仍然较为复杂。作为一个多输入多输出的非线性强耦合系统，其内部运行机理涉及流体力学、材料学、电子学和电化学等，具有多学科交叉融合的特点，系统执行器、传感器和控制器较多，且多属于精密器件，整体控制也较为复杂，在实验调试和实际应



用的过程中出现故障的可能性较高。这些故障可能引发系统性能衰减甚至缩短燃料电池电堆使用寿命,严重情况下甚至造成电池电堆永久损毁失效。除了降低成本和提高其耐久性之外,质子交换膜燃料电池的故障监测和诊断已成为亟待解决的问题,也是重要的研究方向。

随着智能技术的发展,现代设备的监测与管理随着大量、多系统和高维度数据的不断增长日趋复杂。传统的故障监测与诊断方法难以从大量的高维度数据中有效建立数据模型,无法挖掘数据的有效信息,在应用中的局限性也越来越明显。从数据中自动学习隐藏规律的深度学习方法能够处理大量高维度的数据,已成为一种有效的故障监测与诊断方法,受到研究人员广泛的关注。深度学习(Deep Learning)近年来获得了迅速的发展,在人工智能的很多子领域取得了巨大的成功。深度学习方法具有强大的学习能力,提供了一种建立数据模型并从数据中挖掘有效信息的方法,可以从设备的历史运行数据中获取有关的故障信息。因此,探索将深度学习技术应用于质子交换膜燃料电池系统的故障监测与诊断对于解决燃料电池可靠性差和寿命短等不足有一定理论指导意义和工程应用价值。

## 1.2 国内外研究现状

### 1.2.1 燃料电池故障诊断研究现状

目前,针对质子交换膜燃料电池已经提出了多种故障诊断方法,大致可以分为基于模型的诊断方法、基于数据驱动的诊断方法和基于实验测试的诊断方法<sup>[1-4]</sup>。下面分别从基于模型、基于数据驱动和基于实验测试的诊断方法三个方面进行综述。

#### (1)基于模型的故障诊断方法

基于模型的故障诊断方法是将系统实际输出与系统模型输出之间的残差作为故障诊断的依据。实际输出结果与系统模型输出的残差反映了系统的运行信息,对残差进行分析、处理和决策,可以获取系统的故障信息,从而可以进行故障诊断。Yang 等<sup>[5]</sup>采用线性参数可变(LPV, Linear Parameter-Varying)模型描述质子交换膜燃料电池系统行为,提出增强状态观测器(Augmented State Observer)估计系统内部状态和组件故障。Khan 等<sup>[6]</sup>提出了浓差压降的半经验模型,通过计算质子交换膜燃料电池的水含量诊断水淹和膜干故障,并使用蝴蝶优化算法(Butterfly Optimization Algorithm)优化模型参数。周苏等<sup>[7-9]</sup>基于电化学阻抗谱提取故障诊断特征,对故障特征进行分类从而诊断质子交换膜燃料电池系统故障。Pierpaolo 等<sup>[10]</sup>通过结构分析辨识系统涉及的物理量和系统可能的故障间的关系,开发集总参

数模型,以因果关系算法分析设计残差发生器检测和隔离故障。王筱彤等<sup>[11]</sup>提出一种基于离散区间二进制序列脉冲信号的燃料电池电化学阻抗谱在线测量及故障诊断方法。Hernandez 等<sup>[12]</sup>建立质子交换膜燃料电池系统等效电路模型,采用递推最小二乘法辨识部件参数,以特定电阻的阻值变化量检测水淹、膜干和膜退化三种故障。de Lira 等<sup>[13]</sup>建立了模型参数随工作点变化的质子交换膜燃料电池系统模型,设计了质子交换膜燃料电池系统状态的线性变参数观测器,诊断空压机故障、电堆电压降低、氢气泄漏故障和氧气泄漏故障。Laghrouche 等<sup>[14]</sup>提出了一种基于自适应二阶滑动模式观测器的一类具有 Lipschitz 非线性系统的稳健故障重构方法,精确重构了空气供应系统泄漏故障。Rotondo 等<sup>[15]</sup>引入 Takagi-Sugeno (TS)区间观测器检查所有测量是否位于相应的估计区间范围内。当检测到故障时,对与相应估计不一致的测量值进行注释,并触发故障隔离程序。同时使用理论故障特征矩阵,总结不同故障对残差的影响,并采用逻辑推理的方式隔离故障。Buchholz 等<sup>[16]</sup>采用线性规范变量分析方法建立质子交换膜燃料电池的模型,对氧气化学计量比故障进行诊断。

### (2)基于数据驱动的故障诊断方法

刘嘉蔚等<sup>[17]</sup>采用线性判别分析和概率神经网络对质子交换膜燃料电池系统的运行数据进行水管理故障诊断,以较高的准确率实现正常状态、水淹故障和膜干故障的诊断。Liu 等<sup>[18]</sup>基于极限学习机和 Dempster-Shafer 证据理论对质子交换膜燃料电池系统进行四种不同程度的空气化学计量比故障诊断。Zhang 等<sup>[19]</sup>提出基于模拟退火遗传模糊 C-均值聚类(SAGAFCM, Simulated Annealing Genetic Algorithm Fuzzy C-Means Clustering)和深度信念网络(DBN, Deep Belief Network)的故障诊断方法,对去离子水进口高温故障、氢气泄漏故障、空气低压故障和正常状态进行诊断。余嘉熹等<sup>[20]</sup>基于 Bootstrap 法和随机森林算法对燃料电池系统的故障进行分类。刘嘉蔚等<sup>[21]</sup>基于在线序列超限学习机和主成分分析进行燃料电池的故障诊断。Liu 等<sup>[22]</sup>针对有轨电车燃料电池的故障分类问题,提出了一种基于 K-means 聚类的离散隐马尔可夫模型(DHMM, Discrete Hidden Markov Model)故障诊断策略。周苏等<sup>[23]</sup>采用 K 均值和支持向量机算法进行车用燃料电池系统的故障诊断。Benouioua 等<sup>[24-25]</sup>提出小波变换模极大值和模式识别相结合的方法,诊断 PEMFC 的阴极流量故障、阳极流量故障、进口压力故障和冷却水温度故障等。Damour 等<sup>[26]</sup>采用经验模式分解方法分解燃料电池的输出电压,诊断水淹和膜干故障。

### (3)基于实验测试的故障诊断方法

基于实验测试的诊断方法对质子交换膜燃料电池系统进行一系列的实验,通过测试结果揭示相关测试数据与故障之间的关系。Hinaje 等<sup>[27]</sup>建立了质子交换膜

燃料电池的模型,根据电堆电流的磁场效应建立燃料电池的故障与磁场间的对应关系,诊断单电池的故障。Le Ny 等<sup>[28]</sup>开发了一种根据电流分布的磁场估计二维电流密度进行膜干和电极水淹故障的诊断方法。Song 等<sup>[29]</sup>进行了不同条件下的水淹实验,发现质子交换膜燃料电池在水淹发生过程中阳极气体压力降呈现“阶跃平台”式变化特征,根据水淹前边界和沟道尺寸判断水淹和脱水故障。

综上所述,利用基于模型的方法对燃料电池的模型进行故障诊断时,分析模型需要建立精确的对象模型,要求对燃料电池涉及的物理、化学和材料机理进行综合分析。而黑盒模型需要通过历史数据建立燃料电池的数据模型,仅需要采集燃料电池的运行数据建立数据模型进行诊断,能够降低建立分析模型的难度。基于数据驱动的方法直接从数据中学习系统的行为,不需要燃料电池的专业知识。但传统的数据驱动方法对建立大量高维数据模型的能力尚有不足,无法有效处理大规模数据。基于实验的方法需要针对燃料电池设计实验进行研究,现有的实验测试方法可能存在难以大规模开展的问题,测试数据要丰富全面才能体现优势,而且对时间和成本的要求较高。

### 1.2.2 深度学习在燃料电池系统故障诊断研究现状

基于深度学习的故障诊断方法是一种典型的能够自动进行特征提取的智能故障诊断方法。深度学习方法具有强大的数据处理与学习能力,能够从海量数据中挖掘出有用的信息,为从数据中学习潜在的规律提供一种高效的建模方法,在图像处理、语音识别和文本分析等领域得到了广泛应用。深度学习方法通过逐层的特征变换,不断提高特征的抽象性,最后采用高层的特征进行故障诊断。

当前深度学习技术在机械设备故障诊断中得到了的大量应用并获得了一些研究成果。Janssens 等<sup>[30]</sup>采用卷积神经网络对旋转机械的故障进行自动特征学习,获得了优于传统的随机森林故障方法的效果。Lu 等<sup>[31]</sup>使用堆叠去噪自动编码器进行旋转机械的故障诊断。Przystalka 等<sup>[32]</sup>提出基于循环神经网络和混沌工程的稳健故障检测问题。Talebi 等<sup>[33]</sup>提出基于循环神经网络的风力发电机动态建模方法,将搭建的模型与实际系统输出相比较获得残差,提升了故障诊断的准确率。樊家伟等<sup>[34]</sup>基于快速傅里叶变换和长短期记忆网络进行行星齿轮故障诊断。郑一珍等<sup>[35]</sup>运用一维卷积神经网络诊断轴承保持架故障。许子非等<sup>[36]</sup>提出了滚动轴承的多尺度卷积神经网络故障诊断方法。常淼等<sup>[37]</sup>提出了改进的卷积神经网络进行风电轴承故障诊断的方法。曲岳晗等<sup>[38]</sup>采用多深度神经网络和多识别器融合模型识别电力变压器的故障。王崇宇等<sup>[39]</sup>等基于卷积神经网络对汽轮机转子不平衡和不对中故障进行了检测。刘瑶等<sup>[40]</sup>利用集合经验模态分解对风机的振动信号进行预处理,提

取振动信号的低频分量作为长短期记忆网络的输入,开展了风机的故障诊断研究。

目前深度学习技术在燃料电池故障诊断中的研究工作还处于初步探索阶段。Zhang 等<sup>[19]</sup>基于模拟退火遗传模糊 C-均值聚类(SAGAFCM, Simulated Annealing Genetic Algorithm Fuzzy C-Means Clustering)和深度信念网络(DBN, Deep Belief Network)相结合的方法,对燃料电池去离子水进口高温故障、氢气泄漏故障、空气低压故障和正常状态进行了诊断。Zuo 等<sup>[41]</sup>基于卷积神经网络开展了燃料电池的水淹故障诊断。Liu 等<sup>[42]</sup>采用一种结合了 t-SNE 和浅层的双向长短期记忆(BiLSTM)网络的方法对质子交换膜燃料电池水管理系统开展了故障诊断研究。

## 1.3 本文研究内容和结构安排

深度学习方法能够从大量的数据中学习到隐藏的规律,具有强大的数据处理能力。本文针对燃料电池的故障监测与诊断问题,探索采用深度学习方法进行研究可以避免复杂的物理和化学机理分析,降低故障监测与诊断的复杂性,解决燃料电池系统难以建立精确机理模型的问题。本文的结构安排如下:

第 1 章:阐述了燃料电池故障诊断的研究背景与意义,综述了燃料电池故障诊断的研究现状和深度学习在燃料电池系统故障诊断中的应用,分析燃料电池系统各类诊断方法的优缺点,最终确定采用深度学习方法进行燃料电池的故障监测与诊断探索工作。

第 2 章:针对质子交换膜燃料电池系统的组成进行其故障分类,收集燃料电池系统的数据并进行数据处理,制作成故障监测和诊断的数据集,提出了采用深度学习方法开展燃料电池系统故障监测与诊断的总体流程,选取 Python 语言和 TensorFlow 框架进行故障监测和诊断方法开发。

第 3 章:根据燃料电池的时序数据特点设计了基于长短期记忆网络的燃料电池系统故障监测模型,选择 RMSprop 算法对所设计的网络进行训练,根据燃料电池系统的实际电压与网络模型预测电压的残差值判断系统是否存在故障,并与其它神经网络方法进行了性能比较。

第 4 章:以长短期记忆网络作为残差函数提出了残差-长短期记忆网络(Res-LSTM),并设计了基于残差-长短期记忆网络的燃料电池系统故障监测模型,比较了残差-长短期记忆网络和长短期记忆网络在燃料电池系统故障监测中的性能。然后,进一步对残差函数进行了优化,提出一种聚合残差变换的残差-长短期记忆网络(ResNeXt-LSTM)模型,采用 RMSprop 算法训练 ResNeXt-LSTM 模型进行燃料电池系统故障监测,比较了 ResNeXt-LSTM 模型和残差-长短期记忆网络在燃料

电池系统故障监测中的性能。

第 5 章：针对燃料电池系统的燃料电池电堆故障、空气供给系统故障、氢气供给系统故障和正常四种类别采用 Res-LSTM 模型建立了一个四分类模型进行故障诊断。采用 RMSprop 算法训练 Res-LSTM 模型，在测试集上进行故障分类准确率测试。同时，与 LSTM 网络模型和 ResNeXt-LSTM 模型进行性能对比，从模型的计算量和模型在测试数据上的分类准确率方面比较了所设计的 Res-LSTM 模型的优势。

第 6 章：总结了本文的主要内容和工作的，针对不足之处进行了说明，并对后续可能的研究工作进行了展望。

第2章 燃料电池系统深度学习故障监测与诊断方案

本章首先介绍了燃料电池系统的组成，分析质子交换膜燃料电池系统的故障类型，然后收集燃料电池系统的数据并进行数据处理，制作成故障监测和诊断的数据集，其次提出基于深度学习技术开发故障监测与诊断模型的基本方案，最后为进行算法开发选择合适的编程语言与深度学习框架。

2.1 质子交换膜燃料电池系统组成与故障分类

质子交换膜燃料电池系统结构如图 2.1 所示，主要由氢气供给系统、空气供给系统、燃料电池电堆和水热管理系统等组成。

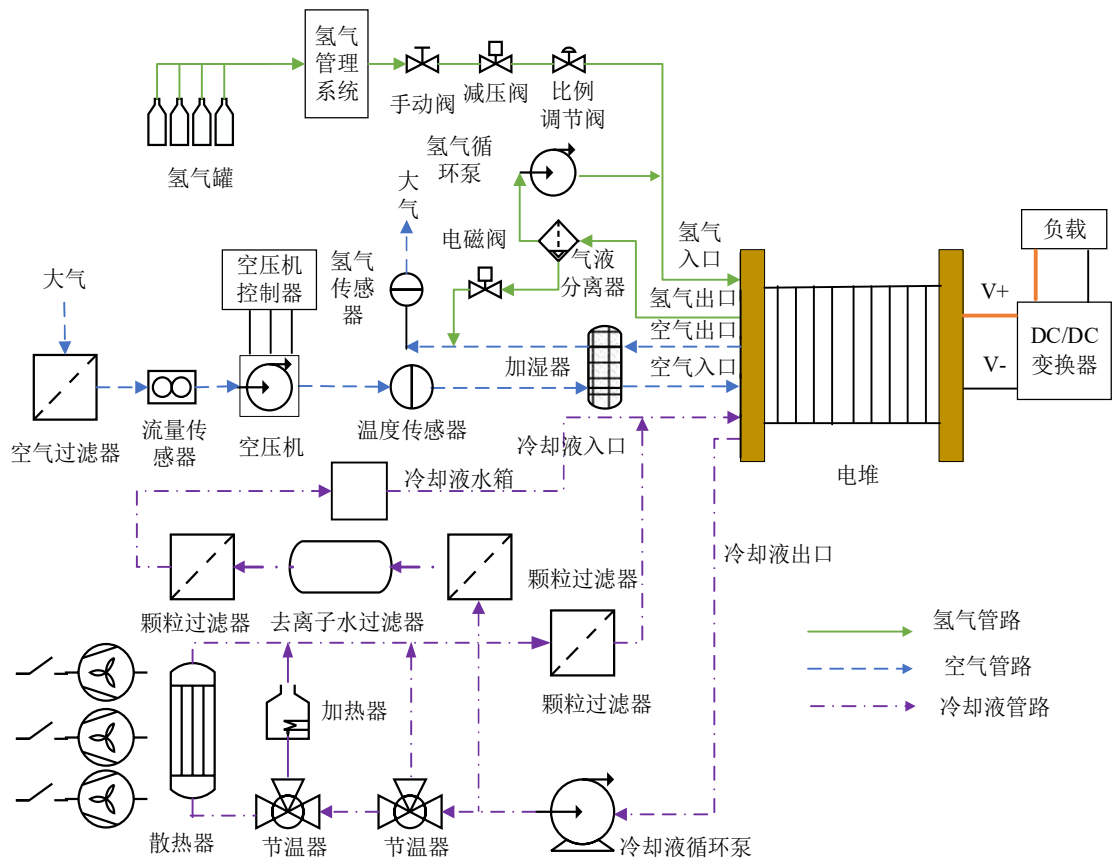


图2.1 质子交换膜燃料电池系统结构

氢气供给系统给燃料电池电堆供应电化学反应的燃料氢气，同时将未完全反应的剩余氢气经过气液分离后重新循环送入燃料电池电堆参与电化学反应。空气供给系统提供电化学反应所需的氧气，同时对气体进行增湿，向电堆补充水分。水

热管理系统采用去离子水作为冷却液，主要是吸收电堆内电化学反应释放的热量，维持电堆水含量和温度均衡。燃料电池电堆通常由多片燃料电池单体电池串并联组成，电堆的输出电压经过 DC/DC 变换器提供所需的电压等级给用电负载。燃料电池控制器负责对各个传感器进行信号采集和对系统运行状态信号进行处理，控制系统的运行。

根据质子交换膜燃料电池系统各个子系统在运行中可能发生的故障，对其故障类型进行分类如表 2.1 所示。燃料电池电堆的故障可分为致命性故障和可恢复性故障，致命性故障包括质子交换膜破损、电极穿孔和双极板损坏等，可恢复性故障包括电堆短路、电极水淹、膜干、电堆过载、催化剂中毒和氢氧混合等。氢气供给系统故障有氢气瓶开启故障、氢气泄漏、手动阀故障、减压阀故障、比例调节阀故障、氢气压力传感器故障、氢气管堵塞、气液分离器故障和氢气循环泵故障等。空气供给系统故障主要有空气过滤器堵塞、空气管道泄漏、空压机故障、空压机控制器故障、空气传感器故障和加湿器故障等。水热管理系统故障有循环泵故障、水管阻塞、水管泄露、过滤器故障、水量不足、节温器故障和散热器故障等。

表 2.1 质子交换膜燃料电池系统故障分类

子系统故障类型	可能存在的故障
燃料电池电堆故障	质子交换膜破损、电极穿孔、双极板损坏、电堆短路、电极水淹、质子交换膜干燥、电堆过载、催化剂中毒、氢氧混合等
氢气供给系统故障	氢气瓶内开启故障、氢气泄漏、手动阀故障、减压阀故障、比例调节阀故障、氢气压力传感器故障、氢气管堵塞、气液分离器故障、氢气循环泵故障等
空气供给系统故障	空气过滤器堵塞、空气管道泄漏、空压机故障、空压机控制器故障、空气传感器故障、加湿器故障等
水热管理系统故障	循环泵故障、水管阻塞、水管泄露、过滤器故障、水量不足、节温器故障、散热器故障等

## 2.2 基于深度学习的燃料电池系统故障监测与诊断方法

深度学习技术在近年来得到迅速发展，基于深度学习技术的故障监测与诊断研究与应用逐渐受到重视。与传统方法相比，基于深度学习的故障监测与诊断方法



具有下列优势：(1)深度学习具有强大的表示学习能力，能够避免对专家诊断经验的依赖；(2)通过建立深层的学习模型，能更好地挖掘出庞大的检测数据和设备健康状况之间的映射关系，以提高监测与诊断能力；(3)深度学习自带分类器对自动提取的特征参数进行识别，可以进行端到端的学习，减少人为选择的影响。

为了满足对质子交换膜燃料电池系统的性能、成本和寿命等不断提高的要求，同时强化系统的稳定性和可靠性，基于深度学习方法实现燃料电池系统的故障监测和诊断功能，构建具有较高准确率的故障诊断系统具有一定的意义。

## 2.2.1 数据提取与预处理

### (1)燃料电池系统

本文实验所用燃料电池系统如图 2.2 所示。燃料电池电堆由两个电堆串联组成，每个电堆包含 100 片单电池。系统的部分参数如表 2.2 所示。



图 2.2 燃料电池系统实物图

表 2.2 燃料电池系统部分参数

参数	单位	范围
电流	A	$\leq 406$
总电压	V	$\leq 138$
功率	kW	$\leq 56$
空气入口压力	kPa	70
氢气入口压力	kPa	85
水入口温度	℃	70
水出口温度	℃	$\leq 80$



## (2)燃料电池系统故障监测数据集

时序数据通常具有更多的信息，反映了一段时间内的系统变化情况，有利于排除干扰噪声。本文通过燃料电池系统的运行实验获取正常状态的测试数据，采集燃料电池系统连续 10 个时刻的时序数据，采样周期为 1 秒。首先对系统运行的传感器采集数据进行整理，剔除部分缺失或不全的数据。由于采集到的变量原始数据具有各维度物理单位不同和数量级差异大等特性，为消除数据的物理单位和数量级等差异对神经网络性能的影响，同时提高神经网络训练的效率和稳定性，对原始数据进行归一化处理。采用最大最小化数据预处理方法<sup>[43]</sup>，将数据归一化到[0,1]区间。即假设  $z_i$  是各维变量原始数据， $z_i'$  是标准化处理后的数据， $z_{i,\min}$  是变量原始数据的最小值， $z_{i,\max}$  是变量原始数据的最大值，归一化处理的计算公式如(2.1)式所示。归一化后的部分变量变化情况如图 2.3 所示。

$$z_i' = \frac{z_i - z_{i,\min}}{z_{i,\max} - z_{i,\min}} \quad (2.1)$$

其次，将标准化后的数据处理成后面章节所需的数据格式，得到燃料电池系统故障监测数据集，如表 2.3 所示。数据集共有 42997 个样本，每个样本由  $(\mathbf{x}, \mathbf{y})$  组成。其中， $\mathbf{x}$  代表样本的输入， $\mathbf{y}$  代表相应的电堆 1#电压和电堆 2#电压的真实值。选取的输入特征维数为 20，时间序列长度为 10，时间采样周期为 1 秒。

最后，将数据集中的样本按照 8:2 的比例随机划分为训练集和测试集，即训练集共有 34397 个样本，测试集共有 8600 个样本。训练集数据用于训练网络，测试集数据用于测试评估完成训练的神经网络模型。

表 2.3 燃料电池系统故障监测数据集

变量符号	变量意义
$\mathbf{x}_i (i=1,2,...,10)$ ： 维度为 20 维	各维变量表示：氢气中压气压、氢气低压气压、入堆空气流量、空压机出口压力、空压机出口温度、入堆空气压力、入堆空气温度、出堆空气压力、入堆冷却液压力、入堆冷却液温度、出堆冷却液温度、空压机转速反馈、电堆 1#最低单片电压、电堆 1#最低单片电压编号、电堆 2#最低单片电压、电堆 2#最低单片电压编号、高压端电流、比例调节阀开度、空压机入口节气门开度反馈、空气出口节气门开度反馈
$\mathbf{x}=[\mathbf{x}_1, \mathbf{x}_2, ..., \mathbf{x}_{10}]$	$\mathbf{x}_i (i=1,2,...,10)$ 的采样周期为 1 秒，共有 10 个时刻的数据
$\mathbf{y}$ ：维度为 2 维	各维变量表示电堆 1#电压和电堆 2#电压，对应 10 个时刻的最后一个时刻电压数据




图 2.3 某段时间部分变量变化情况 (数据已归一化, 纵轴为无量纲量)

### (3) 燃料电池系统故障诊断数据集

燃料电池系统主要包括氢气供给系统、空气供给系统、燃料电池电堆和水热管理系统等。若对所有系统进行诊断, 不仅需要的测试数据多, 也会加大开发神经网络模型的复杂性。因此, 本文仅选择燃料电池电堆、空气供给系统和氢气供给系统三个子系统的故障数据建立具有四个不同类别的燃料电池系统故障诊断数据集。当三个系统都正常时, 则认为燃料电池运行状态正常 (即认为燃料电池电堆、空气供给系统和氢气供给系统三个系统没有故障)。在采用深度学习方法进行故障诊断时, 选取的特征如表 2.4 所示。本文通过燃料电池系统的故障模拟实验获取故障数据, 每个样本采集燃料电池系统连续 10 个时刻的时序数据, 采样周期为 1 秒。

表 2.4 选取的故障诊断特征

系统类别	故障特征
燃料电池电堆	高压端电流、电堆 1#电压、电堆 2#电压、电堆 1#最低单片电压、电堆 1#最低单片电压编号、电堆 2#最低单片电压、电堆 2#最低单片电压编号
空气供给系统	入堆空气流量、入堆空气压力、入堆空气温度、空压机出口压力、空压机出口温度、出堆空气压力、空压机转速反馈、空压机入口节气门开度反馈、空气出口节气门开度反馈、
氢气供给系统	氢气中压气压、氢气低压气压、比例调节阀开度
其它	入堆冷却液压力、入堆冷却液温度、出堆冷却液温度

原始的数据一般有相应的物理意义和单位，其数值的差异可能非常大。为了避免神经网络训练时数据的分布差异对网络性能的影响，仍然采用(2.1)式最大最小化数据归一化方法对燃料电池系统故障特征数据进行预处理。

燃料电池系统故障诊断分为四个类别，分别为燃料电池电堆故障、空气供给系统故障、氢气供给系统故障和正常，因而故障诊断模型是一个四分类模型。为方便算法的处理，将样本的输出类别标签  $y$  的集合用数值编码设置为  $\{1,2,3,4\}$ ，类别标签集合的各个元素具体含义如表 2.5 所示。

表 2.5 数值编码及其类别对应关系

类别	数值编码
燃料电池电堆故障	1
空气供给系统故障	2
氢气供给系统故障	3
正常	4

最终经过数据预处理和数值编码后的燃料电池系统故障诊断数据集如表 2.6 所示。数据集共有 13243 个样本，每个样本由  $(\mathbf{x}, y)$  组成。 $\mathbf{x}$  代表样本的输入特征， $y$  代表相应的数值编码的类别，选取的诊断输入特征维数为 22，分别为氢气中压气压、氢气低压气压、入堆空气流量、空压机出口压力、空压机出口温度、入堆空气压力、入堆空气温度、出堆空气压力、入堆冷却液压力、入堆冷却液温度、出堆冷却液温度、空压机转速反馈、电堆 1#最低单片电压、电堆 1#最低单片电压编号、电堆 2#最低单片电压、电堆 2#最低单片电压编号、高压端电流、比例调节阀开度、空压机入口节气门开度反馈、空气出口节气门开度反馈、电堆 1#电压和电堆 2#电压，时间序列长度为 10，时间采样周期为 1 秒。

在进行故障分类时,将数据集中的样本按照 7:3 的比例随机划分为训练集和测试集,即训练集共有 9270 个样本,测试集共有 3973 个样本。训练集和测试集分别用于训练网络和对完成训练的网络进行测试评估。

表 2.6 燃料电池系统故障诊断数据集

变量符号	变量意义
$\mathbf{x}_i (i=1,2,\dots,10)$ : 维度为 22 维	各维变量表示氢气中压气压、氢气低压气压、入堆空气流量、空压机出口压力、空压机出口温度、入堆空气压力、入堆空气温度、出堆空气压力、入堆冷却液压力、入堆冷却液温度、出堆冷却液温度、空压机转速反馈、电堆 1#最低单片电压、电堆 1#最低单片电压编号、电堆 2#最低单片电压、电堆 2#最低单片电压编号、高压端电流、比例调节阀开度、空压机入口节气门开度反馈、空气出口节气门开度反馈、电堆 1#电压、电堆 2#电压
$\mathbf{x}=[\mathbf{x}_1,\mathbf{x}_2,\dots,\mathbf{x}_{10}]$	$\mathbf{x}_i (i=1,2,\dots,10)$ 的采样周期为 1 秒,共有 10 个时刻的数据
$y$	数值编码的故障类别, $y \in \{1,2,3,4\}$ , 含义见表 2.5
样本总数: 13243	

## 2.2.2 基于深度学习的燃料电池系统故障监测与诊断总体流程

故障是指系统某个部件的特性或功能发生改变而导致系统不再满足性能需求<sup>[3]</sup>。故障监测是通过对系统工作状态进行分析检测其是否存在失效和故障。故障诊断用于检测故障的存在及位置并对故障的类型及原因等进行识别<sup>[3]</sup>。故障监测功能可以看作是故障诊断功能的一部分。

运用深度学习方法进行故障监测与诊断有可靠的理论支撑。深度学习技术在各种实际场景与对象中的应用也已取得了重要进展和实际落地应用。借鉴相对成熟的理论和已有的相关应用开展质子交换膜燃料电池系统故障监测与诊断工作具有可行性。开展燃料电池系统故障监测与诊断时,深度学习模型的构建流程如图 2.4 所示。

首先,收集燃料电池系统的历史运行数据。根据对燃料电池系统的故障分析,初步确定故障监测的方法与诊断的故障类型。采用实验测试的方法获取故障监测与诊断所需的原始数据。

其次,根据采集到的质子交换膜燃料电池系统历史运行数据的特点,选择合适的深度学习算法模型构建故障监测与诊断系统。通过对深度学习算法模型进行训

练、测试和优化，不断提高故障监测与诊断系统的性能。

然后，对收集到的数据进行预处理。对收集到的数据进行检查，剔除异常数据，同时为消除不同变量间的单位和数值差异等对模型性能的影响，进一步对数据采取相应的处理，制作训练模型所需的数据集，为下一步开发模型做好准备工作。

最后，将处理后的数据分为训练集和测试集，用训练集对选取的深度学习模型进行训练，训练完后用测试集对模型进行测试。若测试不满足预定义的性能要求则重新训练，或重新选择深度学习模型，或重新收集数据进行循环迭代操作直到满足要求，若测试满足性能要求则完成模型训练。最终用训练好的模型进行燃料电池系统的故障监测与诊断。

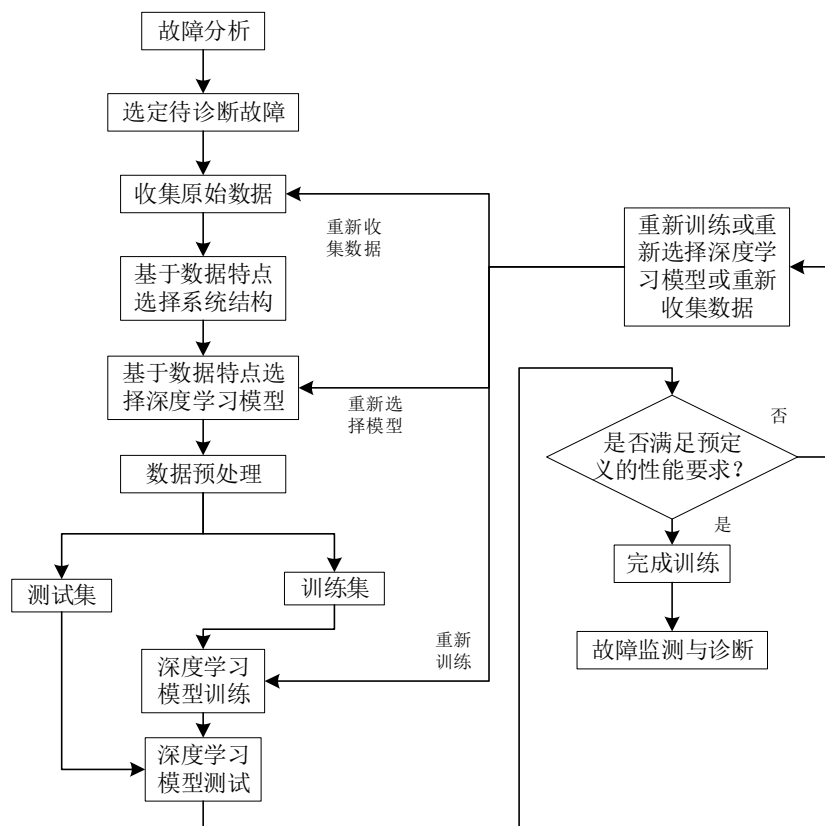


图 2.4 基于深度学习的燃料电池系统故障监测与诊断模型构建流程

## (1) 燃料电池系统故障监测方案

基于模型的故障监测方法(Model-Based Fault Monitoring Method)通过对实际系统输出物理量与模型预测输出物理量的残差进行分析、处理和决策，判断系统的运行有无故障<sup>[1]</sup>。该方法根据实际系统输入变量、中间状态变量和系统输出变量建立系统过程预测模型，将实际系统输出和系统过程预测模型的输出比较产生残差，对残差进行处理决策得到故障信息。

考虑到神经网络具有强大的拟合能力，本文通过采集燃料电池系统的正常运

行数据,使用神经网络拟合系统运行过程中的输入输出变量间的映射关系,从数据中建模燃料电池系统的输入输出模型。

基于神经网络模型的质子交换膜燃料电池系统故障监测方案如图 2.5 所示。该方法将质子交换膜燃料电池系统看作一个黑盒,利用历史运行数据训练神经网络模型,模拟质子交换膜燃料系统的运行状态。在故障监测时,神经网络模型根据系统当前输入数据,预测燃料电池的输出电压,通过燃料电池的实际输出电压与神经网络模型预测的输出电压产生残差判断燃料电池系统当前运行状态有无故障。该监测方案利用深度神经网络建立了一个燃料电池系统的预测模型。

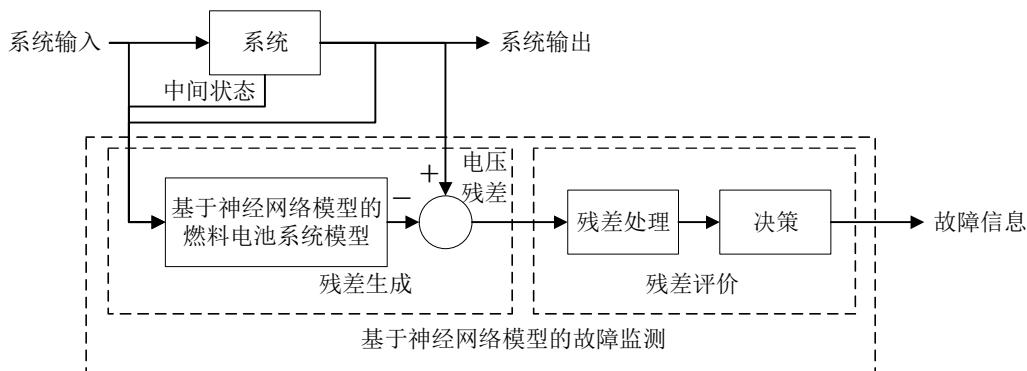


图 2.5 基于模型的燃料电池系统故障监测方法

## (2)故障诊断方案

基于神经网络的故障诊断方案如图 2.6 所示。输入的原始数据首先经过数据预处理后被送入训练好的神经网络模型进行分类,经过逐步的特征变换转变为低层特征、中层特征和高层特征,利用学习到的高层特征进行分类,得到最终的故障类别信息。该诊断方案利用深度神经网络建立了一个燃料电池系统的故障分类模型。




图 2.6 基于分类模型的故障诊断方法

## 2.2.3 深度学习算法开发语言及框架选取

深度学习模型是深度学习常采用的模型,神经网络通常采用梯度优化算法进行学习,网络参数通过迭代搜索的方式进行更新。现代深度学习模型具有强大的能力,相应的网络参数规模也十分巨大。特别是一些大型神经网络模型,网络参数的规模已经跨越千亿级。基于反向传播算法手动推导梯度的方式极其低效,特别是手动求导时容易出错。因此,一些研究机构 and 大型科技公司纷纷推出了多种深度

学习框架，为算法的研究和开发提供便利。

常用的深度学习框架有 Google 的 TensorFlow<sup>[44]</sup>、Facebook 的 PyTorch<sup>[45]</sup>和百度的 PaddlePaddle<sup>[43]</sup>等。这些深度学习框架的特点有：(1)支持 CPU 和 GPU 硬件，特别是可以使用 GPU 的并行计算能力加速神经网络模型的训练，大大提高了算法的开发效率；(2)提供了便捷的自动求导功能，无需手动计算偏导数，减少了人工计算大量神经网络参数的偏导数时可能产生的错误，使得开发新算法的效率大幅提高；(3)提供了常用的神经网络工具模块，使得搭建开发神经网络算法模型大大简化<sup>[43,44,45]</sup>。

TensorFlow 是 Google 发布的深度学习框架，主要应用于机器学习特别是深度学习的研究。自 TensorFlow2.0 版本起，静态图和动态图两种计算方式都已获得支持。TensorFlow 发布时间较早，在工业界的使用广泛，取得了巨大的成功，是最流行的深度学习框架之一。TensorFlow 提供了 C++和 Python 接口，支持 Windows 操作系统，有丰富的开发文档，交流活跃的开发社区，大量的学习教程，易于学习。综合考虑，本文选用 Python 语言、Anaconda 软件、TensorFlow GPU2.3.0 版本和 Jupyter Notebook 交互计算程序进行算法开发。

## 2.3 本章小结

本章首先简述了燃料电池的系统组成和常见的故障，其次收集燃料电池系统的数据并进行数据预处理，制作成燃料电池系统的故障监测和诊断数据集，然后提出了采用深度学习技术进行燃料电池系统故障监测与诊断的总体方案和流程，最后选择 Python 语言和 TensorFlow 框架进行下一步深度学习算法开发工作。

## 第3章 基于LSTM网络的燃料电池系统故障监测

### 3.1 时序数据与循环神经网络

时间序列数据是一种常见的数据结构，例如一段时间内的温度、一段语音和一段时间内燃料电池的输出电压等。时间序列数据简称为时序数据，通常在一段时间内具有时间上的前后关联关系，即当前时刻的输出不仅与当前时刻的输入有关，而且与以前时刻的历史状态有关。

循环神经网络(Recurrent Neural Network, RNN)<sup>[46]</sup>是一种处理时序数据的模型，其突出优点是具有短期记忆力，其网络层结构如图 3.1 所示。假设  $\mathbf{x}=[\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T]$  表示网络层的输入， $\mathbf{x}_t \in \mathbb{R}^d$  ( $t=1, 2, \dots, T$ ) 表示网络在第  $t$  时刻的输入， $\mathbf{h}=[\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_T]$  表示循环网络层的隐藏状态， $\mathbf{h}_t \in \mathbb{R}^D$  表示网络在第  $t$  时刻的隐藏状态。循环神经网络层的隐藏状态的计算模型可表示为：

$$\mathbf{h}_t = f(\mathbf{W}_x \mathbf{x}_t + \mathbf{W}_h \mathbf{h}_{t-1} + \mathbf{b}), \forall t = 1, 2, \dots, T \quad (3.1)$$

式中， $\mathbf{h}_{t-1}$  表示第  $t-1$  时刻的隐藏状态； $\mathbf{h}_0$  是初始值，一般初始化为  $\mathbf{h}_0 = \mathbf{0} \in \mathbb{R}^D$ ； $f(\bullet)$  表示非线性激活函数，按元素运算； $\mathbf{W}_x \in \mathbb{R}^{D \times d}$  表示网络层的输入权值矩阵， $\mathbf{W}_h \in \mathbb{R}^{D \times D}$  表示网络层的隐藏状态权值矩阵， $\mathbf{b} \in \mathbb{R}^D$  表示网络层的偏置向量， $\mathbf{W}_x$ 、 $\mathbf{W}_h$  和  $\mathbf{b}$  均是网络层的参数矩阵或向量。进一步假设网络层的输出为  $\mathbf{y}$ ，则输出可以表示为：

$$\mathbf{y} = \mathbf{O}(\mathbf{h}) \quad (3.2)$$

输出函数  $\mathbf{O}(\bullet)$  可以根据不同的问题设计成不同的形式。

循环神经网络中的神经元同时接受当前时刻的输入和上一个时刻的隐藏状态，使得网络具有短期记忆能力，适合建立时序数据的关系模型。同一层的神经元使用相同的权值参数矩阵  $\mathbf{W}_x$ 、 $\mathbf{W}_h$  和偏置参数向量  $\mathbf{b}$ ，采用了参数共享机制。当时序长度较大时，这种简单的循环神经网络可能存在梯度爆炸或梯度弥散问题<sup>[47,48]</sup>，对长程依赖的状态间的处理能力不足。一种有效的解决办法是加入门控机制，典型的有长短期记忆网络<sup>[48,49]</sup>。



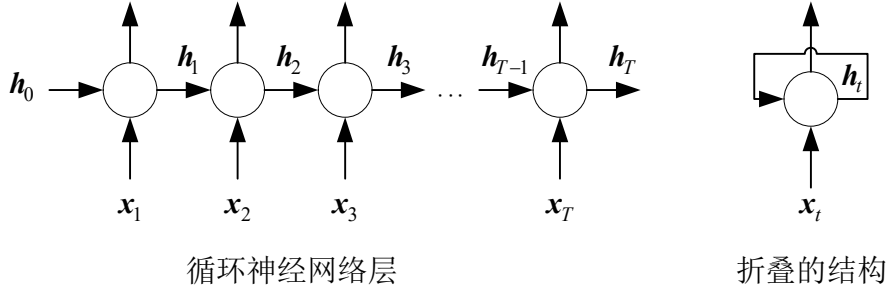


图 3.1 循环神经网络层结构

### 3.2 长短期记忆网络结构

长短期记忆(Long Short-Term Memory, LSTM)网络<sup>[49]</sup>是一类适用于序列数据处理的循环神经网络,是对简单的循环神经网络的改进。针对简单的循环神经网络在训练时可能面临的梯度爆炸或梯度弥散问题,长短期记忆网络引入了门控机制和内部状态的概念。长短期记忆网络提出后,在文本处理和语音识别等领域获得了广泛的应用,取得了巨大的成功。

LSTM 神经元及 LSTM 网络层如图 3.2 所示,其中,图 3.2(a)为 LSTM 网络层的结构图,图 3.2(b)为 LSTM 神经元的结构图,图 3.2(c)为简化的 LSTM 网络层结构图。假设  $\mathbf{x}=[\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T]$  表示 LSTM 神经元的输入,  $\mathbf{x}_t \in \mathbb{R}^d$  ( $t=1, 2, \dots, T$ ) 表示神经元在第  $t$  时刻的输入,  $\mathbf{c}=[\mathbf{c}_1, \mathbf{c}_2, \dots, \mathbf{c}_T]$  表示 LSTM 神经元的内部状态,  $\mathbf{c}_t \in \mathbb{R}^D$  表示 LSTM 神经元在第  $t$  时刻的内部状态,  $\mathbf{h}=[\mathbf{h}_1, \mathbf{h}_2, \dots, \mathbf{h}_T]$  表示 LSTM 神经元的输出,  $\mathbf{h}_t \in \mathbb{R}^D$  表示神经元在第  $t$  时刻的输出。在第  $t$  时刻的 LSTM 神经元计算公式为<sup>[44,45,49]</sup>:

$$\mathbf{g}_{ft} = \sigma(\mathbf{W}_{fh}\mathbf{h}_{t-1} + \mathbf{W}_{fx}\mathbf{x}_t + \mathbf{b}_f) \quad (3.3)$$

$$\mathbf{g}_{it} = \sigma(\mathbf{W}_{ih}\mathbf{h}_{t-1} + \mathbf{W}_{ix}\mathbf{x}_t + \mathbf{b}_i) \quad (3.4)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_{ch}\mathbf{h}_{t-1} + \mathbf{W}_{cx}\mathbf{x}_t + \mathbf{b}_c) \quad (3.5)$$

$$\mathbf{c}_t = \mathbf{g}_{it} \otimes \tilde{\mathbf{c}}_t + \mathbf{g}_{ft} \otimes \mathbf{c}_{t-1} \quad (3.6)$$

$$\mathbf{g}_{ot} = \sigma(\mathbf{W}_{oh}\mathbf{h}_{t-1} + \mathbf{W}_{ox}\mathbf{x}_t + \mathbf{b}_o) \quad (3.7)$$

$$\mathbf{h}_t = \mathbf{g}_{ot} \otimes \tanh(\mathbf{c}_t) \quad (3.8)$$

式中,  $\otimes$  表示两个同维向量或矩阵对应元素相乘运算;  $t=1, 2, \dots, T$ ,  $T$  为一个 LSTM 网络层的 LSTM 神经元个数;  $\mathbf{c}_0 = \mathbf{0}$ ,  $\mathbf{h}_0 = \mathbf{0}$ , 表示初始值。 $\sigma$  表示 sigmoid 激活函数。各式中的激活函数(即 sigmoid 和 tanh 激活函数)均为按元素计算。 $\mathbf{W}_{fh} \in \mathbb{R}^{D \times D}$ 、

$W_{fx} \in \mathbb{R}^{D \times d}$ 、 $W_{ih} \in \mathbb{R}^{D \times D}$ 、 $W_{ix} \in \mathbb{R}^{D \times d}$ 、 $W_{ch} \in \mathbb{R}^{D \times D}$ 、 $W_{cx} \in \mathbb{R}^{D \times d}$ 、 $W_{oh} \in \mathbb{R}^{D \times D}$ 、 $W_{ox} \in \mathbb{R}^{D \times d}$ 、 $b_f \in \mathbb{R}^D$ 、 $b_i \in \mathbb{R}^D$ 、 $b_c \in \mathbb{R}^D$ 、 $b_o \in \mathbb{R}^D$  表示同一层的 LSTM 神经元的参数矩阵或向量，这些参数通过优化算法进行学习。

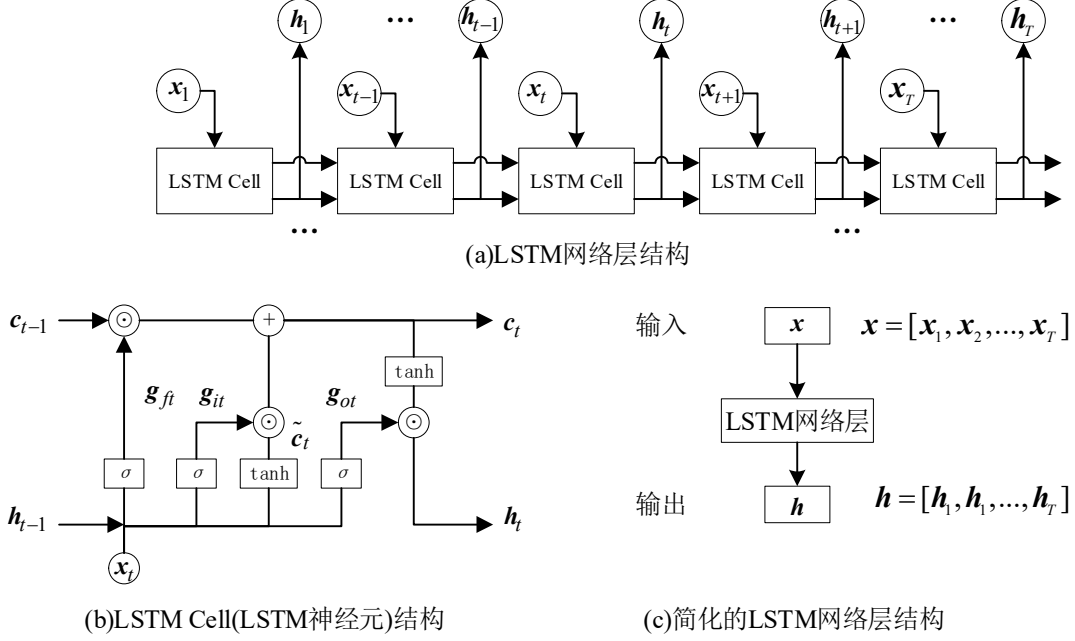


图 3.2 LSTM 神经元及 LSTM 网络层的结构

LSTM 神经元包含遗忘门  $g_{ft}$ 、输入门  $g_{it}$  和输出门  $g_{ot}$  三个门控开关，它们控制信息流的功能类似。三个门控开关的输出信号的取值范围为(0,1)，均是柔性控制门。控制门的输入信号均为上一个时刻的输出状态  $h_{t-1}$  和当前时刻的输入状态  $x_t$ 。

遗忘门  $g_{ft}$  作用于上一个时刻的 LSTM 神经元的内部状态向量  $c_{t-1}$ ，控制接收上一个神经元的内部状态信息程度。当遗忘门  $g_{ft}$  的取值趋近于全一向量  $\mathbf{1} \in \mathbb{R}^D$  时， $g_{ft} \otimes c_{t-1}$  接收信息的强度达到最大，上一个时刻的 LSTM 神经元的状态向量  $c_{t-1}$  信息完全流入当前时刻；当遗忘门  $g_{ft}$  的取值趋近于全零向量  $\mathbf{0} \in \mathbb{R}^D$  时， $g_{ft} \otimes c_{t-1}$  输出为  $\mathbf{0}$ ，接收信息的强度达到最小，当前时刻忽略上一个时刻的 LSTM 神经元的内部状态向量  $c_{t-1}$  信息。

输入门  $g_{it}$  作用于 LSTM 神经元的新状态向量  $\tilde{c}_t$ ，控制接收新状态向量信息程度。当输入门  $g_{it}$  的取值趋近于全一向量  $\mathbf{1} \in \mathbb{R}^D$  时， $g_{it} \otimes \tilde{c}_t$  强度达到最大，上一个时刻的新状态向量  $\tilde{c}_t$  信息完全流入当前时刻；当输入门  $g_{it}$  的取值趋近于全零向量  $\mathbf{0} \in \mathbb{R}^D$  时， $g_{it} \otimes \tilde{c}_t$  输出为  $\mathbf{0}$ ，当前时刻忽略上一个时刻的 LSTM 神经元的新状态向量  $\tilde{c}_t$  信息。

输出门  $g_{ot}$  作用于当前时刻的 LSTM 神经元的内部状态向量  $c_t$ ，控制内部状态向量信息的输出程度。当输出门  $g_{ot}$  的取值趋近于全一向量  $\mathbf{1} \in \mathbb{R}^D$  时， $g_{ot} \otimes \tanh(c_t)$  绝对强度达到最大，与内部状态向量有关的  $\tanh(c_t)$  信息完全流入当前时刻；当输入门  $g_{it}$  的取值趋近于全零向量  $\mathbf{0} \in \mathbb{R}^D$  时， $g_{ot} \otimes \tanh(c_t)$  输出为  $\mathbf{0}$ ，当前时刻忽略与内部状态向量有关的  $\tanh(c_t)$  信息。

LSTM 神经元将信息处理分为遗忘阶段、选择记忆阶段和输出阶段，通过遗忘门、输入门和输出门实现。三个门的组合功能表 3.1 所示，三个控制门通过不同的组合可以实现对输入信息和记忆信息的不同输出功能。

表 3.1 门控状态和 LSTM 神经元的状态

输出门	输入门	遗忘门	LSTM 神经元的状态
0	0	0	关闭输出门，输出清零
0	0	1	关闭输出门，输出清零
0	1	0	关闭输出门，输出清零
0	1	1	关闭输出门，输出清零
1	0	0	开启输出门，清零输入和记忆信息
1	0	1	开启输出门，完全依赖记忆信息
1	1	0	开启输出门，完全依赖输入信息
1	1	1	开启输出门，依赖输入和记忆的综合信息

LSTM 网络层由多个 LSTM 神经元在顺序上有序连接组成，同一网络层内的 LSTM 神经元共享网络参数。深度 LSTM 网络由 LSTM 网络层逐层堆叠形成。LSTM 网络通过同一层的 LSTM 神经元参数共享降低了网络参数量，提高了网络训练效率。LSTM 网络继承了简单的循环神经网络的循环结构，同时引入了门控机制和内部状态向量，这些改进有利于网络性能的提升。

### 3.3 基于 LSTM 网络的燃料电池系统故障监测

通过采集质子交换膜燃料电池系统的运行数据，采用 LSTM 网络拟合燃料电池系统的运行行为，得到质子交换膜燃料电池系统的输入输出关系模型。在进行燃料电池系统故障监测时，LSTM 网络模型根据系统当前输入数据，预测燃料电池的输出电压。通过燃料电池的实际输出电压与 LSTM 网络模型的预测输出电压的电压残差判断系统运行状态有无故障。

电压残差阈值的设置对故障监测具有重要影响。残差处理主要为设置电压残

差阈值提供参考。假设电压残差为  $R$ ，测试数据的电压残差标准差为  $\sigma$ ，电压残差阈值为  $R_{th}$ ，设置电压残差阈值  $R_{th} = 3\sigma$ ，当  $R > R_{th}$  时判定燃料电池系统处于故障运行状态，否则判断为正常运行状态。

根据图 2.4 所示的过程，建立基于 LSTM 网络的燃料电池系统故障监测模型流程为：首先，通过实验收集燃料电池系统的正常运行数据，对收集到的数据进行数据预处理；然后，将预处理后的数据集随机分为训练集和测试集，用训练集训练网络，用测试集对网络进行测试评估；若神经网络满足要求，则完成网络训练工作，否则重新收集数据扩大数据集，或者重新配置网络超参数，或者重新训练网络，直到达到要求。

### 3.3.1 LSTM 网络结构配置与训练

所选择的网络模型配置如图 3.3 所示，具体网络配置说明如表 3.2 所示。整个 LSTM 网络共由六个网络层组成，各层每个时刻点输出数据维度分别为 16,12,10,8,4,2。网络层 1 输入 10 个时刻的 20 维向量数据  $\mathbf{x}_i$  ( $i=1,2,\dots,10$ )，向量  $\mathbf{x}_i$  各维的数据意义已在表 2.3 说明，每个时刻间隔周期为 1 秒。网络层 2 至网络层 6 的输入为相邻前一层的输出。最后一层网络层 6 输出最后一个时刻的数据，得到电堆 1#电压和电堆 2#电压的预测值。

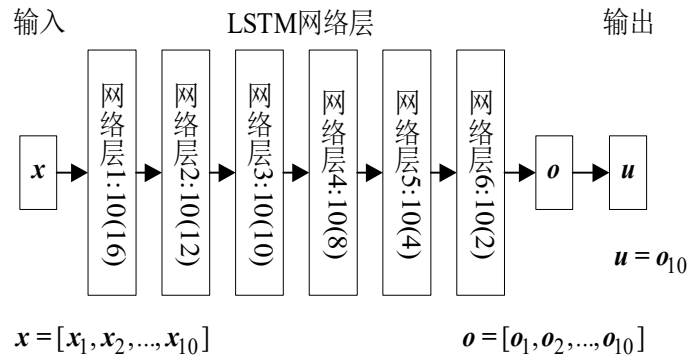


图 3.3 LSTM 网络配置

表 3.2 LSTM 网络结构配置说明

输入变量数据	$\mathbf{x} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_{10}]$	
网络层 1	神经元数：10	每个神经元输出维度：16
网络层 2	神经元数：10	每个神经元输出维度：12
网络层 3	神经元数：10	每个神经元输出维度：10
网络层 4	神经元数：10	每个神经元输出维度：8
网络层 5	神经元数：10	每个神经元输出维度：4
网络层 6	神经元数：10	每个神经元输出维度：2
输出变量	$\mathbf{u}$ 维度：2（表示网络预测的电堆 1#、2#电压）	

神经网络的训练目标是找到一组参数使得损失函数最小，在实数值预测中常用均方差(Mean Square Error, MSE)损失函数<sup>[44]</sup>。梯度下降算法<sup>[50,43]</sup>是神经网络训练的基础算法。由于梯度下降算法针对所有训练样本进行优化，故在样本规模较大时其计算开销较大。一种节约计算资源的方法是采用小批量梯度下降算法<sup>[51,43]</sup>。小批量梯度下降算法在每次迭代时随机选取一个批量的样本进行训练，有利于提高训练效率。

本节选用均方差损失函数，选用小批量梯度下降算法进行训练。设置训练集的训练轮数为 40，小批量梯度下降算法的批量大小  $B=64$ ，对学习率  $\eta$  的调整采用 RMSprop 算法<sup>[52,43]</sup>。假设 LSTM 网络模型的预测值为  $\mathbf{u}=\mathbf{f}(\mathbf{x};\theta)\in\mathbf{R}^d$ ， $\theta$  表示网络的参数，预测的真实值为  $\mathbf{u}\in\mathbf{R}^d$ ，均方差损失函数  $L_{MSE}$  计算方法为：

$$L_{MSE} = L_{MSE}(\mathbf{f}(\mathbf{x};\theta), \mathbf{y}) = \frac{1}{B} \sum_{n=1}^B \frac{1}{d} \sum_{i=1}^d (y_i^{(n)} - f_i(\mathbf{x}^{(n)}; \theta))^2 \quad (3.9)$$

式中， $(\mathbf{x}^{(n)}, \mathbf{y}^{(n)})$  表示某一个批量里的第  $n$  个样本， $y_i^{(n)}$  是  $\mathbf{y}^{(n)}$  的第  $i$  个分量， $f_i(\mathbf{x}^{(n)}; \theta)$  是  $\mathbf{f}(\mathbf{x}^{(n)}; \theta)$  的第  $i$  个分量， $B$  表示某一个批量样本的批量大小， $d=2$  表示  $\mathbf{f}(\mathbf{x}; \theta)$  和  $\mathbf{y}$  的维度。优化目标是找到一组参数集  $\theta$  使得  $L_{MSE}$  最小，即：

$$\theta^* = \arg \min_{\theta} L_{MSE}(\mathbf{f}(\mathbf{x}; \theta), \mathbf{y}) \quad (3.10)$$

式中， $\arg \min$  的意义为求解目标函数为最小值时的参数值。

采用 RMSprop 算法逐轮训练时，某一轮第  $t$  步时网络参数的迭代更新公式为：

$$\mathbf{g}_t = \frac{\partial L_{MSE}(\mathbf{f}(\mathbf{x}; \theta_t), \mathbf{y})}{\partial \theta_t} \quad (3.11)$$

$$\mathbf{G}_1 = (1 - \beta) \mathbf{g}_1^2 \quad (3.12)$$

$$\mathbf{G}_t = \beta \mathbf{G}_{t-1} + (1 - \beta) \mathbf{g}_t^2 \quad (3.13)$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{\mathbf{G}_t + \varepsilon}} \mathbf{g}_t \quad (3.14)$$

式中， $\beta$  是衰减率， $\eta$  是初始的学习率， $\varepsilon$  是防止除数为零的小数值。本节设置  $\eta=0.001$ ， $\beta=0.9$ ， $\varepsilon=10^{-7}$ 。

网络训练时，每轮训练完成后计算在训练集和测试集的均方差损失函数和所有预测变量的平均绝对误差，均方差损失函数用于衡量网络训练的性能。平均绝对误差(Mean Absolute Error, MAE)  $MAE$  可以用于衡量预测误差的大小，其计算方法为：

$$MAE = L_{MAE}(f(\mathbf{x}; \theta), y) = \frac{1}{N} \sum_{n=1}^N \frac{1}{d} \sum_{i=1}^d |y_i^{(n)} - f_i(\mathbf{x}^{(n)}; \theta)| \quad (3.15)$$

式中， $N$  为样本总数量。

LSTM 网络的具体优化步骤如表 3.3 所示。LSTM 网络训练过程中的主要步骤为：(1)导入第 2 章介绍的故障监测数据集，确定迭代轮数、批量大小；(2)划分数数据集，分为训练集和测试集，并将训练集划分为多个批量；(3)通过神经网络的前向传播计算网络的均方差损失函数，然后使用反向传播计算网络参数的梯度并对参数进行更新；(4)训练完成，保存训练好的模型。

表 3.3 LSTM 网络优化步骤

优化步骤
1 对原始数据进行预处理，进行最大最小标准化，制作故障监测数据集
2 输入：故障监测数据集 $D_s$ ，迭代轮数 epochs，批量大小 $B$
3 划分数数据集：按 8:2 随机划分为数据集为训练集 $D_{\text{train}}$ 、测试集 $D_{\text{test}}$
4 训练集 $D_{\text{train}}$ 样本数为 $N_{\text{train}}$ ，按批量大小 $B$ 将训练集 $D_{\text{train}}$ 分成多个批量
5 建立如图 3.3 所示的 LSTM 网络模型 $f(\mathbf{x}; \theta)$
6 随机初始化网络参数 $\theta$
7 训练 LSTM 网络模型
for epoch $\leftarrow$ 1 to epochs do
//批量数量 $K = \lceil N_{\text{train}} / B \rceil$ ，采集小批量样本迭代训练
for step $\leftarrow$ 1 to $K$ do
//前向传播计算均方差损失
按(3.9)式计算 $L_{MSE}$
//反向传播求导计算梯度并更新网络参数
按(3.11)-(3.14)式采用反向传播算法求导并更新参数
end
end
8 训练完成，保存 LSTM 网络模型

### 3.3.2 燃料电池系统故障监测结果分析

在训练过程中，训练集和测试集上的均方差损失函数变化及平均绝对误差变化分别如图 3.4 和图 3.5 所示。随着在训练集上训练轮次的增加，均方差损失和平均绝对误差呈逐渐减小趋势，网络训练到第 27 轮以后减小趋势变缓，均方差损失

和平均绝对误差变化趋于平缓。第 40 轮训练完成后, 在训练集上的均方差损失和平均绝对误差分别约为 0.00096 和 0.010535, 在测试集上的均方差损失和平均绝对误差分别约为 0.00133 和 0.01156。在整个训练过程中, 在训练集和测试集上的均方差损失和平均绝对误差非常接近, 表明网络具有较强的泛化能力。经过 40 轮训练后, LSTM 网络已经能较好拟合燃料电池数据的输入输出关系。




图 3.4 训练集和测试集每轮训练均方差损失变化图




图 3.5 训练集和测试集每轮训练平均绝对误差变化

使用上述训练好的 LSTM 网络测试 8600 个测试集样本, 计算得到电堆 1#电压预测误差均值和标准差分别约为  $\mu_1=0.00393$  和  $\sigma_1=0.03769$ , 电堆 2#电压预测误

差均值和标准差分别约为  $\mu_2=-0.00276$  和  $\sigma_2=0.03507$ 。计算结果表明,测试集样本的预测误差的均值接近于 0。图 3.6 和图 3.7 分别为 LSTM 网络在测试集上的电堆 1#电压和电堆 2#电压的预测误差,除了极少部分样本外,大部分样本的电压预测误差均在  $[-3\sigma_1, 3\sigma_1]$  和  $[-3\sigma_2, 3\sigma_2]$  误差带内分布。




图 3.6 测试集电堆 1#电压预测误差(数据已归一化,纵轴为无量纲量)






图 3.7 测试集电堆 2#电压预测误差(数据已归一化,纵轴为无量纲量)

根据上述对预测误差的分析,设定电堆 1#和电堆 2#的电压残差阈值分别为  $R_{1th}=3\sigma_1=0.11307$ 、 $R_{2th}=3\sigma_2=0.10521$ 。在进行故障监测时,当电堆 1#电压残差或电堆 2#电压残差的绝对值超出阈值时即判定燃料电池系统运行出现故障。图 3.8 为采用训练完成的 LSTM 网络分别对 35 组 1#和电堆 2#故障数据进行预测获得的电压残差,结果表明,电压残差超出了电压残差阈值,与燃料电池系统出现故障是相符的。





(a) 电堆 1#电压残差



(b) 电堆 2#电压残差

图 3.8 电堆 1#/2#故障电压残差(数据已归一化, 纵轴为无量纲量)

全连接神经网络是一种采用全连接层堆叠而成的神经网络, 是一种广泛使用的网络。简单循环神经网络是一类基本循环神经网络, 适用于处理序列信息。本节对全连接神经网络和简单循环神经网络分别进行实验, 网络配置与实验结果如表 3.4 所示。三种不同神经网络模型在训练集上的均方差损失变化如图 3.9 所示。最终得到的第 40 轮训练完成后的训练集均方差损失如表 3.4 所示。全连接神经网络的网络层间采用稠密连接方式, 参数量为 36746, 约是长短期记忆神经网络参数量

5552 的 6.6 倍。在测试集上的计算表明，长短期记忆网络的电压预测误差标准差小于简单循环神经网络，因而长短期记忆网络的预测误差的波动范围更小。简单循环神经网络和长短期记忆神经网络通过网络层内部的连接机制和网络层内部参数共享，降低了参数量，提升了网络参数的利用效率。由于网络层内连接机制，简单循环神经网络在训练时可能出现梯度爆炸或梯度弥散现象，深层的简单循环神经网络训练较为困难。针对梯度爆炸和梯度弥散，本节分别采用了梯度裁剪方法<sup>[53]</sup>和 RMSprop 算法自适应调整学习率进行训练。梯度裁剪方法可以缓解梯度爆炸，但同时也可能降低简单循环神经网络的训练效率。长短期记忆神经网络由于引入了门控机制和内部状态向量，能较好地避免梯度爆炸和梯度弥散问题<sup>[48,49]</sup>。




图 3.9 三种神经网络模型在训练集上的均方差损失变化

表 3.4 几种不同神经网络的实验比较

网络类型	全连接神经网络	简单循环神经网络	长短期记忆神经网络
网络配置	六层，各层神经元数量分别为 128,64,32,16,8,2	六层，每层 10 个神经元，每层输出维度 16,12,10,8,4,2	六层，每层 10 个神经元，每层输出维度 16,12,10,8,4,2
学习率调整方法	RMSprop 算法	RMSprop 算法	RMSprop 算法
网络参数量	36746	1388	5552
训练集训练轮次	40	40	40
训练时是否进行梯度裁剪	否	是	否
训练集均方差损失	0.00067	0.00156	0.00096
测试集均方差损失	0.00108	0.00202	0.00134
测试集预测误差均值	-0.00409(1#电压误差) -0.00489(2#电压误差)	0.00355(1#电压误差) 0.00360(2#电压误差)	-0.00393(1#电压误差) -0.00276(2#电压误差)
测试集预测误差标准差	0.03339(1#电压误差) 0.03172(2#电压误差)	0.04291(1#电压误差) 0.04662(2#电压误差)	0.03769(1#电压误差) 0.03507(2#电压误差)

## 3.4 本章小结

首先，本章阐述了一种针对简单的循环神经网络的改进模型：长短期记忆(Long Short-Term Memory, LSTM)网络。LSTM 网络在简单循环神经网络的基础上引入门控机制和内部状态向量，改善了梯度的传播和短期记忆问题。其次，采用 LSTM 网络构建了燃料电池系统故障监测模型，以燃料电池系统的实际输出电压和网络预测的输出电压产生的残差判断燃料电池系统是否存在故障。当电压残差大于设定阈值时做出发生故障的决策。最后，与全连接神经网络和简单循环神经网络的实验对比表明，LSTM 网络的网络参数量和训练难度适中，具有组合优势，在燃料电池系统的故障监测中有一定可行性。

## 第4章 基于改进LSTM网络的燃料电池系统故障监测

### 4.1 基于残差-长短期记忆网络的燃料电池系统故障监测

2015年,微软研究院(Microsoft Research)的Kaiming He等人提出了采用短路连接(Shortcut Connection)的深度残差网络(Deep Residual Network),并进一步设计了18、34、50、101和152层的残差网络模型<sup>[54]</sup>。残差网络(Residual Network, ResNet)在多个视觉任务数据集上均取得了当时最优异的性能,并产生了广泛的影响力。残差网络提出了残差学习的思想。本节基于残差学习原理对长短期记忆网络进行改进,设计一种具有残差学习的长短期记忆网络,称为残差-长短期记忆网络(Residual Network with Long Short-Term Memory, Res-LSTM),继而进一步利用这种 Res-LSTM 模型进行燃料电池系统的故障监测。

#### 4.1.1 残差学习及残差-长短期记忆网络(Res-LSTM)

##### (1)残差学习思想

假设  $H(\bullet)$  是一个由多个神经网络层(此处不必是整个网络)连结成的待拟合的未知映射,  $\mathbf{x}$  表示这些网络层的第一个网络层的输入,  $\mathbf{y}$  表示这些网络层的最终输出,那么可得到:

$$\mathbf{y} = H(\mathbf{x}) \quad (4.1)$$

残差学习的设计思想为:与其期望多个连结起来的神经网络层拟合映射  $H(\mathbf{x})$ , 不如直接让这些网络层近似一个残差函数(Residual Function)  $F(\mathbf{x})$ , 原始函数  $H(\mathbf{x})$  的拟合结果等效变为  $F(\mathbf{x}) + \mathbf{x}$ ; 尽管两种形式都能渐进地近似期望的函数,但学习的难易程度可能是不同的<sup>[54]</sup>。

这种基于残差学习的结构重构是受到神经网络退化问题而启发的,即如果残差函数(Residual Function)  $F(\mathbf{x})$  趋向于  $\mathbf{0}$ , 在整个模型中添加的多个神经网络层将被构建为恒等映射(Identity Mapping)  $\mathbf{x}$ 。神经网络的退化问题表明,当采用多个非线性神经网络层时,求解器在逼近恒等映射方面具有较大的困难。在残差学习重构下,如果恒等映射是最优的,求解器将简单地驱使多个非线性神经网络层趋向于零,从而更好地逼近恒等映射<sup>[54]</sup>。

然而,在实际情况中,恒等映射可能不是最优的,但残差重构可能预先解决这

个问题。如果最优函数是更接近于一个恒等映射，而不是一个零映射，求解器将应该更容易地寻找到一个参考恒等映射的扰动，而不是将最优函数作为一个新的函数学习<sup>[54]</sup>。通常，学习到的残差函数具有小扰动的特征，进一步表明恒等映射提供了一个合理的先决条件。这些特征揭示了残差学习思想可以作为一种合理的设计思想引入神经网络的设计思路中，从而构建性能更优良的网络架构。

## (2)恒等映射与短路连接

根据残差学习的设计思想，我们可以对每几个连结起来的神经网络层采用残差学习结构。一般地，一个残差块可定义为：

$$\mathbf{y} = \mathbf{F}(\mathbf{x}) + \mathbf{x} \quad (4.2)$$

式中， $\mathbf{x}$ 和 $\mathbf{y}$ 分别表示某几个连结起来的神经网络层的输入和输出， $\mathbf{F}(\mathbf{x})$ 表示待学习的残差函数。该式将待学习的映射拆分成残差函数 $\mathbf{F}(\mathbf{x})$ 和恒等映射(Identity Mapping) $\mathbf{x}$ (即输入 $\mathbf{x}$ )的叠加。残差函数 $\mathbf{F}(\mathbf{x})$ 可以是多个连结起来的神经网络层。在这里，残差函数 $\mathbf{F}(\mathbf{x})$ 和恒等映射 $\mathbf{x}$ 的相加采用按元素相加的方式。从网络结构上看，这种按元素相加的方式在神经网络中可以表示为短路连接(Shortcut Connection，亦可以简称为短接)<sup>[54,55]</sup>方式，如图4.1(a)所示。恒等映射可以通过网络结构上的短接形式简洁地实现。

在残差学习的设计中，网络被拆分为残差函数 $\mathbf{F}(\mathbf{x})$ 和恒等映射 $\mathbf{x}$ 。残差函数 $\mathbf{F}(\mathbf{x})$ 和恒等映射 $\mathbf{x}$ 通过短接的方式形成一个残差块。短接方式在神经网络结构中没有添加新的网络参数，也不会增加计算上的复杂度，具有结构简单且修改灵活的优点。当运用到其它神经网络时，对原始网络的修改非常简洁。这些特点使得残差学习思想在神经网络结构设计中具有广泛的可行性和适用性。

## (3)残差网络

残差网络(Residual Network, ResNet)通过在神经网络层间采用短接形成残差进行残差学习。残差块是残差网络的基本构成单元，将多个不同的残差块堆叠可以形成不同深度的残差网络。残差块示意图如图4.1(a)所示，其计算如(4.2)式所示。输入 $\mathbf{x}$ 经过 $L$ 层神经网络层变换后得到残差函数 $\mathbf{F}(\mathbf{x})$ ， $\mathbf{F}(\mathbf{x})$ 再叠加上原始输入 $\mathbf{x}$ 得到输出 $\mathbf{y}$ 。

特别值得注意的是，当连结的多层神经网络层变换后所得到的结果残差函数 $\mathbf{F}(\mathbf{x})$ 与原始输入 $\mathbf{x}$ 的维度不同时， $\mathbf{F}(\mathbf{x})$ 与 $\mathbf{x}$ 无法实现直接相加。此时，一个简单有效的方法是采用线性投影矩阵 $\mathbf{W}$ 对原始输入 $\mathbf{x}$ 进行维度变换获得与多层堆叠的神经网络层变换后所得的残差函数 $\mathbf{F}(\mathbf{x})$ 相匹配的维度<sup>[54]</sup>。此时相应的计算修改为如(4.3)式所示：

$$y = F(x) + Wx \quad (4.3)$$

可以看到,采用投影矩阵变换会增加网络的参数,同时也因为矩阵乘法的引入添加了少量的计算量。残差块的结构也修改为如图 4.1(b)所示。

由于引入残差学习思想,残差网络在一定程度上抑制了随着神经网络层的加深导致的梯度消失或梯度爆炸问题,因而对缓解深度神经网络中的模型退化问题具有极大的适用性。残差网络能有效避免深度神经网络的退化(Degradation)问题,增强深度神经网络的表示能力,进一步提升深度学习模型的性能<sup>[54,55]</sup>。


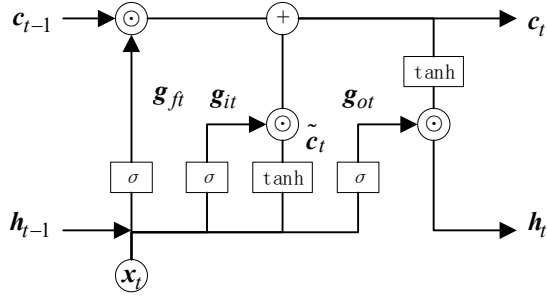


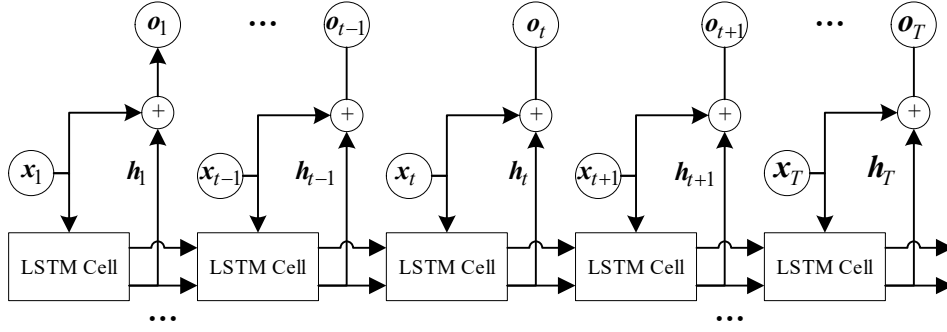
图 4.1 残差块示意图

#### (4)残差-长短期记忆网络(Res-LSTM)

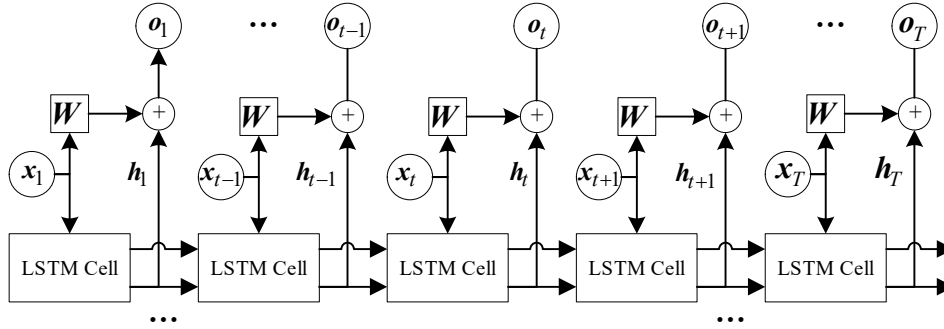
残差-长短期记忆网络(Residual Network with Long Short-Term Memory, Res-LSTM)在传统的 LSTM 网络基础上引入残差学习机制,结合了残差学习设计思想和 LSTM 网络的优点。所设计的 Res-LSTM 网络层的示意图如图 4.2 所示。Res-LSTM 网络层通过残差网络的短路连接将残差学习引入 LSTM 网络层, LSTM 神经元和 LSTM 网络层的模型不变,仅在原来的 LSTM 网络层的输出上叠加了网络层的原始输入。由图 4.2 可知, Res-LSTM 网络层将 LSTM 网络层作为残差函数  $F(x)$ 。如果将 LSTM 网络层抽象为一个神经网络算子  $LSTM(\bullet)$ (即表示 LSTM 神经网络层级的计算),则残差函数的输出可表示为  $F(x)=h=LSTM(x)$ ,具体如(4.4)-(4.9)式所示。当  $F(x)$  与  $x$  的维度相同时, Res-LSTM 的输出计算公式如(4.10)式所示,进一步可简化为  $o = x + F(x) = x + LSTM(x)$ ; 当  $F(x)$  与  $x$  的维度不相同, Res-LSTM 的输出计算公式如(4.11)式所示,进一步可简化为  $o = Wx + F(x) = Wx + LSTM(x)$ 。(4.4)-(4.11)式中各个符号的意义与第 3 章一致,此处不再重述。




(a) LSTM Cell结构



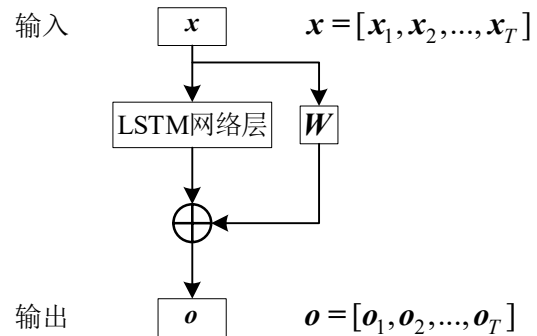
(b) Res-LSTM网络层结构(无线性投影矩阵变换)



(c) Res-LSTM网络层结构(有线性投影矩阵变换)



(d) 简化的Res-LSTM网络层结构  
(无线性投影矩阵变换)



(e) 简化的 Res-LSTM网络层结构  
(有线性投影矩阵变换)

图 4.2 Res-LSTM 网络层的示意图

$$g_{ft} = \sigma(W_{fh}h_{t-1} + W_{fx}x_t + b_f) \quad (4.4)$$

$$\mathbf{g}_{it} = \sigma(\mathbf{W}_{ih}\mathbf{h}_{t-1} + \mathbf{W}_{ix}\mathbf{x}_t + \mathbf{b}_i) \quad (4.5)$$

$$\tilde{\mathbf{c}}_t = \tanh(\mathbf{W}_{ch}\mathbf{h}_{t-1} + \mathbf{W}_{cx}\mathbf{x}_t + \mathbf{b}_c) \quad (4.6)$$

$$\mathbf{c}_t = \mathbf{g}_{it} \otimes \tilde{\mathbf{c}}_t + \mathbf{g}_{ft} \otimes \mathbf{c}_{t-1} \quad (4.7)$$

$$\mathbf{g}_{ot} = \sigma(\mathbf{W}_{oh}\mathbf{h}_{t-1} + \mathbf{W}_{ox}\mathbf{x}_t + \mathbf{b}_o) \quad (4.8)$$

$$\mathbf{h}_t = \mathbf{g}_{ot} \otimes \tanh(\mathbf{c}_t) \quad (4.9)$$

$$\mathbf{o}_t = \mathbf{h}_t + \mathbf{x}_t \quad (4.10)$$

$$\mathbf{o}_t = \mathbf{h}_t + \mathbf{W}\mathbf{x}_t \quad (4.11)$$

#### 4.1.2 Res-LSTM 模型结构配置与训练

本节继续使用第 2 章的燃料电池系统故障监测数据集建立 Res-LSTM 模型预测燃料电池的输出电压。首先，根据燃料电池系统故障监测数据集训练 Res-LSTM 模型预测输出电压。然后，分析系统实际输出的电压与预测电压的残差，确定系统正常时预测电压的阈值。假设电压残差为  $R$ ，测试数据的电压残差标准差为  $\sigma$ ，电压残差阈值为  $R_h$ ，设置电压残差阈值  $R_h = 3\sigma$ ，当  $R > R_h$  时判定质子交换膜燃料电池系统处于故障运行状态，否则判断为正常运行状态。

图 4.3 分别为 LSTM 网络与 Res-LSTM 模型的结构示意图，图 4.3(a)为 LSTM 网络，图 4.3(b)和图 4.3(c)为对应的构造不同数量残差块的 Res-LSTM 模型。三个网络分别命名为 LSTM11、Res-LSTM11-6、Res-LSTM11-10。本节设计的 Res-LSTM 模型选用如图 4.3(c)Res-LSTM11-10 所示的网络结构。整个 Res-LSTM 模型共由 11 层 Res-LSTM 网络层组成，含有 10 个残差块，每层的 LSTM 网络层共有 10 个神经元，各层每个神经元的输出数据维度分别为 16,10,10,10,8,8,8,4,4,4,2。在残差块中，实线短接边表示直接相加，虚线短接边表示进行线性变换后相加。网络输入 10 个时刻的 20 维向量数据  $\mathbf{x}_i (i=1,2,\dots,10)$ ，每个时刻间隔周期为 1 秒，向量  $\mathbf{x}_i$  各维数据的意义已在第 2 章故障监测数据集中说明。前一个网络层的输出作为后一个网络层的输入。最后一个网络层的输出为最后一个时刻的数据  $\mathbf{u}$ ，即为电堆 1#电压和电堆 2#电压的预测值。

在网络训练时需要选定损失函数和优化算法，本节使用均方差损失函数和 Adam 算法<sup>[56]</sup>。假设 Res-LSTM 的预测值为  $\mathbf{u} = \mathbf{u}(\theta) = \mathbf{f}(\mathbf{x};\theta)$ ， $\theta$  表示神经网络的参数集，预测的真实值为  $\mathbf{y}$ ，均方差损失函数  $L_{MSE}$  计算方法为：

$$L_{MSE} = L_{MSE}(\mathbf{u}, \mathbf{y}) = L_{MSE}(\mathbf{f}(\mathbf{x};\theta), \mathbf{y}) = \frac{1}{B} \sum_{r=1}^B \frac{1}{d} \sum_{i=1}^d (y_i^{(r)} - f_i(\mathbf{x}^{(r)}; \theta))^2 \quad (4.12)$$



式中,  $(\mathbf{x}^{(r)}, \mathbf{y}^{(r)})$  表示第  $r$  个样本,  $y_i^{(r)}$  是  $\mathbf{y}^{(r)}$  的第  $i$  个分量,  $f_i(\mathbf{x}^{(r)}; \theta)$  是  $\mathbf{f}(\mathbf{x}^{(r)}; \theta)$  的第  $i$  个分量,  $\mathbf{f}(\mathbf{x}^{(r)}; \theta)$  表示第  $r$  个样本的预测值,  $B$  表示批量大小,  $d$  表示  $\mathbf{u}$  和  $\mathbf{y}$  的维度,  $d=2$ 。神经网络的训练目标是找到一组参数集  $\theta$  使得均方差损失最小, 即:

$$\theta^* = \arg \min_{\theta} L_{MSE}(\mathbf{f}(\mathbf{x}; \theta), \mathbf{y}) \quad (4.13)$$

式中,  $\arg \min$  的意义为求解目标函数最小时的参数值。

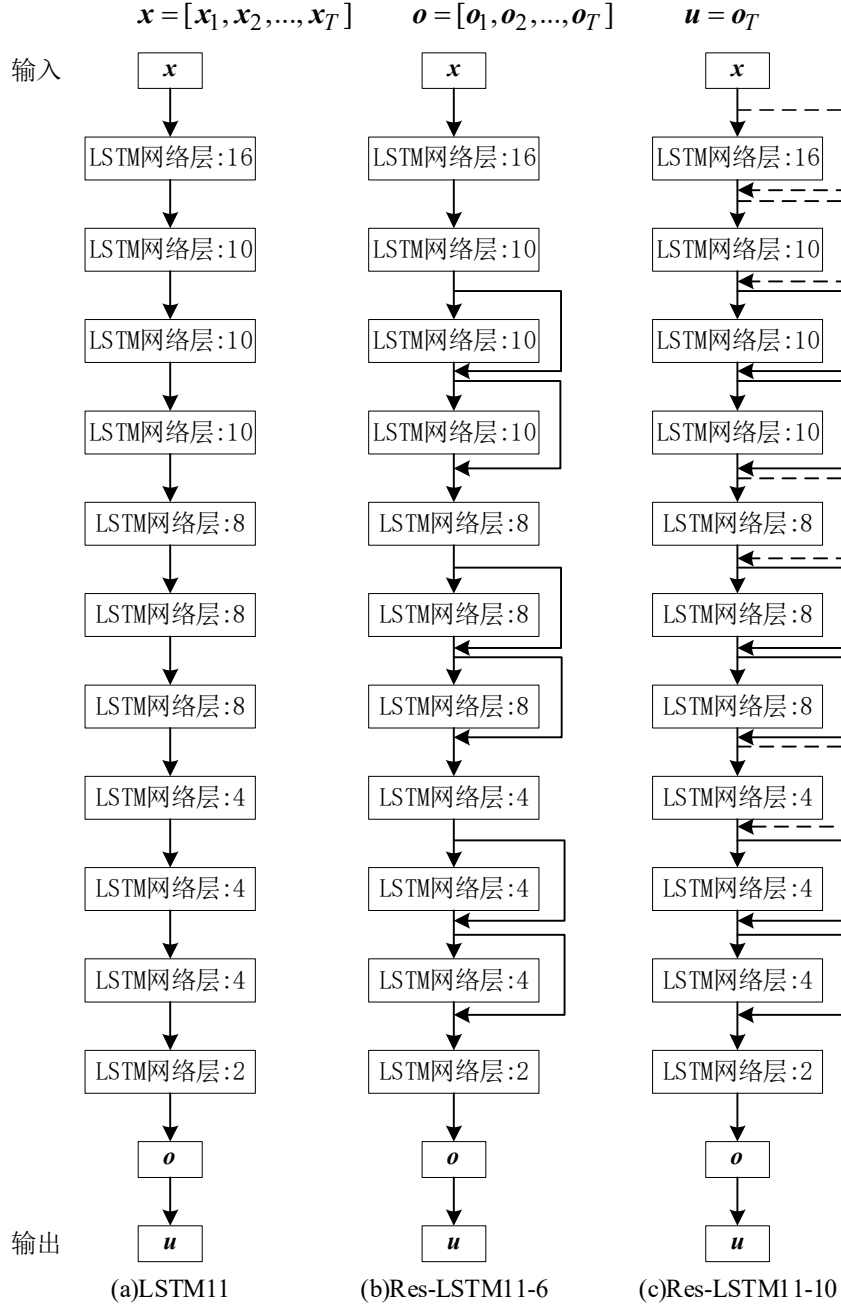


图 4.3 LSTM 网络与 Res-LSTM 结构配置示意图( $T=10$ )

Adam 算法是一种小批量梯度下降法的改进算法, 本节采用 Adam 算法进行网络参数更新。Adam 算法不仅对学习率进行自适应调整, 而且对更新梯度进行修正。假设某一轮第  $t$  步迭代时的梯度为  $g_t$ , Adam 算法计算方法为<sup>[56,43]</sup>:

$$g_t = \frac{\partial L_{MSE}(f(\mathbf{x}; \theta_t), y)}{\partial \theta_t} \quad (4.14)$$

$$M_t = \beta_1 M_{t-1} + (1 - \beta_1) g_t \quad (4.15)$$

$$G_t = \beta_2 G_{t-1} + (1 - \beta_2) g_t^2 \quad (4.16)$$

$$\overline{M}_t = \frac{M_t}{1 - \beta_1^2} \quad (4.17)$$

$$\overline{G}_t = \frac{G_t}{1 - \beta_2^2} \quad (4.18)$$

$$\Delta \theta_t = \frac{\eta}{\sqrt{\overline{G}_t + \varepsilon}} \overline{M}_t \quad (4.19)$$

$$\theta_t = \theta_{t-1} - \Delta \theta_t \quad (4.20)$$

式中,  $M_t$  看作为梯度的一阶矩,  $M_0=0$ ,  $G_t$  看作为梯度的二阶矩,  $G_0=0$ ,  $\eta$  为初始学习率,  $\beta_1$  和  $\beta_2$  分别为衰减率,  $\varepsilon$  为防止除零错误的小常数。本节设置  $\eta=0.001$ ,  $\beta_1=0.9$ ,  $\beta_2=0.999$ ,  $\varepsilon=10^{-7}$ 。

网络训练时, 每轮训练完成后计算在训练集和测试集的均方差损失函数和所有预测变量的平均绝对误差, 均方差损失函数用于衡量网络训练的性能。平均绝对误差  $MAE$  用于衡量预测误差的大小, 计算方法为:

$$MAE = \frac{1}{N} \sum_{r=1}^N \frac{1}{d} \sum_{i=1}^d |y_i^{(r)} - u_i^{(r)}| \quad (4.21)$$

式中,  $N$  为样本总数量。

Res-LSTM 模型的优化步骤如表 4.1 所示, 具体步骤有: (1) 对数据进行预处理, 进行最大最小归一化, 制作成故障监测数据集; (2) 导入故障监测数据集, 确定迭代轮数、批量大小; (3) 划分数据集, 按 8:2 随机划分数据集为训练集和测试集, 分别用于网络模型的训练和测试; (4) 按批量大小将训练集分成多个批量, 便于每次迭代时使用一个批量的样本; (5) 按所设计的结构建立 Res-LSTM 模型; (6) 对网络参数进行初始化, 确定网络参数的初始值; (7) 采用 Adam 算法迭代训练 Res-LSTM 模型, 即先通过前向传播计算均方差损失函数, 再通过反向传播计算各个网络参数的偏导数, 最后根据 Adam 算法的学习率调整方法和梯度修正方法进行运算, 迭代完成参数的更新。

表 4.1 Res-LSTM 模型优化步骤


优化步骤
1 对数据进行预处理，进行最大最小归一化
2 输入：故障监测数据集 $D_s$ ，迭代轮数 epochs，批量大小 $B$
3 划分数数据集：按 8:2 随机划分数数据集为训练集 $D_{\text{train}}$ 、测试集 $D_{\text{test}}$
4 训练集 $D_{\text{train}}$ 样本数 $N_{\text{train}}$ ，按批量大小 $B$ 将训练集 $D_{\text{train}}$ 分成多个批量
5 建立如图 4.3(c)所示的 Res-LSTM 模型 $f(x; \theta)$
6 随机初始化网络参数 $\theta$
7 训练 Res-LSTM 模型
for epoch $\leftarrow$ 1 to epochs do
//批量数量 $K = \lceil N_{\text{train}} / B \rceil$ ，采集小批量样本迭代训练
for step $\leftarrow$ 1 to $K$ do
//前向传播计算均方差损失
按(4.12)式计算 $L_{\text{MSE}}$
//反向传播求导计算梯度并更新网络参数
按(4.14)-(4.20)式采用反向传播算法求导并更新参数
end
end
8 训练完成，保存 Res-LSTM 模型

## 4.1.3 基于 Res-LSTM 模型的燃料电池系统故障监测性能分析


在训练过程中，训练集和测试集的均方差损失函数和平均绝对误差的变化如图 4.4 所示。在前 14 轮训练过程中，训练集和测试集的均方差损失和平均绝对误差呈快速减小趋势，第 14 轮以后均方差损失和平均绝对误差减小趋势变缓，进入平缓变化阶段，总体呈缓慢减小趋势，表明网络参数得到了较好的训练，能够对输入数据较好地拟合。第 40 轮训练完成后，训练集的均方差损失和平均绝对误差分别约为 0.00078 和 0.01129，测试集的均方差损失和平均绝对误差分别约为 0.00103 和 0.01185。在整个训练过程中，Res-LSTM 模型在训练集和测试集上的均方差损失和平均绝对误差非常接近，表明网络具有较强的泛化能力。从图 4.4 中可以看到，训练集和测试集都在第 39 轮训练后得到最小的均方差损失和平均绝对误差。为挑选出性能最好的网络模型，选择第 39 轮训练后的网络模型参数作为最终的 Res-LSTM 模型参数。此时训练集的均方差损失和平均绝对误差分别约为 0.00070 和

0.00918, 测试集的均方差损失和平均绝对误差分别约为 0.00101 和 0.00977。

使用最终得到的 Res-LSTM 模型对 8600 个测试集样本进行测试, 计算得到电堆 1#电压预测误差均值和标准差分别约为  $\mu_1=0.00068$  和  $\sigma_1=0.03179$ , 电堆 2#电压预测误差均值和标准差分别约为  $\mu_2=-0.00031$  和  $\sigma_2=0.03176$ 。计算结果表明, 测试集样本的预测误差的均值非常接近于 0。图 4.5 和图 4.6 分别为 Res-LSTM 模型在测试集上的电堆 1#电压和电堆 2#电压的预测误差。除了极少部分样本外, 大部分样本的电压预测误差均在  $[-3\sigma_1, 3\sigma_1]$  和  $[-3\sigma_2, 3\sigma_2]$  内分布。



(a) 均方差损失变化



(b) 平均绝对误差变化

图 4.4 训练集和测试集每轮均方差损失和平均绝对误差变化




图 4.5 测试集电堆 1#电压预测误差(数据已归一化，纵轴为无量纲量)






图 4.6 测试集电堆 2#电压预测误差(数据已归一化，纵轴为无量纲量)

根据上述预测误差的分析，设定电堆 1#电压残差阈值  $R_{1th}=3\sigma_1=0.09537$ ，电堆 2#电压残差阈值  $R_{2th}=3\sigma_2=0.09528$ 。在进行故障监测时，当电堆 1#电压残差或电堆 2#电压残差的绝对值超出阈值时即可判定燃料电池系统运行出现故障。图 4.7 分别为采用 Res-LSTM 模型预测的 38 组故障样本的电堆 1#电压和电堆 2#电压的残差，图中显示故障样本的电压残差超出了电压残差阈值，因此可以判断燃料电池系统出现了故障，符合实际情况。



(a) 电堆 1#故障电压残差



(b) 电堆 2#故障电压残差

图 4.7 电堆 1#/2#故障电压残差(数据已归一化, 纵轴为无量纲量)

为比较 LSTM 网络和 Res-LSTM 模型的性能, 分别设计了一个 LSTM 网络和相应的两个不同数量残差块的 Res-LSTM 模型, 三个网络的结构如 4.1.2 节的图 4.3 所示。图 4.3(a)、(b)、(c) 三个网络分别已被命名为 LSTM11、Res-LSTM11-6 和 Res-LSTM11-10。四个网络模型的实验结果如表 4.2 所示, 表中所列为在 40 轮训练过程中在训练集上的均方差损失最小的四个模型及其结果。其中, LSTM 网络为两个 Res-LSTM 模型去除短接后的模型, 两个 Res-LSTM 模型的残差块数量分别为 6 和 10, 三个网络结构的其它超参数保持相同。Res-LSTM11-6 结构只在相同的输入输出维度构造残差, 没有在 LSTM11 结构的基础上增加网络参数; Res-LSTM11-10 结构继续在不同的输入输出维度构造残差, 加入了线性投影矩阵变换, 增加了约 8% 的网络参数。针对 Res-LSTM11-10 结构模型, 分别选用 Adam 算法和 RMSprop 算

法训练。同时采用 RMSprop 算法训练 LSTM11 结构模型和 Res-LSTM11-6 结构模型。在均方差损失、预测误差均值和预测误差标准差等指标上，Res-LSTM 模型比具有相同 LSTM 网络层的 LSTM 网络性能表现更好。Res-LSTM 的预测电压均方差损失更小，预测电压误差均值更接近于 0，预测电压误差标准差更小。相比 LSTM 网络，Res-LSTM 模型在性能上具有全面的改进提高。特别是在网络参数量相同时，Res-LSTM 模型相比 LSTM 网络依然具有全面的性能优势。LSTM 网络和 Res-LSTM 模型在训练集上的均方差损失随训练轮次的变化如图 4.8 所示。可以看到相比 LSTM 网络，Res-LSTM 模型的均方差损失更快达到稳定值，训练速度更快。同时对于相同的 Res-LSTM 模型结构，Adam 算法比 RMSprop 算法的训练速度更快。

表 4.2 LSTM 网络模型和 Res-LSTM 模型的实验比较

网络类型	LSTM	Res-LSTM	Res-LSTM	
网络结构	LSTM11	Res-LSTM11-6	Res-LSTM11-10	
网络参数量	7376	7376	7968	
训练优化方法	RMSprop 算法	RMSprop 算法	RMSprop 算法	Adam 算法
训练集训练轮次	40	40	40	40
训练集均方差损失	0.00165	0.00091	0.00070	0.00070
测试集均方差损失	0.00202	0.00119	0.00097	0.00101
测试集预测误差均值 (1#/2#)	-0.00523/ -0.00495	-0.00149/ -0.00305	0.00027/ -0.00170	0.00068/ -0.00031
测试集预测误差标准 差 $\sigma$ (1#/2#)	0.04607/ 0.04322	0.03579/ 0.03291	0.03247/ 0.02959	0.03179/ 0.03176
电压残差阈值	0.13821/ $R_{th} = 3\sigma$ (1#/2#)	0.10737/ 0.09873	0.09741/ 0.08877	0.09537/ 0.09528

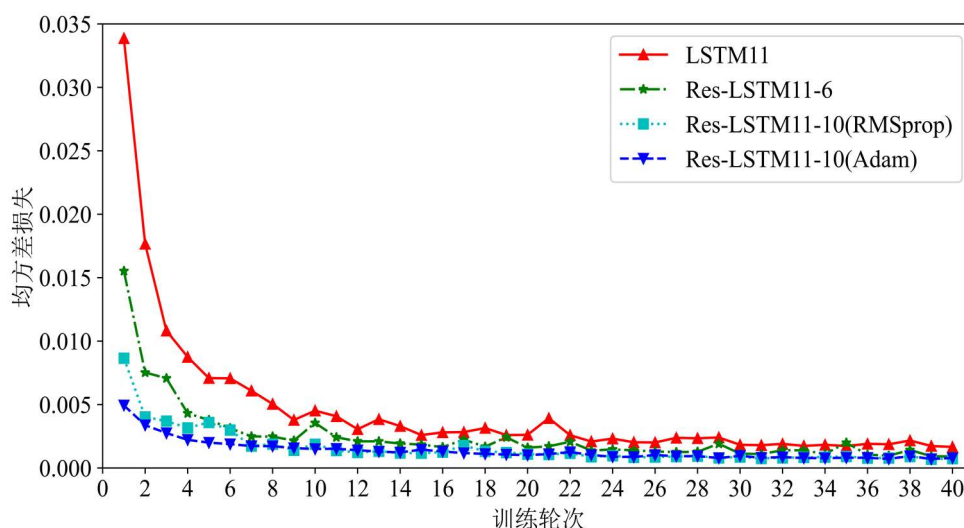


图 4.8 LSTM 网络和 Res-LSTM 在训练集上的均方差损失变化

## 4.2 基于 ResNeXt-LSTM 模型的燃料电池系统故障监测

残差网络在网络结构中采用短接的跨层连接形式重构网络, 形成残差学习机制。这一简洁的设计思想促使残差网络获得了巨大的性能提升。在原始的残差网络中, 残差函数是由逐层堆叠的神经网络层实现的, 因而这种自然而然的残差函数的设计有可能并不是最优结构。针对残差函数进行结构优化设计有可能进一步提高残差网络的性能。一些研究人员对残差网络中的残差函数进行了改进, 提出了 ResNeXt (NeXt 表示 next, 指代 ResNeXt 模型的设计在 ResNet 模型的基础上增加了一个称为残差变换数量的维度) 模型<sup>[57]</sup>。ResNeXt 模型对残差网络 ResNet 中由卷积算子实现的残差函数进行了重新设计, 并在多个视觉任务上取得了更优良的性能。本节基于 ResNeXt 模型提出的聚合残差变换 (Aggregated Residual Transformations) 的设计思想, 对原始的残差-长短期记忆网络 (Res-LSTM) 进行重新设计, 从而设计一种聚合残差变换的残差-长短期记忆网络 (ResNeXt-LSTM), 并进行燃料电池系统的故障监测。

### 4.2.1 聚合残差变换的残差网络

残差网络的残差函数采用高度模块化的设计。整个残差网络由一系列具有相同拓扑结构的残差块组成。原始的 ResNeXt 模型受 VGG 网络和 ResNet 网络的启发, 采用了两个简单的设计规则: 当生成的特征的维度相同时, 残差块保持相同的超参数设计; 每次当特征图的维度缩减 2 倍时, 将残差块的通道数扩大 2 倍<sup>[57]</sup>。这两条设计规则与原始的 ResNet 模型一致, 缩窄了网络的设计空间, 因而 ResNeXt 模型的设计只专注于设计残差模块。

神经元模型是人工神经网络的基础模型, 基本的神经元模型执行内积 (即加权和) 运算和非线性激活变换。内积可以被认为是一种形式的聚合变换:

$$\sum_{i=1}^D w_i x_i \quad (4.22)$$

式中,  $\mathbf{x}=[x_1, x_2, \dots, x_D]$  是神经元模型的  $D$  维输入向量,  $w_i$  是第  $i$  维输入的权重, 是可学习的参数。神经元模型中的内积 (加权和) 运算如图 4.9 所示, 可以重新描述为拆分 (splitting)-变换 (transforming)-聚合 (aggregating)<sup>[57]</sup> 的形式。(1) 拆分 splitting: 向量被切片为低维的表示。在简单神经元模型中, 输入数据  $\mathbf{x}=[x_1, x_2, \dots, x_D]$  被切片为单维的子空间表示  $x_i (i=1, 2, \dots, D)$ 。(2) 变换 transforming: 对低维表示进行变换。在



简单神经元模型中采用简单的比例缩放  $w_i x_i$ 。(3)聚合 aggregating: 对所有表示的变换进行聚合。在简单神经元模型中采用简单的求和  $\sum_{i=1}^D$  进行聚合。




图 4.9 基本神经元模型中的内积运算

ResNeXt 模型中的残差块设计受到最基本的神经元模型的启发, 其将基本变换  $w_i x_i$  替换为更通用的函数, 即将其也设计成一个网络。在形式上, 聚合变换可以表示为:

$$\mathbf{F}(\mathbf{x}) = \sum_{i=1}^C \mathbf{T}_i(\mathbf{x}) \quad (4.23)$$

式中,  $\mathbf{T}_i(\mathbf{x})$  可以是任何函数, 通常可以用神经网络来实现。对任意的  $i$ ,  $\mathbf{T}_i(\bullet)$  对输入  $\mathbf{x}$  进行变换, 然后所有的变换通过相加的形式进行聚合。ResNeXt 模型通过堆叠聚合残差变换的残差块构建神经网络模型。在 ResNeXt 模型中, 聚合的变换被用作残差函数, 即:

$$\mathbf{y} = \mathbf{x} + \mathbf{F}(\mathbf{x}) = \mathbf{x} + \sum_{i=1}^C \mathbf{T}_i(\mathbf{x}) \quad (4.24)$$

式中,  $\mathbf{y}$  表示输出。当恒等映射  $\mathbf{x}$  与残差函数  $\mathbf{F}(\mathbf{x})$  的维度不同时, 可以采用线性投影矩阵变换匹配维度后再相加, 即:

$$\mathbf{y} = \mathbf{W}\mathbf{x} + \mathbf{F}(\mathbf{x}) = \mathbf{W}\mathbf{x} + \sum_{i=1}^C \mathbf{T}_i(\mathbf{x}) \quad (4.25)$$

ResNeXt 模型对残差网络 ResNet 中的残差函数  $\mathbf{F}(\mathbf{x})$  的形式进行了重新设计, 即残差函数  $\mathbf{F}(\mathbf{x})$  由多个不同的残差变换(Residual Transformation)  $\mathbf{T}_i(\mathbf{x})$  ( $i = 1, 2, \dots, C$ ) 聚合而成, 而残差变换的聚合通过相加的运算形式执行。所有的残差变换  $\mathbf{T}_i(\mathbf{x})$  ( $i = 1, 2, \dots, C$ ) 可以采用神经网络实现, 且具有相同拓扑结构。聚合残差变换的残差块如图 4.10 所示。因为残差变换  $\mathbf{T}_i(\mathbf{x})$  ( $i = 1, 2, \dots, C$ ) 的拓扑结构相同, 设计出一个残差变换之后可以采用重复模块的方法构造所有的残差变换。这种结构具有高度模块化、可扩展性强的特点, 展现了一种高效简洁的神经网络设计方法。

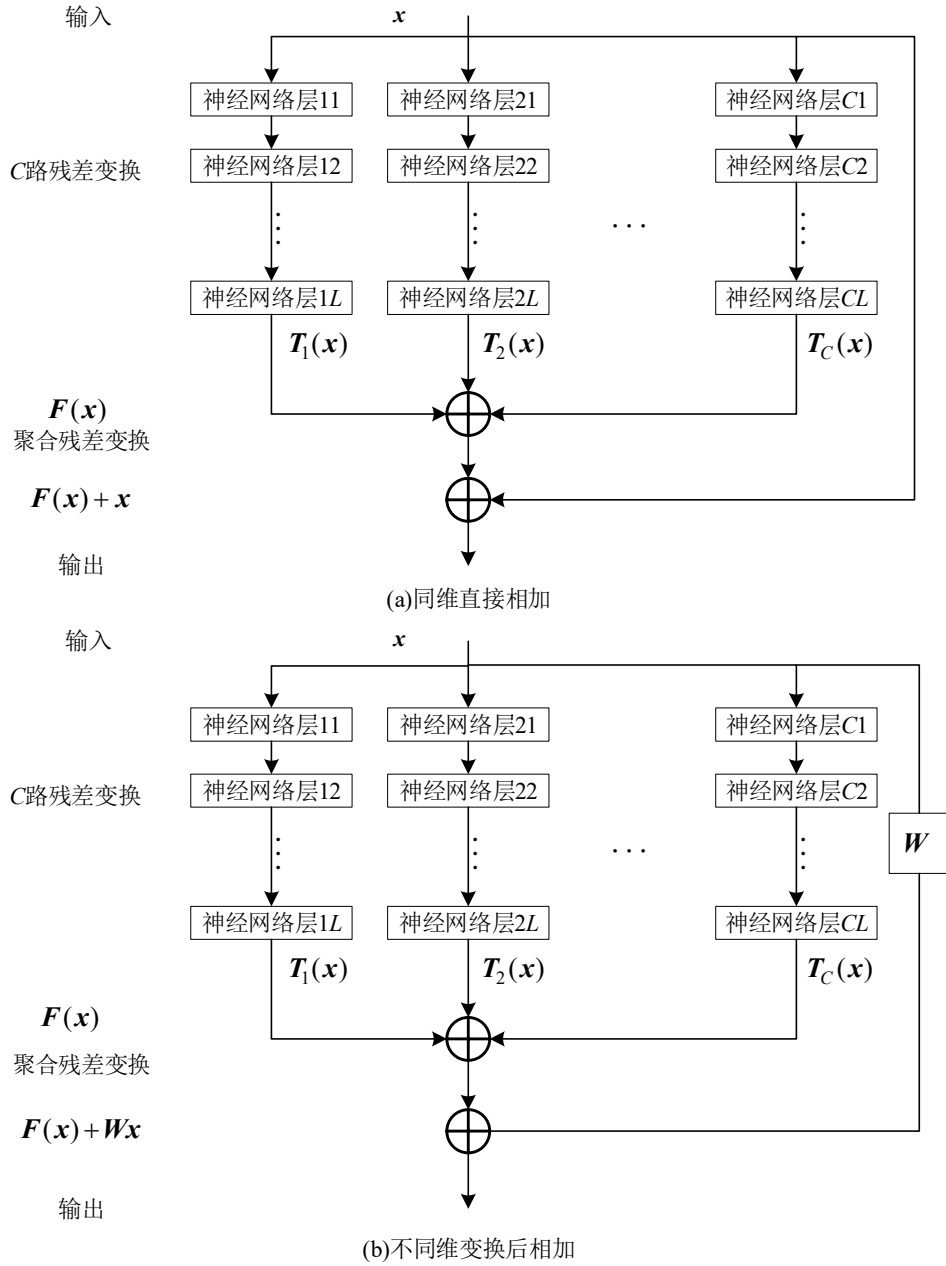


图 4.10 聚合残差变换的残差块

ResNeXt 模型相比残差网络 ResNet 增加了一个设计的维度, 即聚合的残差变换的数量  $C$  [57]。聚合的残差变换的数量称为基数(Cardinality), 其代表了具有相同拓扑的残差变换  $T_i(x)$  ( $i=1,2,\dots,C$ ) 的数量, 是 ResNeXt 模型的重要超参数。

ResNeXt 名称中的 NeXt 即表示增加了一个维度(next, 下一个)。

#### 4.2.2 聚合残差变换的残差-长短期记忆网络 (ResNeXt-LSTM)

ResNeXt 模型对残差网络中的残差函数进行改造, 采用了拓扑结构相同的神经网络构建高度模块化和易扩展的多路残差变换, 并进一步将多路残差变换聚合

成 ResNeXt 模型中残差模块的残差函数。本节以长短期记忆网络为基础，根据 ResNeXt 模型引入的聚合残差变换的设计原则，构建一种聚合残差变换的残差-长短期记忆网络，简称为 ResNeXt-LSTM。

假设有  $C$  路残差变换，每一路残差变换均采用 LSTM 神经网络实现，则各路残差变换的输出  $h^{(k)}$  的计算过程如(4.26)-(4.31)所示。对  $C$  路 LSTM 神经元的输出求和即可得到聚合后的神经元层级的残差输出，如(4.32)式所示。当  $F(x)$  与  $x$  的维度相同时，ResNeXt-LSTM 残差块在神经元层级的输出计算公式如(4.33)式所示；当  $F(x)$  与  $x$  的维度不相同，ResNeXt-LSTM 残差块在神经元层级的输出计算公式如(4.34)式所示。(4.26)-(4.34)式中各个符号除上标  $(k)$  表示第  $k$  路残差变换外的计算外，其它符号的意义与第 3 章中 LSTM 网络类似。

$$g_{ft}^{(k)} = \sigma(W_{fh}^{(k)} h_{t-1}^{(k)} + W_{fx}^{(k)} x_t + b_f^{(k)}) \quad (4.26)$$

$$g_{it}^{(k)} = \sigma(W_{ih}^{(k)} h_{t-1}^{(k)} + W_{ix}^{(k)} x_t + b_i^{(k)}) \quad (4.27)$$

$$\tilde{c}_t^{(k)} = \tanh(W_{ch}^{(k)} h_{t-1}^{(k)} + W_{cx}^{(k)} x_t + b_c^{(k)}) \quad (4.28)$$

$$c_t^{(k)} = g_{it}^{(k)} \otimes \tilde{c}_t^{(k)} + g_{ft}^{(k)} \otimes c_{t-1}^{(k)} \quad (4.29)$$

$$g_{ot}^{(k)} = \sigma(W_{oh}^{(k)} h_{t-1}^{(k)} + W_{ox}^{(k)} x_t + b_o^{(k)}) \quad (4.30)$$

$$h_t^{(k)} = g_{ot}^{(k)} \otimes \tanh(c_t^{(k)}) \quad (4.31)$$

$$h_t = \sum_{k=1}^C h_t^{(k)} \quad (4.32)$$

$$o_t = h_t + x_t \quad (4.33)$$

$$o_t = h_t + Wx_t \quad (4.34)$$

在网络层级上，(4.26)-(4.31)式可进一步用神经网络算子写为：

$$h^{(k)} = LSTM_k(x) \quad (4.35)$$

则(4.32)式可以写为：

$$F(x)=h = \sum_{k=1}^C LSTM_k(x) \quad (4.36)$$

(4.33)式可写为：

$$o = x + F(x) = x + \sum_{k=1}^C LSTM_k(x) \quad (4.37)$$

(4.34)式可写为：

$$o = Wx + F(x) = Wx + \sum_{k=1}^C LSTM_k(x) \quad (4.38)$$

聚合残差变换的残差-长短期记忆网络(ResNeXt-LSTM)遵循 ResNeXt 模型的聚合多路残差变换的设计思想,采用 LSTM 网络实现残差变换,每路残差变换的拓扑结构相同。ResNeXt-LSTM 模型只在原始的 Res-LSTM 模型上增加了残差变换的基数这一个需要设计的超参数,延续了简易和模块化的设计方法,具有较好的扩展性。

## 4.2.3 基于 ResNeXt-LSTM 模型的燃料电池系统故障监测性能分析

本节继续使用第 2 章介绍的燃料电池系统故障监测数据集建立 ResNeXt-LSTM 模型预测燃料电池的输出电压。首先,根据燃料电池系统故障监测数据集训练 ResNeXt-LSTM 模型预测输出电压。然后,分析系统实际输出的电压与预测电压的残差,确定系统正常时预测电压的阈值。假设电压残差为  $R$ ,测试数据的电压残差标准差为  $\sigma$ ,电压残差阈值为  $R_{th}$ ,设置电压残差阈值  $R_{th} = 3\sigma$ ,当  $R > R_{th}$  时判定燃料电池系统处于故障运行状态,否则判断为正常运行状态。

图 4.11 分别为 ResNeXt-LSTM 模型和其对应的 Res-LSTM 模型。本节设计的 ResNeXt-LSTM 模型结构配置如图 4.11(b)所示。整个 ResNeXt-LSTM 模型含有 10 个聚合残差变换的残差块,每个聚合残差变换的残差块共有 2 路残差变换,图 4.11(a)画出了与其对应的 Res-LSTM 模型,与图 4.3(c)的 Res-LSTM11-10 模型一致。在残差块中,实线短接线表示直接相加,虚线短接线表示采用线性变换后相加。网络输入 10 个时刻的 20 维向量数据  $\mathbf{x}_i (i=1,2,\dots,10)$ ,向量  $\mathbf{x}_i$  各维的数据意义参见第 2 章故障监测数据集所述。最后一个网络层输出为最后一个时刻的数据  $\mathbf{u}$ ,即为电堆 1# 电压和电堆 2# 电压的预测值。

在训练 ResNeXt-LSTM 模型时选择均方差损失函数和小批量梯度下降算法。假设 ResNeXt-LSTM 模型的预测值为  $\mathbf{u} = \mathbf{f}(\mathbf{x}; \theta)$ ,  $\theta$  表示神经网络的参数集,预测的真实值为  $\mathbf{y}$ ,均方差损失函数  $L_{MSE}$  计算方法为:

$$L_{MSE} = L_{MSE}(\mathbf{f}(\mathbf{x}; \theta), \mathbf{y}) = \frac{1}{B} \sum_{r=1}^B \frac{1}{d} \sum_{i=1}^d (y_i^{(r)} - f_i(\mathbf{x}^{(r)}; \theta))^2 \quad (4.39)$$

式中,  $(\mathbf{x}^{(r)}, \mathbf{y}^{(r)})$  表示第  $r$  个样本,  $y_i^{(r)}$  是  $\mathbf{y}^{(r)}$  的第  $i$  个分量,  $f_i(\mathbf{x}^{(r)}; \theta)$  是  $\mathbf{f}(\mathbf{x}^{(r)}; \theta)$  的第  $i$  个分量,  $\mathbf{u}^{(r)} = \mathbf{f}(\mathbf{x}^{(r)}; \theta)$  表示第  $r$  个样本的预测值,  $B$  表示批量大小,  $d$  表示  $\mathbf{u}$  和  $\mathbf{y}$  的维度,  $d=2$ 。优化目标是找到一组参数集  $\theta$  使得  $L_{MSE}$  最小,即:

$$\theta^* = \arg \min_{\theta} L_{MSE}(\mathbf{f}(\mathbf{x}; \theta), \mathbf{y}) \quad (4.40)$$

式中,  $\arg \min$  的意义为求解目标函数为最小值时的参数值。

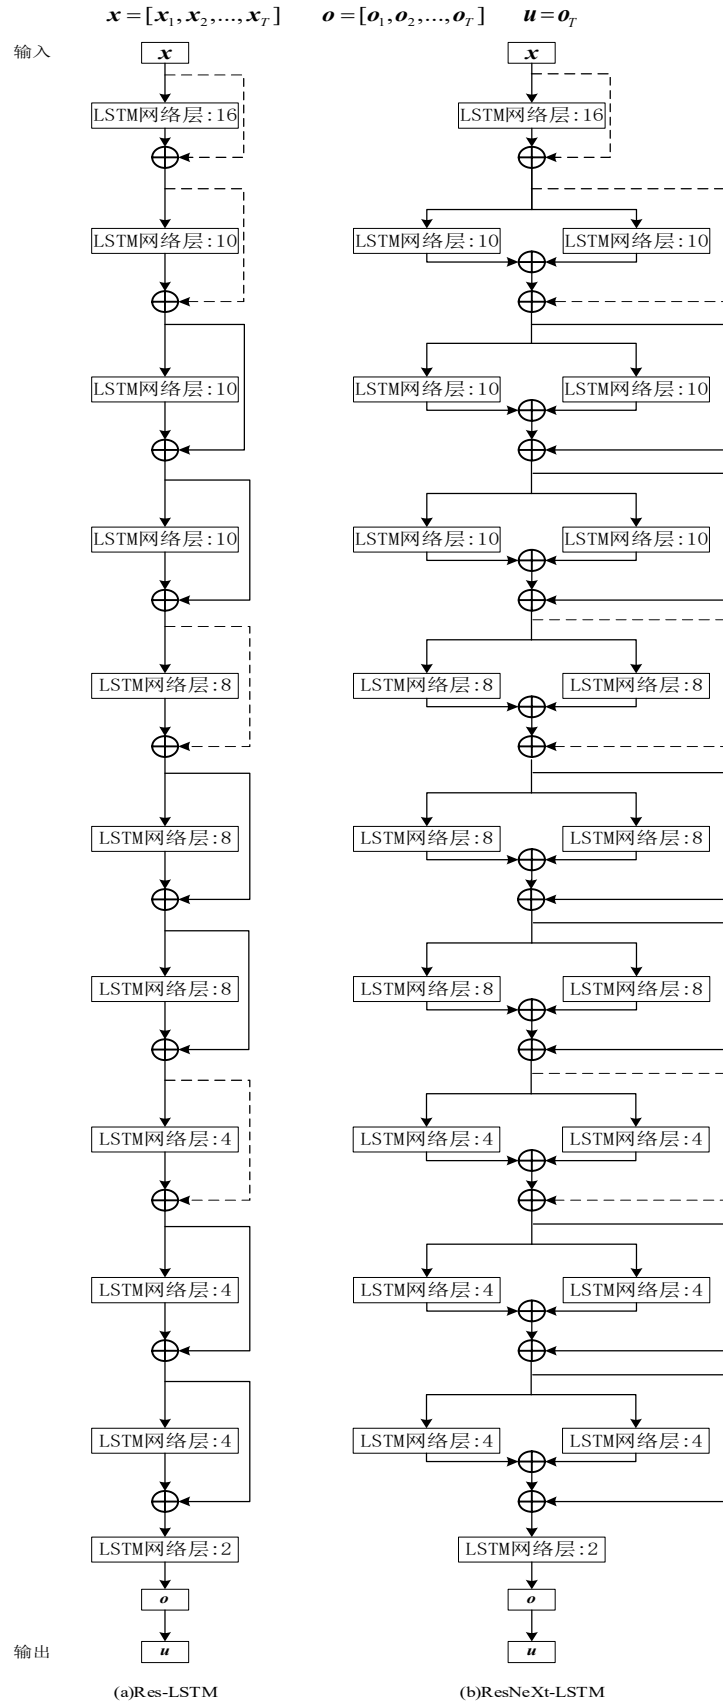


图 4.11 Res-LSTM 模型和对应的 ResNeXt-LSTM 模型( $T=10$ )

RMSprop 算法是一种小批量梯度下降法的改进算法，可以对学习率进行自适应调整。本节采用 RMSprop 算法进行网络参数更新。假设某轮第  $t$  步迭代时的梯度为  $g_t$ ，则网络参数更新方法为：

$$g_t = \frac{\partial L_{MSE}(f(\mathbf{x}; \theta_t), y)}{\partial \theta_t} \quad (4.41)$$

$$G_1 = (1 - \beta) g_1^2 \quad (4.42)$$

$$G_t = \beta G_{t-1} + (1 - \beta) g_t^2 \quad (4.43)$$

$$\Delta \theta_t = \frac{\eta}{\sqrt{G_t + \varepsilon}} g_t \quad (4.44)$$

$$\theta_t = \theta_{t-1} - \Delta \theta_t \quad (4.45)$$

式中， $\eta$  为初始学习率， $\beta$  为衰减率， $\varepsilon$  为防止除零错误的小常数。本节设置  $\eta = 0.001$ ， $\beta = 0.9$ ， $\varepsilon = 10^{-7}$ ， $B = 64$ 。

同时，每轮训练完成后计算在训练集和测试集的均方差损失函数和所有预测变量的平均绝对误差，衡量所建立网络模型的性能。平均绝对误差  $MAE$  计算方法为：

$$MAE = \frac{1}{N} \sum_{r=1}^N \frac{1}{d} \sum_{i=1}^d |y_i^{(r)} - u_i^{(r)}| \quad (4.46)$$


式中， $N$  为样本总数量。

ResNeXt-LSTM 模型的具体优化步骤如表 4.3 所示，主要有：(1)对数据进行预处理，进行最大最小归一化，制作成故障监测数据集；(2)导入故障监测数据集，确定迭代轮数、批量大小；(3)划分数据集，按 8:2 随机划分数据集为训练集和测试集，分别用于网络模型的训练和测试；(4)按批量大小将训练集分成多个批量，便于每次迭代时使用一个批量的样本；(5)按所设计的结构建立 ResNeXt-LSTM 模型；(6)对网络参数进行初始化；(7)采用 RMSprop 算法训练 ResNeXt-LSTM 模型。


训练集和测试集的均方差损失函数和平均绝对误差随训练轮次的变化如图 4.12 所示。可见，经过 4 轮训练后，训练集和测试集的均方差损失和平均绝对误差快速减小，第 4 轮以后均方差损失和平均绝对误差减小趋势变缓，进入平缓变化阶段，总体呈缓慢减小趋势，网络的参数已得到较好的训练，对输入数据进行拟合能力得到增强。第 40 轮训练完成后，训练集的均方差损失和平均绝对误差分别约为 0.00057 和 0.0080，测试集的均方差损失和平均绝对误差分别约为 0.00087 和 0.00887。在整个训练过程中，ResNeXt-LSTM 模型在训练集和测试集上的均方差损失和平均绝对误差非常接近，表明该网络具有较强的泛化能力。

表 4.3 ResNeXt-LSTM 模型优化步骤

优化步骤
1 对数据进行预处理，进行最大最小归一化，制作故障监测数据集
2 输入：数据集 $D_s$ ，迭代轮数 $\text{epochs}$ ，批量大小 $B$
3 划分数数据集：按 8:2 随机划分数数据集为训练集 $D_{\text{train}}$ 、测试集 $D_{\text{test}}$
4 训练集 $D_{\text{train}}$ 样本数 $N_{\text{train}}$ ，按批量大小 $B$ 将训练集 $D_{\text{train}}$ 分成多个批量
5 建立如图 4.11(b)所示的 ResNeXt-LSTM 模型 $f(x; \theta)$
6 随机初始化网络参数 $\theta$
7 训练 ResNeXt-LSTM 模型
for epoch $\leftarrow 1$ to $\text{epochs}$ do
//批量数量 $K = \lceil N_{\text{train}} / B \rceil$ ，采集小批量样本迭代训练
for step $\leftarrow 1$ to $K$ do
//前向传播计算均方差损失
按(4.39)式计算 $L_{\text{MSE}}$
//反向传播求导计算梯度并更新网络参数
按(4.41)-(4.45)式采用反向传播算法求导并更新参数
end
end
8 训练完成，保存 ResNeXt-LSTM 模型



(a) 均方差损失变化



(b) 平均绝对误差变化

图 4.12 训练集和测试集每轮均方差损失和平均绝对误差变化

使用最终得到的 ResNeXt-LSTM 模型对 8600 个测试集样本进行测试，计算得到电堆 1#电压预测误差均值和标准差分别约为  $\mu_1=0.00059$  和  $\sigma_1=0.03154$ ，电堆 2#电压预测误差均值和标准差分别约为  $\mu_2=-0.00095$  和  $\sigma_2=0.02756$ 。计算结果表明测试集样本的预测误差的均值非常接近于 0。ResNeXt-LSTM 模型在测试集上的电堆 1#电压和电堆 2#电压的预测误差分别如图 4.13 和图 4.14 所示。除了极少部分样本外，大部分样本的电压预测误差均在  $[-3\sigma_1, 3\sigma_1]$  和  $[-3\sigma_2, 3\sigma_2]$  内分布。




图 4.13 测试集电堆 1#电压预测误差(数据已归一化，纵轴为无量纲量)






图 4.14 测试集电堆 2#电压预测误差(数据已归一化，纵轴为无量纲量)

针对上述预测误差的分析，设定电堆 1#电压残差阈值  $R_{1th}=3\sigma_1=0.09462$ ，电堆 2#电压残差阈值  $R_{2th}=3\sigma_2=0.08268$ 。在进行故障监测时，设定当电堆 1#电压残差或电堆 2#电压残差的绝对值超出阈值时即判定燃料电池系统运行出现故障。

图 4.11 所示的两个不同结构网络的实验及结果如表 4.4 所示，表中所选模型均为在 40 轮训练过程中在训练集上均方差损失最小的网络模型。除表 4.4 所列出的设置外，其它实验设置均保持相同。选用 RMSprop 算法训练图 4.11 所示的两个网络模型，同时也选用一个对应的无残差结构的 LSTM 网络，对三种神经网络模型的性能进行对比。

表 4.4 LSTM 网络、Res-LSTM 和 ResNeXt-LSTM 的实验比较

网络类型	LSTM	Res-LSTM	ResNeXt-LSTM
训练优化方法	RMSprop 算法	RMSprop 算法	RMSprop 算法
网络参数量	7376	7968	12920
训练集训练轮次	40	40	40
训练集均方差损失	0.00165	0.00070	0.00057
测试集均方差损失	0.00202	0.00097	0.00087
测试集预测误差均值 (1#/2#)	-0.00523/ -0.00495	0.00027/ -0.00170	0.00059/ -0.00095
测试集预测误差标准差 $\sigma$ (1#/2#)	0.04607/ 0.04322	0.03247/ 0.02959	0.03154/ 0.02756
电压残差阈值 $R_{th}=3\sigma$ (1#/2#)	0.13821/ 0.12966	0.09741/ 0.08877	0.09462/ 0.08268

三种不同神经网络在训练集上的均方差损失具体变化如图 4.15 所示。结合表

4.4 可知, 在均方差损失和预测误差标准差等指标上, ResNeXt-LSTM 模型比对应的 LSTM 网络模型和 Res-LSTM 模型的性能表现更好。ResNeXt-LSTM 模型的预测电压均方差损失更小。由于 ResNeXt-LSTM 模型预测电压误差标准差更小, 因而判断故障的电压阈值更小。由于聚合了 2 路残差变换, ResNeXt-LSTM 模型的参数量约是 ResNet-LSTM 模型的 1.6 倍, 因而 ResNeXt-LSTM 模型是一种网络容量更大的模型。ResNeXt-LSTM 模型的容量可以通过扩大基数(即聚合的残差变换的数量)实现, 因而 ResNeXt-LSTM 模型相比 Res-LSTM 模型的可扩展性更强。




图 4.15 三种不同神经网络在训练集上的均方差损失变化

### 4.3 本章小结

利用现代深度学习设计方法, 本章对长短期记忆网络进行了改进。首先, 在长短期记忆网络的基础上, 本章提出了残差-长短期记忆网络, 并利用其进行燃料电池系统故障监测。具体地, 首先采用 LSTM 网络层实现残差函数部分, 进而构建了引入残差学习机制的长短期记忆网络, 即残差-长短期记忆网络(Residual Network with Long Short-Term Memory, Res-LSTM)。然后使用 Adam 算法训练所建立的 Res-LSTM 模型进行预测, 设置故障判断的电压残差阈值, 根据电压残差阈值判断系统状态是否存在故障, 实现故障监测。与 LSTM 网络的比较结果表明, Res-LSTM 模型的预测性能更加优良, 训练速度也更快。

其次, 在 Res-LSTM 模型的基础上, 本章提出了聚合残差变换的残差-长短期记忆网络模型, 即 ResNeXt-LSTM 模型, 并利用其进行燃料电池系统故障监测。根据 ResNeXt 模型的多路残差变换聚合的设计思想, 采用 LSTM 网络实现残差变换, 构建聚合残差变换的残差-长短期记忆网络(即 ResNeXt-LSTM), 并使用 RMSprop 算法训练所建立的 ResNeXt-LSTM 模型。ResNeXt-LSTM 模型保持了 Res-

LSTM 模型设计的简洁性，同时又兼有可扩展性强的特点，模型的容量可以通过残差变换的数量进行扩展。相比于 LSTM 网络和 Res-LSTM 模型，利用 ResNeXt-LSTM 模型进行燃料电池系统故障监测有一定的优势。

## 第 5 章 基于 Res-LSTM 模型的燃料电池系统故障诊断

残差-长短期记忆网络(Residual Network with Long Short-Term Memory, Res-LSTM)是一种将残差学习思想引入长短期记忆(LSTM)网络的改进网络。在网络优化时,残差-长短期记忆网络改善了梯度的传播,能够更高效的训练。本章采用残差-长短期记忆网络(Res-LSTM)开展燃料电池系统的故障诊断工作。

### 5.1 燃料电池系统故障诊断问题分析

softmax(柔性最大值)激活函数是分类模型中常用的激活函数,可以表示为:

$$v_i = \text{softmax}(q_i) = \frac{e^{q_i}}{\sum_{j=1}^C e^{q_j}}, i = 1, 2, \dots, C \quad (5.1)$$

从 softmax 激活函数的表达式可以看出

$$v_i \in [0, 1], \sum_{i=1}^C v_i = 1 \quad (5.2)$$

因此, softmax 激活函数常用于具有  $C$  个类别的多分类问题的输出概率预测。

交叉熵(Cross-Entropy)损失函数常用于分类问题。假设样本的输出共有  $C$  个类别,即  $y = c \in \{1, 2, \dots, C\}$  表示样本属于第  $c$  个类别,模型  $f(\mathbf{x}; \theta)$  预测出样本的输入  $\mathbf{x}$  分别属于  $C$  个类别的概率值,即:

$$\mathbf{f}(\mathbf{x}; \theta) = [f_1(\mathbf{x}; \theta), f_2(\mathbf{x}; \theta), \dots, f_C(\mathbf{x}; \theta)] \quad (5.3)$$

并且有约束

$$f_i(\mathbf{x}; \theta) \in [0, 1], \sum_{i=1}^C f_i(\mathbf{x}; \theta) = 1 \quad (5.4)$$

为方便构造损失函数,将样本的输出  $y = c \in \{1, 2, \dots, C\}$  用一个  $C$  维的独热(One-hot)向量进行编码。对于样本的输出  $y = c \in \{1, 2, \dots, C\}$  的情形,采用独热向量编码为  $C$  维向量  $\mathbf{y}_c = [0, 0, \dots, 1, \dots, 0]$ ,其中只有第  $c$  维元素的取值为 1,其余各维元素的取值为 0。独热向量编码可以理解为样本属于第  $c$  个类别的概率为 1,属于其它类别的概率为 0。模型  $\mathbf{f}(\mathbf{x}; \theta)$  的预测结果应该使得类别  $c$  的概率  $f_c(\mathbf{x}; \theta)$  尽可能大,而其他  $C-1$  个类别的概率尽可能小。交叉熵可以很好地衡量这种分布差异。交叉熵损失函数的计算方法为:

$$\begin{aligned} L_{CE} &= L_{CE}(\mathbf{f}(\mathbf{x}; \theta), y = c) = L_{CE}(\mathbf{f}(\mathbf{x}; \theta), \mathbf{y}_c) \\ &= -\mathbf{y}_c^T \cdot \ln(\mathbf{f}(\mathbf{x}; \theta)) = -\ln(f_c(\mathbf{x}; \theta)) \end{aligned} \quad (5.5)$$

式中,  $\mathbf{y}_c$  是  $y = c$  的独热编码。从式中可以看到, 最小化交叉熵损失的实质就是最大化样本属于真实类别  $c$  的条件概率。

燃料电池系统的故障诊断可以视为一个分类问题, 其最终目的是根据故障特征判断故障的类别, 因而可以设计一个神经网络模型对燃料电池系统数据进行分类实现故障诊断功能。神经网络分类模型通过对燃料电池系统输入数据的计算, 逐层提取数据的特征, 预测出各个类别的概率分布, 确定特征数据的类别, 将输入数据归属到某个类别, 实现故障诊断。假设  $\mathbf{x} = [\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_T] \in \mathbf{R}^{T \times d}$  表示样本的故障特征, 即输入数据, 则故障诊断的目标是要找到一个条件概率分布预测各个类别的概率, 使得样本的真实类别的概率尽可能大。假设样本共有  $C$  个类别, 样本的真实标签  $y = c \in \{1, 2, \dots, C\}$  表示样本属于第  $c$  个类别, 则神经网络模型  $\mathbf{f}(\mathbf{x}; \theta)$  应预测样本的输入  $\mathbf{x}$  属于  $C$  个类别的概率向量  $\mathbf{p} = [p_1, p_2, \dots, p_C]$ , 即

$$\mathbf{p} = \mathbf{f}(\mathbf{x}; \theta) = [f_1(\mathbf{x}; \theta), f_2(\mathbf{x}; \theta), \dots, f_C(\mathbf{x}; \theta)] \quad (5.6)$$

且满足

$$f_i(\mathbf{x}; \theta) \in [0, 1], \sum_{i=1}^C f_i(\mathbf{x}; \theta) = 1 \quad (5.7)$$

继而将最大概率值对应的类别作为模型最终预测的类别  $\bar{y}$ , 即

$$\bar{y} = \arg \max_{c \in \{1, 2, \dots, C\}} \{\mathbf{p}\} = \arg \max_{c \in \{1, 2, \dots, C\}} \{p_1, p_2, \dots, p_c, \dots, p_C\} \quad (5.8)$$

式中,  $\arg \max$  表示求解目标值最大时的参数值。

根据第 2 章的燃料电池系统故障诊断数据集, 样本标签总共有四个类别, 分别表示燃料电池电堆故障(包含质子交换膜破损、电极穿孔、双极板损坏、电堆短路、电极水淹、质子交换膜干燥、电堆过载、催化剂中毒、氢氧混合等)、空气供给系统故障(包含空气过滤器堵塞、空气管道泄漏、空压机故障、加湿器故障等)、氢气供给系统故障(包含氢气瓶开启故障、氢气泄漏、比例调节阀故障、氢气压力传感器故障、氢气管堵塞等)、正常(表示燃料电池电堆、空气供给系统故障和氢气供给系统故障没有故障), 样本的输出类别标签  $y$  的集合用数值编码设置为  $\{1, 2, 3, 4\}$ , 类别标签集合的各个元素代表的含义如表 5.1 所示, 因而故障诊断模型是一个四分类模型。为便于计算分类模型的交叉熵损失函数, 对类别标签进一步编码为独热向量。独热编码向量的每个分量表示了每个类别的概率, 因而独热编码可以看作是一个所有类别的概率向量表示。

表 5.1 故障类别标签的含义及其编码

类别	数值编码	独热编码
燃料电池电堆故障	1	[1,0,0,0]
空气供给系统故障	2	[0,1,0,0]
氢气供给系统故障	3	[0,0,1,0]
正常	4	[0,0,0,1]

## 5.2 Res-LSTM 故障诊断模型的结构配置和训练

本章使用第 2 章的燃料电池系统故障诊断数据集。图 5.1 分别为 LSTM 网络、Res-LSTM 模型和 ResNeXt-LSTM 模型结构示意图。本节所设计的 Res-LSTM 模型的结构如图 5.1(b)所示，整个 Res-LSTM 模型有 6 个残差块、1 个 LSTM 网络层和 1 个 softmax 激活函数。6 个残差块中的 LSTM 网络层的每个时刻的输出特征维度分别是 8,8,8,4,4,4。在残差块中，实线短接线表示直接相加，虚线短接线表示进行线性变换后相加。最后一个 LSTM 网络层输出最后一个时刻的特征(维度是 4)，然后通过 softmax 函数输出四个类别的概率向量。概率向量中最大的概率值对应的类别即为 Res-LSTM 模型预测出的最终类别。

在分类模型中使用交叉熵损失函数。本章使用小批量梯度下降算法优化。假设 Res-LSTM 模型预测出的样本输入  $\mathbf{x}$  属于每个类别的概率为  $\mathbf{p} = \mathbf{f}(\mathbf{x}; \theta) \in \mathbf{R}^C$ ， $C$  表示分类的总类别数(在这里  $C=4$ ，即  $\mathbf{p} = [p_1, p_2, p_3, p_4]$  表示属于四个类别的概率)， $\theta$  表示神经网络的参数集，真实类别标签  $y$  的独热编码为  $\mathbf{y}$  (如表 5.1 所示)，交叉熵损失函数  $L_{CE}$  计算方法为：

$$L_{CE} = L_{CE}(\mathbf{p}, \mathbf{y}) = L_{CE}(\mathbf{f}(\mathbf{x}; \theta), \mathbf{y}) = \frac{1}{B} \sum_{r=1}^B \frac{1}{C} \sum_{i=1}^C -y_i^{(r)} \ln(f_i(\mathbf{x}^{(r)}; \theta)) \quad (5.9)$$

式中， $(\mathbf{x}^{(r)}, \mathbf{y}^{(r)})$  表示第  $r$  个样本， $\mathbf{y}$  是  $y$  的独热编码， $y_i^{(r)}$  是  $\mathbf{y}^{(r)}$  的第  $i$  个分量， $f_i(\mathbf{x}^{(r)}; \theta)$  是  $\mathbf{f}(\mathbf{x}^{(r)}; \theta)$  的第  $i$  个分量， $\mathbf{p}^{(r)} = \mathbf{f}(\mathbf{x}^{(r)}; \theta)$  表示第  $r$  个样本的预测概率向量， $B$  表示批量大小。本章设置  $B=64$ 。本章使用 RMSprop 算法自适应调整学习率，第  $t$  步迭代时网络参数的更新公式为：

$$\mathbf{g}_t = \frac{\partial L_{CE}(\mathbf{f}(\mathbf{x}; \theta_t), \mathbf{y})}{\partial \theta_t} \quad (5.10)$$

$$\mathbf{G}_t = (1 - \beta) \mathbf{g}_t^2 \quad (5.11)$$

$$\mathbf{G}_t = \beta \mathbf{G}_{t-1} + (1 - \beta) \mathbf{g}_t^2 \quad (5.12)$$

$$\theta_{t+1} = \theta_t - \frac{\eta}{\sqrt{G_t + \varepsilon}} g_t \quad (5.13)$$

本章设置  $\eta=0.001$ ,  $\beta=0.9$ ,  $\varepsilon=10^{-7}$ 。

在分类模型中可以使用准确率(Accuracy)衡量模型的分类性能。假设分类正确的样本数量为  $N_{true}$ , 总样本数量为  $N$ , 则准确率  $acc$  的计算方法如(5.14)式所示, 即准确率是分类正确的样本数量占总样本数量的比例。准确率越高, 说明模型的分类性能越好。

$$acc = \frac{N_{true}}{N} \quad (5.14)$$

Res-LSTM 模型的具体优化步骤如表 5.2 所示, 主要有: (1)导入故障诊断数据集, 确定迭代轮数和批量大小; (2)划分数据集, 按 7:3 划分为训练集和测试集; (3)创建 Res-LSTM 模型, 并使用 RMSprop 算法训练模型。

表 5.2 Res-LSTM 模型的优化步骤

优化步骤
1 对数据进行预处理, 进行最大最小标准化
2 输入: 故障诊断数据集 $D_s$ , 迭代轮数 epochs, 批量大小 $B$
3 划分数据集: 按 7:3 随机划分数据集为训练集 $D_{train}$ 、测试集 $D_{test}$
4 训练集 $D_{train}$ 样本数 $N_{train}$ , 按批量大小 $B$ 将训练集 $D_{train}$ 分成多个批量
5 建立如图 5.1(b)所示的 Res-LSTM 模型 $f(x; \theta)$
6 随机初始化网络参数 $\theta$
7 训练 Res-LSTM 模型
for epoch $\leftarrow$ 1 to epochs do
//批量数量 $K = \lceil N_{train} / B \rceil$ , 采集小批量样本迭代训练
for step $\leftarrow$ 1 to $K$ do
//前向传播计算均方差损失
按(5.9)式计算 $L_{CE}$
//反向传播求导计算梯度并更新网络参数
按(5.10)-(5.13)式采用反向传播算法求导并更新参数
end
end
8 训练完成, 保存 Res-LSTM 模型

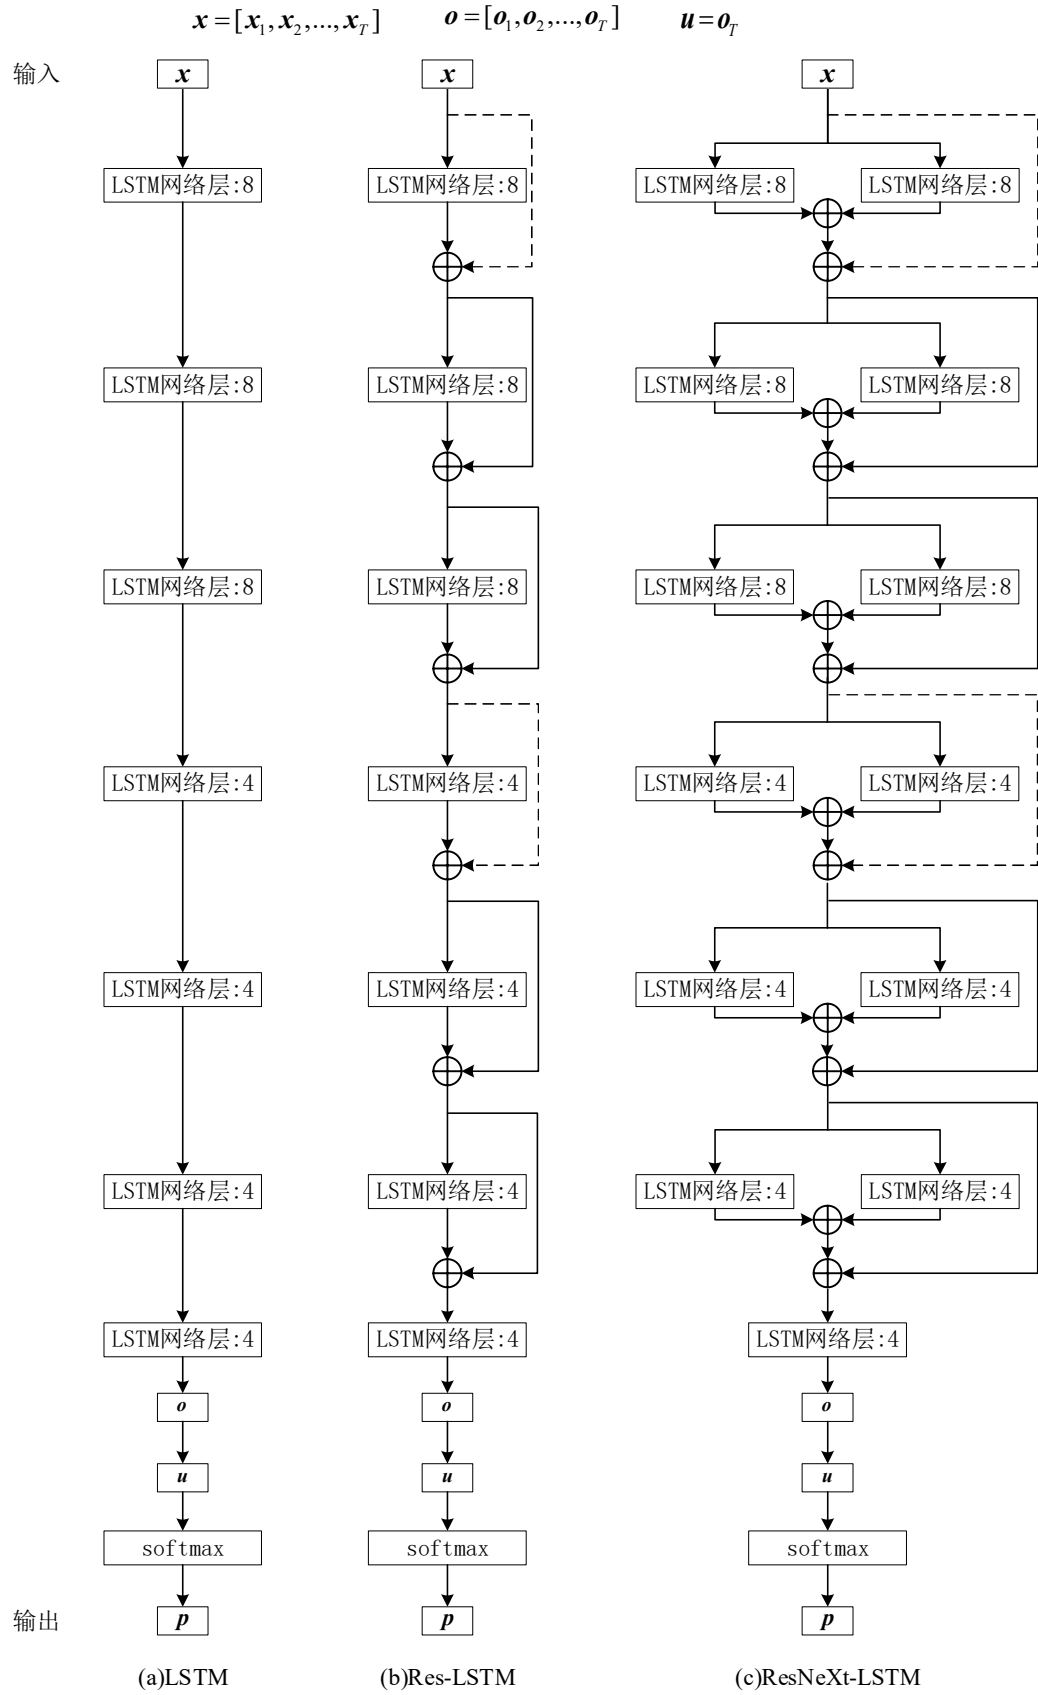



图 5.1 LSTM 网络、Res-LSTM 和 ResNeXt-LSTM 模型结构配置对比( $T=10$ )




### 5.3 基于 Res-LSTM 模型的故障诊断性能测试

#### 5.3.1 Res-LSTM 模型的故障诊断结果

设置 Res-LSTM 模型的训练轮数为 15 轮。在训练过程中 Res-LSTM 模型的交叉熵损失函数变化和分类准确率变化如图 5.2 所示。可见, 在前 5 轮的训练过程中, 训练集和测试集的交叉熵损失函数大幅减小, 第 5 轮到第 15 轮时训练集和测试集的交叉熵损失函数逐渐趋于稳定。在训练过程中, 训练集和测试集的分类准确率总体呈现逐渐提升趋势。经过 15 轮的训练后, 所设计的 Res-LSTM 模型在训练集和测试集的故障诊断的准确率分别达到了约 0.9942 和 0.9934。



(a) 交叉熵损失函数变化



(b) 准确率变化

图 5.2 Res-LSTM 模型在训练过程中的交叉熵损失函数变化和准确率变化

## 5.3.2 Res-LSTM 模型和其它模型的故障诊断性能比较

Res-LSTM 模型和 LSTM 网络、ResNeXt-LSTM 模型的结构如图 5.1 所示，LSTM 网络为 Res-LSTM 模型去掉短接后的模型，ResNeXt-LSTM 模型为 2 路由 LSTM 网络层实现的聚合残差变换的模型，其它模型结构等超参数均保持一致。在优化训练三个模型时，RMSprop 算法的参数设置也保持一致，同时设置模型的训练轮数为 15。三种神经网络模型在训练集上的交叉熵损失函数变化和测试集上的准确率变化分别如图 5.3 和图 5.4 所示。最终 15 轮训练后的交叉熵损失和准确率如表 5.3 所示。通过表 5.3 的统计可以看到三个模型的参数量分别为 2720、2928、5504。Res-LSTM 模型和 ResNeXt-LSTM 模型在测试集上的准确率分别约是 0.9934 和 0.9932，大于 LSTM 网络模型的准确率(0.9906)。ResNeXt-LSTM 模型的参数量为 5504，约是 Res-LSTM 模型的 1.88 倍，因此其计算量相对更大。可能由于所使用的燃料电池系统故障诊断数据集规模较小，Res-LSTM 模型和 ResNeXt-LSTM 模型在相同测试集上的故障诊断准确率差别非常小。

表 5.3 Res-LSTM 模型和其它模型的对比

网络类型	LSTM	Res-LSTM	ResNeXt-LSTM
优化算法	RMSprop 算法	RMSprop 算法	RMSprop 算法
网络参数量	2720	2928	5504
训练集训练轮次	15	15	15
训练集交叉熵损失	0.357	0.395	0.597
测试集交叉熵损失	0.359	0.398	0.601
测试集准确率 (保留四位小数)	0.9906	0.9934	0.9932




图 5.3 三种神经网络模型在训练集上的交叉熵损失函数变化




图 5.4 三种神经网络模型在测试集上的准确率变化

## 5.4 本章小结

本章针对燃料电池系统的燃料电池电堆、空气供给系统、氢气供给系统三个系统建立了基于 Res-LSTM 模型的燃料电池系统四分类故障诊断模型。首先，将燃料电池电堆故障、空气供给系统故障、氢气供给系统故障和正常状态四种标签分别进行数值编码和独热编码。然后，采用 RMSprop 算法训练所设计的 Res-LSTM 模型，根据输入特征预测每个故障类别的概率向量，继而以概率向量中最大的概率值对应的类别为模型最终预测的燃料电池系统的输出标签类别。最终，所设计的 Res-LSTM 模型在测试集上达到了 0.9934 的故障诊断准确率。与 LSTM 网络模型和 ResNeXt-LSTM 模型的对比表明，在相同的测试数据集上，Res-LSTM 模型的诊断准确率较 LSTM 网络模型高，计算量比 ResNeXt-LSTM 模型小，综合而言具有最佳的性能。

## 第6章 总结与展望

### 6.1 总结

质子交换膜燃料电池是一种环境友好、零碳或低碳的清洁能源转换装置，具有良好的发展前景。燃料电池系统由多个子系统组成，燃料电池电堆的物理化学机理复杂，容易发生多种故障。对燃料电池系统进行故障监测与诊断研究，可以获取系统的不正常运行信息进行提前处理，有利于提高系统的安全可靠性。本文探索采用深度学习方法对燃料电池系统进行故障监测与诊断研究。本文的主要工作及结果如下：

(1)阐述了燃料电池故障诊断的背景与意义，综述了燃料电池故障诊断的研究现状和深度学习在燃料电池系统故障诊断中的应用，分析了燃料电池系统各类故障诊断方法的优缺点；

(2)针对质子交换膜燃料电池系统的组成进行其故障分类，收集燃料电池系统的数据并进行数据处理，制作成故障监测和诊断的数据集，提出了基于深度学习方法的燃料电池系统故障监测与诊断的总体方案；

(3)分析了长短期记忆网络的原理，继而根据收集到的燃料电池系统的时序数据采用长短期记忆网络开展基于模型方法的故障监测工作，设计了一个长短期记忆网络模型，并采用 RMSprop 算法训练该网络。利用所设计的长短期记忆网络对燃料电池系统的电压进行预测，根据燃料电池系统的实际电压与网络预测电压的电压残差判断系统是否存在故障。当电压残差小于阈值时判定系统正常，否则判断系统出现故障。长短期记忆网络和其它神经网络模型的对比表明，长短期记忆网络的参数规模比全连接网络的大大降低，相比简单的循环神经网络，长短期记忆网络的性能也更好；

(4)利用现代深度学习的先进神经网络设计方法对长短期记忆网络模型进行了改进。一种改进是在网络中引入残差学习机制构建残差-长短期记忆网络(Res-LSTM)。该网络通过堆叠残差块实现。残差块被拆分为残差函数和恒等映射，残差函数由长短期记忆网络实现，恒等映射由输入通过短路连接实现。这种改进方法十分简洁，复杂性不高，有利于提升网络的性能。相比长短期记忆网络，残差-长短期记忆网络预测性能更好，网络训练也更高效，有利于提高燃料电池的故障监测性能。在残差-长短期记忆网络的基础上，进一步对残差函数进行优化。根据 ResNeXt

模型的聚合残差变换设计思想,进一步将残差-长短期记忆网络的残差函数重新设计为多路拓扑结构相同的残差变换的聚合形式,即 ResNeXt-LSTM 模型。ResNeXt-LSTM 模型延续了简洁的设计风格,网络容量可以通过残差变换的数量进行高效扩展,同时也表现出优良的预测性能,有助于进一步提高燃料电池系统的故障监测性能。

(5)针对燃料电池系统的燃料电池电堆故障、空气供给系统故障、氢气供给系统故障三个故障类别采用 Res-LSTM 模型进行分类实现故障诊断。采用 RMSprop 算法训练的 Res-LSTM 模型最终在测试集上达到了 0.9934 的故障诊断准确率。与 LSTM 网络模型和 ResNeXt-LSTM 模型的对比结果表明,在所使用的数据集上 Res-LSTM 模型的诊断准确率比 LSTM 网络模型高,计算量也比 ResNeXt-LSTM 模型小。

燃料电池系统具有一定的复杂性,因而本文难以做到对所有的故障进行监测与诊断。本文工作中的不足有:

(1)数据对深度学习模型的性能有重要影响,因而需要进一步收集燃料电池系统的故障运行数据,在更大的样本空间中继续验证提升模型的可靠性,开展更多故障类型的监测与诊断工作;

(2)神经网络的超参数对模型的性能表现有重要的影响。本文模型的超参数设置可能不是性能最优的,因而可以继续优化神经网络的超参数,搜寻性能更好的神经网络超参数设置。

## 6.2 展望

燃料电池具有良好的应用前景,对燃料电池系统开展故障监测与诊断工作有利于提高系统的可靠性和安全性,可以进一步推动燃料电池的商业开发与示范应用。本文基于深度学习方法开展故障监测与诊断初步探索工作,仍然有部分内容值得进一步研究:

(1)基于神经网络的深度学习方法具有从数据中发现隐藏规律的强大学习能力。数据的丰富性对深度学习方法的性能至关重要。数据不足可能导致神经网络的学习能力未充分发挥,限制了模型能力的提升。因此,需要进一步针对燃料电池系统运行状态尽可能多地收集故障数据,从而进一步发挥深度学习的优势,提高模型的故障监测与诊断能力;

(2)对于不同规格的燃料电池系统,其性能参数也不同。针对某一种参数组合的燃料电池系统建立的神经网络模型可能并不适用于其它参数情形的燃料电池系

统。因此需要研究建立一种考虑了不同燃料电池系统参数的深度学习模型，提高深度学习模型的开发效率，扩大其适用性，节约开发成本；

(3)燃料电池在运行过程中可能发生多种故障，对尽可能多的故障进行监测与诊断有利于开发高可靠性的燃料电池系统，但也可能提高深度学习模型的复杂度，提高故障监测与诊断的成本。因此需要对燃料电池系统的各种故障进一步开展统计分析工作，根据故障的影响和频率对深度学习模型的复杂度进行平衡，降低故障监测与诊断开发的复杂性；

(4)燃料电池的部分系统或部件有明确的解析模型，建立一种考虑燃料电池系统已知的解析关系和测试数据融合的深度学习模型进行其故障监测和诊断有待进一步研究。

## 参考文献

- [1] 陈维荣,刘嘉蔚,李奇,等. 质子交换膜燃料电池故障诊断方法综述及展望[J]. 中国电机工程报, 2017, 36(16): 4712-4721+4896.
- [2] WANG J, YANG B, ZENG C, et al. Recent advances and summarization of fault diagnosis techniques for proton exchange membrane fuel cell systems: a critical overview[J]. Journal of Power Sources, 2021, 500: 229932.
- [3] 张雪霞,蒋宇,黄平,等. 质子交换膜燃料电池容错控制方法综述[J]. 中国电机工程报, 2021, 41(4): 1431-1444+1549.
- [4] 张雪霞,蒋宇,孙腾飞,等. 质子交换膜燃料电池水淹和膜干故障诊断研究综述[J]. 西南交通大学学报, 2020, 55(4): 828-838+864.
- [5] YANG D, WANG Y, CHEN Z. Robust fault diagnosis and fault tolerant control for PEMFC system based on an augmented LPV observer[J]. International Journal of Hydrogen Energy, 2020, 45(24): 13508-13522.
- [6] KHAN S S, SHAREEF H, KANDIDAYENI M, et al. Dynamic semiempirical PEMFC model for prognostics and fault diagnosis[J]. IEEE Access, 2021, 9: 10217-10227.
- [7] 周苏,韩秋玲,胡哲,等. 质子交换膜燃料电池故障诊断的模式识别方法[J]. 同济大学学报(自然科学版), 2017, 45(3): 408-412.
- [8] LU H, CHEN J, YAN C, et al. On-line fault diagnosis for proton exchange membrane fuel cells based on a fast electrochemical impedance spectroscopy measurement[J]. Journal of Power Sources, 2019, 430: 233-243.
- [9] SHOU C, YAN C, CHEN J, et al. Condition monitoring and fault diagnosis of PEMFC systems[C] //2019 Chinese Automation Congress (CAC). IEEE, 2019: 4787-4791.
- [10] PIERPAOLO P, FRISK E, JUND D, et al. Model-based diagnosis through Structural Analysis and Causal Computation for automotive Polymer Electrolyte Membrane Fuel Cell systems[J]. Journal of Power Sources, 2017, 357: 26-40.
- [11] 王筱彤,李奇,王天宏,等. 基于离散区间二进制序列激励信号的燃料电池 EIS 测量及故障诊断方法[J]. 中国电机工程学报, 2020, 40(14): 4526-4537+4732.
- [12] HERNANDEZ A, HISSEL D, OUTBIB R. Modeling and fault Diagnosis of a polymer electrolyte fuel cell using electrical equivalent analysis[J]. IEEE Transactions on Energy Conversion, 2010, 25(1): 148-160.
- [13] DE LIRA S, PUIG V, QUEVEDO J, et al. LPV observer design for PEM fuel cell system: application to fault detection[J]. Journal of Power Sources, 2011, 196(9): 4298-4305.
- [14] LAGHROUCHE S, LIU J, AHMED F S, et al. Adaptive second-order sliding mode observer-based fault reconstruction for PEM fuel cell air-feed system[J]. IEEE Transactions on Control Systems Technology, 2015, 23(3): 1098-1109.
- [15] ROTONDO D, FERNANDEZ-CANTI R M, TORNIL-SIN S, et al. Robust fault diagnosis of proton exchange membrane fuel cells using a Takagi-Sugeno interval observer approach[J].

- International Journal of Hydrogen Energy, 2016, 41(4): 2875-2886.
- [16] BUCHHOLZ M, ESWEIN M, KREBS V. Modelling PEM fuel cell stacks for FDI using linear subspace identification[C]//2008 IEEE International Conference on Control Applications, San Antonio, America, 2008: 341-346.
- [17] 刘嘉蔚,李奇,陈维荣,等. 基于概率神经网络和线性判别分析的 PEMFC 水管理故障诊断方法研究[J]. 中国电机工程学报, 2019, 39(12): 3614-3622.
- [18] LIU J, LI Q, CHEN W, et al. A fast fault diagnosis method of the PEMFC system based on extreme learning machine and Dempster-Shafer evidence theory[J]. IEEE Transactions on Transportation Electrification, 2018, 5(1): 271-284.
- [19] ZHANG X, ZHOU J, CHEN W. Data-driven fault diagnosis for PEMFC systems of hybrid tram based on deep learning[J]. International Journal of Hydrogen Energy, 2020, 45(24): 13483-13495.
- [20] 余嘉熹,李奇,陈维荣,等. 基于随机森林算法的大功率质子交换膜燃料电池系统故障分类方法[J]. 中国电机工程学报, 2020, 40(17): 5591-5599.
- [21] 刘嘉蔚,李奇,陈维荣,等. 基于在线序列超限学习机和主成分分析的蒸汽冷却型燃料电池系统快速故障诊断方法[J]. 电工技术学报, 2019, 34(18): 3949-3960.
- [22] LIU J, LI Q, CHEN W, et al. A discrete hidden Markov model fault diagnosis strategy based on K-means clustering dedicated to PEM fuel cell systems of tramways[J]. International Journal of Hydrogen Energy, 2018, 43(27): 12428-12441.
- [23] 周苏,胡哲,文泽军. 基于 K 均值和支持向量机的燃料电池在线自适应故障诊断[J]. 同济大学学报(自然科学版), 2019, 47(2): 255-260.
- [24] BENOUIOUA D, CANDUSSO D, HAREL F, et al. Fuel cell diagnosis method based on multifractal analysis of stack voltage signal[J]. International Journal of Hydrogen Energy, 2014, 39(5): 2236-2245.
- [25] BENOUIOUA D, CANDUSSO D, HAREL F, et al. PEMFC stack voltage singularity measurement and fault classification[J]. International Journal of Hydrogen Energy, 2014, 39(36): 21631-21637.
- [26] DAMOUR C, BENNE M, GRONDIN-PEREZ B, et al. Polymer electrolyte membrane fuel cell fault diagnosis based on empirical mode decomposition[J]. Journal of Power Sources, 2015, 299: 596-603.
- [27] HINAJE M, BÉTHOUX O, KREBS G, et al. Nonintrusive diagnosis of a PEMFC[J]. IEEE Transactions on Magnetics, 2015, 51(3): 1-4.
- [28] LE NY M, CHADEBEC O, CAUFFET G, et al. PEMFC stack diagnosis based on external magnetic field measurements[J]. Journal of Applied Electrochemistry, 2015, 45: 667-677.
- [29] SONG M, PEI P, ZHA H, et al. Water management of proton exchange membrane fuel cell based on control of hydrogen pressure drop[J]. Journal of Power Sources, 2014, 267: 655-663.
- [30] JANSSENS O, SLAVKOVIKJ V, VERVISCH B, et al. Convolutional neural network based fault detection for rotating machinery[J]. Journal of Sound and Vibration, 2016, 377: 331-345.
- [31] LU C, WANG Z Y, QIN W L, et al. Fault diagnosis of rotary machinery components using a stacked denoising autoencoder-based health state identification[J]. Signal processing, 2017, 130: 377-388.
- [32] PRZYSTAŁKA P, MOCZULSKI W. Methodology of neural modelling in fault detection with



- the use of chaos engineering[J]. *Engineering Applications of Artificial Intelligence*, 2015, 41: 25-40.
- [33] TALEBI N, SADRNIA M A, DARABI A. Robust fault detection of wind energy conversion systems based on dynamic neural networks[J]. *Computational Intelligence and Neuroscience*, 2014, 2014: 580972.
- [34] 樊家伟,郭瑜,伍星,等. 基于LSTM神经网络和故障特征增强的行星齿轮箱故障诊断[J]. *振动与冲击*, 2021, 40(20): 271-277.
- [35] 郑一珍,牛茵楷,熊晓燕,等. 基于一维卷积神经网络的圆柱滚子轴承保持架故障诊断[J]. *振动与冲击*, 2021, 40(19): 230-238+285.
- [36] 许子非,金江涛,李春. 基于多尺度卷积神经网络的滚动轴承故障诊断方法[J]. *振动与冲击*, 2021, 40(18): 212-220.
- [37] 常淼,沈艳霞. 基于改进卷积神经网络的风电轴承故障诊断策略[J]. *电力系统保护与控制*, 2021, 49(6): 131-137.
- [38] 曲岳晗,赵洪山,马利波,等. 多深度神经网络综合的电力变压器故障识别方法[J]. *中国电机工程学报*, 2021, 41(23): 8223-8231.
- [39] 王崇宇,郑召利,刘天源,等. 基于卷积神经网络的汽轮机转子不平衡与不对中故障检测方法研究[J]. *中国电机工程学报*, 2021, 41(7): 2417-2427.
- [40] 刘瑶,徐海平,初宁,等. 基于长短时记忆模型的风机故障诊断[J]. *工程热物理学报*, 2020, 41(10): 2437-2445.
- [41] ZUO B, ZHANG Z, CHENG J. et al. Data-driven flooding fault diagnosis method for proton-exchange membrane fuel cells using deep learning technologies[J]. *Energy Conversion and Management*, 2022, 251: 115004.
- [42] LIU J, LI Q, YANG H, et al. Sequence fault diagnosis for PEMFC water management subsystem using deep learning with t-SNE[J]. *IEEE Access*, 2019, 7: 92009-92019.
- [43] 邱锡鹏. *神经网络与深度学习*[M]. 北京:机械工业出版社, 2020.
- [44] 龙良曲. *TensorFlow深度学习: 深入理解人工智能算法设计*[M]. 北京:清华大学出版社, 2020.
- [45] 孙玉林,余本国. *PyTorch深度学习入门与实战: 案例视频精讲*[M]. 北京:中国水利水电出版社, 2020.
- [46] ELMAN J L. Finding structure in time[J]. *Cognitive science*, 1990, 14(2): 179-211.
- [47] BENGIO Y, SIMARD P, FRASCONI P. Learning long-term dependencies with gradient descent is difficult[J]. *IEEE Transactions on neural networks*, 1994, 5(2): 157-166.
- [48] HOCHREITER S, SCHMIDHUBER J. Long short-term memory[J]. *Neural computation*, 1997, 9(8): 1735-1780.
- [49] GERS F A, SCHMIDHUBER J, CUMMINS F. Learning to forget: Continual prediction with LSTM[J]. *Neural Computation*, 2000, 12(10): 2451-2471.
- [50] RUMELHART D E, HINTON G E, WILLIAMS R J. Learning internal representations by error propagation[M]// *Parallel distributed processing: explorations in the microstructure of cognition*, volume 1: foundations. MIT Press, 1986: 318-362.
- [51] BOTTOU L. Large-scale machine learning with stochastic gradient descent[M]//*Proceedings of*

COMPSTAT'2010. Physica-Verlag HD, 2010: 177-186.

- [52] TIELEMAN T, HINTON G E. Lecture 6.5-rmsprop: Divide the gradient by a running average of its recent magnitude[Z]. 2012.
- [53] PASCANU R, MIKOLOV T, BENFIO Y. On the difficulty of training recurrent neural networks[C]//International conference on machine learning. PMLR, 2013: 1310-1318.
- [54] HE K, ZHANG X, REN S, et al. Deep residual learning for image recognition[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. Springer, Cham, 2016: 630-645.
- [55] HE K, ZHANG X, REN S, et al. Identity mappings in deep residual networks[C]//European conference on computer vision. Springer, Cham, 2016: 630-645.
- [56] KINGMA D P, BA J. Adam: A method for stochastic optimization[C]//Proceedings of International Conference on Learning Representations. 2015.
- [57] XIE S, GIRSHICK R, DOLLÁR P, et al. Aggregated residual transformations for deep neural networks[C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2017: 1492-1500.

## 致谢

时光匆匆，三年的学习生活马上就要结束。在这三年中，我学到了很多，也收获了很多。在此，向在生活和学习上给我帮助的老师、同学和家人们致以真诚的感谢与诚挚的祝福。

首先，对指导与帮助我的团队老师表示衷心的感谢，特别是我的指导老师全睿老师。从选题到写作，全老师都给予了及时的帮助。在平常的生活中，全老师也总是给予学生自由时间锻炼身体，放松休息，劳逸结合。正是在导师的帮助下，我才能找到研究方向，顺利完成学业。在此，真诚感谢全老师的帮助。

其次，感谢实验室的师兄和同学们的帮助。在三年的学习过程中，实验室的师兄们真诚地传授技能，帮助我快速掌握研究方法和工具。实验室的同学们相互学习，和睦相处，始终保持一股勤奋钻研的学风，一起度过了一段轻松愉快的学习生涯。这段友谊将始终留存在脑海中。

最后，感谢父母亲人的支持与理解。正是父母亲人的无私帮助与鼓励，我才能坚定地前行。感谢你们的默默付出与无私关怀。

特别感谢抽出宝贵时间进行评审的各位专家老师们，你们辛苦了！祝一切顺利！

## 附录

### 附录1 攻读硕士学位期间发表的学术论文

- [1] Rui Quan, Yousheng Yue, Zikang Huang, Yufang Chang, Yadong Deng. Effects of Backpressure on the Performance of Internal Combustion Engine and Automobile Exhaust Thermoelectric Generator[J]. Journal of Energy Resources Technology-Transactions of the Asme, 2022, 144(9): 092301.已录用online,署各单位为湖北工业大学和武汉理工大学.
- [2] 全睿, 乐有生, 李涛, 常雨芳, 谭保华. 基于门控循环单元神经网络的燃料电池系统故障监测[J]. 昆明理工大学学报(自然科学版), 2022, 47(2): 65-74.署各单位为湖北工业大学.
- [3] 全睿, 乐有生, 李涛, 常雨芳, 谭保华. 基于Res-LSTM的燃料电池系统故障检测[J]. 昆明理工大学学报(自然科学版), 已录用, 署各单位为湖北工业大学.