

分类号：U472.9

单位代码：11510

学号：20104008

密级：



山东交通学院

专业学位硕士学位论文

(2023 届)

基于生成对抗网络的燃料电池发动机传感器和执行器故障 诊断研究

Research on fault diagnosis of sensor and actuator of fuel cell
engine based on generation countermeasure network

论文作者：李光胜

专业学位类别：交通运输

专业领域：道路运输

专业方向：汽车运行安全与节能环保

指导教师：李方媛 王培森

所在学院：汽车工程学院

2023 年 5 月 29 日

分类号：U472.9
学号：20104008

单位代码：11510
密级：

山东交通学院

专业学位硕士学位论文

基于生成对抗网络的燃料电池发动机传感器和执行器
故障诊断研究

Research on fault diagnosis of sensor and actuator of fuel cell
engine based on generation countermeasure network

论文作者：	李光胜
学科专业：	交通运输
专业方向：	道路运输
研究方向：	汽车运行安全与节能环保
指导教师：	李方媛 王培森
所在学院：	汽车工程学院

2023 年 5 月 29 日

目 录

1 绪论.....	1
1.1 研究背景与意义.....	1
1.2 国内外研究现状.....	2
1.2.1 PEMFC 传感器故障研究现状	2
1.2.2 PEMFC 空气压缩机故障诊断研究现状	3
1.2.3 GAN 研究现状	4
1.2.4 故障诊断方法研究现状.....	6
1.3 本文主要研究内容.....	9
1.4 本文结构安排.....	9
2 PEMFC 发动机传感器和执行器故障分析	11
2.1 传感器故障及数学模型.....	11
2.2 执行器故障及故障建模.....	14
2.3 本章小结.....	16
3 基于 PEMFC 发动机模型传感器和执行器故障研究	17
3.1 PEMFC 发动机原理	17
3.2 PEMFC 发动机模型	18
3.2.1 PEMFC 空气系统.....	18
3.2.2 空气压缩机模型.....	19
3.3 故障设置.....	22
3.3.1 PEMFC 发动机空气压缩机故障	23
3.3.2 PEMFC 发动机传感器故障	24
3.4 本章小结.....	27
4 基于生成对抗网络的传感器和执行器故障诊断方法研究	28
4.1 卷积神经网络.....	28
4.1.1 卷积层.....	28
4.1.2 激活函数层.....	29
4.1.3 池化层.....	29
4.1.4 全连接层.....	30
4.1.5 优化算法.....	30
4.2 辅助分类器生成对抗网络	33
4.2.1 GAN 基本结构	33
4.2.2 辅助分类器生成对抗网络(ACGAN).....	34
4.2.3 模型质量评价.....	36
4.3 基于辅助分类器生成对抗网络故障诊断方法研究	37

4.3.1 模型结构.....	37
4.3.2 模型训练.....	40
4.3.3 模型验证.....	42
4.3.4 方法比较.....	44
4.4 试验验证.....	49
4.5 小结.....	52
5 总结与展望.....	53
5.1 总结.....	53
5.2 展望.....	53
参考文献.....	55

摘 要

质子交换膜燃料电池(Proton Exchange Membrane Fuel Cell, PEMFC)发动机将氢气和氧气的化学能转化为电能生成水,具有启动速度快、零碳排放等优点。传感器是 PEMFC 发动机的“眼睛”,执行器是“手和脚”,二者在氢燃料电池发动机中具有举足轻重的作用。PEMFC 发动机反应机理复杂,传感器和执行器长期工作在高温、高压、外界环境冲击、电磁环境影响等恶劣环境下,极易导致发生故障,轻则导致电堆性能下降,重则导致电堆彻底损坏。

针对 PEMFC 发动机大都处于正常运行状态,传感器和执行器的故障数据集难以获取的问题,提出一种基于一维卷积神经网络的辅助分类器生成对抗网络,通过生成器和判别器相互博弈挖掘数据故障特征,生成模拟数据,扩充故障样本,实现基于少量故障样本的传感器和空气压缩机故障诊断,并进行了实验验证。主要研究内容如下:

分析 PEMFC 发动机传感器和执行器故障特征,针对传感器和空气供给系统典型故障建立相应的数学模型。

基于密歇根州立大学 PEMFC 公开模型研究发动机传感器和执行器的故障特征。在模型中设置空气压缩机卡涩、净功率传感器漂移、电压传感器偏置和过氧比传感器短路故障,提取相应的故障特征。

针对实际故障数据集难以获取的问题,基于模型仿真生成故障数据集,加入高斯白噪声模拟实际故障。提出一种基于一维卷积神经网络的辅助分类器生成对抗网络,用于不平衡类的数据增强。使用欧氏距离、PCC、KL 散度对生成的故障数据进行评价,实现故障数据集的扩充和故障诊断。

利用实测健康电压数据集,添加偏置故障,模拟电压传感器偏置故障,对所提生成对抗网络模型进行验证。并与 CGAN 和 DCGAN 进行对比分析,验证了模型的准确性。

关键词: 氢燃料电池发动机;生成对抗网络;传感器故障;空气压缩机故障;故障诊断。

ABSTRACT

Proton Exchange Membrane Fuel Cell (PEMFC) engines convert the chemical energy of hydrogen and oxygen into electricity to produce water, which has the advantages of fast start-up speed and zero carbon emissions. The sensor is the "eye" of the PEMFC engine, and the actuator is the "hand and foot", both of which play a pivotal role in hydrogen fuel cell engines. PEMFC engine has a complex reaction mechanism, sensor and actuator long-term work in high temperature, high pressure, external environmental impact, electromagnetic environment and other harsh environments, easy to lead to failure, light lead to the performance of the stack, heavy lead to complete damage to the stack.

Aiming at the problem that most of the PEMFC engines are in normal operation and the fault data sets of sensors and actuators are difficult to obtain, an auxiliary classifier generative adversarial network based on one-dimensional convolutional neural network is proposed, and the fault characteristics of data are mined through the mutual game of generators and discriminators, simulation data is generated, fault samples are expanded, and fault diagnosis of sensors and air compressors based on a small number of fault samples is realized, and experimental verification is carried out. The main research contents are as follows:

The fault characteristics of PEMFC engine sensors and actuators were analyzed, and the corresponding mathematical models were established for the typical faults of sensors and air supply systems.

Study of fault characteristics of engine sensors and actuators based on the PEMFC public model of Michigan State University. In the model, the air compressor jamming, net power sensor drift, voltage sensor bias and peroxide ratio sensor short-circuit faults are set to extract the corresponding fault characteristics.

Aiming at the problem that the actual fault data set is difficult to obtain, the fault data set is generated based on model simulation, and Gaussian white noise is added to simulate the actual fault. An auxiliary classifier generative adversarial network based

on one-dimensional convolutional neural network is proposed for data enhancement of unbalanced classes. The generated fault data is evaluated by using Euclidean distance, PCC, and KL divergence, and the fault data set is expanded and diagnosed.

Using the measured healthy voltage data set, the bias fault is added and the voltage sensor bias fault is simulated, and the proposed generative adversarial network model is verified. Comparative analysis was carried out with CGAN and DCGAN to verify the accuracy of the model.

Key words: Hydrogen fuel cell engine; generating confrontation network; sensor fault; air compressor fault; fault diagnosis

1 绪论

1.1 研究背景与意义

质子交换膜燃料电池具有功率密度高,使用寿命长,发电效率高、工作温度低、对外界的负载响应速度快的特点,在固定电站、运输车辆中得到了广泛的应用^[1]。

传统内燃机将燃料的化学能转化为热能,将热能转化为机械能,需进行两次能量转换,同时由于热能转换效率受到卡诺循环^[2]的限制,导致转换效率低。相比之下氢燃料电池发动机将化学能直接转化为电能,不会受到卡诺循环的限制(理论值为 36%)。普通的燃料电池反应物和化学反应都是在电池内部进行,而氢燃料电池氢气储存在电池外部。当燃料耗尽时只需加注燃料即可,时间接近于燃油汽车加油时间,远低于电池左右充电时间。PEMFC 发动机具有高效率的优点(理论上 83%,但实际上是 50%)相比于内燃机和普通电池拥有更高的效率。

PEMFC 发动机系统是燃料电池汽车的核心部件。PEMFC 发动机由传感器、执行器、控制器、空气供给系统、燃料供给系统、冷却系统等组成。PEMFC 发动机传感器监测系统运行过程中的各项指标,一旦发生故障将导致测量数据不准确,影响控制器的执行。传感器工作环境相对复杂,导致传感器容易出现故障,小的故障会造成传感器不能对 PEMFC 发动机状态进行准确监测,大的故障会导致严重的安全事故。

PEMFC 空气压缩机能够提供的空气量与燃料电池反应需要的理论空气量之间的比值,称为“过氧比”。氢燃料电池发动机的过氧比为二到三,燃料电池发动机具有很强的滞后性。当车辆需要急加速时,空气消耗量急剧提升,但是空气压缩机的空气供给量不能及时增加,使得电池容易出现“氧饥饿”,导致质子交换膜出现烧蚀点。当燃料电池汽车功率需求较小时,如果空气压缩机仍供给较高的空气流量会导致空气压缩机的辅助功率消耗量大、净功率输出降低。因此对于空气压缩机的过氧比控制,有着相当重要的作用。空气压缩机作为最大的辅助设备,功率消耗量占到总功率的 20%左右。当发生“氧饱和”现象时,

空气压缩机的功率消耗会显著增强, 占电堆净输出功率的 30%左右^[3]。如此巨大的功率消耗严重影响氢燃料电池的净功率输出。由于 PEMFC 发动机空气供给系统是一个多输入多输出的非线性系统, 因此空气供给系统具有一定的延迟性。功率响应不能实时满足外界的需要, 不仅会影响系统的稳定性, 甚至损坏电堆, 缩短电堆使用寿命^[4]。氢燃料电池发动机传感器和空气压缩机的故障数据不易被获取, PEMFC 发动机智能故障诊断需要大量的故障数据对模型进行训练, 故障状态的数据量与健康状态的数据量极不平衡, 是阻碍智能故障诊断的最主要因素。生成对抗网络由于其强大的特征学习能力被广泛应用于故障样本的扩充以及故障诊断。

故障诊断方法主要分为基于模型的方法、基于数据的方法、基于混合的方法^[5]。基于模型的故障诊断首先要建立氢燃料电池发动机的机理模型, 通过改变模型的参数来仿真氢燃料电池发动机运行。基于数据的方法对大量故障数据进行分析, 由于氢燃料电池发动机传感器和空气压缩机故障数据样本量较少, 健康数据与故障数据之间数量极不平衡, 使用基于数据的故障诊断会造成故障诊断效果差。基于混合的方法将模型和数据的方法进行融合, 进行故障诊断。

1.2 国内外研究现状

1.2.1 PEMFC 传感器故障研究现状

PEMFC 发动机的正常运行需要各种传感器对整个系统进行实时监控, PEMFC 传感器包括流量传感器、电流传感器、电压传感器、流量传感器等。传感器的工作环境相对恶劣, 不仅受到电磁干扰。车辆的运动颠簸也会造成传感器损坏, 故障传感器如果不能被及时检测, 会造成严重的安全事故。还有可能由于故障传感器, 得到的错误信号而做出错误的操作损坏电堆。PEMFC 发动机故障的定义为, 导致堆栈提供的功率下降的操作条件, 并可能对燃料电池堆栈造成重大损坏。它们可能是执行器故障、传感器故障以及系统或电堆组件故障的结果^[6]。

传感器故障数据的采集非常困难, 可以用于故障检测的数据量较少, 严重影响了氢燃料电池发动机的故障检测及诊断。针对上述问题国内外的专家学者给出了相应的解决办法:

张菊秀^[7]等将深度神经网络应用于传感器的故障识别,使用多个相同的传感器测量同一个物理量,将得出异常值的传感器测量值进行剔除,使用埃尔曼网络和 BP 神经网络一起构建了一种传感器故障识别模型。Damiano Di Penta 等^[8],基于催化剂在电池组阳极和阴极上的气体建模。开发了燃料电池堆的简化热模型,考虑电化学反应、传热和水的蒸发/冷凝产生的热量。它用于评估整个系统的效率变化,为故障检测提供重要指标。MW Fowler, RF Mann 等^[9],研究了燃料电池老化。电压退化是一种可以被广泛观察到的现象,导致电池堆产生的电功率显著降低。早期的工作,描述了广义稳态电化学模型的开发,该模型接受操作变量的值,将电池设计参数作为输入。在实际应用中,反应物饥饿,渗油和干燥等不适当的操作条件,可能会严重恶化燃料电池的性能,通常会导致几个单电池的电压下降。如果不适当的故障情况反复出现或长期持续,可能会发生其他退化现象,加速燃料电池堆的老化甚至损坏^[10]。MaoLei 等^[11]提出了一种传感器选择技术,用于识别聚合物电解质膜(PEM)燃料电池堆故障和辅助系统故障等各种系统故障,研究了传感器异常测量对聚合物电解质膜燃料电池故障诊断性能的影响。使用异常传感器会极大地影响诊断性能。应用传感器选择技术可以识别异常的阴极湿度传感器,并通过从分析去除异常传感器测量值,可以准确地识别燃料电池浸水。S. de Lira 等^[12]建立了燃料电池模型,基于模型设置故障进行故障诊断。介绍了一种被动鲁棒故障检测方法,该方法使用区间 LPV 观测器,采用 zoonotope 的算法生成自适应阈值,考虑了参数不确定性和干扰。

1.2.2 PEMFC 空气压缩机故障诊断研究现状

PEMFC 发动机的组成包括传感器、执行器、控制器。控制器在接受传感器采集到的数据信息后控制执行器进行相关操作,控制器包括控制空气和氢气流量的阀门、冷却水泵、以及继电器开关等。供电单元主要由 DC/DC 以及 DC/AC 组成,其中 PEMFC 发动机的执行器在汽车上使用,因此会有破裂、脱落、以及卡涩故障的出现。执行器出现故障会导致 PEMFC 发动机不能正常运行,车辆功率会显著下降。空气压缩机作为 PEMFC 发动机空气供给系统核心的部件,如果发生故障会导致反应氧气不足。容易出现的故障为空气压缩机喘振、空气压缩机停转、空气压缩机开关卡滞等故障,影响车辆使用,造成“氧饥饿”严重甚至

会损坏燃料电池电堆。

空气压缩机作为 PEMFC 发动机空气供给系统中重要的执行机构。故障数据量少,使得故障诊断困难,针对上述问题国内外学者进行了一系列的研究,主要包括:

杨建等^[13]对光电继电器进行隔离,选取小电阻和极少量电流泄露的光电隔离放大器,解决了继电器在测量时间,精度、执行器使用寿命以及经济性不能得到良好平衡的弊端,得到了良好平衡。赵洪波等^[14]对 PEMFC 在外界功率需求急剧变化时,电池的水热管理系统不能对温度进行及时调整,使得电池的温度变化幅度大,影响电池寿命等问题。采取了将流量对电池电流和发动机功率同步进行跟踪,以及使用神经网络自抗扰两种针对 PEMFC 的热管理方法。首先使用,流量同步跟踪电流和电池功率的方法使得水泵和散热器之间的耦合作用被大大削弱,使得电堆进出口之间的冷却水水温明显降低,同时两者的温差也会缩小,减少了温度的调节时间。刘志祥等在研究了离心式空气压缩机的动态响应特性后,跟随在实际运行中的电流,并且将电堆的动态响应曲线和稳态控制曲线采取不同的 PID 控制策略,对实验结果进行了仿真验证^[15]。胡美等在深入研究了 PEMFC 空气压缩机的机理之后,结合空气压缩机的动态特性搭建了 PEMFC 空气供应系统模型,在模型中验证了,空气压缩机在氢燃料电池的空气供给系统中的重要作用,仿真结果表明,空气压缩机的供电电压对于空气压缩机的性能有显著影响,外界负载越大,阴极压力越小,空气压缩机电压越大,阴极压力越大^[16]。MMKAL 等^[17]提出了一种用于 PEMFC 系统故障智能检测的径向基函数网络,模型输入为堆电流和空气压缩机机电电压,模型输出为净功率、过氧比和堆电压。利用该模型,可以识别不同的传感器故障,空气压缩机故障、以及供气歧管故障。

1.2.3 GAN 研究现状

生成对抗网络是 Goodfellow^[18]在 2014 年提出的一种生成式对抗网络模型,创新性的使用了生成器和判别器之间的相互对抗,得到生成样本的方法。解决了以往生成式网络模型生成效果差的问题,生成对抗网络最初被用在生成图像,解决图像不足的问题。在近年的研究中生成对抗网络被越来越多的用于故障诊断,国内外的研究如下:

李洪军等^[19]对于质子交换膜燃料电池电堆会遇到的水淹和膜干故障，与深度卷积生成对抗网络相结合。首先使用主成分分析法对质子交换膜燃料电池得到的故障数据进行降维，借助于卷积网络强大的特征提取能力，对质子交换膜燃料电池膜干和水淹的故障特征进行提取，仿真结果表明，深度卷积生成对抗网络，对于膜干和水淹的故障以及正常三种状态进行了准确分类。Z Li 等^[20]提出一种基于球形多分类的支持向量机和 shapelet 变换，两者相结合的质子交换膜燃料电池的故障诊断方法。实验验证结果表明论文所提方法可以准确识别质子交换膜的膜干、低高压、过量空气系数过低等故障状态和健康状态。

Zuo, Bin 等^[21]对质子交换膜燃料电池的表征故障的各种指标进行研究，使用基于深度学习的质子交换膜燃料电池的水淹故障诊断方法，可以实现对原始数据的故障进行提取，对质子交换膜燃料电池的水淹故障进行准确的故障诊断。郭俊峰等^[22]针对轴承故障数据样本量少，提出一种 CWGAN-GAP 网络构型用于扩充轴承故障样本，将 Wasserstein 距离作为生成对抗网络的惩罚条件，用于补充轴承数据集样本不足的问题，文章提出的方法可以避免生成对抗网络容易出现的模式崩溃问题，加入 Wasserstein 作为约束条件，可以生成高质量的生成样本数据，对生成的故障数据进行了质量评估。评估结果表明生成数据质量良好，可以使故障样本数量得到了良好的扩充，使得故障诊断变得更加容易，对于提高轴承的故障诊断准确率有着重要作用。杨光友等^[23]通过判断生成器和判别器在模型训练过程中的性能变化，采用自适应调整生成器和判别器损失函数的方法，结果表明文章所提网络构型具有收敛速度快，生成样本质量高的优点。为了更好的验证模型的性能将所提模型与一维卷积生成对抗网络、CFVS-SVM、FFT-CNN 等方法的结果进行了对比。结果表明文章所提网络构型在故障识别准确率和模型训练时间是均拥有优势，验证了模型的有效性。卢锦玲等^[24]针对风电机组主轴承故障数据样本量少的问题，提出一种在辅助分类器生成对抗网络中加入梯度惩罚的方法，搭建了辅助分类器生成对抗网络。为了提高模型的稳定性和故障诊断识别率，在判别器中加入池化层，来提高网络的特征提取能力。在对模型进行实验验证阶段，文章提出的网络构型，可以很好的实现对故障数据的故障特征提取，对真实数据的空间分布实现良好学习，而且对于外界噪声的干扰有很好的隔绝效果，生成数据样本质量更高。实验结果表明文章提出的

网络构型，能够很好的补充风电机组主轴承故障数据集不足的问题，大幅度提高风电机组主轴承故障诊断能力。李志忠等^[25]在生成对抗网络的基础上加入卷积神经网络，提升网络的特征提取能力。同时采用 Wasserstein 作为约束加速网络的收敛速度。将卷积神经网络得到的故障数据的空间特征，利用解码器将生成器输出的故障特征进行解码，得到生成样本数据。为了提高生成数据的样本质量，将得到的故障特征与故障诊断误差，一起送入生成器的损失函数中。试验结果表明，文章提出的网络构型可以得到高质量的生成样本数据，可以很好的解决小样本数据集的数据分类。

1.2.4 故障诊断方法研究现状

在过去的几十年里，人们致力于利用故障诊断技术来评估 PEMFC 在运行中的状态。确定故障发生的来源，用于设计缓解策略，以恢复和扩展 PEMFC 性能。从这些研究中，诊断技术可以大致分为两类，数据驱动方法^[26]和基于模型^[27]的方法。

在基于模型的方法中，模型是对堆栈及其内部现象，综合理解的结果。PEMFC 电堆的内部状态表达，主要涉及电化学反应即氢气的化学键断裂生成电流、热力学主要包括 PEMFC 的化学反应会生成大量的热、涉及正常运行就要保证电堆温度在一个合理范围内、流体学问题主要是涉及氢气和空气的供应问题。由于 PEMFC 模型开发中使用的假设，例如整个 PEMFC 的相对湿度恒定，一些内部行为(包括燃料电池内部的湿度分布)无法模拟，因此相应的传感器测量(如相对湿度)无法用所开发的模型进行分析。开发的 PEMFC 模型只能分析有限的 PEMFC 故障和传感器测量值，这限制了传感器选择算法在实际 PEMFC 系统中的应用，需要考虑更多的 PEMFC 故障和传感器。当传感器用于燃料电池故障诊断时，通常假设传感器能够提供可靠的测量值，而在以往的研究中，尚未对系统运行过程中传感器的可靠性损失进行研究。在实际应用中，系统运行过程中传感器的可靠性可能会发生变化。由于异常传感器的测量结果不能代表 PEMFC 系统的实际状态，在 PEMFC 故障诊断中加入不准确的传感器测量结果将会产生误导。有必要考虑传感器的可靠性来确定最优传感器，从而识别出提供异常测量的传感器，在故障诊断中将其排除。

基于模型的方法的优点是，如果系统被修改，只需要调整模型。由于电力

需求波动引起的行为变化可以通过模型模拟再现,从而确保诊断方法对不同的运行条件具有鲁棒性。此外,由于模型参数具有物理意义,老化现象的模拟可以相当直接。T.Escobet 等^[28]提出并验证了一种基于相对剩余故障灵敏度的故障诊断方法。在这种方法中,它检查所观察到的行为的一致性,然后分离出不同灵敏度的故障组件。R. Petrone 等^[29]使用基于模型的技术,建立一个模型来表示 PEMFC 的行为,通过计算模型输出和实际测量值之间的残差,可以检测和隔离 PEMFC 故障。Frappe, E 等^[30]提出一种基于电池电压空间特征的简单非侵入式在线故障检测方法。并且相关的算法可以在线实现。结果表明,在水淹情况下特别有效。它直接使用堆栈作为传感器,从而能够快速反馈其健康状态。由于 PEMFC 系统及其电化学特性的复杂性,通常很难开发出包含所有可能失效模式的可靠模型。基于模型的故障诊断方法包括核主成分分析(KPCA)^[31]、小波包变换(WPT)^[32]、奇异值分解(SVD)^[33]等

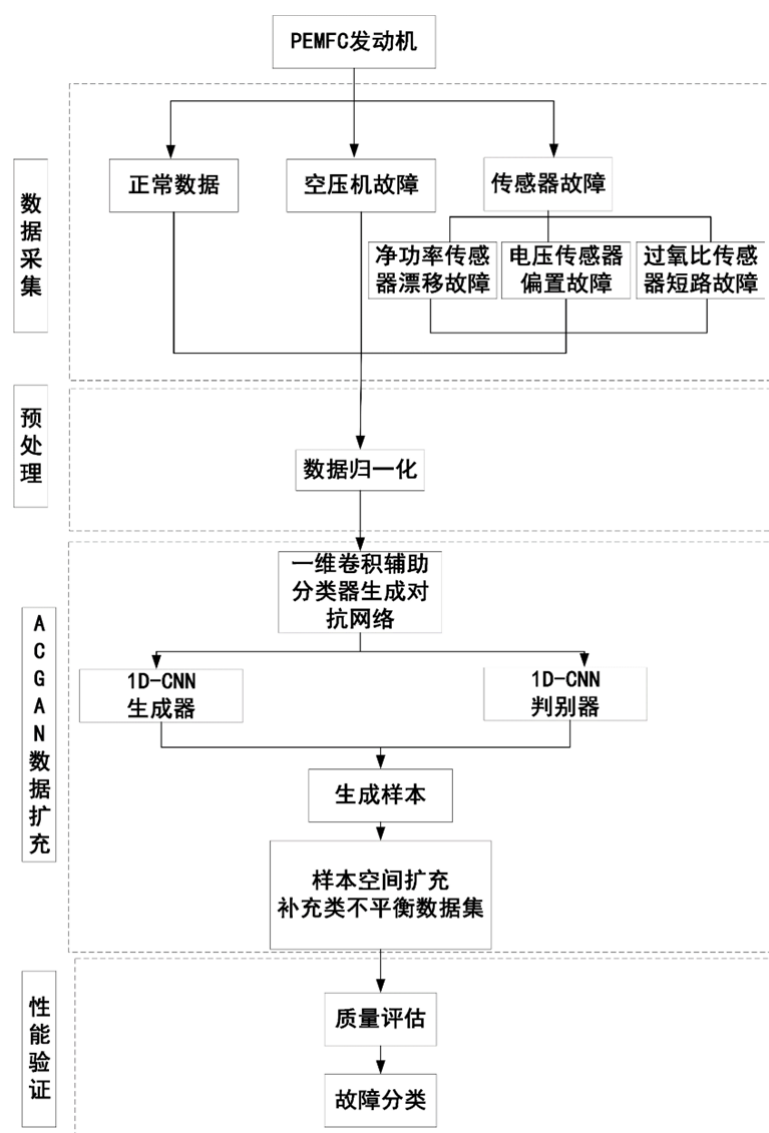
PEMFC 是一个非常复杂的系统具有强耦合,大滞后等问题,因此建立精确的燃料电池仿真模型是非常困难的,恰恰故障诊断性能高度依赖于模型的精度。其次,基于知识的模型对计算量的要求很高,这对实时嵌入式应用是不利的。所有这些原因都推动了基于数据的方法的发展。

在基于数据的方法^[34-36]中,唯一可用的信息是与系统不同运行模式相对应的历史数据。首先,在学习阶段,训练算法将历史数据(通常在实际燃料电池上收集)分类为故障类别。然后,一旦经过训练,算法就能够对新数据进行分类,并检测和识别故障的运行模式。基于数据的方法,优点是不需要燃料电池行为的精确模型,而且易于实现。然而,这些表现与收集到的可用数据的质量和数量有着深刻和内在的联系。基于数据的方法通常使用神经网络,神经网络已被许多作者提出作为故障诊断的一种替代方法,特别是用于处理非线性行为。RIASCOS 等^[37]采用贝叶斯网络作为早期预警,诊断了空气反应风扇故障、冷却系统故障、燃料交叉和内部损耗电流增长以及氢气进料管路故障。此外,为了提高 PEMFC 系统的可靠性和耐久性,N.Yousfi Steiner 等^[38]提出了一种基于 ELMAN 神经网络黑盒模型(ENN)的水淹诊断方法。使用 ENN 对实测压降和计算压降进行比较对故障进行检测。

通过对国内外 PEMFC 故障诊断技术的研究,当前 PEMFC 发动机传感器和

执行器故障诊断受限于故障样本不足，使得基于数据的故障诊断方法，不能很好的发挥其故障诊断的优势。同时氢燃料电池发动机传感器和空气压缩机的故障数据，相比于其他数据有自身的特点。为数据生成带来了较大难度，造成生成的各类数据之间不易被分辨，无法达到提高诊断精度的目的。使用生成对抗网络，扩充数据量不足的故障样本数据，提高故障样本量，使得基于数据的故障诊断，可以实现更好的故障诊断。本文在 Pukrushpan^[39]开发的 PEMFC 模型的基础上通过对传感器和空气压缩机数学建模，设置传感器和空气压缩机故障。提出一种辅助分类器生成对抗网络对故障数据进行增强。同时将故障数据进行分类。实现故障数据的增强和分类。实现数据增强，扩充故障数据实现基于数据的故障诊断。并且在实测数据中对模型进行了验证。

本文技术路线为：



1.3 本文主要研究内容

研究 PEMFC 发动机传感器和执行器故障诊断，基于密歇根州立大学燃料电池模型设置传感器和空气压缩机故障，使用基于一维卷积网络的辅助分类器生成对抗网络，进行数据增强并且实现了故障诊断。主要研究内容如下：

(1)分析了 PEMFC 发动机传感器和执行器故障诊断研究现状，PEMFC 发动机传感器和执行器的故障诊断受限于故障样本量少，使得故障诊断效果不理想。

(2)研究传感器和空气压缩机故障类型，对 PEMFC 发动机传感器故障进行深入研究。传感器常见故障分为软故障主要包括偏置故障，漂移故障，周期性故障等危害性较小，和硬故障包括短路故障、开路故障等传感器自身的结构故障。本文选取净功率传感器设置漂移故障，电压传感器偏置故障，过氧比传感器短路故障，进行故障诊断，空气压缩机作为空气供给系统的核心，设置空气压缩机卡涩故障。对主要故障进行了数学建模和公式推导。

(3)基于密歇根大学燃料电池模型对传感器和空气压缩机故障数学建模设置传感器和空气压缩机故障，得到典型故障数据，为故障数据的增强做准备。

(4)提出一种基于生成对抗网络生成器和判别器中采用一维卷积神经网络的辅助分类器生成对抗网络，使用卷积神经网络强大的特征提取能力，使得网络可以很好的学习到故障样本数据的空间特征分布，同时在生成器和判别器中加入表示样本故障特征的标签，加快模型的收敛速度。使用欧氏距离验证生成数据的质量。将模型得到的 PEMFC 传感器和空气压缩机的故障数据得到了很好的补充同时实现了很好的故障分类效果，实现了 PEMFC 发动机的故障数据增强和故障诊断任务。与不同结构生成器网络进行了分类准确度对比验证了模型的有效性。最后将 PEMFC 采集的电压结果设置传感器偏置故障，对模型进行了验证，同 CGAN,DCGAN 进行了对比，验证了所提模型的有效性。

1.4 本文结构安排

第一章论述了本文题目选取的背景，阐述了论文选题的现实意义。对本文内容相关的现状研究，包括 PEMFC 发动机传感器故障研究现状、PEMFC 空气压缩机故障研究现状和生成对抗网络的研究进展以及在故障诊断领域的应用进行了介绍，论述了本文的研究内容以及文章的结构安排。

第二章研究氢燃料电池发动机传感器和执行器的主要故障。传感器选择净功率传感器、电压传感器、过氧化率传感器进行研究，执行器包括继电器、阀门。选取空气压缩机转速为执行器控制指标，对传感器和空气供给系统进行了故障数学建模，为模型设置故障做准备。

第三章分析密歇根州立大学建立的氢燃料电池模型。在第二章的基础上设置了空气压缩机卡滞的执行器故障，净功率传感器漂移故障，电压传感器偏置故障，过氧化率传感器短路故障，生成了典型故障数据集，为故障数据集扩充做准备。

第四章基于第三章得到的典型故障数据集，在卷积神经网络、生成对抗网络等深度学习基础知识，提出一种基于一维卷积神经网络的辅助分类器生成对抗网络。在生成对抗网络的生成器和判别器中，使用一维卷积神经网络。同时在生成器和判别器中加入故障标签，实现了 PEMFC 发动机传感器和空气压缩机的故障数据的扩充和故障分类。为了对生成数据的质量进行评估，使用欧式距离、KL 散度和皮尔逊相关系数对生成数据进行评价。为了更进一步的验证生成数据在模型中的实用性，提出利用生成数据对模型进行训练。然后使用真实数据对模型进行验证同 CGAN、DCGAN 进行了对比。实验结果证明所提方法可以很好的实现故障样本的扩充以及对于故障样本数据的故障分类任务，证明了模型的有效性。

第五章主要工作为对全文进行了总结，指出了论文的不足，并对未来的研究方向提出了展望。

2 PEMFC 发动机传感器和执行器故障分析

PEMFC 发动机传感器作为氢燃料电池的“眼睛”，执行器作为氢燃料电池的“手和脚”在氢燃料电池发动机中具有举足轻重的作用。传感器出现故障会导致控制器得到错误信号，做出错误决定，轻则会对电堆造成损伤，重则会引起安全事故，空气压缩机作为 PEMFC 发动机空气供应系统的核心部件，发生故障会造成电堆反应空气供应不足，损伤电堆。本章首先建立传感器常见故障数学模型。对 PEMFC 发动机空气系统进行建模，并对空气系统主要故障进行故障建模。

2.1 传感器故障及数学模型

传感器作为氢燃料电池发动机的“眼睛”，对于氢燃料电池发动机的各项指标实时进行监控。PEMFC 发动机的传感器出现故障，轻则会导致电堆损坏，严重则会造成严重的安全事故。为了降低传感器发生故障的概率，首先要做的就是提高传感器的质量，好的材料的选取是质量优秀传感器质量的保证。在平衡经济性的基础上使用质量要求高的材料，同时借助于日益提高的加工工艺，使得传感器质量有了前提保障；其次，要把已经或者将要发生故障的传感器进行及时的处理。以免故障传感器在工作过程中反馈错误的信号，使得控制器或者操作人员做出错误决策，导致安全事故。但是由于传感器数量众多，故障特征复杂，且故障数据不易被获取，使得基于人工对传感器故障特征识别有一定的困难。随着深度学习在故障诊断领域有着诸多应用，将深度学习引入 PEMFC 传感器故障诊断，首先要解决故障数据量少的问题，基于模型对故障数据进行扩充，应当对故障进行建模。得到故障数据集以便于后续使用深度学习对故障数据进行故障分类。

PEMFC 发动机系统是一个复杂的系统，传感器出现的故障一般为软故障主要为测量灵敏度漂移，存在固定偏差，采集得到的故障数据是逐渐变化的，因此故障不容易被发现，这就使得传感器故障诊断的难度非常大。学者 Kulla^[40]对于传感器常见的故障进行了分类，其中包括偏置故障、线性偏差故障、冲击故障，漂移故障等 4 种软故障；传感器卡死故障、短路故障开路故障等 3 种硬故

障。首先建立传感器数学模型。

传感器的数学模型为：

$$\begin{aligned} x_{k+1} &= f(k, x_k, u_k) + v_k \\ y_k &= h(k, x_k) + e_k \end{aligned} \quad (2.1)$$

其中 $f(k, x_k, u_k)$, $h(k, x_k)$ 是非线性函数, x_k 表示传感器状态的变量, y_k 是传感器输出变量, u_k 是传感器输入, e_k 是加入的噪声, v_k 是运行过程噪声, y_k , u_k 是常数。

根据传感器故障发生的概率大小以及基于模型仿真故障的实际, 本文主要研究传感器的偏置故障、短路故障和漂移故障。

(1) 传感器偏置故障数学模型为：

$$\begin{cases} x_{k+1} = f(k, x_k, u_k) + v_k \\ y_{k+1} = h(k+1, x_{k+1}) + g(s_{k+1}) + e_{k+1} \\ g(s_{k+1}) = g(s_k), g(s_0) = 0 \end{cases} \quad (2.2)$$

当由先验知识得知, 当第 a_1, a_2, \dots, a_n 输出传感器可能发生故障时, 可得到下面的简化模型为：

$$\begin{cases} x_{k+1} = f(k, x_k, u_k) + v_k \\ y_{k+1} = h(k+1, x_{k+1}) + \bar{g}(s_{k+1}) + e_{k+1} \\ \bar{g}(s_{k+1}) = \bar{g}(s_k), g(s_0) = 0 \end{cases} \quad (2.3)$$

其中: $\bar{g}(s_k) = [\bar{g}_{a_1}(s_k), \dots, \bar{g}_{a_n}(s_k)]^T$, $D \in R^{m \times m_1}$, 其第 a_i 行, 第 i 列元素为 1, 其余为零。

(2) 增益故障数学模型为：

$$\begin{cases} x_{k+1} = f(k, x_k, u_k) + v_k \\ y_{k+1} = g(s_k)h(k+1, x_{k+1}) + e_{k+1} \\ g(s_{k+1}) = g(s_k), g(s_0) = 1 \end{cases} \quad (2.4)$$

当由先验知识得知, 只有当输出传感器发生故障时, 可得到简化模型为：

$$\begin{cases} x_{k+1} = f(k, x_k, u_k) + v_k \\ y_{k+1} = h_1(k+1, x_{k+1}) + D(k)\bar{g}(s_{k+1}) + e_{k+1} \\ \bar{g}(s_{k+1}) = \bar{g}(s_k), \bar{g}(s_0) = 1 \end{cases} \quad (2.5)$$

其中: $\bar{g}(s_k) = [\bar{g}_{a_1}(s_k), \dots, \bar{g}_{a_n}(s_k)]^T$, $h(\cdot)$ 为 $h(\cdot)$ 中用 “0” 代替 a_i , $i=1, 2$,

3, ..., n 个元素而得到的列向量; $D \in R^{m \times m}$ 其 a_i 行, 第 i 列, $i = 1, 2, 3, \dots, n$, 其余元素为零。

(3) 冲击故障

冲击故障表现为波浪状的电压或者电流, 仿真冲击故障是加入一个脉冲信号, 使得信号产生突变。

冲击故障的强度与其陡峭有关, 用陡峭系数 m 表示。

$$m = \frac{\frac{1}{t} \int_0^t x^4(t) dt}{\frac{1}{t} \int_0^t (x(t) - \mu_x)^2 dt} \quad (2.6)$$

式中, t 为冲击响应时间, μ_x 为均值。陡峭系数反映了冲击故障的强度。

冲击信号越大, 陡峭系数也越大。

传感器冲击故障系统数学模型为:

$$\begin{cases} x(t) = k_1(t)f_1(x, t) + k_2(t)f_2(x, t) + \dots + k_n(t)f_n(x, t) \\ x(t_0) = x_0, x \in R^N, f_i(x, t) \in R^N, k_i(t) \in R^N \end{cases} \quad i = 0, 1, \dots, n \quad (2.7)$$

脉冲信号的产生与消失时间一般非常短数学表达式为, $k_i(t)$ 在很短的时间 $[t_0, t_0 + \Delta t]$ 内发生变化。名义上, 一般情况下 $k_i(t)$ 出现一个时间很短的高峰值以后会快速恢复到正常值, 这将会出现在时间 Δt 内产生突变间。故障的解决方法为将传感器出现故障的状态信号 $x(t_0 + \Delta t)$ 进行诊断和识别, 或者传感器系统状态跳变 $x(t_0 + \Delta t) - x(t_0)$ 。

(4) 漂移故障

漂移故障的表现故障信号随时间呈现线性变化的一种故障, 数学模型为:

$$\begin{cases} x(k+1) = f(x(k), u(k), \beta(k)) \\ y(k) = g(x(k), u(k), \beta(k)) \end{cases} \quad x(0) = x_0, k = 0, 1, \dots, n \quad (2.8)$$

$x(k)$ 表示状态变量, u 和 y 分别表示输入和输出, $\beta(k)$ 表示系统的参数向量, $x(0)$ 表示向量初始值, k 表示离散时间, $\hat{\beta}(k)$ 表示 $\beta(k)$ 的估计值。在健康状态下 $\hat{\beta}(k)$ 在正常值附近做随机运动, 发生故障时, $\hat{\beta}(k)$ 偏离正常值。

$\hat{\beta}(k)$ 的线性近似值为:

$$\hat{\beta}(k) = \beta(k) + (k - k_0)\alpha + n(k) \quad (2.9)$$

$n(k)$ 表示零均值随机向量，由参数和漂移故障确定， α 表示漂移率， k_0 表示随机的时间点。

（5）传感器完全故障

传感器完全故障是指传感器不能够对被测量进行准确实时进行测量。通常表现为得出的数值为一条直线，当测量值为传感器的最大值时表示传感器出现了开路故障，当直线接近于零时表示传感器为短路故障。

2.2 执行器故障及故障建模

PEMFC 发动机由于其结构的复杂性，在传感器获取发动机状态后需要大量的执行器对系统进行响应。PEMFC 发动机执行器包括：空气压缩机供电开关、电堆负载开关、尾气阀开关、氢气阀开关、循环水泵控制开关以及各种继电器的开关。继电器包括负载开关、风机供电开关、循环水泵供电开关和氢气循环泵供电开关等。PEMFC 发动机执行器故障主要包含执行器自身的机械故障、执行器的控制电路的故障、执行器的供电电路故障等。执行器在出现故障时主要表现为执行器不能正常工作，或者表现为对控制器的命令不能及时响应。由于使用条件相对恶劣，相关执行器设备存在破裂、脱落和卡死等故障，主要原因因为控制器的控制电路或者执行器内部的结构本身出现了故障。执行器设备接近使用末期，设备发生故障的概率将会随着使用时间的延长进一步增大。降低 PEMFC 发动机可靠性及使用时间。

PEMFC 发动机空气供给系统主要由过滤器、空气压缩机、空气冷却器、供气歧管等组成。空气压缩机作为供气系统的核心部件，一旦发生故障轻会导致性能下降，重则会发生安全事故，因此需要对空气压缩机故障进行故障诊断。燃料电池常用的离心式空气压缩机容易出现喘振和扼流圈，限制了空气压缩机的效率和性能。空气压缩机必须保证氧气的分压不低于阴极处的临界水平。另一方面，不能使氧气分压过大减少空气压力的寄生损失。为了探究空气压缩机故障对于空气系统的影响，首先对空气系统进行建模，对空气系统中的故障，进行数学建模，由质量守恒定律可知燃料电池电堆中氧气、氮气和水的情况；

$$\frac{dm_{O_2}}{dt} = W_{O_2,in} - W_{O_2,out} - W_{O_2,react} \quad (2.10)$$

m_{O_2}, m_{N_2}, m_w 表示阴极氧气, 氮气和水的质量, $W_{O_2,react}$ 表示氧气反应速率, $W_{v,m}$ 表示电堆中水通过膜的质量流量。

$$\frac{dm_{N_2}}{dt} = W_{N_2,in} - W_{N_2,out} \quad (2.11)$$

W_{in}, W_{out} 表示进入和离开阴极的质量流量。

$$\frac{dm_w}{dt} = W_{v,in} - W_{v,out} + W_{v,g} + W_{v,m} - W_{l,out} \quad (2.12)$$

$W_{l,out}$ 表示液态水离开阴极的质量流量。

根据阴极气体的饱和状态, 可以得知阴极中为水蒸气与液态水共存的状态, 根据蒸汽饱和压力可以得出蒸汽最大质量:

$$m_{v,max} = \frac{p_{sat} V}{R_v T_{st}} \quad (2.13)$$

$m_{v,max}$ 表示阴极中蒸汽质量;

p_{sat} 表示饱和蒸汽压力;

R_v 表示气体常数;

T_{st} 表示电堆温度;

通过电堆阴极各分压可以得出电堆阴极压力:

$$P_{O_2} = \frac{m_{O_2} R_{O_2} T_{st}}{V_{ca}} \quad (2.14)$$

$$P_{N_2} = \frac{m_{N_2} R_{N_2} T_{st}}{V} \quad (2.15)$$

$$P_v = \frac{m_v R_v T_{st}}{V_{ca}} \quad (2.16)$$

$$P = P_{O_2} + P_{N_2} + P_v \quad (2.17)$$

P 表示阴极压力;

V 表示阴极体积;

P_{O_2} , P_{N_2} , P_v 表示氧气, 氮气和蒸汽分压;

(1) 阴极扩散层流量阻力增大故障

通过公式(2.18), 出口孔常数的增量 Δk_{out} 可以模拟阴极扩散层流量阻力增大故障。

$$W_{out} = (k_{out} + \Delta k_{out})(p - p_{rm}) \quad (2.18)$$

W_{out} 表示阴极出口质量流量;

k_{out} 表示阴极出口孔常数;

Δk_{out} 表示阴极出口孔常数的增量;

p_{rm} 表示返回歧管压力;

(2) 供气歧管泄露故障

由公式(2.19)可知供气歧管出口流量增量 $\Delta k_{s,out}$ 可以模拟供气歧管泄露故障。

$$W_{s,out} = (k_{s,out} + \Delta k_{s,out})(p_s - p_{rm}) \quad (2.19)$$

$W_{s,out}$ 表示供气歧管出口质量流量;

$k_{s,out}$ 表示供气歧管出口孔流量常数;

$\Delta k_{s,out}$ 表示供气歧管出口孔流量常数增量;

p_s 表示供气歧管压力;

2.3 本章小结

本章分析了 PEMFC 发动机传感器故障, 并对常见传感器及其故障进行了数学建模。介绍了空气压缩机的重要作用以及容易发生的故障。空气压缩机在 PEMFC 发动机空气管理系统中具有重要作用, 将空气压缩机故障作为执行器故障。对空气系统进行了建模, 给出了空气供给系统常见故障数学模型。

3 基于 PEMFC 发动机模型传感器和执行器故障研究

本章基于密歇根州立大学 Pukrushpan J.T.^[39]公开模型，研究 PEMFC 发动机传感器和执行器的故障特征。在模型上设置净功率传感器、电压传感器和过氧比传感器三个典型传感器故障和空气压缩机故障，得到典型故障数据集。

3.1 PEMFC 发动机原理

燃料电池的化学反应为，氢原子分裂为质子和电子。电子流过外界负载，而质子通过电解质迁移到阴极侧，通过电解质的质子与氧气结合产生水和热。为了维持所需的空气，空气供给系统需要为电堆提供稳定高效的空气，以维持氧气分压。送风系统由空气压缩机、电动机和部件之间连接的管道或歧管组成。空气压缩机在提供充足空气流量的同时，还增加了空气压力，显著改善了质子交换膜上的氢气与氧气的化学反应，从而提高了整体效率和功率密度。PEMFC 发动机反应示意图如图 3.1 所示。




图 3.1 氢燃料电池化学反应

PEMFC 发动机系统是复杂的，它涉及热、流体和电化学反应。此外，还需要气门、空气压缩机、传感器、调节器等辅助元件，才能使燃料电池在预先设定的最佳操作点上工作。由于系统复杂，使得 PEMFC 发动机出现的故障也复杂多样，严重的会导致燃料电池损坏甚至会造成严重的安全事故。为了保证燃料电池系统的安全运行，需要首先建立精确的燃料电池仿真模型，来探究不同操作会导致的故障。

3.2 PEMFC 发动机模型

本文研究氢燃料电池发动机传感器和执行器故障诊断，由于传感器和空气压缩机的故障数据量少，制约了燃料电池故障诊断。通过在模型中设置传感器和空气压缩机故障典型故障，获得典型故障数据集。本文基于密歇根州立大学的 Pukrushpan J.T^[39]建立的燃料电池仿真模型，对传感器和空气压缩机故障进行仿真得到故障数据集，该 PEMFC 堆叠由 381 个电池组成，活性面积为 280cm^2 ，堆叠工作温度为 80°C 。用于计算健康系统的理论状态值，如燃料电池电压，燃料电池净功率，燃料电池过氧比等。首先对空气系统和空气压缩机进行建模。

3.2.1 PEMFC 空气系统

PEMFC 空气系统中唯一的动态变化参数是空气压缩机转速 w_{cp} 。模型的输入包括入口空气压力 $p_{cp,in}$ ，温度 $T_{cp,in}$ ，空气压缩机电机的电压命令 v_{cm} ，以及下游压力，供应歧管压力， $p_{cp,out} = p_{sm}$ 。入口空气通常是大气，其压力和温度分别假设固定在 $p_{atm} = 1$ 和 $T_{atm} = 25^\circ\text{C}$ 。马达指令是燃料电池系统的输入之一。下游压力由供气歧管模型确定。空气压缩机空气质量流 $W_{cp} (\text{kg} / \text{sec})$ ，是通过空气压缩机流量图确定的。使用查表的形式，提供压缩机流量图不适合动态系统模拟，标准插值程序不是连续可微的进行外推不准确。为此，采用非线性曲线拟合方法对空气压缩机特性进行建模如图 3.2。

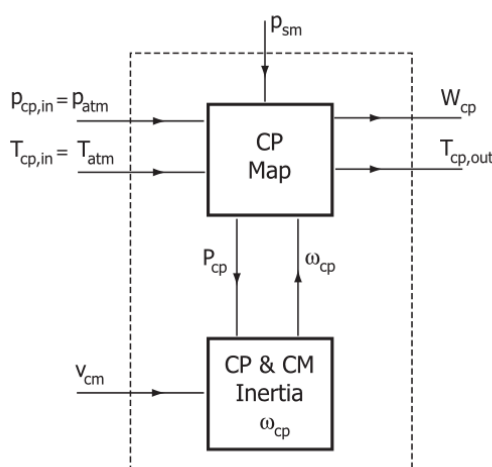


图 3.2 空气压缩机模型框图

在模型中使用了 P Moraal 等描述的 Jensen & Kristensen 方法^[41]。为了反映空气压缩机进口条件进口流量压力和温度的变化，在空气压缩机图中使用了质量流量和压缩机速度的“修正值”。修正值^[42]为修正后的压缩机转速(rpm)， $N_{cr} = N_{cp} / \sqrt{\theta}$ 和修正后的质量流量 $W_{cr} = W_{cp} \sqrt{\theta} / \delta$ ，其中修正后的温度 $\theta = T_{cp,in} / 288K$ ，修正后的压力 $\delta = P_{cp,in} / 1$ 。使用 Jensen & Kristensen 方法，首先定义了无量纲参数：

$$\psi = \frac{C_p T_{cp,in} \left[\left(\frac{P_{cp,out}}{P_{cp,in}} \right)^{\frac{\gamma-1}{\gamma}} - 1 \right]}{\frac{1}{2} U_c^2} \quad (3.1)$$

式中，进气温度 $T_{cp,in}$ 为开尔文， U_c 为压气机叶尖转速(m/s)：

$$U_c = \frac{\pi}{60} d_c N_{cr} \quad (3.2)$$

d_c 为空气压缩机直径(m)， γ 为气体在恒压下的比热之比 cp/cv ，取大气状态下等于 1.4。归一化空气压缩机流量 ϕ ：

$$\phi = \frac{W_{cr}}{p_a \frac{\pi}{4} d_c^2 U_c} \quad (3.3)$$

其中 p_a 为空气密度(kg/m³)。归一化的空气压缩机流量 ϕ ，与扬程参数 ψ 通过公式进行关联：

$$\phi = \phi_{\max} \left(1 - \exp^{\beta \left(\frac{\psi}{\psi_{\max}} - 1 \right)} \right) \quad (3.4)$$

入口马赫数 M ：

$$M = \frac{U_c}{\sqrt{\lambda R_a T_{cp,in}}} \quad (3.5)$$

3.2.2 空气压缩机模型

空气压缩机流出的流量和温度 W_{cp} 和 T_{cp} 取决于空气压缩机转速 w_{cp} 。采用带惯性的集总转动参数模型，来表示压缩机转速的动态行为，如公式(3.6)：

$$J_{cp} \frac{dw_{cp}}{dt} = (\tau_{cm} - \tau_{cp}) \quad (3.6)$$

J_{cp} 是空气压缩机和电机的组合惯性 $kg \cdot m^2$;

w_{cp} 是空气压缩机转速 rad/sec ;

τ_{cm} 空气压缩机转矩输入 $N-m$;

τ_{cp} 驱动空气压缩机需要的转矩 $N-m$;

$\tau_{cm}(v_{cm}, w_{cp})$ 为空气压缩机电机(CM)转矩, τ_{cp} 为负载转矩。空气压缩机电机转矩的计算采用静态电机方程如公式(3.7)所示:

$$\tau_{cm} = \eta_{cm} \frac{k_t}{R_{cm}} (v_{cm} - k_v w_{cp}) \quad (3.7)$$

其中 k_t 是电机转矩常数, R_{cm} 是压缩机电机电阻常量, k_v 是电机常数; η_{cm} 是电机机械效率。

利用热力学方程计算了驱动空气压缩机所需的扭矩如公式(3.8)。

$$\tau_{cp} = \frac{C_p}{w_{cp}} \frac{T_{atm}}{\eta_{cp}} \left[\left(\frac{p_{sm}}{p_{atm}} \right)^{\frac{\gamma-1}{\gamma}} \right] W_{cp} \quad (3.8)$$

C_p 空气的比热容为 $1004 J \cdot kg^{-1} \cdot K^{-1}$; γ 空气的比热比为 1.4; η_{cp} 为电机效率; p_{sm} 为供气总管压力; p_{atm} 大气压力; T_{atm} 大气温度。

PEMFC 传感器和空气压缩机模型如图 3.3-3.4 所示。

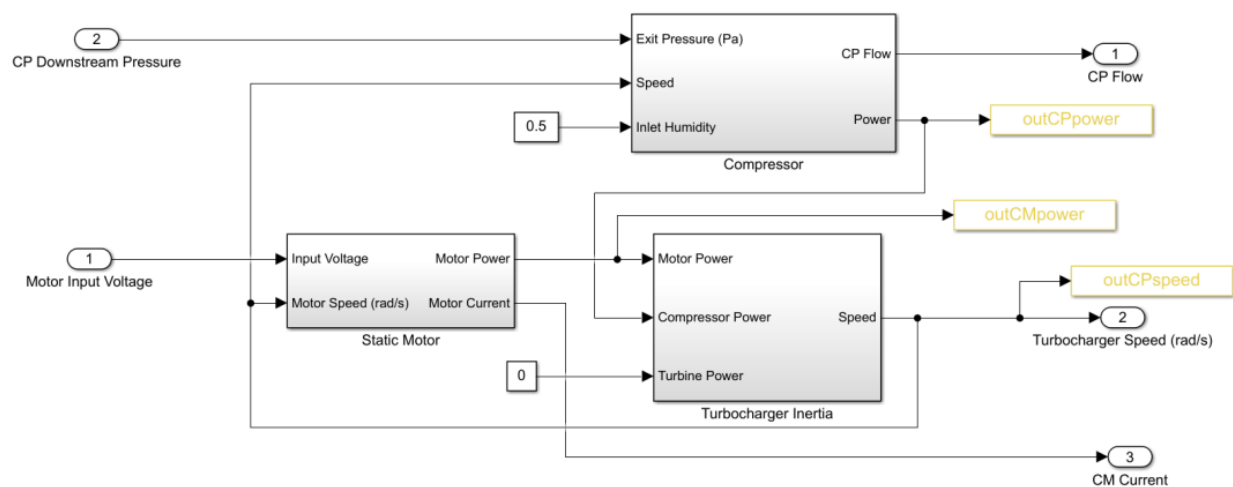


图 3.3 PEMFC 空气压缩机模型

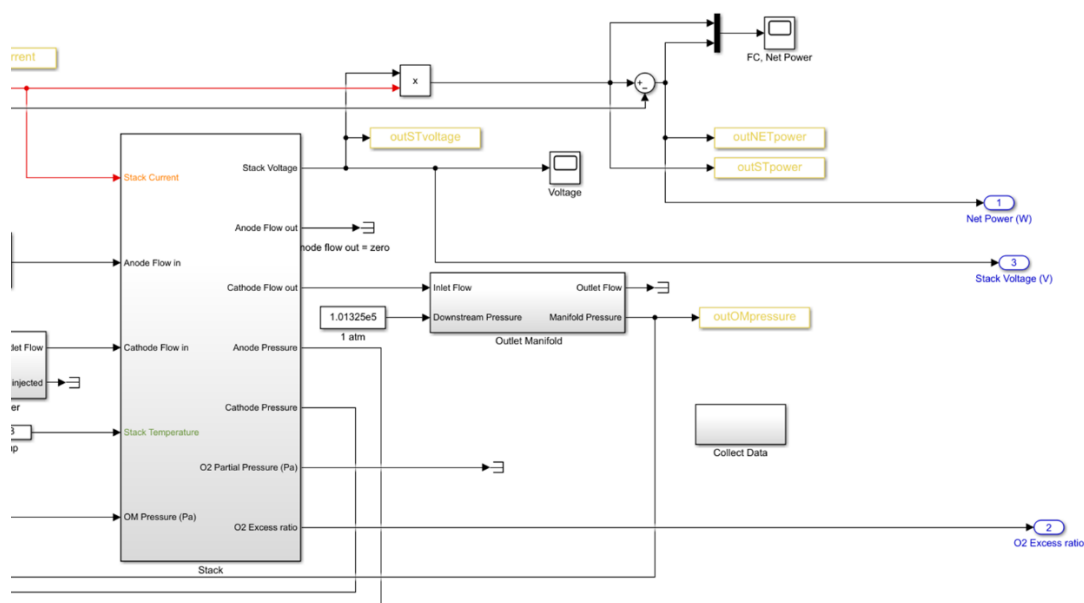


图 3.4 PEMFC 传感器模型

为了与故障数据形成对比，首先在健康状态下运行 30s 得到传感器和空气压缩机转速健康数据，输出如图 3.5 所示。在 simulink 中每种状态得到健康数据集 3345 组数据。

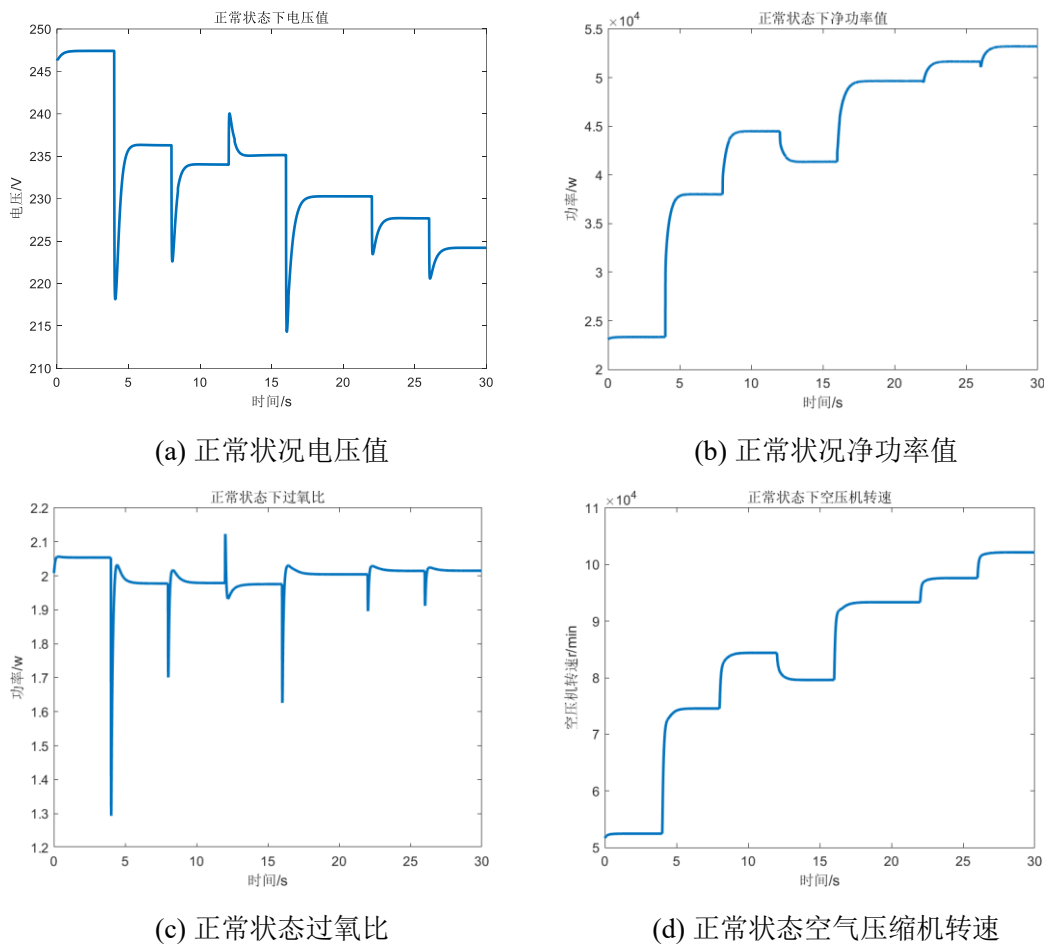


图 3.5 PEMFC 发动机正常状态传感器和空气压缩机参数

3.3 故障设置

空气流量和压力是燃料电池堆的关键性能表现，以实现燃料电池高效和动态性能。燃料电池在大电流需求和快速负荷变化时存在缺氧风险。PEMFC 发动机缺氧会导致功率下降，影响汽车正常运行。氧气是否充足，使用过氧比进行衡量，定义为，空气压缩机提供氧气分压与使用氧气分压之比。它伴随着氧气分压的下降而下降。过氧比是空气供给是否充足的直观体现。电堆电压和净功率是 PEMFC 发动机性能的直观展现。选取空气压缩机研究执行器故障，净功率传感器、过氧比传感器和电压传感器研究传感器故障。空气压缩机故障由正常运行空气压缩机电压的 90%模拟空气压缩机供气不足，三个传感器故障分别通过对净功率传感器设置漂移故障、过氧比传感器设置短路故障和电压传感器偏置故障。故障布置如图 3.6 所示。

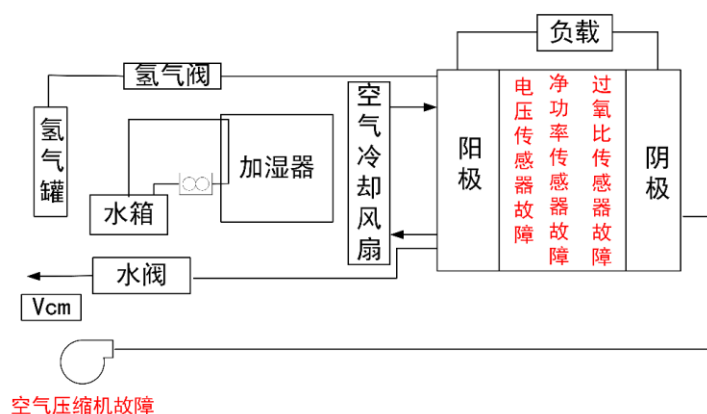


图 3.6 燃料电池发动机故障设置

3.3.1 PEMFC 发动机空气压缩机故障

燃料电池中使用的离心式空气压缩机大多易受喘振和扼流圈的影响，限制了空气压缩机的效率和性能。空气流动必须确保氧气的分压不低于阴极的临界水平。另一方面，它还必须尽量减少空气压力的寄生损失。空气压缩机出现喘振和阻塞，影响供气歧管内的气流。为了得到更加接近于真实的数据在模型中加入高斯白噪声，空气压缩机故障设置如图 3.7 所示。

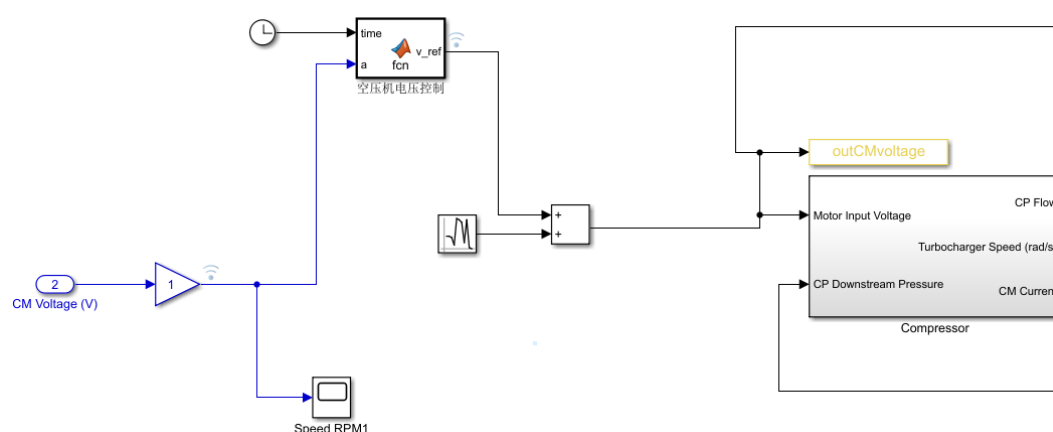


图 3.7 空气压缩机故障设置

将式(3.7)添加一个电机增量常数 Δk_v 模拟空气压缩机电压不足，得到式(3.9)

$$\tau_{cm} = \eta_{cm} \frac{k_t}{R_{cm}} (v_{cm} - (k_v + \Delta k_v) w_{cp}) \quad (3.9)$$

通过改变空气压缩机电压，控制空气压缩机转速，改变进入到供气歧管中的气流。空气压缩机性能降为正常值的 90%，来反映空气压缩机执行器发生故

障的情况。如图 3.8 所示，在 simulink 中运行 30s 共得到 1000 组空气压缩机卡涩故障数据。




图 3.8 空气压缩机故障

3.3.2 PEMFC 发动机传感器故障

传感器是氢燃料电池发动机安全稳定运行的必要组成部分，传感器的精确测量关系到系统的安全运行，分析传感器信号，是实现对被测对象故障诊断的重要手段。

由于传感器是精密元件，因此可能发生的故障是复杂多样的。根据传感器故障严重程度不同，可将其故障分为硬故障和软故障。硬故障是指传感器结构损坏引起的故障，传感器的信号会发生突然变化一般不可恢复。软故障会导致传感器信号逐渐偏离正常值，包括时隐时现的间歇故障和不可恢复的永久性故障。模型故障可设为乘以某系数的乘性故障，或对信号添加一个增量的加性故障。

为模拟真实数据集，在模型中加入高斯噪声。PEMFC 传感器故障设置如图 3.9-3.10 所示。

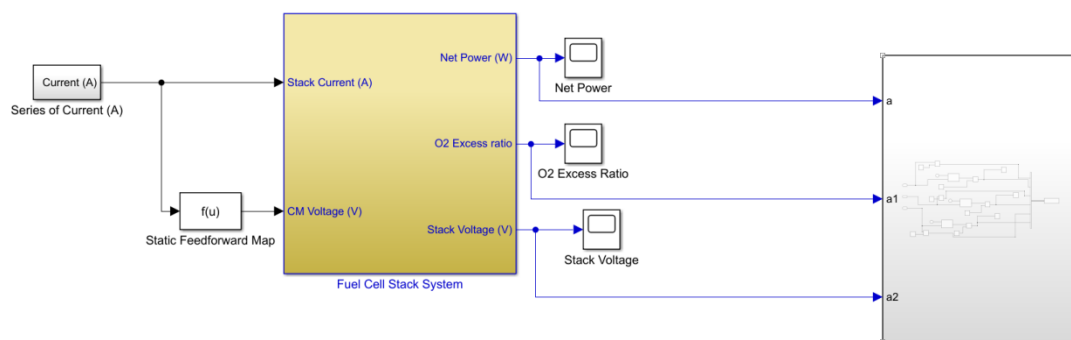


图 3.9 PEMFC 传感器故障

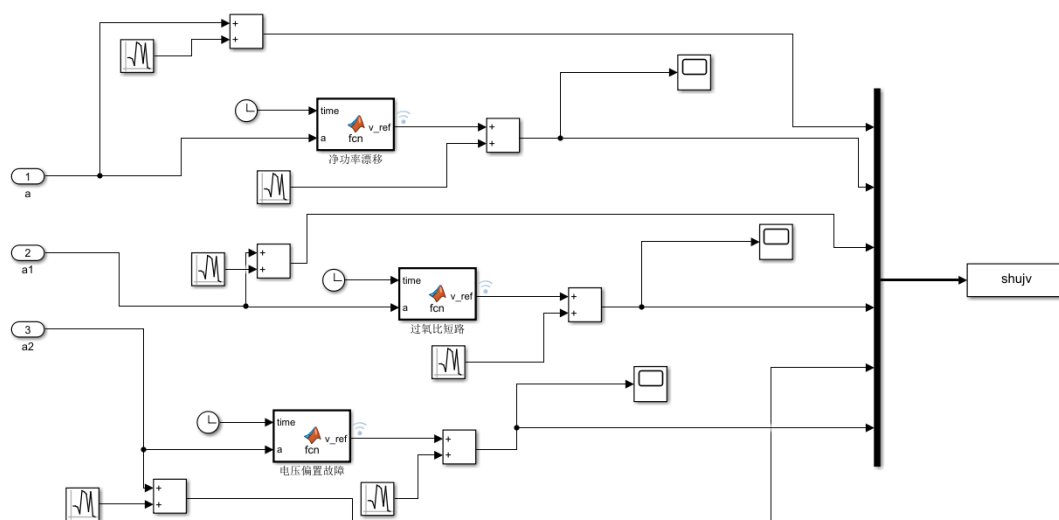


图 3.10 PEMFC 传感器故障设置

依据第二章传感器故障建模数学方法，在模型中设置传感器故障的方法如表 3.1 所示。

表 3.1 传感器故障定义及其参数

传感器故障类型	定义	故障表现	参数设置
偏置故障	传感器信号相比正常值有恒定偏差	信号突然产生偏差	固定偏置大小
漂移故障	传感器信号逐渐偏离其正常值	信号以固定速率随时间偏离正常值	随时间变化的偏置
短路故障	传感器损坏	信号变为一条直线	所测信号接近于零

分别采集正常数据，偏置故障、漂移故障、短路故障，各类型分别采集 1000 组故障数据。

(1)净功率传感器故障漂移故障如图 3.11 所示。




图 3.11 净功率传感器漂移故障

(2)电压传感器偏置故障如图 3.12 所示。

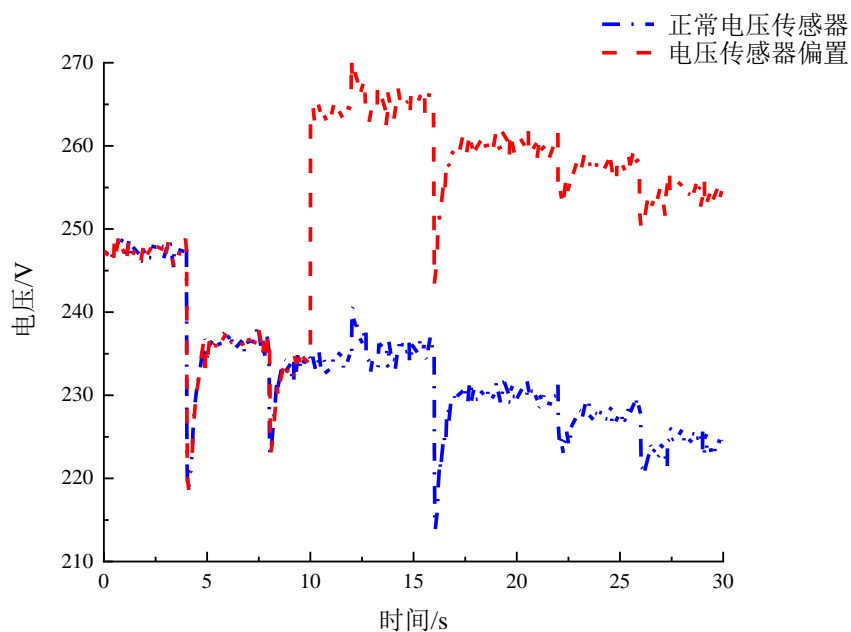


图 3.12 电压传感器偏置故障

(3)过氧比传感器设置为短路故障如图 3.13 所示。




图 3.13 过氧比传感器短路故障

3.4 本章小结

本章基于密歇根州立大学氢燃料电池模型研究传感器和执行器故障。选取空气压缩机研究 PEMFC 发动机执行器故障，分析三个典型传感器电压传感器、净功率传感器和过氧比传感器的故障特性研究传感器故障。通过在模型上设置相应故障，获取故障数据集。

4 基于生成对抗网络的传感器和执行器故障诊断方法研究

本章针对实际使用中传感器和空气压缩机故障数据难以获取的问题,提出一种基于一维卷积神经网络的辅助分类器生成对抗网络。基于生成对抗网络对故障数据进行扩充,并对生成数据进行质量评估。诊断结果与多种生成对抗网络构型进行对比。实现基于少量故障样本的传感器和空气压缩机故障诊断。使用健康电压数据集,设置传感器偏置故障,生成测试集,对诊断方法进行验证,并与 CGAN,DCGAN 方法进行对比,验证本章提出的诊断方法的有效性。

4.1 卷积神经网络

卷积神经网络因其强大的特征提取能力,在深度学习中得到广泛应用。卷积运算是卷积神经网络的核心,具有很好的线性拟合功能,可以提取信息的高阶特征,基于上述特点 CNN 被广泛应用于故障诊断。本小节对 CNN 各层进行介绍。

4.1.1 卷积层

卷积神经网络(Convolutional Neural Network, CNN),是基于数学上的卷积运算,对于故障特征的提取具有优异表现^[43],使用卷积核提取数据特征。卷积运算如公式(4.1)

$$x_j^{out} = f_{cov} \left(\sum_{i \in M_j} x_i^{input} \bullet k_{ij} + b_j \right) \quad (4.1)$$

$f_{cov}()$ 表示卷积运算 x_i^{input} 卷积层输入, x_j^{out} 表示卷积输出 k_{ij} 表示权重矩阵, b_j 表示偏置项。

CNN 的优势主要体现在,(1)稀疏交互:相互两层之间不是完全连接使得训练速度加快;(2)参数共享:卷积核中的参数是可以被其他卷积核共享的,数据的特征在经过平移、旋转等操作时,数据特征不会发生变化。卷积运算如图 4.1 所示。

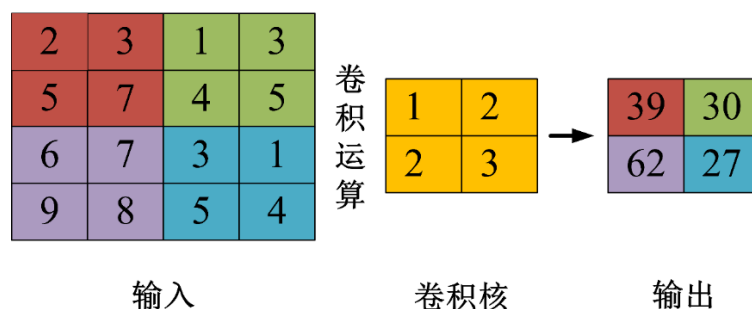


图 4.1 卷积运算

4.1.2 激活函数层

线性函数对于复杂特征不能很好拟合，使用非线性函数作为激活函数，可以实现特征的良好拟合，常用的激活函数为 Sigmoid、Tanh、Relu、Leaky Relu 等函数，激活函数一般位于卷积与池化层之间。

(1) *Sigmoid* 函数可以将特征反映到(0,1),适用于二分类问题:

$$Sigmoid(x) = \frac{1}{1 + e^{-x}} \quad (4.2)$$

(2) *Tanh* 为双曲线正切函数:

$$Tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} \quad (4.3)$$

(3) *relu* 函数很好的解决了 *Sigmoid* 函数、*Tanh* 函数训练过程中的梯度消失和梯度爆炸问题。

$$relu(x) = \max(0, x) \quad (4.4)$$

(4) *relu* 函数很好的提升了训练效率，缓解了梯度消失和梯度爆炸问题，但是当数据小于零时 *relu* 会丢失一些特征信息，*leakyrelu* 通过添加一个系数解决了上述问题。

$$leakyrelu(x) = \max(\alpha x, x) \quad (4.5)$$

如公式(4.5)可知在 *leakyrelu* 中当数值小于零时可以通过参数 α 进行调节。

4.1.3 池化层

池化层的作用为实现特征降维，分为最大池化和平均池化，最大池化可以

得到局部最强信号。平均池化可以消除噪声，池化操作后可以提高网络的特征提取能力。本文中的池化操作主要为最大池化进行降维操作，提高模型的特征提取能力。池化运算如图 4.2 所示。




图 4.2 池化运算

4.1.4 全连接层

全连接层是 CNN 网络不可或缺的组成部分，一般在倒数第二层使用全连接层进一步整合池化层提取到的故障特征，将整合后的特征送入 softmax 函数进行故障分类。

Softmax 函数常用于多分类问题如公式(4.6)。

$$\text{out} = \begin{bmatrix} P(y=1|x;W_1,b_1) \\ P(y=2|x;W_2,b_2) \\ \dots \\ P(y=k|x;W_k,b_k) \end{bmatrix} = \frac{1}{\sum_{j=1}^k \exp(W_j x + b_j)} \begin{bmatrix} \exp(W_1 x + b_1) \\ \exp(W_2 x + b_2) \\ \dots \\ \exp(W_k x + b_k) \end{bmatrix} \quad (4.6)$$

out 是 CNN 中 Softmax 函数的输出值， W_j ， b_j 表示对应类型的权值和偏移量，输出结果为每个类型输出对应的概率值，将最大的概率值作为最后的分类结果。

4.1.5 优化算法

网络训练的目标函数如公式(4.7)，训练的目的在于取得损失函数的最小值。其中 L 是样本数据的损失函数， $f(x;\theta)$ 是输入 x 的估计值， E_{data} 是真实样本数据分布， y 是目标输出。在实际使用中，真实样本的数据分布很难获得，因此使用伪样本的数据分布替代真实数据分布，如公式(4.8)所示。

$$J^* = E_{(x,y) \sim data} L(f(x; \theta), y) \quad (4.7)$$

$$J = E_{(x,y) \sim data} L(f(x; \theta), y) \quad (4.8)$$

想要实现最小化损失函数，需要不断地调整网络模型中的超参数，寻找到最优超参数的过程就是优化算法的实现过程。

(1) 随机梯度下降

随机梯度下降(Stochastic Gradient Descent, SGD)^[44]，是在梯度下降的基础上进行改进的一个优化算法，跟随随机选择的少量数据进行梯度下降，通过对比选择下降速度最快的路线，对模型参数进行不断优化，直到到达谷底。算法参数更新的方式如公式(4.9)所示。其中 m 是批量样本数。然后通过公式(4.10)的方式优化模型参数，其中 ε 是学习率。

$$g \leftarrow +\frac{1}{m} \nabla_{\theta} \sum_i L(f(x^{(i)}; \theta), y) \quad (4.9)$$

$$\theta \leftarrow \theta - \varepsilon g \quad (4.10)$$

学习率是随机梯度下降算法中关键的超参数，学习率代表算法每次移动的距离，学习率设置的过大，虽然会提高模型的收敛速度，但是同时会导致算法可能会错过最优解。过小的学习率，虽然不会错过最优解，但是会增加模型训练难度，严重会导致模型崩塌。因此正确的学习方式应当为前期选用大的学习率，当接近最优解时，选择小的学习率，提高模型训练效率。学习率更新公式如(4.11)所示。

$$\varepsilon_k = (1 - \alpha) \varepsilon_0 + \alpha \varepsilon_{\tau} \quad (4.11)$$

其中， $\alpha = \frac{k}{\tau}$ ， ε_0 ， ε_k ， ε_{τ} 分别是初始学习率、第 k 次迭代学习率和最终学

习率。常用的自适应优化算法学习率包括：AdaGrad^[45]、Adam^[46] RMS Prop^[47] 等。本文主要使用 Adam 优化算法，对 Adam 进行简要介绍。

(2) Adam 自适应优化算法

Adam(Kingma and Ba, 2014) 优化算法对每个参数都有相应的学习率和动量，学习率会自适应调整，每个网络权重从梯度的一阶矩估计和二阶矩估计中计算各自的学习率。结果表明使用 Adam 优化算法的模型可以实现快速收敛，具有

更好表现，具体的算法伪代码见算法 4.1。

算法 4.1 Adam 算法

算法 4.1 Adam 算法

Require: 步长 ε

Require: 矩估计的指数衰减速率, p_1 和 p_2 在区间 $[0,1)$ 内。

Require: 用于数值稳定的小常数

Require: 初始参数 θ

初始化一阶和二阶矩变量 $s = 0, r = 0$

初始化时间步 $t = 0$

while 没有达到停止准则 *do*

从训练集中采包含 m 个样本 $[x(1), x(2), \dots, x(m)]$ 的小批量, 对应目标为 $y(i)$

计算梯度: $g \leftarrow \frac{1}{m} \nabla \theta \sum_i L(f(x^{(i)}; \theta), y^{(i)})$

$t \leftarrow t + 1$

更新有偏一阶矩估计: $s \leftarrow p_1 s + (1 - p_1) g$

更新有偏二阶矩估计: $r \leftarrow p_2 r + (1 - p_2) g \odot g$

修正一阶矩的偏差: $\tilde{s} \leftarrow \frac{s}{1 - p_1}$

修正二阶矩的偏差: $\tilde{r} \leftarrow \frac{r}{1 - p_2}$

计算更新: $\Delta \theta = -\varepsilon \frac{\tilde{s}}{\sqrt{\tilde{r} + \delta}}$

应用更新: $\theta \leftarrow \theta + \Delta \theta$

end while

4.2 辅助分类器生成对抗网络

本文主要的研究工作为提出一种基于一维卷积辅助分类器生成对抗网络。解决 PEMFC 发动机传感器和空气压缩机故障样本少的问题。本节首先介绍生成对抗网络和辅助分类器生成对抗网络，并且给出了数据生成质量的判别标准。

4.2.1 GAN 基本结构

GAN^[18]是 Goodfellow 在 2014 年提出的一种生成式模型，模型由生成器和判别器两部分组成。生成对抗网络的结构如下图 4.3 所示。

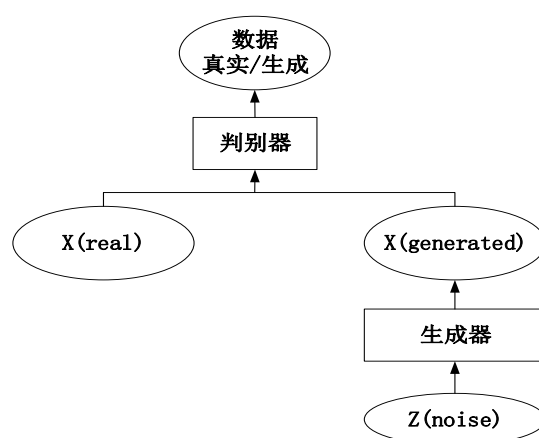


图 4.3 生成对抗网络结构

生成对抗网络对于数据扩充的灵感来源于博弈论，通过生成器和判别器之间的相互博弈，得到高质量的生成数据，生成器从随机噪声 z 中学习符合真实数据空间分布的生成数据。 $x_{generated} = G(z)$ ，判别器的输入为真实数据样本和生成器生成的假样本，判别器训练的目的为辨别出样本是真实样本数据还是生成器生成的假样本，判别器训练的目的为辨别出样本是真实样本数据还是生成器生成的假样本。判别器的输出为样本来源的概率值，一般使用 sigmoid 激活函数来解决二分类问题。损失函数是深度学习模型性能的最直观体现，可以用来优化模型，判别器的损失函数定义为公式(4.12)。

$$\begin{aligned} L &= E_{x \sim p_{data}} [\log p(s = real \parallel x_{real})] + E_{z \sim P(z)} [\log p(s = generate \parallel x_{generate})] \\ &= E_{x \sim p_{data}} [\log(D(x))] + E_{z \sim P(z)} [\log(1 - D(G(z)))] \end{aligned} \quad (4.12)$$

公式中 p_{data} 代表真实样本的数据分布， $p(z)$ 代表随机噪声的数据分布，

$D(x)$ 代表 x 样本是真实数据样本的概率， $E_{x \sim p_{data}}$ 代表真实样本的数据分布 p_{data}

对 x 样本期望值, $E_{z \sim p(z)}$ 代表得到的随机噪声对 $p(z)$ 用于生成数据的期望。鉴别器的训练目标为损失函数的最大化, 生成器的训练目标为 $E_{z \sim p(z)}[\log(1 - D(G(z)))]$ 最小化, 最终结果为判别器不能准确判断数据来源于真实样本数据。生成对抗网络的目标函数可以由式(4.13)给出:

$$\min_G \max_D V(G, D) = E_{x \sim p_{data}(x)}[\log D(x)] + E_{z \sim p_z(z)}[\log(1 - D(G(z)))] \quad (4.13)$$

GAN 相比于其他模型的优势在于, 生成器和判别器的组成形式是丰富多样的。可以由多层感知器, 深度卷积神经网络等组成, 模型最初用途为, 解决图像数据的扩充。随着应用的广泛在故障诊断领域得到了广泛应用。生成对抗网络有着上述诸多优点, 但是随着使用的增多也暴露出了各种问题。最先出现的问题是, 模型训练稳定性差, 模型在训练过程中很容易出现梯度爆炸的问题。为了解决模型训练不稳定的问题引入了 Wasserstein GAN(WGAN)利用推土距离(Wasserstein distance)^[48]WGAN 改进了原始生成对抗网络的损失函数使用推土距离代替交叉熵损失函数。通过大量应用证明, WGAN 模型相比于原始 GAN 拥有更好的适用性, 模型也更加稳定。将卷积神经网络应用在生成器和判别器中, 可以得到深度卷积生成对抗网络(Deep convolution GAN, DCGAN), 得到一种无监督学习模型。DCGAN 利用卷积神经网络强大的特征提取能力, 对目标物体进行特征提取的基础上学习特征, 实现数据增强。将类别标签引入原始 GAN, 就可以得到半监督学习结构。判别器不仅可以判别数据的真伪, 还可以对数据进行分类。可以大幅度提升伪样本的质量^[49]。在 DCGAN 的启发下得到 GAN 的另一种变形, 辅助分类对抗生成网络(Auxiliary classifier GAN, ACGAN), 在生成器和判别器中同时引入类别标签, 监督学习模式可以得到高质量的生成样本, 同时可以得到样本的分类标签^[50, 51]。

4.2.2 辅助分类器生成对抗网络(ACGAN)

生成对抗网络是典型的无监督样本生成模式, 因此数据生成的过程没有约束, 数据生成过程不可控。为了解决生成对抗网络的弊端, M Mirza 等^[52]提出条件生成对抗网络, 在生成器和判别器中加入样本标签 c 。使用样本标签使数据生成向真实数据靠近, 通过类别标签, 可以实现网络训练的有监督学习。A.Odena 等^[53]在条件生成对抗网络的基础上继续优化, 将样本类型标签, 作为

生成器的输入，把辅助分类器作用于判别器用来对样本的类型进行判断。辅助分类器生成对抗网络的判别器，在辨别出数据的真伪的同时可以实现对数据样本的分类。

辅助分类器生成对抗网络的网络结构类型由图 4.4 给出。

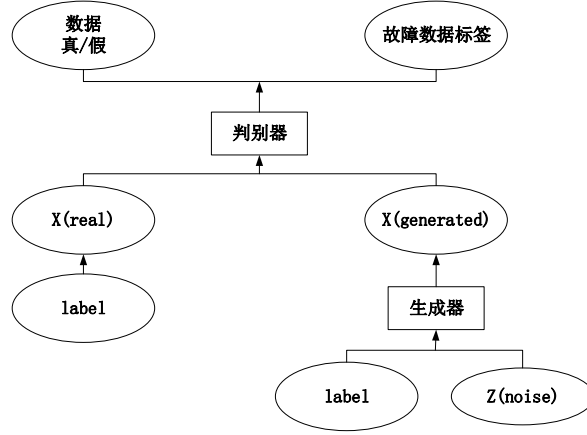


图 4.4 ACGAN 结构示意图

由辅助分类器生成对抗网络的结构示意图可知，ACGAN 同生成对抗网络最大的不同在于，判别器中加入辅助分类器使得网络扩充，高品质生成样本的前提下，实现给生成数据打上类别标签。将生成器和判别器的数学表现形式，可以概括为，将随机噪声和样本标签数据，作为生成器的输入得到含有标签的生成数据样本 $x_{generate} = G(z, label)$ 。将带标签的生成数据和带标签的真实数据，送入含有辅助分类器的判别器。判别器使用 sigmoid 输出数据真伪，softmax 函数输出故障标签。

辅助分类器生成对抗网络的损失函数分为两部分，首先是用来判断数据真伪的损失函数 L ，其次是用来表示样本数据类别的损失函数 L_C ：由公式(4.14)和(4.15)可知：

$$L = E_{x \sim P_{data}} [\log_2 D(x)] + E_{z \sim P_z} [\log_2 (1 - D(G(z)))] \quad (4.14)$$

$$L_C = E_{t \sim P_{data}} [\log_2 D(c)] + E_{t \sim P_z} [\log_2 (1 - D(G(c)))] \quad (4.15)$$

辅助分类器生成对抗网络，判别器目标函数是使损失函数 $L_C + L$ 最大化，生成器的目标函数是使损失函数 $L_C - L$ 最大化。辅助分类器生成对抗网络由于加入了代表数据类型的类别标签，使得模型在多分类问题中有着优异表现。

4.2.3 模型质量评价

生成对抗网络可以生成与真实样本分布相近的伪样本，以此来弥补数据不足的问题。这就引出如何评价生成样本的生成质量，也就是生成数据与真实样本数据的差异，显得尤为重要^[54]。生成对抗网络生成数据的评价体系，是多种多样的相关的学者提出了，这几种评价指标包括 Inception Score (IS)，用来评估生成对抗网络得到的数据样本的生成质量与生成图片的丰富性^[55]、Frechet inception distance (FID)^[56]，用来度量真实样本与生成样本之间的特征向量之间的距离，来对生成样本进行评估。Sliced Wasserstein distance (SWD)^[57]，在维斯坦距离的基础上，进行改进被定义为随即投影上的期望。因为图像独有的特性，因此生成数据的质量评价指标丰富多样，可以使用基于视觉的评价指标。由于 PEMFC 发动机传感器采集到的为，时域与频域信号的数据，使用图像生成数据的评价指标是不恰当的。结合传感器采集的数据特性，主要通过统计指标来对生成样本进行评估。使用欧氏距离(ED)用来在多维空间中衡量两个点之间的绝对距离、皮尔逊相关系数(PCC)^[58]用来衡量两个变量之间的相关程度，范围为(-1,1)。Kullback-Leibler (K-L)散度^[59]用来比较两个概率分布之间的距离。目的是使用较为简单的分布来描绘复杂的真实分布。通过上述三种评价指标，评估 ACGAN 得到的生成样本与真实样本之间的相关性，计算得到的数值用来评价得到的生成样本的生成质量。欧氏距离是通过计算两个样本之间的绝对距离来评估生成样本的质量。使用数学表达式(4.16)，可以计算出向量 x 和 y 之间的欧式距离：

$$ED(x, y) = \sqrt{(x_1 - y_1)^2 + (x_2 - y_2)^2 + \cdots + (x_n - y_n)^2} = \sqrt{\sum_{i=1}^n (x_i - y_i)^2} \quad (4.16)$$

通过计算生成样本与真实样本之间的欧氏距离，评估生成样本与真实样本拟合程度，即生成样本的生成质量。

皮尔逊相关系数，用来衡量两个变量之间的相关程度，范围为(-1,1)，数字越大代表两个变量之间的相关性越强。用来分析两个变量之间的相关性的拟合程度。皮尔逊相关系数的计算公式如(4.17)所示：

$$b = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2} \sqrt{\sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\sum x_i y_i - n\bar{x}\bar{y}}{\sqrt{(\sum x_i^2 - n\bar{x}^2)} \sqrt{(\sum y_i^2 - n\bar{y}^2)}} \quad (4.17)$$

上式中的 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$, PPC 如果等于 0 表示两个数据样本之间

不存在线性相关性。

K-L 散度用来衡量两个概率分布之间的距离，距离越小代表两者的分布越近似，KL 散度的计算公式如(4.18)所示：

$$KL(Ge || True) = \sum_{x \in X} Ge(x) \log \frac{Ge(x)}{True(x)} \quad (4.18)$$

公式中 Ge 表示生成样本的空间分布情况，True 表示真实数据样本的空间分布。

为了更好的评估本文提出模型生成数据的质量，将第三章得到的故障数据集进行划分，得到训练集和测试集。将训练集应用于所提辅助分类器生成对抗网络得到生成数据，使用生成数据作为训练集对辅助分类器生成对抗网络进行故障识别训练，利用真实数据对模型准确性进行验证。

4.3 基于辅助分类器生成对抗网络故障诊断方法研究

本节提出一种改进的辅助分类器生成对抗网络，为适应传感器数据的特性，生成器和判别器使用一维卷积神经网络(1D-CNN)。对 PEMFC 发动机传感器和空气压缩机故障数据进行扩充和故障诊断。PEMFC 发动机传感器和空气压缩机通常处于正常运行状态，故障数据难以获取。在多分类问题中影响分类效果的往往是数据量最少样本，因此小样本数据扩充问题亟待解决，本节提出 1D-CNN_ACGAN 扩充 PEMFC 传感器和空气压缩机故障数据集，降低数据挖掘难度的同时提高传感器和空气压缩机的故障分类准确度。

4.3.1 模型结构

提出的模型由两部分组成，第一部分辅助分类器生成对抗网络扩充故障样本，第二部分对生成数据质量进行评价。模型的结构如图 4.5 所示。

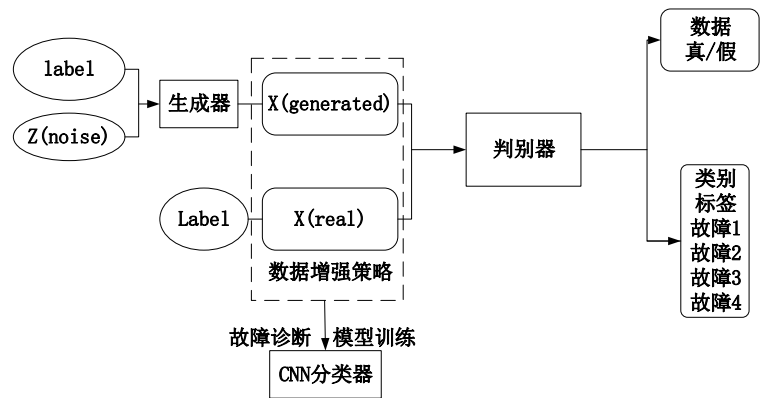


图 4.5 基于辅助分类器生成对抗网络的故障诊断模型结构

由图 4.5 可知，生成器将故障标签和随机噪声作为输入从随机噪声中，学习样本的潜在特征。并且在同判别器的相互对抗中，提高生成数据的质量。判别器则使用带有标签的真实样本数据，生成器生成的带有样本标签的生成数据进行训练。通过标签的约束，逐渐学习到数据的故障特征。判别器将输出两种数据标签，一个是代表数据真伪的数据标签，另一个是代表数据类型的类型标签。

为了验证生成数据的质量，即是否生成了合格的数据，可以用于数据集扩充。在模型中获得生成数据后，首先要对生成数据的有效性进行验证。利用由上节提出的方法，将模型得到的生成数据对故障诊断模型进行训练。使用真实数据对故障诊断模型进行验证，得出分类精度。计算生成的数据与真实数据之间的距离，用来评估生成质量。本文提出的辅助分类器生成对抗网络，是由一维卷积神经网络实现的。使用多个卷积神经网络对真实数据样本的空间特征进行学习，提取样本特征信息。在生成对抗网络中引入类别标签，使得训练在类别约束下进行可以帮助模型更加快速的收敛。有效降低训练的难度，防止模型训练过程中崩溃。

生成器的输入为随机噪声和表示数据样本的类型标签相乘。使用两层全连接层，对生成器输入的数据采取一次上采样的工作，上采样的参数设置为 1。一维卷积神经网络操作后紧跟着一个一阶动量 0.5 的批量归一化操作，得到一个小的卷积模块。使用修正线性单元进行特征提取，可以得到一个特征图像。对第二个卷积单元的卷积核大小设置为 1，激活函数的选取使用双曲正切函数进行特征提取。由以上设置得出的生成器输出样本为一维数据。

生成器网络参数设置如表 4.1 所示。

表 4.1 1D-CNN_ACGAN 生成器网络参数设置

网络层类型	数量/卷积核大小/步长
全连接层	512
全连接层	1024
上采样	-/2/1
一维卷积层	128/5/1
ReLU 激活函数	0.2
批量归一化	0.5
一维卷积层	128/5/1
ReLU 激活函数	0.2
批量归一化	0.8
ReLU 激活函数	0.2
一维卷积层	1/1/1
Tanh 激活函数	0.2

生成器使用随机噪声 z 生成样本数据，对于区间在 $(-1,1)$ 上的空间分布 $R(-1,1)$ ，进行特征提取，可以得到具有真实样本空间的向量 z 。生成器输出数据的集合，可以得到生成样本集合 $x_{generated}$ 。将生成器得到的生成样本与真实样本一起作为判别器的输入。判别器的参数设置为，真实数据样本输入判别器，后面跟着一维卷积层，卷积核大小为 4。激活函数使用 LeakyRelu 进行特征提取。一维卷积操作以后再跟着一个一维卷积操作，卷积核大小设置为 8。激活函数仍然为 LeakyRelu 进行特征提取。为了降低训练的复杂度，采用 droupout 策略，随机舍弃一部分训练样本，大小设置为 0.7。经过两层卷积网络后，将数据样本平铺，并设置一个全连接网络与平铺后的特征数据相连接。仍然采用 droupout 方法，设定为 0.7。最后将带有两个数据标签的生成样本数据进行输出，将得到的数据，使用 sigmoid 函数对数据真伪进行判别。采用 softmax 函数对数据的故障类别进行多分类输出。

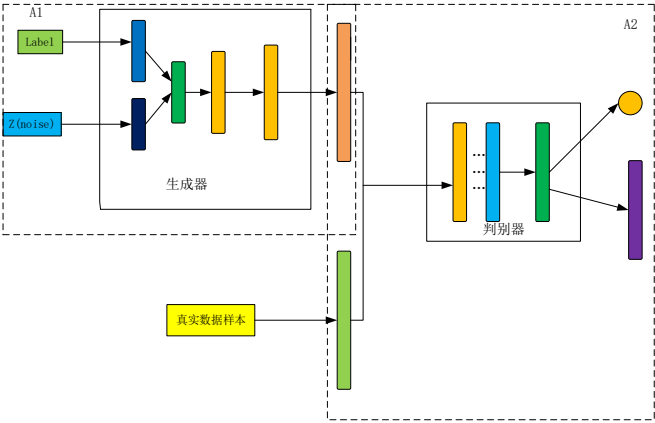
判别器网络参数设置如表 4.2 所示。

表 4.2 1D-CNN_ACGAN 判别器网络参数设置

网络层类型	数量/卷积核大小
一维卷积层	64/4
LeakyReLu 激活函数	0.4
最大池化层	3/3
一维卷积层	64/8
LeakyReLu 激活函数	0.4
最大池化层	3/3
平铺	-
随机失活	0.7
激活函数	1(Sigmoid)/1(Softmax)

4.3.2 模型训练

辅助分类器生成对抗网络损失函数的确定，是随着模型不断地迭代训练。通过误差反向传播和随机梯度下降法不断更新的。本节使用 Adam 优化算法训练模型，Adam 优化算法的伪代码实现已由算法 4.1 给出，首先要确定算法的学习率。由于带有标签的生成器训练，相比于判别器有一定优势，且判别器的不仅要分辨数据真伪，还要对数据类别进行分辨。因此判别器的学习率设置为 0.001，生成器的学习率设置为 0.003。一个完整的迭代周期的步骤由图 4.6 给出。



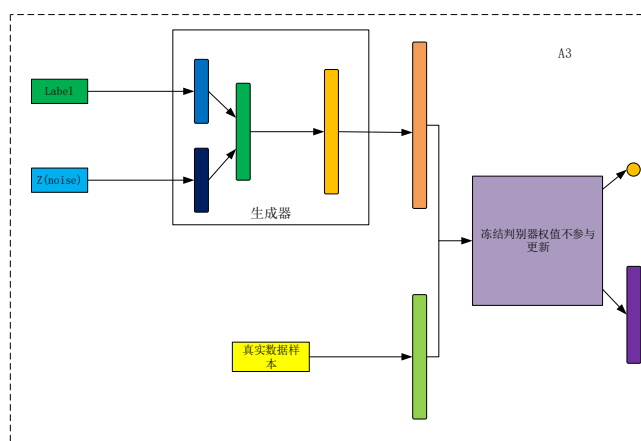


图 4.6 辅助分类器生成对抗网络训练步骤

A1：在随机噪声中加入类别标签，生成器可以得到带有类别标签的生成数据；

A2：将 A1 在生成器中得到的，带有标签数据的假样本和真实数据样本进行混合，共同送入判别器中。通过类别标签值和损失函数，对判别器进行单独训练，加速判别器的数据收敛。使得判别器可以判断出，生成器的生成样本数据，对判别器中的超参数进行不断更新。

A3：通过 A2 的训练，判别器性能将会得到明显提升，然后将生成器和判别器合为一个整体，对整个网络模型进行训练。在这个过程中，将判别器的超参数进行锁死，使得判别器不参与训练过程，使其承担分类器作用，只训练生成器。提升生成器生成假样本数据的性能，得到更加接近于真实数据样本分布的生成样本数据，这就完成了一次整体的网络训练。然后不断循环这个过程，直到模型收敛。

生成器和判别器的目标函数是相互矛盾的过程，是一种相互博弈的结果。模型训练稳定的标志为，整个模型达到纳什均衡，说明模型训练达到收敛。生成器得到的生成样本的空间分布与真实样本非常接近。由文献^[18]可知，给出任意一个生成器 G，最佳的判别器 D 的值为如式(4.19)所示：

$$D_G^*(x) = \frac{P_{data}(x)}{P_{data}(x) + P_g(x)} \quad (4.19)$$

生成对抗网络总的目标函数如式(4.20)：

$$\begin{aligned}
 Goal &= \max Los(G, D) \\
 &= E_{x \sim p_{data}} [\log(D_G^*(x))] + E_{z \sim p(z)} [\log(1 - D_G^*(G(z)))] \\
 &= E_{x \sim p_{data}} [\log(D_G^*(x))] + E_{x \sim p_g} [\log(1 - D_G^*(x))] \\
 &= E_{x \sim p_{data}} [\log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}] + E_{x \sim p_g} [\log \frac{p_{data}(x)}{p_{data}(x) + p_g(x)}]
 \end{aligned}
 \tag{4.20}$$

由公式(4.19)可知达到纳什均衡标志为 $p_{data}(x) = p_g(x)$ 。

4.3.3 模型验证

为了验证提出的，基于生成对抗网络的 PEMFC 发动机传感器和空气压缩机故障诊断方法的有效性，使用第三章得到的故障数据。使用统计指标对数据生成质量进行评估。

将 3 种传感器故障、一种空气压缩机供气不足故障、一种健康状态共五种状态，每种工况随机选取 400 个数据作为故障数据集，一共采集得到 2000 个故障样本。把数据集分为训练集和测试集划分比例为 3:1，每种故障类型有 300 个样本用于训练辅助分类器生成对抗网络。在训练过程中，得到模型训练生成的假数据样本。剩余的 100 个样本，用于辅助分类器生成对抗网络的测试。对各种状态使用独热码进行编码详细设置如表 4.3。

表 4.3 故障设置及编码

故障编号	故障类型	故障特征	样本数与比例	独热码编码
故障 0	正常	正常	400(3:1)	[1,0,0,0,0]
故障 1	空气压缩机	供气不足(降低 10%)	400(3:1)	[0,1,0,0,0]
故障 2	净功率传感器	传感器漂移	400(3:1)	[0,0,1,0,0],
故障 3	过氧比传感器	传感器短路	400(3:1)	[0,0,0,1,0]
故障 4	电压传感器	传感器固定偏差	400(3:1)	[0,0,0,0,1]

在进行训练前首先将数据预处理将 2000 组数据采用式(4.21)归一化到(0,1)。

$$y = \frac{x - x_{\min}}{x_{\max} - x_{\min}}
 \tag{4.21}$$

其中 x_{\min} 、 x_{\max} 分别为 2000 组数据特征数据的最小值和最大值。

在模型测试过程中，不使用生成数据，测试完成后对生成数据进行评估。

为了防止模型训练出现过拟合的情况，即生成的数据出现过拟合，对于其他数据的拟合效果过差。在一次训练之后，紧接着进行一次测试，使用未参与模型训练的，真实样本数据进行验证。如果验证结果差距较大，代表模型存在过学习情况，需要对模型超参数进行修改。本节提出的辅助分类器生成对抗网络，用来解决 PEMFC 发动机传感器和空气压缩机故障样本数量不足导致的训练效果差的问题。使用 ACGAN 扩充故障数据样本，提升故障诊断能力。对 PEMFC 发动机，3 种传感器故障和一种空气压缩机故障进行数据增强。用来扩充每种故障的数据样本，并验证模型可用性。ACGAN 生成器从随机噪声样本空间中生成符合真实数据样本的空间特征提取特征信息，进行数据增强，根据训练经验将训练轮次设置为 100。经过 100 轮的训练后，每种故障样本可扩充到 1000 个故障样本。

深度学习算法是在 Pycharm2021 版开发环境中用 Python3.7 编写。

深度学习算法在 AMD Ryzen7 4800H 处理器上执行，该处理器是 AMD 公司生产的 CPU。计算机内存为 16gb，操作系统为 Windows10×64。

混淆矩阵是用来评价分类准确性的一个重要工具，可以用来确定故障的分类效果，使用混淆矩阵对诊断结果进行进一步分析。

利用故障分类的准确率，对模型进行性能评估。TP 表示样本为正样本，模型预测为正样本；TN 表示样本为负样本，模型预测为负样本；FP 表示样本为负样本，模型预测为正样本；FN 表示样本为正样本，实际为负样本。混淆矩阵示意图如图 4.7 所示：

预 测 实 际	True	False
Positive	TP	FP
Negative	FN	TN


4.7 混淆矩阵示意图

模型准确度(Precision),表示预测正确的正样本数在所有预测为正样本中的比例。

$$Precision = \frac{TP}{TP + FP}$$

(4.22)

模型的分类准确率表现如图 4.8 所示。



4.8 混淆矩阵故障分类准确率

由混淆矩阵可知，本文建立的网络模型可以实现对空气压缩机故障和三种传感器故障准确的准确分类。建立模型对于空气压缩机故障的识别准确率为 91%，净功率传感器漂移故障识别准确率为 93%，电压传感器偏置故障识别准确率为 91%，过氧比传感器短路故障识别准确率为 94%，通过结果表明，所提模型可以对空气压缩机故障和传感器故障准确识别，识别准确率高。


4.3.4 方法比较

为了证明本文提出的模型的有效性，使用另外几种不同的生成对抗网络构型进行对比，生成式模型的关键在于生成器生成样本的质量，因此为了控制变量，突出对比效果，本节判别器结构一致改变生成器的结构。


- (1)选取只有输入层、输出层，隐含层使用三层全连接，选取反向传播算法进行误差训练;
- (2)为了与本节所提构型形成对比，凸显批量归一化的作用，构造一个一维卷积神经网络，在网络层后面不进行批量归一化;
- (3)证明一维卷积神经网络的作用，剔除批量归一化的影响设置对照组，在

方法一提出的网络构型中加入批量归一化操作；

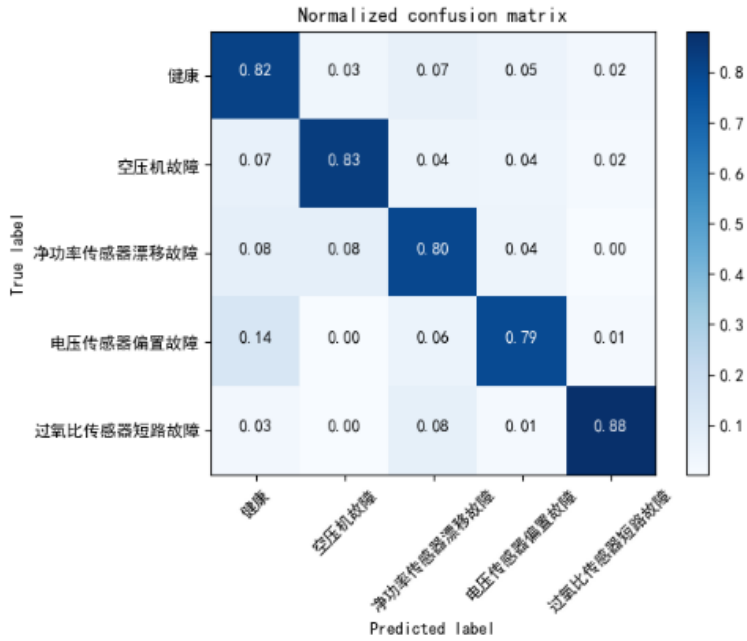
(4)使用本节提出的模型构型，与上面三种方法形成对比试验。不同生成器模型的分类结果如图 4.9 所示。




(a) NN



(b) 1D-CNN



(c) NN-BN



(d) 1D-CNN_BN

图 4.9 故障分类结果对比

使用不同模型得到的分类准确率结果，可以表现模型对于多故障诊断的表现，如图 4.9 可知，本节提出模型的故障诊断分类准确率是最高的，对于各种故障的识别准确率均达到了 90%以上；三层全连接的网络不能对故障进行准确识

别，识别准确率仅为 50%左右，网络不能收敛。采用一维卷积神经网络可以实现对于故障的识别，识别准确率为 70%，故障识别效果不理想。采用用批量归一化的三层全连接网络，可以对故障进行识别，但是识别准确率仅为 80%左右，故障分类效果不够理想。综上所述，本节所提基于一维卷积神经网络的辅助分类器生成对抗网络，和其他构型网络相比具有更高的故障识别准确率。

为了评估辅助分类器生成对抗网络，得到的生成数据的质量。利用上一节提出的评价指标进行评估，计算相对应的统计特征指标。由上述介绍可知，欧氏距离表示两个样本量之间的绝对距离，数值越小，表明生成数据与真实数据之间越相近，生成数据质量越高。KL 散度表示两个数据分布之间的差异，数值越小，两个分布差异越小，得到的生成数据质量越好。皮尔逊相关系数，表示两个数据样本之间的相关性，取值范围为(-1,1)，值小于零代表负相关，值大于零代表正相关。当值大与 0.8 时代表两个数据之间强相关。由表 4.4 可知本节提出的网络构型，在三种评价指标中都取得了优良成绩。表明生成数据符合真实数据的空间分布。

表 4.4 不同生成器生成对抗网络生成数据质量

模型	ED	PCC	K-LD
NN	0.35	0.57	0.35
NN_BN	0.16	0.86	0.21
1D-CNN	0.13	0.83	0.16
1D-CNN_BN	0.06	0.82	0.14

为了找出生成样本与真实样本的最佳组合比例，选用不同比例的生成样本与真实样本得到相关的分类准确率和损失函数结果如表 4.5 所示：

表 4.5 真实样本数据和生成数据数量以及故障诊断准确率

	A	B	C	D	E	F	G	H	I	J	K	L
真实样本	100	0	0	0	0	0	0	100	200	200	200	200
生成本数	0	200	200	400	600	800	1000	100	200	400	800	1000
故障诊断 准确率(%)	81.7	84.8	82.3	81.1	83.2	84.3	84.1	85.7	84.2	87.2	88.2	89.1

由表 4.5 可知，故障分类准确率与参与训练的样本数量成正比。同时由于生成样本，可以使得数据分布空间更加丰富，因此，使用生成数据与真实数据相组合时，可以得到更好的分类性能，经过充分的训练，可以使故障诊断模型得到大幅的提升。一个好的生成对抗网络构型，在经过充分训练后可以得到与真实样本空间特征类似的生成样本数据，用来解决传感器和空气压缩机故障数据不足的问题。为了验证使用不同数量数据生成样本对分类准确率的影响。分别选取不同比例的数量生成样本与真实样本进行组合对模型进行验证。故障诊断识别准确率结果如表 4.6 所示：

表 4.6 不同比例真实样本数据集故障分类准确率

生成数据的样本数量	真实数据样本的使用比例		
	25%	50%	100%
0	80.8%	81.3%	83.7%
50	81.6%	82.6%	84.6%
100	83.9%	84.4%	85.8%
200	84.3%	85.5%	86.9%
300	83.8%	84.5%	97.4%

通过表 4.6 可知，当数据量足够大时，使用数据增强策略对于故障诊断没有大幅提升，不能体现生成对抗网络的优越性。当真实样本数据量为 25%时随着生成数据样本量的增多，故障诊断分类准确率，随着生成样本数量的增多不断提升，表明了辅助分类器生成对抗在类不平衡数据中的重要作用。为了更直观的证明，基于一维卷积神经网络的辅助分类器生成对抗网络，在数据增强中的重要作用。剔除 50%的净功率传感器漂移故障，电压传感器偏置故障数据使用辅助分类器生成对抗网络进行数据增强。将剔除后的数据集与生成数据一起作为训练集，输入一个含有三层隐藏层的，深度卷积神经网络对模型进行训练，得到相应的故障分类准确率。将第三章得到的故障数据随机选取 200 个净功率传感器漂移故障数据集，200 个电压偏置故障数据集，剔除 50%后剩余 100 个故障数据。使用本章提出的，基于一维卷积网络的辅助分类器生成对抗网络进行数据增强，数据量组成为 100 个真实数据，100 个生成数据。将得到的 200 个数据输入三层卷积神经网络进行训练，使用验证集对模型进行验证，实验结果如

表 4.7 所示。

表 4.7 数据不足情况下的故障诊断准确率

不平衡种类	类不平衡数据	数据增强策略
净功率传感器漂移故障	80.7%	86.8%
电压传感器偏置故障	65.4%	89.7%

通过表 4.7 可知过少的数据量使用深度卷积神经网络并不能对于故障诊断得到好的诊断结果，在经过本章提出的基于辅助分类器生成对抗网络数据增强后，可以有效补充故障数据，同时故障诊断准确率也表明了本文提出的 ACGAN 方法的有效性，可以解决 PEMFC 发动机传感器和空气压缩机数据量不足造成的故障分类效果差的问题。为了使分类效果更直观展示，使用 TSNE 对特征进行处理，得到本文提出的，一维卷积神经网络的辅助分类器生成对抗网络，得到的故障诊断模型的特征提取图。TSNE^[60]是一种降维算法对于故障特征提取效果优异，数据集故障特征如图 4.10 所示。




图 4.10 故障特征分类

如图 4.10 可知，将采集得到的故障数据使用 TSNE 算法进行故障特征提取后故障特征得到了有效分类，其中空气压缩机故障与净功率传感器漂移故障由于故障特征不明显使得部分故障特征偏离，但是对于总体故障特征影响较小。

4.4 试验验证

为了验证本章提出的，辅助分类器生成对抗网络模型对于实验数据故障分类的有效性，使用氢燃料电池采集的真实数据，对模型进行验证。试验台架电

堆为氢普新能源科技有限公司生产 ST70FA，电堆由 244 片燃料电池单体组成，如图 4.11 所示。台架运行 1 小时，采集到 2938 个健康电压数据集。由于缺少传感器故障数据，使用第三章中相似的方法，在健康数据中加入偏置得到电压传感器偏置故障数据集。




图 4.11 电堆

在 938 个数据后加入偏置故障得的偏置电压如图 4.12 所示：



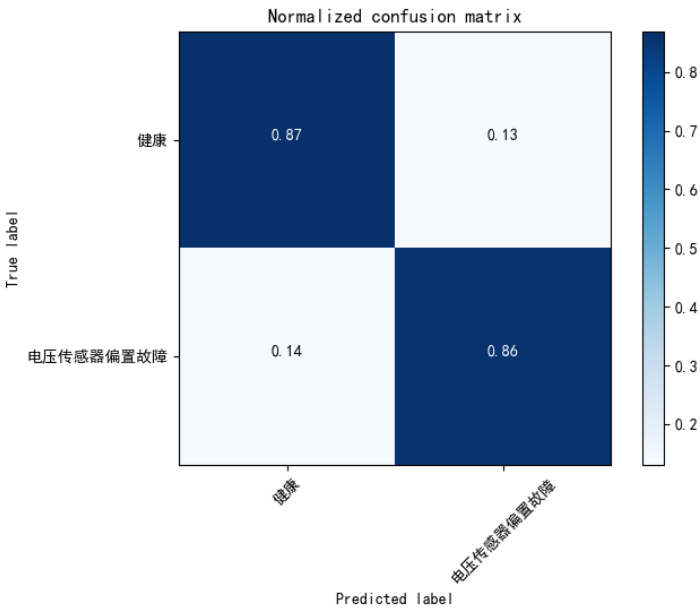


图 4.12 实验电压数据集


首先将得到的故障数据使用公式(4.21)进行归一化预处理，进行 100 轮训练。得到故障分类准确率如图 4.13(a)所示。为了验证 ACGAN 诊断准确性，将实验得到的电压数据集使用 CGAN，DCGAN 与本文所提模型进行对比，分别如图 4.13(b)和(c)所示。



(a) 1D-CNN_ACGAN



(b) CGAN



(c) DCGAN

图 4.13 不同方法分类准确率

由图 4.13 可知，CGAN 对于电压传感器偏置故障识别准确率为 86%，DCGAN 对于电压传感器偏置故障识别准确率为 89%，本章所提基于一维卷积神经网络辅助分类器生成对抗网络，对于电压传感器偏置故障的识别准确率为 93%。同其他两种方法相比，本文所提模型对于故障识别准确率是最高的，验证了模型的有效性。

4.5 小结

本章基于一维卷积神经网络，提出一种基于一维卷积神经网络的辅助分类器生成对抗网络。由于 PEMFC 发动机传感器和空气压缩机故障数据难以获取，使用第三章获得的典型故障数据集，对模型进行验证。为了对模型得到的生成数据进行质量评估，提出两种质量评价体系，一种是借助于欧氏距离、KL 散度、皮尔逊相关系数进行评价；另一种是使用生成样本数据对模型进行验证。验证结果表明生成样本数据质量优异，可以很好的拟合真实样本数据。为了验证所提模型的准确性使用健康电压数据集，设置偏置故障，对故障进行分类。同时为了验证模型的准确性，使用 CGAN、DCGAN 与所提模型进行对比，结果表明本文所提模型可以很好的实现传感器故障样本数据的扩充与识别。

5 总结与展望

5.1 总结

PEMFC 发动机传感器和执行器故障诊断实质是对传感器和执行器状态进行识别,及时快速识别出传感器和执行器故障,对于保证 PEMFC 发动机的平稳高效运行具有重要意义。本文针对实际 PEMFC 发动机传感器和执行器故障数据集难以获取导致故障诊断数据集的不平衡的问题,提出一种基于一维卷积神经网络的辅助分类器生成对抗网络,基于少量故障样本,实现对于传感器和空气压缩机的故障诊断。

本文的主要研究工作及成果如下:

(1)分析了 PEMFC 发动机传感器和执行器故障特征。针对传感器和空气供给系统典型故障建立相应的故障数学模型。

(2)基于密歇根州立大学 PEMFC 公开模型研究发动机传感器和执行器的故障特征。在模型中设置空气压缩机卡涩、净功率传感器漂移、电压传感器偏置和过氧比传感器短路故障,提取相应的故障特征。

(3)针对实际故障数据集难以获取的问题,基于模型仿真生成故障数据集,加入高斯白噪声模拟实际故障,提出一种基于一维卷积神经网络的辅助分类器生成对抗网络,用于不平衡类的数据增强,使用欧氏距离、PCC、KL 散度对生成的故障数据进行评价,实现故障数据集的扩充和故障诊断。利用实测健康电压数据集,添加偏置故障模拟电压传感器偏置故障,对所提生成对抗网络模型进行验证,并与 CGAN 和 DCGAN 进行对比分析,验证模型的准确性。

5.2 展望

实际燃料电池发动机传感器和执行器众多,受设备条件和时间的限制,本文的研究工作主要是针对于 PEMFC 发动机的空气压缩机,电压传感器、净功率传感器、过氧比传感器的故障进行分析。

(1)本文的研究工作主要是针对于 PEMFC 发动机的空气压缩机,电压传感器、净功率传感器、过氧比传感器的故障进行分析。未来研究中可以考虑增加

更多的传感器，例如温度传感器、压力传感器、湿度传感器等不同类型的传感器，拓宽 PEMFC 发动机故障诊断的范围。

(2)使用不同的深度学习模型对故障特征进行特征提取，使用迁移学习，得到 PEMFC 的故障特征，提升诊断方法的泛化能力。

参考文献

- [1] ALASWAD A, BAROUTAJI A, ACHOUR H, et al. Developments in fuel cell technologies in the transport sector [J]. International journal of hydrogen energy, 2016, 41(37): 16499-508.
- [2] LUTZ A E, LARSON R S, KELLER J O. Thermodynamic comparison of fuel cells to the Carnot cycle [J]. International journal of hydrogen energy, 2002, 27(10): 1103-11.
- [3] 李艳昆. 质子交换膜燃料电池电堆电压均衡性及其控制策略研究 [D]; 西南交通大学, 2015.
- [4] 张建灿, 陶国良, 周文祎. 燃料电池用空气压缩机性能测试系统研究 [J]. 液压气动与密封, 2005, (1): 33-5.
- [5] TAHAN M, TSOUTSANIS E, MUHAMMAD M, et al. Performance-based health monitoring, diagnostics and prognostics for condition-based maintenance of gas turbines: A review [J]. Applied Energy, 2017, 198: 122-44.
- [6] 杨忠君, 刘精一, 宗学军. 质子交换膜燃料电池故障检测研究 [J]. 可再生能源, 2015, 33(1): 128-33.
- [7] 张菊秀, 全书海, 王超. 信息融合在燃料电池传感器故障识别中的应用 [J]. 武汉理工大学学报, 2006, 28(6): 113-6.
- [8] PENTA D D, ZHANG K B M S Q. A Reduced Fuel Cell Stack Model for Control and Fault Diagnosis [J]. Journal of Fuel Cell Science and Technology, 2006, 3(4): p.384-8.
- [9] FOWLER M W, MANN R F, AMPHLETT J C, et al. Incorporation of voltage degradation into a generalised steady state electrochemical model for a PEM fuel cell [J]. Journal of Power Sources, 2002, 106(1-2): 274-83.
- [10] ZHENG Z, PETRONE R, PERA M C, et al. A review on non-model based diagnosis methodologies for PEM fuel cell stacks and systems [J]. International journal of hydrogen energy, 2013, 38(21): 8914-26.
- [11] MAO L, JACKSON L, HUANG W, et al. Polymer electrolyte membrane fuel cell fault diagnosis and sensor abnormality identification using sensor selection method [J]. Journal of Power Sources, 2020, 447: 227394-.
- [12] LIRA S D, PUIG V, QUEVEDO J. Robust LPV model-based sensor fault diagnosis and estimation for a PEM fuel cell system; proceedings of the Control & Fault-tolerant Systems, F, 2010 [C].
- [13] 杨建, 朱新坚. 高精度 PEMFC 单体电压检测器的开发 [J]. 电池, 2006, 36(5): 393-5.
- [14] 赵洪波, 刘杰, 马彪, et al. 水冷 PEMFC 热管理系统控制策略及仿真研究 [J]. 化工学报, 2020, 71(5): 2139-50.

- [15] 刘志祥, 李伦, 韩喆等. 大功率 PEMFC 空气系统电流跟随分段 PID 控制方法研究 [J]. 西南交通大学学报, 2016, 51(3): 437-45.
- [16] 胡美, 马磊, 陈志远. 燃料电池空气供应系统动态建模与仿真 [J]. 电源技术, 2013, 37(10): 1767-9.
- [17] KAMAL M M, YU D W, YU D L. Fault detection and isolation for PEM fuel cell stack with independent RBF model [J]. Engineering Applications of Artificial Intelligence: The International Journal of Intelligent Real-Time Automation, 2014, 28: 52-63.
- [18] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative Adversarial Nets; proceedings of the Neural Information Processing Systems, F, 2014 [C].
- [19] 李洪军, 汪大春, 杨哲昊等 基于 DCGAN 的燃料电池故障诊断 [J]. 电池, 2022, 52(5): 502-6.
- [20] LI Z, OUTBIB R, GIURGEA S, et al. Fault diagnosis for PEMFC systems in consideration of dynamic behaviors and spatial inhomogeneity [J]. IEEE Transactions on Energy Conversion, 2018: 1-10.
- [21] ZUO B, ZHANG Z, CHENG J, et al. Data-driven flooding fault diagnosis method for proton-exchange membrane fuel cells using deep learning technologies [J]. 2022, 251(Jan.): 115004.1-9.
- [22] 郭俊锋, 王淼生, 孙磊, et al. 基于生成对抗网络的滚动轴承不平衡数据集故障诊断新方法 [J]. 计算机集成制造系统, 2022, 28(9): 2825-35.
- [23] 杨光友, 刘浪, 习晨博. 自适应辅助分类器生成式对抗网络样本生成模型及轴承故障诊断 [J]. 中国机械工程, 2022, 33(13): 1613-21.
- [24] 卢锦玲, 张祥国, 张伟, et al. 基于改进辅助分类生成对抗网络的风机主轴承故障诊断 [J]. 电力系统自动化, 2021, 45(7): 148-54.
- [25] 李忠智, 尹航, 左剑凯, et al. 不平衡训练数据下的基于生成对抗网络的轴承故障诊断 [J]. 小型微型计算机系统, 2021, 42(1): 46-51.
- [26] WENBO, LIU, ZHIPING, et al. A Review of Industrial Fault Diagnosis Based on Data-driven Methods, F, 2018 [C].
- [27] TE A, DD C, SA C, et al. Model-based fault diagnosis and prognosis of dynamic systems: a review - ScienceDirect [J]. Procedia Manufacturing, 2019, 30: 435-42.
- [28] ESCOBET T, FEROLDI D, LIRA S D, et al. Model-based fault diagnosis in PEM fuel cell systems [J]. Journal of Power Sources, 2009, 192(1): 216-23.
- [29] PETRONE R, ZHENG Z, HISSEL D, et al. A review on model-based diagnosis methodologies for PEMFCs [J]. International journal of hydrogen energy, 2013, 38(17): 7077-91.
- [30] FRAPPÉ E, DE BERNARDINIS A, BETHOUX O, et al. PEM fuel cell fault detection and

- identification using differential method: Simulation and experimental validation [J]. The European physical journal Applied physics, 2011, 54(2): 23412-1--11.
- [31] SCHOLKOPF B, SMOLA A. Kernel Principal Component Analysis; proceedings of the International Conference on Artificial Neural Networks, F, 1997 [C].
- [32] SUN Z, CHANG C C. Structural Damage Assessment Based on Wavelet Packet Transform [J]. Journal of Structural Engineering, 2002, 128(10): 1354-61.
- [33] LATHAUWER L D, DE B. A Multi-Linear Singular Value Decomposition [J]. SIAM Journal on Matrix Analysis and Applications, 2000, 21(4): 1253-78.
- [34] PAHON E, STEINER N Y, JEMEI S, et al. A signal-based method for fast PEMFC diagnosis [J]. Applied Energy, 2016, 165(Mar.1): 748-58.
- [35] Z., ZHENG, AND, et al. A review on non-model based diagnosis methodologies for \{PEM\} fuel cell stacks and systems [J]. International Journal of Hydrogen Energy, 2013.
- [36] PETRONE R, PAHON E, HAREL F, et al. Data-driven multi-fault approach for H₂/O₂ PEM FuelCell diagnosis; proceedings of the IEEE Vehicle Power & Propulsion Conference, F, 2017 [C].
- [37] RIASCOS L A M, COZMAN F G, MIYAGI P E, et al. Bayesian Network Supervision on Fault Tolerant Fuel Cells; proceedings of the IEEE, F, 2006 [C].
- [38] STEINER N Y, CANDUSSO D, HISSEL D, et al. Model-based diagnosis for proton exchange membrane fuel cells [J]. Mathematics & Computers in Simulation, 2010, 81(2): 158-70.
- [39] J.T. P, A.G. S, PENG H. Control of fuel cell breathing [J]. IEEE Control Systems Magazine, 2004, 24(2): 30-46.
- [40] KULLAA J. Detection, identification, and quantification of sensor fault in a sensor network [J]. Mechanical Systems & Signal Processing, 2013, 40(1): 208-21.
- [41] MORAAL P, KOLMANOVSKY I. Turbocharger Modeling for Automotive Control Applications [J]. 1999, 1.
- [42] CUNNINGHAM J M, MAN M, MOORE R M, et al. Requirements for a Flexible and Realistic Air Supply Model for Incorporation into a Fuel Cell Vehicle (FCV) System Simulation [J]. Simulation & Modeling, 1999.
- [43] Handwritten digit recognition: applications of neural network chips and automatic learning [J]. Communications Magazine, IEEE, 1989.
- [44] CHERRY J M, ADLER C, BALL C A, et al. SGD: Saccharomyces Genome Database [J]. Nucleic Acids Research, 1998, 26(1): 73-9.
- [45] OGREN P, FIORELLI E, LEONARD N E. Cooperative control of mobile sensor networks: Adaptive gradient climbing in a distributed environment [J]. IEEE Transactions on

- Automatic Control, 2004, 49(8): 1292-302.
- [46] KINGMA D, BA J. Adam: A Method for Stochastic Optimization [J]. Computer Science, 2014.
- [47] SUTSKEVER I, MARTENS J, HINTON G E. Generating Text with Recurrent Neural Networks; proceedings of the International Conference on Machine Learning, F, 2016 [C].
- [48] ARJOVSKY M, CHINTALA S, BOTTOU L. Wasserstein GAN [J]. 2017.
- [49] ODENA A. Semi-Supervised Learning with Generative Adversarial Networks [Z]. arXiv. 2016
- [50] DONAHUE C, MCAULEY J, PUCKETTE M. Synthesizing Audio with Generative Adversarial Networks [J]. 2018.
- [51] HARTMANN K G, SCHIRRMESTER R T, BALL T. EEG-GAN: Generative adversarial networks for electroencephalographic (EEG) brain signals [J]. 2018.
- [52] MIRZA M, OSINDERO S. Conditional Generative Adversarial Nets [J]. Computer Science, 2014: 2672-80.
- [53] ODENA A, OLAH C, SHLENS J. Conditional Image Synthesis With Auxiliary Classifier GANs [J]. 2016.
- [54] SPRINGENBERG J T. Unsupervised and Semi-supervised Learning with Categorical Generative Adversarial Networks; proceedings of the International Conference on Learning Representations, F, 2015 [C].
- [55] SALIMANS T, GOODFELLOW I, ZAREMBA W, et al. Improved Techniques for Training GANs [J]. 2016.
- [56] HEUSEL M, RAMSAUER H, UNTERTHINER T, et al. GANs Trained by a Two Time-Scale Update Rule Converge to a Nash Equilibrium [J]. 2017.
- [57] LUXBURG U V. Foundations and Trends® in Machine Learning [J]. Now Publishers, 2009.
- [58] ADLER J, PARMRYD I. Quantifying colocalization by correlation: The Pearson correlation coefficient is superior to the Mander's overlap coefficient [J]. Cytometry Part A, 2010, 77a(8): 733-42.
- [59] HERSHEY J R, OLSEN P A. Approximating the Kullback Leibler Divergence Between Gaussian Mixture Models; proceedings of the IEEE International Conference on Acoustics, F, 2007 [C].
- [60] TENENBAUM J B, SILVA V D, LANGFORD J C. A Global Geometric Framework for Nonlinear Dimensionality Reduction [J]. Science, 290.