

# PEM 燃料电池的数据驱动故障诊断

## 使用传感器预选方法和神经网络模型

Yanqiu Xing,  学生会员,IEEE,王博文,会员,IEEE,龚志超,  
Zhongjun Hou, Fuqiang Xi, Guodong Mou, Qing Du

 , IEEE 会员,高飞  
 , 会员, IEEE

 IEEE 学生会员,  
 , IEEE 高级会员、焦奎

**摘要 :**故障诊断是质子交换膜燃料电池 (PEMFC)可靠性和耐用性的关键过程。由于质子交换膜燃料电池内部传输过程的复杂性,开发考虑各种故障机制的精确模型极其困难。本文提出了一种基于传感器预选和神经网络 (ANN)的新型数据驱动方法。首先提取传感器数据的时域和频域特征进行灵敏度分析。对系统状态变化响应较差的传感器被过滤掉。然后利用剩余传感器监测的实验数据,利用ANN模型建立故障诊断模型。神经网络训练中分别采用Levenberg-Marquardt (LM)算法、弹性传播 (RP)算法和缩放共轭梯度 (SCG)算法。诊断结果表明,该方法的诊断准确率达到99.2%,召回率达到98.3%。通过将本文的诊断结果与支持向量机 (SVM)和逻辑回归 (LR)的诊断结果进行比较,验证了所提方法的有效性。

能源、氢和燃料电池技术,特别是质子交换膜燃料电池 (PEMFC),由于其高功率密度、低工作温度和快速响应而引起了广泛的关注。PEMFC可应用于许多领域,例如固定电站和汽车工业[1]。然而,可靠性和耐用性仍然是其商业化的两个主要障碍[2]。因此,质子交换膜燃料电池的故障诊断越来越受到人们的重视。

作为一个非线性、动态和时变的系统,燃料电池系统涉及燃料电池堆和多个辅助子系统,包括反应气体供应子系统、水和热管理子系统[3]。准确地检测和识别系统中发生的故障并不是一项简单的任务。在此基础上,针对质子交换膜燃料电池的故障诊断开展了一系列的研究。在文献中,诊断方法主要分为两类,即基于模型的方法和数据驱动的方法[4]。

此外,该方法的高计算效率支持了在线诊断的可能性。同时,早期检测故障可以为质子交换膜燃料电池系统的容错控制提供有效指导。

在基于模型的方法中,可以分析实验测量值和数值模型输出之间的残差以进行故障识别[5]。因此,诊断结果的可靠性主要取决于数值模型的准确性。

**索引术语** 神经网络、数据驱动方法、故障诊断、质子交换膜燃料电池系统、氢气。

### 一、简介

替代能源已受到广泛关注和关注。在这些替代方案中

手稿于 2021 年 5 月 6 日收到; 2021年8月30日和2021年10月25日修订; 2022 年 1 月 5 日接受。出版日期 2022 年 1 月 14 日;当前版本的日期为 2022 年 8 月 22 日。这项工作部分得到了中国国家自然科学基金委员会 51976138 的支持,部分得到了天津市自然科学基金杰出青年基金 18JCJC46700 的支持。TEC-00480-2021。(通讯作者:杜庆;高飞;奎娇。)

Yanqiu Xing, Bowen Wang, Zhichao Gong, Qing Du, and Kui Jiao are with the State Key Laboratory of Engines, Tianjin University, Tianjin 300350, China (e-mail: xingyanqiu@tju.edu.cn; rabbitbill@tju.edu.cn; gzchao@tju.edu.cn; duqing@tju.edu.cn; kjiao@tju.edu.cn).

侯中军 上海氢能推进技术有限公司  
有限公司,上海 215332,中国 (电子邮件: houzhongjun@shpt.com)。  
Fuqiang Xi and Guodong Mou are with Weichai Power Company Ltd., Weifang 261016, China (e-mail: xifq@weichai.com; mugd@weichai.com).  
高飞在 FEMTO-ST 研究所和勃艮第大学 FCLAB 工作  
Franche-Comté,F-90010 贝尔福,法国 (电子邮件: fei.gao@utbm.fr)。  
本文中一幅或多幅图的彩色版本可在<https://doi.org/10.1109/TEC.2022.3143163>上获取。

数字对象标识符 10.1109/TEC.2022.3143163

Outbibe等人[5]建立了一个电气等效模型,可用作燃料电池系统的统一方法,用于燃料电池溢流检测。此外,使用区间线性参数变化 (LPV)观测器来生成自适应阈值[6]-[8]。故障隔离基于使用可用传感器生成一组残差,并利用对所考虑的故障集的不同敏感性。刘等人。[9]基于简化的非线性模型,采用改进的超扭曲滑模算法进行观测设计。通过系统模型和观测系统获得的氧过率率之间的比较,在线计算剩余信号。

李等人。[10]使用传热速率、两种冷却剂流量和一种冷却剂温度的残差来诊断质子交换膜燃料电池的热管理系统。泵、传感器和热交换器中发生的故障也可以利用基于残差的方法进行诊断。

随着现代处理器性能的提高,数据驱动诊断的另一个分支得到了越来越多的关注。数据驱动诊断方法的基本原理是收集和分析来自多个传感器数据 (历史或非历史)的实时信息,以检测可能的故障。

正确数据特征的提取和选择,以及系统状态标签的识别,构成了数据驱动方法中最关键的部分。对于特征构建和选择,基于经验模式分解 (EMD)的诊断方法依靠 PEM-FC 输出电压的分解来检测和隔离洪水和干燥故障 [11]。斯坦纳等人。 [12] 和帕洪等人。文献[13]从信号处理域提出了一种基于离散小波变换的多尺度分解特征提取方法。

该方法仅使用堆电压作为输入变量。赵等[14]华等人[15]提出了一种基于多传感器信号和主成分分析 (PCA)的故障诊断方法,并基于PCA推导了故障诊断的简化统计指标。系统的复杂性使得引入更多的传感器以获得更好的诊断性能。因此,如何筛选最合适的传感器采集到的信息是实现诊断的关键。为了找到尺寸最小的最佳传感器组,Mao等人。考虑了传感器灵敏度和抗噪性。关联传感器测量和燃料电池健康参数的灵敏度矩阵是通过燃料电池模型[16]-[18]开发的。基于小波变换的技术被用来研究传感器在运行过程中的一致性。传感器灵敏度可以在没有质子交换膜燃料电池物理模型的情况下进行评估[19]。

支持向量机 (SVM)是数据驱动的故障诊断中最常用的算法。李等人。 [20]-[22]将有向无环图支持向量机 (DAGSVM)与设计的诊断规则相结合。为了实时完成诊断算法,开发了具有多路复用和高速计算能力的高度集成的电子芯片。曹等人。 [23]采用ML-SVM进行多标签模式识别。韩等人。文献[24]提出了一种可能模糊C均值聚类人工蜂群支持向量机 (PFCM-ABC-SVM)方法,用高斯噪声过滤数据,将特征参数的幅度降低到± 10%。田等人。 [25]利用人工蜂群 (ABC)优化的支持向量数据描述 (SVDD)和相关向量机 (RVM)来避免故障诊断中的误报。还应该提到一些其他方法。刘等人。提出了多种数据融合方法,例如极限学习机 (ELM)和Dempster-Shafer (DS)证据理论相结合的方法[26],以及基于K均值聚类的离散隐马尔可夫模型 (DHMM)故障诊断策略[27]。安杜哈尔等人。 [28]根据专家经验和知识构建了诊断树。系统从电状态、热状态、燃料状态、电堆状态四个方面进行故障诊断。为了处理 PEMFC 系统的时间序列数据,Gu等人。 [29]开发了一种用于洪水故障诊断的长短期记忆 (LSTM)网络模型,并采用辅助系统状态作为网络的输入。此外,一些研究还结合了基于模型和数据驱动的方法。巴拉特等人。 [30]开发了一种基于半经验模型的 PEMFC 3D 模型,用于膜干燥和水淹故障诊断。

系统。为了实现质子交换膜燃料电池系统的在线诊断,必须考虑在线诊断方法的计算效率,因为在线算法是在计算能力有限的嵌入式系统中实现的[22]。另一方面,当故障发生时,PEMFC系统传感器的异常测量数据,如电流、电压、热电偶、湿度、压力等,可以有效帮助我们识别可能的故障状态[19]。因此,使用多个传感器可以为特定系统故障提供更多可区分的信息。然而,这会导致系统运行期间产生高维数据集。由于高维数据集的分析复杂且耗时,因此需要传感器预选方法来保持计算时间和诊断准确性之间的平衡。

在这项研究中,提出了一种基于传感器预选方法和人工神经网络 (ANN)算法的PEM-FC系统创新故障诊断策略。对于灵敏度分析,首先针对一组选定的 PEMFC 故障条件提取时域和频域中的传感器数据特征。来自传感器的针对特定故障的不敏感数据将从原始数据集中删除。因为这些数据不仅没有提高诊断的准确性,反而增加了计算时间。之后,训练基于 Levenberg-Marquardt 训练算法 (LM-BPNN)的反向传播神经网络进行故障分类。文章最后讨论了训练样本分布对诊断效率的影响,以供实际应用。本文的贡献如下:

- 1)提出了一种新颖的传感器预选方法,可以排除无用信息并选择最佳传感器进行 PEMFC系统故障诊断。该方法可以明显降低车载传感器诊断的计算复杂度和安装成本。
- 2)所提出的传感器选择技术可以在不使用PEMFC物理模型的情况下选择传感器,这在实际系统中更有用。由于高精度、准确物理模型的开发极其困难且耗时。
- 3)基于Levenberg-Marquardt训练算法的神经网络具有较高的计算效率和诊断性能,有利于在线诊断的实现。

本文的其余部分组织如下:在第二节中,描述了所提出的方法,包括传感器选择算法和故障分类算法。第三节介绍了本研究中使用的数据集的详细信息。在第四节中,验证了所提出方法的有效性。

根据结果,结论列于第五节。

二.方法论

在本节中,介绍了所提出方法的完整过程和详细实现。重点研究了基于传感器预选和 LM-BPNN的质子交换膜燃料电池系统故障检测与诊断的关键技术。

文献研究表明,故障诊断,特别是在线故障诊断,已被认为是保证燃料电池安全运行的关键技术之一。

表一  
从PEMFC系统中选择的20个变量

Variables	Explanation	Abbreviations
Variables 1	anode outlet pressure #1	AOP1
Variables 2	anode outlet pressure #2	AOP2
Variables 3	cathode outlet pressure #1	COP1
Variables 4	cathode outlet pressure #2	COP2
Variables 5	current	I
Variables 6	anode reactant flow	ARF
Variables 7	anode inlet pressure #1	AIP1
Variables 8	anode inlet pressure #2	AIP2
Variables 9	cathode air inlet flow	CAIF
Variables 10	cathode inlet pressure #1	CIP1
Variables 11	cathode stoichiometry	CS
Variables 12	cathode outlet temperature #2	COT2
Variables 13	cathode inlet temperature #2	CIT2
Variables 14	cathode outlet temperature #1	COT1
Variables 15	cathode inlet temperature #1	CIT1
Variables 16	primary water inlet pressure #2	PWIP2
Variables 17	primary water inlet pressure #1	PWIP1
Variables 18	primary water inlet flow #2	PWIF2
Variables 19	primary water inlet flow #1	PWIF1
Variables 20	water inlet temperature	WIT

数据准备是数据驱动的故障诊断系统的第一步,数据一般从历史数据库中获取。本研究中使用的数据由 Mao等人报告。 [31]。该数据集总共包含206420组数据,每组包含20个传感器测量结果,如表1所示 (该系统由两个燃料电池堆组成,#表示堆数量)。测试时采用恒流和快速波动两种负载电流模式来获得不同的系统状态。借助电化学阻抗谱 (EIS)后分析,系统状态可分为三类。负载电流恒定且无故障的状态定义为正常,用标签[1 0 0]表示。将具有瞬态负载但未检测到故障的情况定义为未知,用标签[0 1 0]表示。将具有瞬态负载电流和故障的状态定义为故障,用标签[0 0 1]表示。这里的未知状态可以视为实际系统中传感器指示异常。因此,本研究故障诊断的目的不仅是区分燃料电池的健康状态和故障状态,而且是将故障信号与未知部件分开。

A. 故障检测与诊断方案框架

所提出的故障诊断方法的流程为  
如图1所示,详细流程如下:

1)数据的预处理。本研究中使用的数据来自历史数据库。首先要对原始数据进行预处理,将数据集分为训练集、验证集和测试集,用于后续模型的建立和验证。为了消除奇异样本的影响,以上三个数据集

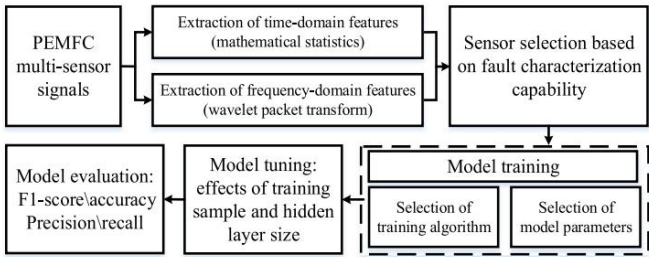


图1.利用多传感器数据进行PEMFC故障诊断的流程图。

分别通过以下公式进行归一化[32]:

$$x^*_j = \frac{x_i - \text{平均值}(x_i)}{\text{准差}(x_i)} \tag{1}$$

其中x\*是标准化变量, j是变量的维度j, mean 和 std 分别是第 j 维度的平均值和标准差。

2)传感器预选。实验数据采集集中引入了多个传感器。考虑到计算成本和诊断准确性,对原始传感器进行了过滤。对所选故障条件敏感度较低的变量将从数据集中删除。该过程是通过传感器的时频分析来执行的。由过滤传感器记录的剩余数据用作下一段中的输入变量。

3)LM-BPNN的建立。选定的带有标记数据 XL 的传感器用于训练整个神经网络

工作。比较了 Levenberg-Marquardt (LM)、弹性传播 (RP) 和缩放共轭梯度 (SCG) 的不同训练算法。选择收敛速度快、诊断性能较好的训练算法,以提高计算效率。

4)在测试集上验证训练好的LM-BPNN。

利用训练好的LM-BPNN来预测测试集中每个样本的类型,并将样本与真实标签进行比较,验证所提方法的效果。

B. 基于时频分析的传感器预选

可靠的质子交换膜燃料电池故障诊断和预测的关键是从质子交换膜燃料电池系统中收集和利用足够的信息。为此,在质子交换膜燃料电池系统中安装了电流传感器、流量计、压力表、湿度传感器等各种传感器来收集系统信息。结果,在系统运行过程中产生了高维数据集。如前所述,要实现质子交换膜燃料电池系统的在线诊断,必须考虑诊断方法的计算效率。此外,由于数据是通过实验收集的,因此不可避免地受到噪声和异常数据的污染。

因此,包含不灵敏的传感器可能不会改善诊断结果,而只会增加计算时间。

可以得出结论,有必要进一步调查

传感器中的信息,并选择对 PEM 燃料电池系统性能变化更敏感的传感器。

时频域分析是信号处理领域的常用方法,有助于提取隐藏在大量看似杂乱的数据背后的信息。仅通过传感器记录的原始数据很难得到传感器与系统状态之间的关系。在本研究中,将每个传感器收集的数据视为一个整体。

分别计算各个传感器在不同系统状态下的时频特性。同一传感器在不同系统状态下的特征值差异揭示了传感器对系统故障情况的敏感性。

在时域分析中,从每个传感器变量中提取一些统计特征。统计可以用来检查数据的特征,包括数据的集中度、离散度和分布形状。从传感器数据中提取的统计特征如下:

标准差=

$$\frac{1}{N} \sum_{i=1}^N (S(i) - \text{均值}S(i))^2$$

(2)

有效值=

$$\frac{1}{N} \sum_{i=1}^N (S(i))^2$$

(3)

SK=

$$\frac{\frac{1}{N} \sum_{i=1}^N (S(i) - \text{均值}S(i))^3}{SD^3}$$

(4)

库=

$$\frac{\frac{1}{N} \sum_{i=1}^N (S(i) - \text{均值}S(i))^4}{SD^4}$$

(5)

其中SD是标准差,RMS是均方根,SK是偏度,KU是峰度,N是每个传感器的数据总量,S(i)是i-记录的数据值第 i 个传感器,mean 是第 i 个传感器记录的数据的平均值。

在频域分析中,利用小波包变换 (WPT)将原始信号分解为不同频率范围的小波包;然后重建这些频率范围的信号以计算信号能量。

选择最高能量进行分析。广义能量可以使用下面提取的小波包系数来计算[12]:

$$ep = \frac{1}{\sum_{j,k} CP_{j,k}^2}$$

(6)

其中p表示数据包编号, Cp包含在数据包p中, Np是数据包p中的系数的数量。

在本研究中,时域分析结果与频域分析结果相结合。详细的计算和分析结果见3.1节。值得一提的是,以往的研究中也利用了皮尔逊相关系数 (PCC)进行初步筛选。

但PCC分析中变量之间的相关性应服从正态分布和线性关系。因此,PCC在燃料电池故障诊断领域的应用需要进一步考虑。




图 2. 模式识别神经网络。

C.LM-BP神经网络

ANN已广泛应用于工业领域,例如非线性控制、系统分析和数据分类[33]。燃料电池的诊断可以看作是一个监督分类学习问题。这里利用人工神经网络来完成高效、准确的分类。作为一阶算法,误差反向传播 (EBP)算法是训练神经网络中最流行的方法。然而,EBP算法以其训练效率低而闻名。与具有恒定学习率的EBP算法相比,二阶算法可以利用Hessian矩阵来估计梯度各个方向的学习率,从而可以显著提高训练速度。通过结合 EBP 算法和牛顿算法,LM 算法被评为模式识别最有效的训练算法之一[34]。

1)人工神经网络的构成:神经网络是由大量的“神经元”及其连接组成的运算模型。每个节点代表一个特定的输出函数,称为激活函数。本研究采用了 sigmoid 函数。两个节点之间的每条连接都代表了通过该连接的信号的一个加权值,称为权重。此外,利用偏差矩阵可以获得更好的数据拟合结果。神经网络通过更新权重矩阵和偏差矩阵来最小化损失函数,以达到更好的诊断结果。图 2 显示了用于故障诊断的神经网络的一般结构

不可知论。在本研究中,神经网络的损失函数 $L(x^d, \cdot)$ ,即重建误差,可以通过式 (1)计算: (7)。神经网络隐藏层大小n可以根据柯尔莫哥洛夫定理通过式 (1)计算: (8)。

相关方程如下:

$$L(x^d, x^d) = \frac{1}{N} \sum_{i=1}^N (y_i - h\theta(x_i))^2$$

(7)

$$n = \sqrt{n_{in} + n_{out} + 1} + a$$

(8)

其中 $n_{in}$ 是输入层中的神经元数量,  $n_{out}$ 是输出层中的神经元数量,a 是常数 ( $a \in [1, 10]$ )。

网络的输出根据网络的连接方式、权值、激励函数的不同而变化。

如前所述,数据驱动的诊断方法将问题转化为监督分类学习。

因此,在神经网络的输出层选择一个分类器。机器学习处理多类别分类问题常用的分类器有两种,即SoftMax分类器和K-Binary分类器



分类器。它们的功能是将线性或非线性预测值转换为类别概率。在两个分类器之间，SoftMax分类器更适合互斥的情况

排除类。在本研究中,系统的状态是完全排他性的（有故障的或健康的）。因此,SoftMax分类器被用于PEMFC系统的诊断。

2)Levenberg-Marquardt方法 :如前所述,神经网络的训练目的是调整网络的权重参数以最小化损失函数。优化方法是寻找使目标函数达到最大值或最小值的参数向量。

传统的BP算法采用梯度下降法来更新参数。高斯-牛顿方法在每次迭代中利用目标函数的泰勒展开将非线性函数的最小二乘问题转化为线性函数的最小二乘问题。 LM 可以看作是最速下降法和高斯-牛顿法的结合。当当前解与正确解相差甚远时,该算法的行为类似于最速下降法 :缓慢但保证收敛。虽然当前解接近正确解,但它变成了高斯-牛顿方法。

$$\Delta w = (J^T J + \mu I)^{-1} J^T e$$

(9)

其中w是权重向量 ,是单位矩阵,μ是组合系数。雅可比矩阵 J(P × M × N) 和误差向量 e(P × M × 1) 定义为

$$J = \begin{bmatrix} \frac{\partial e_{11}}{\partial w_1} & \frac{\partial e_{11}}{\partial w_2} & \cdots & \frac{\partial e_{11}}{\partial w_N} \\ \frac{\partial e_{12}}{\partial w_1} & \frac{\partial e_{12}}{\partial w_2} & \cdots & \frac{\partial e_{12}}{\partial w_N} \\ \vdots & \vdots & \ddots & \vdots \\ \frac{\partial e_{PM}}{\partial w_1} & \frac{\partial e_{PM}}{\partial w_2} & \cdots & \frac{\partial e_{PM}}{\partial w_N} \end{bmatrix} \quad \text{和} = \begin{bmatrix} e_{11} \\ e_{12} \\ \vdots \\ e_{PM} \end{bmatrix}$$

(10)

其中 P 是训练模式的数量,M 是输出的数量,N 是权重的数量。误差向量 e 中的元素计算如下

$$e_{pm} = d_{pm} - o_{pm}$$

(11)

中dpm和Opm分别是训练模式 p 时网络输出m的期望输出和实际输出。当至少满足以下条件之一时,LM算法终止[35]:

- i) eT e的梯度大小降至阈值ε1 以下。
- ii) δp幅度的相对变化降至阈值ε2 以下。 iii) 误差eT e 降至阈值ε3 以下。
- iv)完成最大迭代次数kmax 。

D. 故障诊断模型性能测量

为了评估诊断性能,提出了三个评估标准 :准确性、精确性和召回率。它们是机器学习文献中的基本测量[36]。以二分类问题为例,根据其真实类别与预测类别的组合,将样本分为四种情况 :真阳性（TP） 、假阳性

阳性（FP）、真阴性（TN） 和假阴性（FN）。TP、FP、TN、FN分别表示对应的样本数。

故障 x 的精度定义为故障的比例发生在确诊者中,此处表现为:

$$P \text{精度} = TP / (TP + FP)$$

(12)

错误 x 的召回率定义为以下错误的比例实际故障诊断:

$$\text{召回率} = TP / (TP + FN)$$

(13)

准确性是一个额外的补充指标,用于评估全局泛化性能。它的定义如下:

$$\text{准确度} = TP + TN / (TP + TN + FP + FN)$$

(14)

综合考虑三个指标,召回是最重要的措施,因为故障诊断的目的是全面诊断故障。另外,F1-score也用于评价。它是一种结合了精确度和召回率的测量方法。它表示可以检测到真实事件的概率与事件已检测到但确实发生的概率之间的平衡。它可以定义如下:

$$F1score = 2 \times P \text{精度} \times \text{召回率} / (P \text{精度} + \text{召回率})$$

(15)

三.结果与讨论

为了验证所提出的基于数据的方法的有效性,进行了以下计算。首先,在时频分析的支持下,对原始传感器数据进行预选 ;其次,使用上一步中预选的数据对LM-BPNN 进行训练和验证 ;第三,将所提出的方法与其他几种方法进行比较,以证明其有效性 ;最后,讨论了对训练集大小的影响。值得一提的是,该方法旨在解决多传感器复杂、在线实施需求的质子交换膜燃料电池系统背景下的故障诊断问题。因此,该方法也可以应用于具有相同要求的故障诊断。

A. 所提出的传感器预选方法的有效性

为了去除与系统状态变化相关性不大的传感器变量,分别计算各个传感器在不同系统状态下的时频特性。

在时域分析中,将每个传感器收集的数据视为一个整体,并使用式 (1)从每个传感器中提取四个统计特征。(2)-(5)。如图3所示,每个传感器的三个状态的值区分度越大,传感器对系统变化的响应越好。换句话说,传感器与系统状态变化之间的相关性随着四个特征分离度的增加而增加。可以看出,前四个传感器的四个统计特征在三种不同的系统状态下完全一致,这表明传感器对系统不敏感

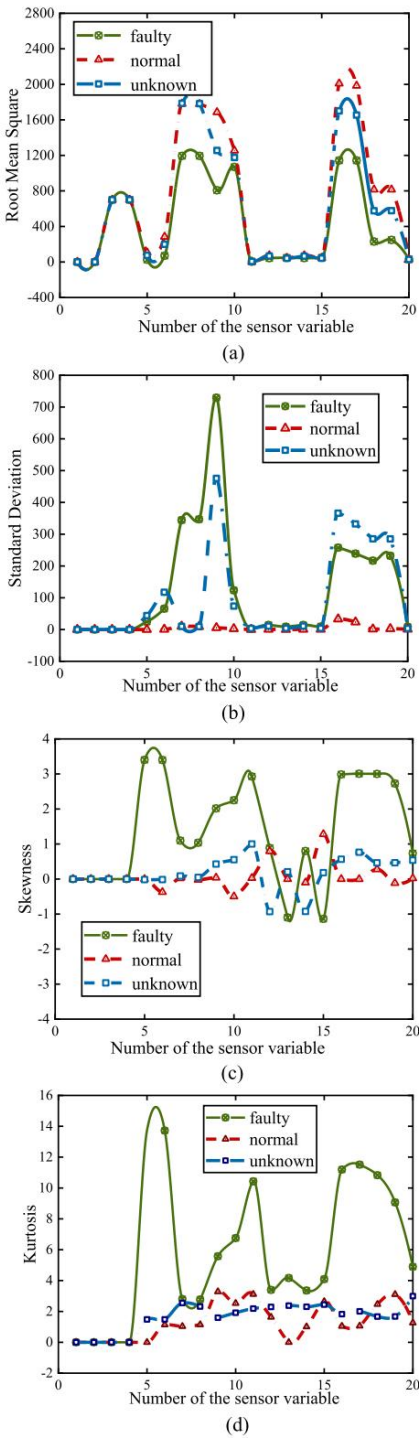


图 3 PEMFC 不同健康状态下 20 个传感器数据的统计特征 (a) 均方根。 (b) 标准差。 (c) 偏度。 (四) 峰度。

变化。为了量化差值,将其转换为二进制矩阵。当差值 $x$ 太小时 (对于RMS和Std,  $x < 10$ ;对于Skewness和Kurtosis,  $x < 1$ ), 标记为零;否则,它被标记为一。因此,满分为 12。表 II - IV 显示了三个典型传感器变量的结果。根据结果,这二十个传感器可以分为三类。传感器,带有序列号

表二

阳极出口压力#1统计特征分析

Anode outlet pressure #1	std	rms	skewness	kurtosis
Faulty-Normal	0	0	0	0
Unknown-Normal	0	0	0	0
Faulty-Unknown	0	0	0	0

表三

当前统计特征分析

Current	std	rms	skewness	kurtosis
Faulty-Normal	1	1	0	0
Unknown-Normal	1	1	0	0
Faulty-Unknown	1	1	1	1

表四

一次进水流量# 2统计特征分析

Primary water inlet flow	std	rms	skewness	kurtosis
Faulty-Normal	1	1	1	1
Unknown-Normal	1	1	0	0
Faulty-Unknown	1	1	1	1




图 4. 每个数据包中包含的能量。

1,2,3,4,13,20中,与系统状态关系不大 (分数占满分的比例小于25%)。序号为5,7,8,11,12,14,15的传感器与系统变异呈现一定程度的关系 (得分占满分的比例在25%~75%之间)。并且其他传感器对系统变化的响应显著 (得分占满分的比例超过75%)。

在频域分析中,首先对整个数据集进行小波包变换。此过程的目的是找到最高能量,为进一步分析提供更好的分离能力。从图4中可以看出,数据包1,3,7适合判别,且数据包7对应的能量值最高。这与[12]中的结果一致。之后,计算每个传感器在第7包处的归一化能量,结果如图5所示。

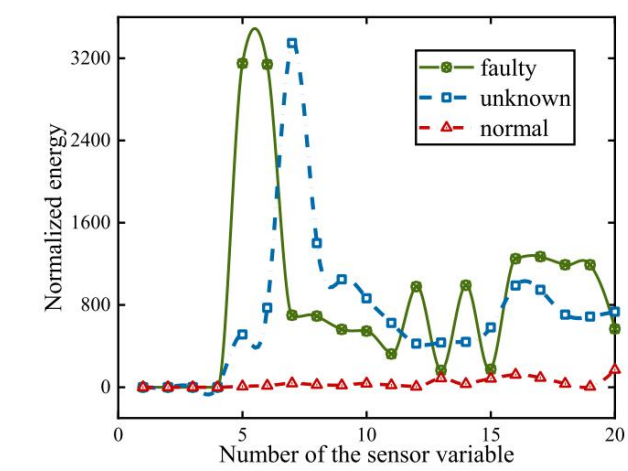


图5 传感器信号数据的小波分解能量特性。

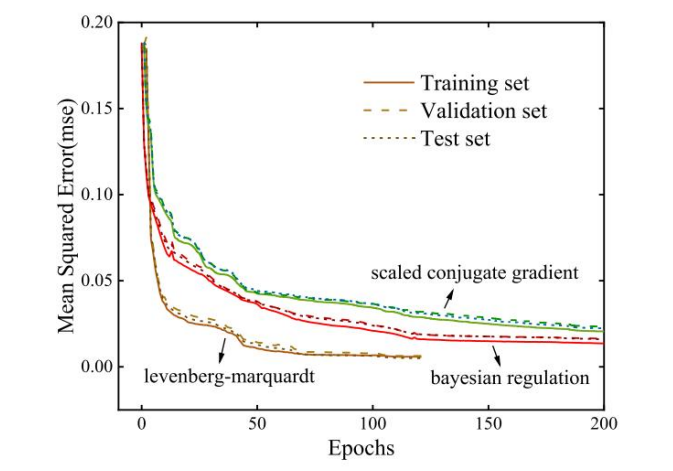


图 7. 不同训练算法的学习曲线:缩放共轭梯度 vs. 贝叶斯调节 vs. Levenberg-Marquardt。

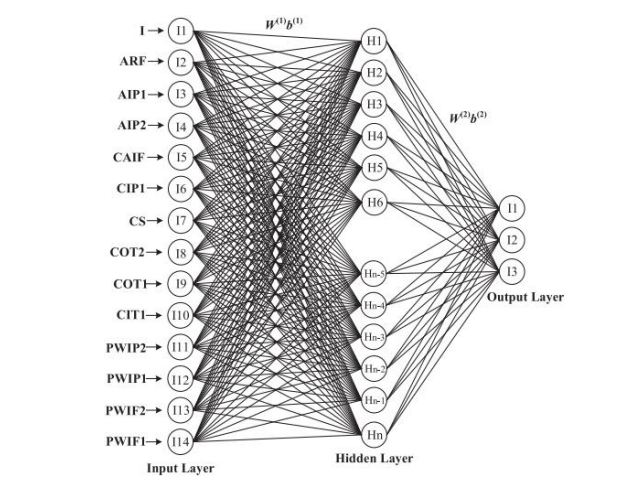


图 6. 神经网络的最终结构。

分析方法与时域分析方法类似。标记为1、2、3、4、11、13、20的传感器在频域分析中得分为零，结果与时域分析具有较高的一致性。时域和频域得分较低的传感器将被删除。因此，AOP1、AOP2、COP1、COP2、CIT2和WIT被过滤。第三节C进一步验证了传感器选择方法的有效性。

B. 训练算法的评估

选择传感器后,选择剩余变量来训练神经网络,如图6所示。预先选择的传感器用作神经网络的输入变量,输出变量对应于三个系统状态。数据首先通过等式进行归一化。(1),然后将数据集随机选为训练集(60%)、验证集(20%)和测试集(20%)。训练集用于确定模型参数;验证集用于调整模型参数;测试集用于验证模型诊断的性能。监督中常用的LM算法、SCG算法、RP算法

表五

四种分类算法的诊断评估

Algorithm	SVM	LR	LM-BPNN-all	LM-BPNN
Accuracy (%)	95.57	90.62	95.37	99.18
Precision (%)	99.31	91.29	88.01	99.59
Recall (%)	90.45	89.46	93.87	98.06

学习,分别用于训练阶段。训练算法的目的是调整参数以最小化损失函数。为了评估参数性能,选择均方误差 (MSE)作为损失函数。

如图 7 所示,LM 算法收敛速度较快,在第50 epoch 时开始收敛,而 SCG 和 RP 在第 150 epoch 时开始收敛。在本研究中,停止迭代的标准是损失函数小于0.001。可以看出,LM 算法在第120个epoch停止迭代,而SCG和RP算法需要超过200个epoch。而且,在这个过程中,LM的训练损失始终小于其他算法。

综上所述,LM训练算法收敛速度快,训练损失较小,在现实中具有相当的实用价值。

C. 与其他方法的诊断结果比较

为了验证所提出的 LM-BPNN 方法的性能,使用其他三种方法:SVM、逻辑回归 (LR)和无传感器预选的 LM-BPNN 进行比较。为了方便起见,将所提出方法的缩写记为LM-BPNN,将没有传感器选择的LM-BPNN缩写记为LM-BPNN-all。SVM和LR的超参数通过网格搜索来选择,以获得更好的诊断性能。表VI列出了LR的参数;表VII显示了 SVM 的参数。LM-BPNN-all 的参数与 LM-BPNN 相同,如表 VIII 所示。它们之间唯一的区别在于传感器是否在数据处理阶段进行过滤。

值得一提的是,本文中的 LM-BP 神经网络

表六

逻辑回归模型参数	
Parameters	Value
'C'	1
class_weight	None
dual	False
fit_intercept	True
intercept_scaling	1
l1_ratio	None
max_iter	100
multi_class	auto
n_jobs	None
penalty	l2
random_state	None
solver	lbfgs
tol	0.0001
verbose	0
warm_start	False

表七

支持向量机模型参数	
Parameters	Value
'C'	1
break_ties	False
cache_size	200
class_weight	None
coef0	0
decision_function_shape	ovr
degree	3
gamma	scale
kernel	rbf
max_iter	-1
probability	False
random_state	None
shrinking	True
tol	0.001
verbose	False

表八

人工神经网络模型参数	
Parameters	Value
trainFcn	Levenberg-Marquardt
hiddenLayerSize	10
divideFcn	dividerand
trainRatio	60%
valRatio	20%
testRatio	20%
performFcn	mean squared error
activation functions	sigmoid

工作在 MATLAB R2019a 中运行； SVM 和 LR 在 python 3.8.3 中运行。

上述四种方法在测试数据集中的准确率、查准率和查全率如表 5 所示。可以看出,本文提出的 LM-BPNN 方法给出了最好的故障诊断结果,准确率达到 99.2%,准确率达到 99.5%,召回率达到98.3%。由于正常状态下的数据比例较大,正确识别正常状态下的数据可以获得较高的准确性和精密度。

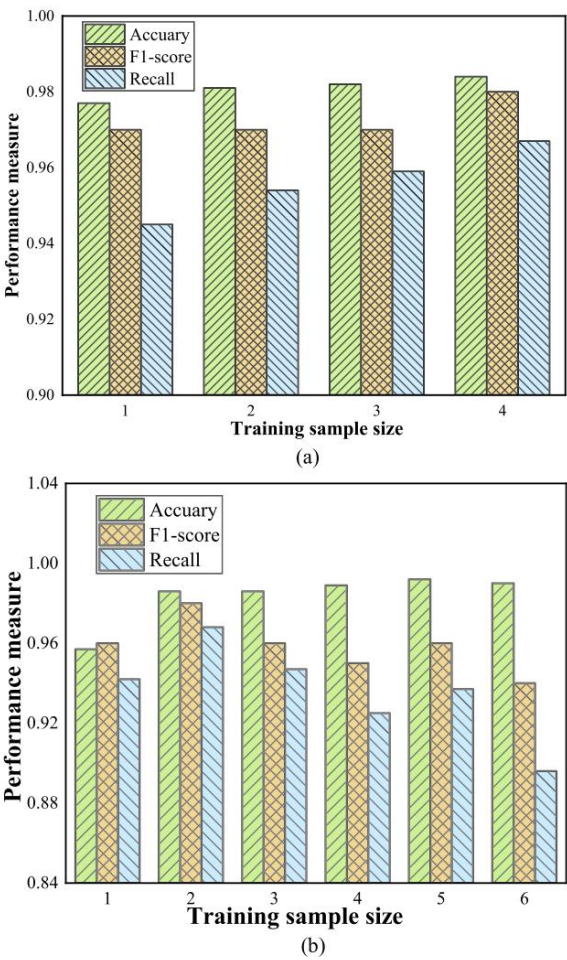


图8 不同训练样本量的故障诊断结果。(a) 三种系统状态的数据比例是固定的。(b) 训练集中仅添加健康者和未知者的数据。

正常状态。然而,故障诊断最关心的还是故障部分。因此,作为故障诊断中比较受关注的评价指标,召回率的高分表明该方法可以推断出大部分系统故障。

表5中SVM的诊断结果在诊断精度上达到了与LM-BPNN相同的水平,但召回分数较低意味着SVM不能很好地区分故障状态和未知状态。同时,作为一种小样本学习方法,其时间成本随着训练数据样本的增长而迅速增加。值得注意的是,LM-BPNN-all使用实验中监测到的所有数据作为输入变量;其诊断性能不如LM-BPNN。证实了所提出的传感器选择方法的有效性;通过最佳的传感器组,可以更好地区分不同的燃料电池状态。

D. 训练样本大小的影响

为了探讨应用LM-BPNN方法时训练集大小与故障诊断性能之间的关系,进行了使用不同训练集大小的对比实验。图8 诊断结果



应用 LM-BPNN 方法时,不同训练样本大小的准确率、召回率和 F1 分数。从EC燃料电池系统获取的历史数据集总计206400个 (正常171000,故障111111,未知24260)。图8(a)中三种系统状态的数据比例始终一致;而在图8(b)中,训练集中只添加了健康和未知的数据。横轴上的数字表示占总数据集的百分比。

从图8(b)中可以看出,随着训练样本的减少,诊断的准确率降低;主要原因是有限的训练样本无法提供足够的分类信息。这表明基于 LM-BPNN 的方法适合处理大规模训练集。

然而,召回率并没有出现与准确率相同的趋势;当使用所有数据集时获得最低召回率。图8(a)中,召回率和准确率呈现一致的变化;随着样本量的增加,它们略有增加。

因此,诊断性能的趋势变化应该是由数据不平衡引起的。除了收集足够的训练样本以获得更好的诊断结果外,在实际数据积累中还应注意数据平衡。然而,在实际应用中,故障状态下收集到的数据量远小于健康状态下的数据量。为了彻底解决不平衡问题,今后的研究将采用修改分类模型损失函数中不同系统状态下数据权重的方法。此外,在不同的数据尺度下,类权重是否等于总数占数据尺度的比例的倒数也很关键。

四 结论

故障诊断作为提高质子交换膜燃料电池系统可靠性和稳定性的解决方案之一,可以为系统的容错控制提供有效指导,有效减少设备停机维护。由于PEMFCs模型开发涉及多领域知识,因此开发精确的PEMFCs模型极其困难。此外,某些故障机制无法准确建模。因此,本研究开发了一种基于LM-BPNN的数据驱动诊断技术。为了缓解当前系统中传感器数量增加带来的数据爆炸,并实现计算时间和诊断精度之间的平衡,在诊断之前采用传感器预选方法。

通过时域 (统计方法)和频域 (小波包变换)分析对传感器进行滤波;对系统状态变化响应较差的变量将从原始数据集中删除。后来的诊断结果证实了所提出的传感器预选方法是有效的;通过最佳的传感器组,可以更好地区分不同的燃料电池状态。从历史数据库和经验预选中获得的数据用于训练神经网络。根据实际应用,选择sigmoid函数作为激活函数,输出层采用 SoftMax分类器。为了计算效率高,训练算法,即

LM,SCG 和 RP 分别使用。结果表明LM算法能够快速收敛且训练损失较小。此外,与其他三种常用方法的比较验证了预选方法的 LM-BPNN 具有更好的性能。结果表明,该方法能够快速有效地识别系统的故障状态。

总之,总体结果表明,最佳传感器可以产生可靠的系统信息并减少不必要的计算负担。此外,基于LM-BPNN的方法由于其高计算效率而提供了在线诊断的可能性。应该提到的是,这项研究可以用于进一步的工作,考虑传感器在不同故障模式下对系统性能变化的敏感性。

参考

[1] Z. Li,R. Outbib,S. Giurgea 和 D. Hissel,“考虑动态行为和空间不均匀性的 PEMFC 系统故障诊断”, IEEE Trans.能源转换器,卷。 34,没有。 1,第 3-11 页,2019 年 3 月,doi: [10.1109/TEC.2018.2824902](#)。

[2] R. Vepa,“PEM 燃料电池的自适应状态估计”, IEEE Trans.能源转换器,卷。 27,没有。 2,第 457-467 页, 2012 年 6 月,doi: [10.1109/TEC.2012.2190073](#)。

[3] FD Bianchi,C. Ocampo-Martinez,C. Kunusch 和 RS Sánchez-Peña,“PEM 燃料电池系统的容错非伪造控制”, IEEE 传输.能源转换器,卷。 30,没有。 1,第 307-315 页,2015 年,doi: [10.1109/TEC.2014.2351838](#)。

[4] Z. Li,C. Cadet 和 R. Outbib,“基于磁测量和数据驱动方法的 PEMFC 诊断”, IEEE Trans.能源转换器,卷。 34,没有。 2,第 964-972 页,2019 年 3 月,doi: [10.1109/TEC.2018.2872118](#)。

[5] A. Hernandez,D. Hissel 和 R. Outbib,“使用电等效分析对聚合物电解质燃料电池进行建模和故障诊断”, IEEE 传输.能源转换器,卷。 25,没有。 1,第 148-160 页,2010 年 3 月,doi: [10.1109/TEC.2009.2016121](#)。

[6] S. De Lira,V. Puig 和 J. Quevedo,“在 PEM 燃料电池中使用相对故障敏感性特征方法进行基于 LPV 模型的故障诊断”, IFAC Proc.卷,卷。 42,没有。 8,第 528-533 页,2009 年,doi: [10.3182/20090630-4-ES-2003.0335](#)。

[7] S. De Lira,V. Puig,J. Quevedo 和 A. Husar,“PEM 燃料电池系统的 LPV 观测器设计:故障检测应用”, J. Power Sources,卷。 196,没有。 9,第 4298-4305 页,2011 年,doi: [10.1016/j.jpowsour.2010.11.084](#)。

[8] S. De Lira,V. Puig 和 J. Quevedo,“针对 PEM 燃料电池系统的基于稳健 LPV 模型的传感器故障诊断和估计”, Proc.会议。 控制容错系统。 SysTol 10 - 最终程序。 B. 摘要, 2010 年,第 819-824 页,doi: [10.1109/SYSTOL.2010.5676000](#)。

[9] J. Liu,W. Luo,X. Yang,L. Wu,“基于稳健模型的质子交换膜燃料电池供气系统故障诊断”, IEEE Trans. 《工业电子》,卷。 63,没有。 5,第 3261-3270 页,2016 年 5 月,doi: [10.1109/TIE.2016.2535118](#)。

[10] H. Oh,WY Lee,J. Won,M. Kim,YY Choi 和 SB Han,“质子交换膜燃料电池热管理系统的基于残余的故障诊断”, Appl.能源,卷。 277,2020,艺术.不。 115568,doi: [10.1016/j.apenergy.2020.115568](#)。

[11] C. Damour,M. Benne,B. Grondin-Perez,M. Bessafi,D. Hissel 和 JP Chabriat,“基于经验模式分解的聚合物电解质膜燃料电池故障诊断”, J. Power Sources,卷。 299,第 596-603 页,2015 年,doi: [10.1016/j.jpowsour.2015.09.041](#)。

[12] NY Steiner,D. Hissel,P. Moçotéguy 和 D. Candusso,“通过小波包变换对聚合物电解质燃料电池进行非侵入式诊断”, Int. J.氢能源,卷。 36,没有。 1,第 740-746 页,2011 年,doi: [10.1016/j.ijhydene.2010.10.033](#)。

[13] E. Pahon等人,“基于小波变换方法的固体氧化物燃料电池故障诊断和老化估计”, Int. J.氢能源,卷。 41,没有。 31,第 13678-13687 页,2016 年,doi: [10.1016/j.ijhydene.2016.06.143](#)。

[14] 赵晓,徐立,李建,方春,欧阳明,“基于多传感器信号和主成分分析方法的质子交换膜燃料电池系统故障诊断”, Int. J.氢能源,卷。 42,没有。 29,第 18524-18531 页,2017 年,doi: [10.1016/j.ijhydene.2017.04.146](#)。

[15] 华建, 李建, 欧阳明, 陆丽, 徐丽, 基于多元统计的质子交换膜燃料电池系统诊断方法”, Int. J. 氢能源, 卷. 36, 没有. 16, 第 9896–9905 页, 2011 年, doi: [10.1016/j.ijhydene.2011.05.075](#).

[16] L. Mao 和 L. Jackson, “选择最佳传感器来预测聚合电解质膜燃料电池的性能”, J. Power Sources, 卷. 328, 第 151–160 页, 2016 年, doi: [10.1016/j.jpowsour.2016.08.021](#).

[17] L. Mao, L. Jackson 和 B. Davies, “PEM 燃料电池在线诊断中新型传感器选择算法的有效性”, IEEE 跨. 《工业电子》, 卷. 65, 没有. 9, 第 7301–7310 页, 2018 年 9 月, 二: [10.1109/TIE.2018.2795558](#).

[18] L. Mao 和 L. Jackson, “传感器组尺寸对聚合电解质膜燃料电池故障诊断”, 传感器 (瑞士), 卷. 18, 没有. 9, 页 2018 年 1–10 日, doi: [10.3390/s18092777](#).

[19] L. Mao, L. Jackson, W. Huang, Z. Li 和 B. Davies, “聚合电解质使用传感器选择方法进行膜燃料电池故障诊断和传感器异常识别”, J. Power Sources, 卷. 447, 2020, 艺术. 不. 227394, doi: [10.1016/j.jpowsour.2019.227394](#).

[20] Z. Li, R. Outbib, S. Giurgea, D. Hissel 和 Y. Li, “故障检测和通过分离聚合电解质膜燃料电池系统电池电压产生空间”, Appl. 能源, 卷. 148, 第 260–272 页, 2015 年, doi: [10.1016/j.apenergy.2015.03.076](#).

[21] Z. Li 等人, “基于 SVM 的 PEMFC 系统故障诊断策略的在线实现”, Appl. 能源, 卷. 164, 第 284–293 页, 2016 年, doi: [10.1016/j.apenergy.2015.11.060](#).

[22] Z. Li, R. Outbib, S. Giurgea, D. Hissel, A. Giraud 和 P. Couderc, “断层燃料电池系统诊断: 使用高精度的数据驱动方法电压传感器”, 可再生能源, 卷. 135, 第 1435–1444 页, 2019 年, doi: [10.1016/j.renene.2018.09.077](#).

[23] S. Li, H. Cao, Y. Yang, “使用多标签模式识别的数据驱动的固体氧化物燃料电池系统同步故障诊断”, J. Power Sources, 卷. 378, 没有. 1, 第 646–659 页, 2018 年, doi: [10.1016/j.jpowsour.2018.01.015](#).

[24] 韩锋, 田宇, 邹强, 张涛, 故障诊断研究聚合电解质膜燃料电池系统”, 能源, 卷. 13, 不. 10, p. 2531, 2020 年 5 月.

[25] Y. Tian, Q. Zou 和 J. Han, “基于稳态识别的汽车 PEMFC 系统数据驱动的故障诊断”, Energies, 卷. 14, 没有. 第 7 页. 1918 年, 2021 年, doi: [10.3390/en14071918](#).

[26] J. Liu, Q. Li, W. Chen, Y. Yan, X. Wang, “一种快速故障诊断方法”基于极限学习机的 PEMFC 系统方法及登普斯特-谢弗证据理论”, IEEE Trans. 运输. 电气, 卷. 5, 第 1 期, 第 271–284 页, 2019 年 3 月, doi: [10.1109/TTE.2018.2886153](#).

[27] J. Liu, Q. Li, W. Chen 和 T. Cao, “离散隐马尔可夫模型 PEM 专用的基于 K-means 聚类的故障诊断策略有轨电车燃料电池系统”, Int. J. 氢能源, 卷. 43, 没有. 27, 第 12428–12441 页, 2018 年, doi: [10.1016/j.ijhydene.2018.04.163](#).

[28] JM Andújar, F. Segura, F. Isorna 和 AJ Calderón, “故障检测和识别的综合诊断方法, 风冷聚合电解质燃料的研究与性能改进细胞”, 可再生维持. 能源评论, 卷. 88, 第 193–207 页, 2018 年, doi: [10.1016/j.rser.2018.02.038](#).

[29] 顾晓, 侯正, 蔡杰, 基于数据的质子水泛故障诊断使用 LSTM 网络交换膜燃料电池系统”, Energy AI, 卷. 2021 年 4 月, 货号. 100056, doi: [10.1016/j.egai.2021.100056](#).

[30] KVS Bharath, F. Blaabjerg, A. Haque 和 MA Khan, “基于模型的数据驱动的质子交换膜燃料电池故障识别方法”, Energies, 卷. 13, 没有. 12, p. 3144, 2020, doi: [10.3390/en13123144](#).

[31] L. Mao, L. Jackson 和 S. Dunnett, “实用故障诊断”采用数据驱动方法的聚合电解质膜 (PEM) 燃料电池系统”, 燃料电池, 卷. 17, 没有. 2, 第 247–258 页, 2017 年, 二: [10.1002/fuce.201600139](#).

[32] 张志, 李书, 肖勇, 杨勇, “基于深度学习的固体氧化物燃料电池系统智能同步故障诊断”, 应用活力, 卷. 233–234, 页. 930–942, 2019, doi: [10.1016/j.apenergy.2018.10.113](#).

[33] BM Wilamowski 和 H. Yu, “改进了 levenbergmar-quardt 训练的计算”, IEEE Trans. 神经网络, 卷. 21, 没有. 6, 第 930–937 页, 六月 2010, doi: [10.1109/TNN.2010.2045657](#).

[34] NM Nawi, A. Khan 和 MZ Rehman, “新的 Levenberg Marquardt 基于布谷鸟搜索训练的反向传播算法”, Procedia 技术, 卷. 11, 第 18–23 页, 2013 年, doi: [10.1016/j.protcy.2013.12.157](#).

[35] MIA Lourakis, “Levenberg-Marquardt 的简要描述由 Levmar 实现的算法”, Inst. 计算. 科学, 伊拉克利翁, 克里特岛, 希腊, 第 4–9 页, 2005 年.

[36] P. Costamagna, A. De Giorgi, L. Magistri, G. Moser, L. Pellaco 和 A. Trucco, “基于模型的故障诊断的分类方法基于固体氧化物燃料电池的发电系统”, IEEE Trans. 能源转换器, 卷. 31, 没有. 第 2 页. 676–687, 2016 年 6 月.



邢艳秋 (IEEE 学生会会员) 荣获水利学院工学学士  
西北农林科技大学建筑工程专业, 中国咸阳, 2019 年. 她目前正在天津大学发动机国家重点实验室攻读硕士学位。

目前的研究兴趣包括故障诊断  
质子交换膜燃料电池技术  
面向健康预测与管理  
燃料电池系统。



王博文 (IEEE 会员), 现任电气电子工程国家重点实验室助理教授。

发动机, 天津大学, 天津, 中国. 他是致力于将人工智能技术应用于燃料电池研究。在《Nature》等国际领先期刊上独着或合着论文十余篇, 获得四项专利、三项软件著作权. 他是学生研究员的获得者

国际氢能协会奖 (2021)、国际氢能协会最佳演讲奖

能源与人工智能会议 (2019) 和最佳再  
国际绿色能源杂志观众奖 (2021 年)。



龚志超 (IEEE 学生会会员) 荣获毕业于中国重庆市重庆大学汽车工程学院,

2019 年. 他目前正在攻读博士学位。发动机国家重点实验室博士学位, 天津大学, 天津, 中国. 他的主要研究兴趣包括燃料电池及其应用在交通运输、多物理建模和真实时间模拟系统。



侯忠军获得博士学位. 中国科学院大连化学物理研究所化学工程专业, 大连,

中国, 2003 年, 曾在日出动力、燃料电池国家工程研究中心及氢能技术有限公司工作, 历任总工程师、副总工程师

经理, 加入上海氢能科技有限公司, 任总工程师  
2018 年任副总经理, 跟随实业发展. 他撰写或合着的作品超过

在工程科学期刊、会议和新闻界发表论文 20 篇  
60 多项专利. 他的研究兴趣包括燃料电池技术和燃料电池电动汽车应用. 他被授予国家领导人的获得者  
“万人计划”科技创新  
被评为国务院特殊津贴专家. 他已经完成了  
参与“国家 863”项目 1 项, 参与“国家 973”项目 1 项。



奚富强现任国家统计局副局长  
新能源氢能研究室  
潍柴动力股份有限公司研究院



牟国栋, 1990年出生于山东省寿光市,2012年毕业于大连理工大学机械工程专业 ,获硕士学位。



杜庆 (IEEE会员)获得博士学位。 1998年毕业于天津大学机械工程学院,获博士学位。博士后在天津大学发动机国家重点实验室进行博士后研究,2006年晋升为教授。他在其研究领域内撰写或共同撰写了约100篇同行评审期刊论文,并获得约15项专利和软件著作权,主要包括燃料电池和发动机,特别是燃料电池、液体燃料电池的水和热管理的模拟和实验、内燃机的燃料分解和燃烧过程。



高飞 (IEEE高级会员)获得博士学位获得法国贝尔福贝尔福-蒙贝利亚尔理工大学可再生能源博士学位,并于 2010 年获得杰出青年博士奖。

现任法国国家科学研究中心FEMTO-ST研究所副所长,贝尔福-蒙贝利亚尔理工大学能源与计算机科学学院教授。他的主要研究兴趣包括燃料电池及其在交通运输、多物理建模和实时仿真系统中的应用。

高教授荣获 IEEE 工业电子学会颁发的 2020 年 IEEE J. David Irwin 早期职业奖。他是 IET 院士,并获得法国高等教育和研究部颁发的法国研究专家奖金 (PEDR)。他还是《IEEE工业电子技术新闻》的主编,《IEEE TRANSACTIONS ON TRANSACTIONS ON TRANSPORTATION ELEFICATION》的助理副主编,以及《IEEE TRANSACTIONS ON INDUSTRIAL ELECTRONICS》、《IEEE TRANSACTIONS ON INDUSTRY APPLICATIONS》的副主编、 IEEE TRANSACTIONS ON ENERGY CONVERSION和 IEEE 工业电子学会开放期刊。

2017 年,他被提名为 IEEE 交通电气化社区会议委员会主席。自2019年起,他担任IEEE电力电子学会车辆和运输系统技术委员会秘书,并于2018年至2019年担任IEEE工业电子学会运输电气化技术委员会主席。



焦奎 (IEEE会员)获得博士学位。 2011年获得加拿大滑铁卢大学机械工程博士学位。现任天津大学发动机国家重点实验室教授。他撰写或合着了一本有关燃料电池水和热管理的书,并在《自然》等国际期刊上发表了 100 多篇论文。他的研究兴趣包括燃料电池、电池、热电发电机和涡轮增压压缩机。他曾担任多个国际会议的主席,例如国际能源和人工智能会议。 2016年获得国家自然科学基金杰出青年基金资助,2018年获得英国皇家学会高级牛顿奖学金。主持了30多个国内国家和行业项目,并在开发过程中提供建模和设计服务。为一汽、上汽、旭日动力、博世、潍柴动力等多家主要汽车燃料电池制造商提供燃料电池发动机。他是《能源与人工智能》的编辑以及《国际绿色能源杂志》的副主编。兼任中国内燃机学会燃料电池发动机专业委员会副主任委员。